پیوست آ

واژه‌نامه، نقشهٔ منابع و مسیر تمرین

استاد درس: دکتر شیرین شعاعی
گردآورنده جزوه: احسان شهبازی

آ.۱ واژه‌نامهٔ کلیدی

اصطلاح	معنی و تمایز اصلی
Feature / Target	ویژگیِ قابل استفاده برای پیش‌بینی، در برابر پاسخ مورد پیش‌بینی.
Parameter / Hyperparameter	پارامتر از داده برازش می‌شود؛ ابرپارامتر شیوهٔ آموزش یا ظرفیت را تعیین می‌کند.
Training / Validation / Test	برازش، انتخاب تنظیم و ارزیابی مستقل سه نقش جدا هستند.
Leakage	ورود اطلاعاتی به آموزش که هنگام استفادهٔ واقعی یا ارزیابی مستقل مجاز نیست.
Accuracy / Precision	سهم کل پیش‌بینی‌های درست، در برابر سهم هشدارهای مثبتِ درست.
Recall / Specificity	سهم مثبت‌های کشف‌شده، در برابر سهم منفی‌های درست تشخیص‌داده‌شده.
Bias / Variance	خطای نظام‌مند میانگین مدل‌ها، در برابر حساسیت مدل به نمونهٔ آموزش.
Centroid / Medoid	میانگین خوشه، در برابر یک عضو واقعی با کمترین مجموع ناهمانندی.
Support / Confidence / Lift	فراوانی اجتماع، احتمال شرطی تجربی و نسبت همراهی به استقلال.
Correlation / Causation	همراهی آماری، در برابر اثر تغییر با مداخله؛ اولی دومی را اثبات نمی‌کند.

۲.آ تطبیق فصل‌ها با منابع

مبنای ترتیب، هفت فایل IE500 Data Mining ارسالی از گروه داده و وب دانشگاه مانهایم است. منبع کتاب، ویرایش دوم جهانیِ Introduction to Data Mining اثر Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, Vipin Kumar است. شماره‌های زیر شمارهٔ صفحه در PDF اسلاید و شمارهٔ چاپی کتاب‌اند؛ در فایل کتاب، صفحهٔ PDF یک واحد بیشتر است.

فصل	اسلاید	بسط کتاب
۱	مقدمه، ۱۹–۵۸؛ ۱–۱۸ اداری	فصل ۱، ۲۴–۳۳؛ بخش ۶٫۳، ۴۱۰–۴۱۳
۲	پیش‌پردازش، ۳–۵۹	فصل ۲، ۴۶–۱۱۹؛ بخش ۶٫۱۱
۳	طبقه‌بندی ۱، ۳–۶۰؛ طبقه‌بندی ۲، ۴۲–۶۱	فصل ۳، ۱۳۴–۱۹۳؛ بخش ۶٫۱۰، ۴۹۸–۵۱۴؛ ۶٫۱۱، ۵۱۵–۵۳۱
۴	طبقه‌بندی ۲، ۳–۴۱	بیز: ۴۱۴–۴۲۸؛ شبکه: ۴۵۱–۴۷۷؛ SVM: ۴۷۸–۴۹۷
۵	رگرسیون، ۳–۵۵	تعمیم: ۱۶۷–۱۹۳؛ اریبی–واریانس: ۵۰۲–۵۰۴. رگرسیون تفصیلی از اسلاید و بسط ریاضی است.
۶	خوشه‌بندی، ۳–۶۴	فصل ۵، ۳۰۷–۳۷۸؛ ناهنجاری فصل ۹، ۷۲۳–۷۵۱؛ فاصله بخش ۲٫۴
۷	وابستگی، ۳–۴۶	فصل ۴، ۲۱۳–۲۷۴؛ گسسته‌سازی و اقلام اسمی بخش‌های ۷٫۱–۷٫۲

صفحات عنوان، پرسش پایانی و فهرست منابع، جزو مطالب علمی تازه شمرده نشده‌اند. سخنرانی‌های آنلاینِ ارجاع‌شده که فایلشان ارائه نشده، مطالعه‌شده یا به‌طور کامل بازسازی‌شده تلقی نشده‌اند. خوشه‌بندی سلسله‌مراتبی با اتکا به کتاب بسط داده شده، زیرا اسلاید آن را صریحاً به منبع مکمل ارجاع می‌دهد. FP-growth و مجموعه‌های بسته نیز بسط مرتبط کتاب‌اند، نه ادعای تدریس مستقیم در اسلاید.

۳.آ مسیر پیشنهادی تمرین و پروژه

۱. یک مجموعهٔ داده و واحد مشاهده را تعریف کنید. پرسش هدف، زمان پیش‌بینی و معیار موفقیت را پیش از مدل‌سازی بنویسید.

۲. یک تقسیم مستقل و متناسب با زمان یا گروه بسازید. پیش‌پردازش را فقط با آموزش بیاموزید و یک خط مبنای ساده بسازید.

۳. برای طبقه‌بندی، حداقل یک مدل درختی، همسایه یا بیز را با معیارهای چندگانه و هزینهٔ خطا بررسی کنید. آستانه را روی اعتبارسنجی انتخاب کنید.

۴. برای پاسخ عددی، خط پایه، رگرسیون خطی و یک مدل انعطاف‌پذیر را با MAE و RMSE مقایسه کنید؛ منطقهٔ برون‌یابی را مشخص کنید.

۵. برای خوشه‌بندی، دو تعریف متفاوت خوشه، دو مقیاس‌بندی و بیش از یک شروع اولیه را بررسی کنید. خوشه‌ها را فقط با زیبایی نمودار قضاوت نکنید.

۶. برای قواعد، شمارش، پشتیبانی، اطمینان و نرخ پایه را هم‌زمان گزارش کنید. رابطهٔ جالب را روی دادهٔ مستقل یا با تحلیل پایداری بررسی کنید.

۷. تنظیمات، بذر تصادفی، شناسهٔ تقسیم‌ها و نسخهٔ داده را ثبت کنید. هیچ انتخابی را بر اساس آزمون نهایی انجام ندهید.

آ۴.۰ چک‌لیست فهم مفهومی

اگر برای هر روش بتوانید «ورودی چیست؟ خروجی چیست؟ چه چیزی بهینه می‌شود؟ چه فرضی لازم است؟ چه تنظیمی دارد؟ چگونه ارزیابی می‌شود؟ در چه داده‌ای شکست می‌خورد؟» را پاسخ دهید، از حفظ نام الگوریتم فراتر رفته‌اید. فرمول را همراه با واحد، دامنه، حالت مخرج صفر و قرارداد مقیاس توضیح دهید. در آزمایشگاه، پیش از حرکت کنترل‌ها نتیجه را حدس بزنید و پس از مشاهده، تفاوت را با فرض‌های مدل تفسیر کنید.