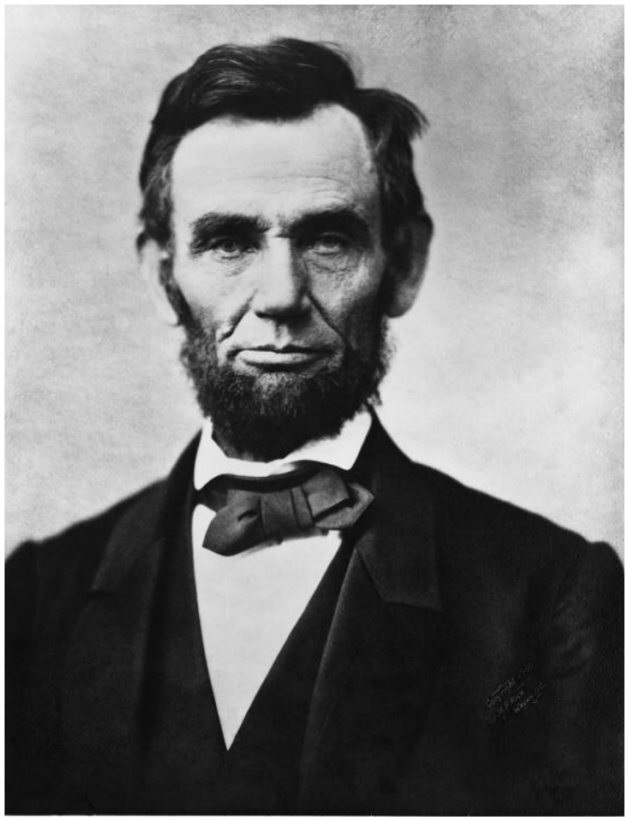
UNIVERSITY OF MANNHEIM
School of Business Informatics and Mathematics

پیش‌پردازش داده‌ها

IE500 داده‌کاوی



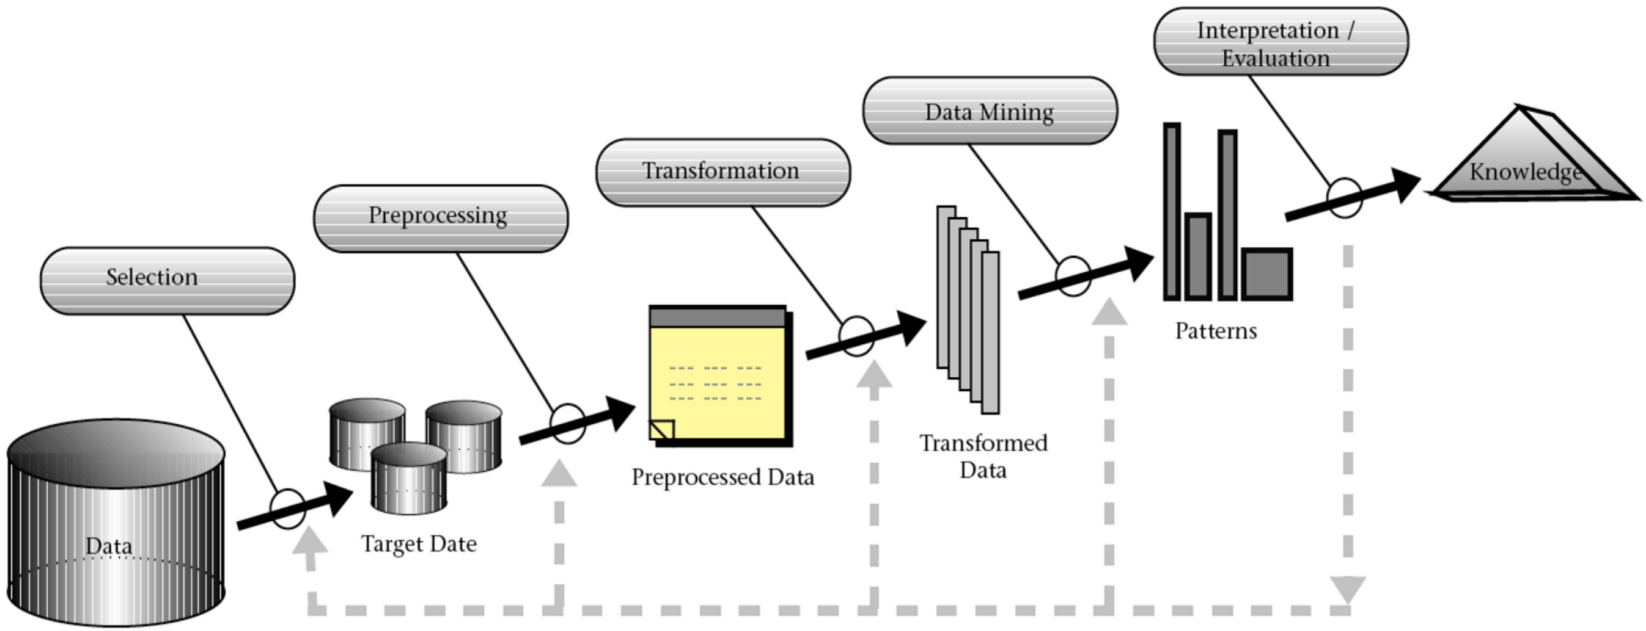
مقدمه



- **«به من شش ساعت برای قطع یک درخت فرصت بدهید، چهار ساعت اول را صرف تیز کردن تبر خواهم کرد.»**

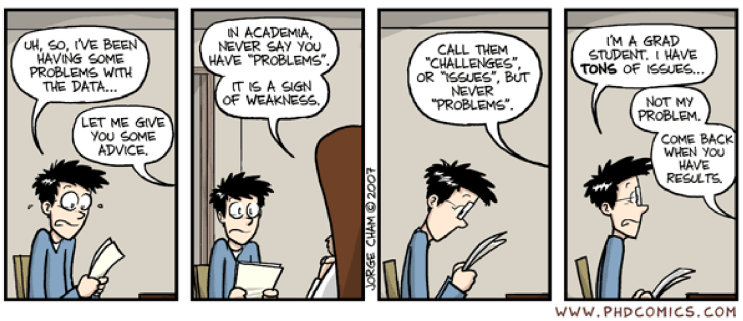
آبراهام لینکلن (1809–1865)

مرور: فرآیند داده‌کاوی



منبع: Fayyad et al. (1996)

پیش‌پردازش داده‌ها



- **داده‌های شما ممکن است با مسائلی مواجه باشند:**
  - به این معنی که ممکن است برای مراحل بعدی کاوش مشکل‌ساز شوند.
- پیش از ادامه و ورود به الگوریتم‌ها، این مسائل را برطرف کنید.
- چه مسائلی به ذهنتان می‌رسد؟

پیش‌پردازش داده‌ها

- **مشکلاتی که ممکن است با داده‌های خود داشته باشید:**
  - خطاها و داده‌های پرت (Errors & Outliers)
  - مقادیر گمشده / ازدست‌رفته (Missing Values)
  - توزیع نامتوازن کلاس‌ها (Unbalanced Distribution)
  - مقیاس‌های متفاوت ویژگی‌ها (Different Scales)
  - متغیرهای پیش‌بینی کاذب / نشت داده (False Predictors)
  - انواع داده‌های پشتیبانی‌نشده (Unsupported Data Types)
    - داده‌های رسته‌ای/کیفی و تاریخ‌ها (Categorical Data & Dates)
    - مقادیر متنی (Textual Values)
  - ابعاد بالا / نفرین ابعاد (High Dimensionality)
    - انتخاب زیرمجموعه ویژگی‌ها (Feature Subset Selection)
    - تحلیل مؤلفه‌های اصلی (PCA)
    - نمونه‌گیری (Sampling)

خطاها در داده‌ها



- **منابع ایجاد خطا:**
  - خرابی یا کالیبره نبودن حسگرها (Malfunctioning sensors)
  - خطاهای ورود دستی داده‌ها (مانند جابجایی ارقام twisted digits)
  - خطاهای ذخیره‌سازی و انتقال شبکه (Storage/transmission errors)
- **خطاهای انسانی:**
  - پاسخ‌های تعمدی نامعتبر در پرسشنامه‌ها
  - سوگیری در طرح سوالات یا برداشت کاربر

خطاها در داده‌ها: راه‌حل‌ها

- **راه‌حل ساده و مستقیم:**
  - حذف نقاط داده‌ای که خارج از یک بازه مجاز مشخص قرار دارند.
- **این کار نیازمند شناخت و دانش حوزه مسئله (Domain Knowledge) است**
  - حذف مقادیر دمای محیطی خارج از بازه $-30°C$ تا $+50°C$
  - حذف مقادیر منفی برای متغیرهای مربوط به مدت‌زمان
  - حذف تراکنش‌های خرید غیرعادی بالای ۱ میلیون یورو (احتمال تقلب یا ارقام ساختگی برای تست)
- **راه‌حل‌های پیشرفته‌تر:**
  - شناسایی خودکار نمونه‌های داده مشکوک با استفاده از الگوریتم‌های تشخیص ناهنجاری (Anomaly / Outlier Detection)
  - برازش توزیع‌های آماری بر متغیرها و بررسی فاصله نقاط از توزیع مورد انتظار

مقادیر گمشده / ازدست‌رفته



- **دلایل احتمالی فقدان مقادیر:**
  - قطع موقت ارتباط یا خرابی حسگر
  - از بین رفتن بسته‌های داده در حین انتقال شبکه
  - عدم گردآوری یا ثبت اطلاعات در منبع اولیه
  - عدم پاسخ مشتریان به پرسش‌های اختیاری در فرم‌ها
  - عدم وجود ویژگی در برهه زمانی ثبت رکورد

مقادیر گمشده: راهکارهای حذف و جایگزینی

- **روش‌های مواجهه با مقادیر گمشده (Treatments):**
  - **حذف رکوردهای دارای نقص در داده‌های آموزش (Deletion):** نادیده گرفتن سطرها
  - **جایگزینی مقادیر (Imputation):**
    - مقدار پیش‌فرض یا برچسب مشخص (مانند 0 یا "missing")
    - میانگین یا میانه برای متغیرهای عددی (Mean / Median)
    - بیشترین فراوانی برای متغیرهای اسمی (Mode)

```
SimpleImputer(missing_values=np.nan, strategy='mean')
```

  - **تلاش برای پیش‌بینی هوشمند مقادیر گمشده:**
    - در نظر گرفتن تخمین مقادیر مفقود به عنوان یک مسئله یادگیری ماشین
    - **هدف (Target):** متغیری که مقدار گمشده دارد
    - **داده‌های آموزش:** رکوردهایی که متغیر در آن‌ها وجود دارد
    - **داده‌های آزمون:** رکوردهایی که متغیر در آن‌ها مفقود است

```
KNNImputer(n_neighbors=2, weights="uniform")
```

مقادیر گمشده: تصادفی در برابر غیرتصادفی

- **نکته کلیدی: مقادیر به دلایل گوناگون گم می‌شوند:**
  - بسیار مهم: آیا گم‌شدگی تصادفی است یا غیرتصادفی؟ (Random vs. Not at Random)

- **نمونه‌هایی از گم‌شدگی غیرتصادفی (Not at Random):**
  - سوالات اختیاری حساس در پرسشنامه‌ها (مثلاً «میزان درآمد سالیانه» یا «مصرف دخانیات»)
  - مقادیری که فقط تحت شرایط خاص تعریف می‌شوند (مثلاً «معدل مدرک ارشد»)
  - متغیرهایی که تنها به بخش خاصی از جامعه مربوط می‌شوند (مثلاً «وضعیت بارداری»)
  - حسگرهایی که در شرایط حدی (دمای بسیار بالا یا فشار شدید) دچار قطعی می‌شوند

- **در این سناریوها، پر کردن داده با میانگین منجر به از بین رفتن اطلاعات حیاتی می‌شود!**
  - به بیان دیگر: **«گمشده بودن» خود یک سیگنال اطلاعاتی معنادار است!**

مدیریت مقادیر گمشده: ملاحظات و ریسک‌ها

- یک کارآزمایی بالینی برای بررسی عوارض جانبی یک داروی خاص را در نظر بگیرید:
- در این آزمایش، ۵۰ نفر مقدار قند خون خود را می‌دانند و گزارش کرده‌اند؛
  - از میان آن‌ها، 4/5 نفر قند خون بالا دارند.

Overall, the side effects are moderate (~23%), but people with an increased blood sugar value have a 75% risk of side effects

		side effects	
		Yes (n=58)	No (n=192)
increased blood sugar	Yes (n=40)	**30**	**10**
	No (n=10)	**8**	**2**
	-- (n=200)	**20**	**180**

- به طور کلی عوارض جانبی معتدل است (~23%)، اما افراد با قند خون بالا ریسک 75% برای ابتلا به عوارض دارند.

مدیریت مقادیر گمشده: ملاحظات و ریسک‌ها (ادامه)

- فرض کنید مقدار گمشده قند خون بالا را با مقدار اکثریت («بله») پر کنیم:

Overall, the side effects are moderate (~23%), and even slightly lower (~21%) for people with an increased blood sugar value

		side effects	
		Yes (n=58)	No (n=192)
increased blood sugar	Yes (n=240)	**50**	**190**
	No (n=10)	**8**	**2**

- در کل عوارض جانبی معتدل باقی می‌ماند (~23%)، اما ریسک برای افراد با قند خون بالا از 75% به ~21% کاهش می‌یابد (نتیجه کاملاً گمراه‌کننده)!

توزیع نامتوازن کلاس‌ها

- **مثال: یادگیری مدلی برای تشخیص HIV**
  - با توجه به مجموعه‌ای از علائم بالینی
- **مجموعه داده:**
  - پرونده بیمارانی که از نظر ابتلا به HIV آزمایش شده‌اند
- **توزیع کلاس‌ها:**
  - 99.9% منفی (Negative)
  - 0.1% یا 0.01% مثبت (Positive)
- **یادگیری درخت تصمیم:**
  - یافتن هرگونه انشعاب با بهبود کیفیت معنادار بسیار دشوار خواهد بود.
  - درخت تصمیم آموخته‌شده تنها یک خروجی همواره «منفی» پیش‌بینی می‌کند.

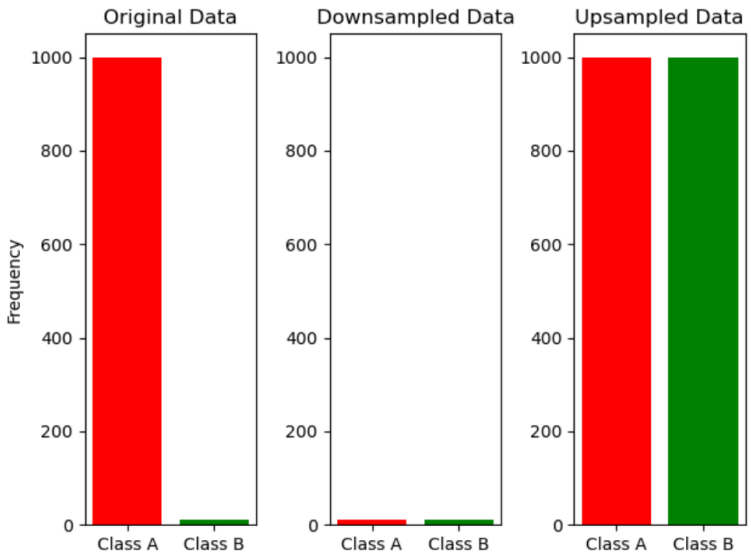


بازنمونه‌گیری داده‌های نامتوازن

- **دو هدف متناقض:**
  - استفاده از حداکثر داده‌های آموزشی ممکن (Use as much training data as possible)
  - استفاده از حداکثر تنوع در داده‌های آموزشی (Use as diverse training data as possible)

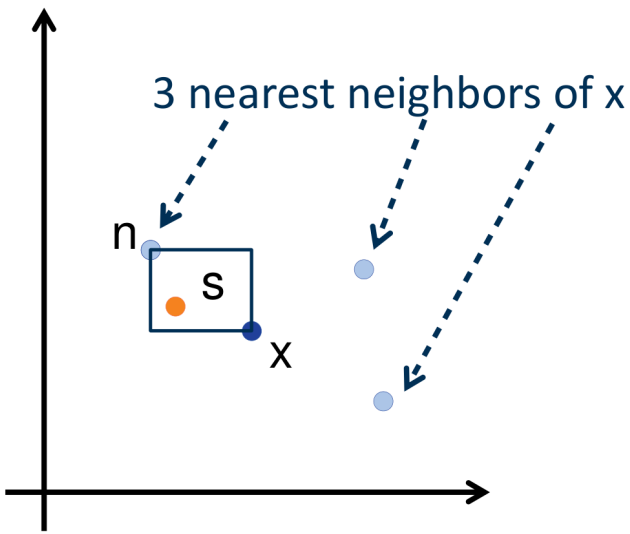
- **استراتژی‌های بازنمونه‌گیری (Resampling):**
  - **زیرنمونه‌گیری از کلاس اکثریت (Downsampling):**
    - در تضاد با هدف اول (داده‌های زیادی دور ریخته می‌شود)
  - **بیش‌نمونه‌گیری از کلاس اقلیت (Upsampling):**
    - در تضاد با هدف دوم (تنوع جدیدی اضافه نمی‌شود)

بررسی یک سناریوی حدی از عدم توازن



- **یک مثال حدی را در نظر بگیرید:**
  - 1,000 نمونه از کلاس A
  - 10 نمونه از کلاس B
- **زیرنمونه‌گیری (Downsampling):**
  - 990 نمونه را استفاده نمی‌کند و نادیده می‌گیرد.
- **بیش‌نمونه‌گیری (Upsampling):**
  - از هر نمونه کلاس B تعداد 100 کپی ایجاد می‌کند.
  - طبقه‌بند تمایل پیدا می‌کند صرفاً این 10 نمونه کلاس B را حفظ کند!
- **کتابخانه پایتون:**
  - `https://imbalanced-learn.org/`

تکنیک بیش‌نمونه‌گیری اقلیت مصنوعی (SMOTE)



- **روش SMOTE (تکنیک بیش‌نمونه‌گیری اقلیت مصنوعی)**
  - ساخت نمونه‌های مصنوعی از کلاس اقلیت
- **مراحل الگوریتم برای نمونه مفروض x:**
  - انتخاب یک همسایه n در میان k نزدیک‌ترین همسایه (درون همان کلاس) x
  - ایجاد نمونه مصنوعی s:

به ازای هر ویژگی a:

$$s.a \leftarrow x.a + \text{rand}(0,1) \times (n.a - x.a)$$

مرجع اصلی: Chawla, Bowyer, Hall, Kegelmeyer (JAIR, 2002)

مقیاس‌های متفاوت ویژگی‌ها: نرمال‌سازی

ID	Age	Income
371	25	70,000
433	30	85,000
864	40	90,000

- **مرور: حساسیت شدید k-NN به مقیاس ویژگی‌ها:**
  - فاصله اقلیدسی سن و درآمد:
    $D = \sqrt{(25-30)^2 + (70000-85000)^2} \approx 15000$
  - اثر تغییرات سن در برابر درآمد محو می‌شود!
- **راهکار: مقیاس‌بندی و استانداردسازی:**
  - **StandardScaler:** میانگین صفر و واریانس یک:
    $z = \frac{x-\mu}{\sigma}$
  - **MinMaxScaler:** نگاشت به بازه معین (معمولاً $[0, 1]$):
    $X_{\text{norm}} = \frac{X-X_{\min}}{X_{\max}-X_{\min}}$

پیش‌پردازشگرها نیز نیاز به آموزش دارند!

- **بسیاری از روش‌های پیش‌پردازش دارای حالت داخلی (Internal State) هستند**
  - به عنوان نمونه: میانگین و واریانس در StandardScaler، یا کمینه و بیشینه در MinMaxScaler.



```
import pandas as pd
from sklearn.preprocessing import MinMaxScaler
from sklearn.model_selection import train_test_split

golf = pd.read_csv('golf.csv')

scaler = MinMaxScaler()
golf_scaled = scaler.fit_transform(golf[['Temperature', 'Humidity']])

X_train, X_test, y_train, y_test = train_test_split(golf_scaled, golf['Play'], test_size=0.3, random_state=0)
```

- **هشدار مهم:**
  - هرگز پیش‌پردازش را روی کل مجموعه داده قبل از تقسیم‌بندی اعمال نکنید!
  - این کار مصداق بارز **نشت اطلاعات (Data Leakage)** از داده‌های ارزیابی به آموزش است.

پیش‌پردازشگرها نیز نیاز به آموزش دارند (ادامه)

```
golf = pd.read_csv('golf.csv')
X_train, X_test, y_train, y_test = train_test_split(golf, golf['Play'], test_size=0.3, random_state=0)

scaler = MinMaxScaler()
golf_scaled = scaler.fit_transform(X_train[['Temperature', 'Humidity']], y_train)

golf_test_scaled = scaler.transform(X_test[['Temperature', 'Humidity']])
```

- **تفکیک فاز برازش (Fit) و تبدیل (Transform)**
  - تابع fit_transform منحصراً برای داده‌های آموزشی (Training Set) استفاده می‌شود تا پارامترها را محاسبه و اعمال کند.
  - تابع transform برای داده‌های آزمون (Test Set) استفاده می‌شود (با استفاده از پارامترهای آموخته‌شده از داده آموزش).
- این تفکیک ضامن ارزیابی واقع‌بینانه مدل در محیط واقعی است.

ترکیب اجزای یادگیری ماشین: پایپ‌لاین‌ها

```python
from sklearn.pipeline import Pipeline
from sklearn.svm import SVC
estimators = [
    ('scale', MinMaxScaler()),
    ('clf', SVC())
]
pipe = Pipeline(estimators)
pipe.fit(X_train, y_train)
pipe.score(X_test, y_test)
```

```python
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder

column_trans = ColumnTransformer(
    [('categories', OneHotEncoder(dtype='int'), ['Outlook']),
    ('scale', MinMaxScaler(), ['Temperature'])],
    remainder='drop'
)

estimators = [
    ('preprocessing', column_trans),
    ('clf', SVC())
]
pipe = Pipeline(estimators)
pipe.fit(X_train, y_train)
pipe.score(X_test, y_test)
```

Component

Columns

- **ساخت زنجیره پردازشی منظم با Pipeline**
  - تجمیع پیش‌پردازشگرها و مدل تخمین‌زننده در یک شیء واحد.
  - جلوگیری خودکار از نشت داده در اعتبارسنجی متقاطع (Cross-Validation).
- **اعمال تبدیل‌های مجزا بر ستون‌های مختلف:**
  - استفاده از ColumnTransformer برای اعمال پایپ‌لاین‌های متفاوت بر ویژگی‌های عددی و متنی/دسته‌ای.

متغیرهای پیش‌بینی‌کننده کاذب (False Predictors)



- **صحت نزدیک به 100%~ یک نتیجه عالی است...**
  - ...اما نتیجه‌ای است که باید شما را کاملاً به شک بیندازد!
- **روایتی واقعی از یک تجربه:**
  - کار با افزونه داده‌های پیوندی باز (Linked Open Data - LOD)
  - تلاش برای پیش‌بینی رتبه‌بندی دانشگاه‌های جهان با داده‌های DBpedia
  - هدف: درک عواملی که یک دانشگاه را به یک دانشگاه برتر (Top University) تبدیل می‌کند.

متغیرهای پیش‌بینی‌کننده کاذب (False Predictors)



- **افزونه داده‌های پیوندی باز (LOD)**
  - استخراج خودکار ویژگی‌های تکمیلی از گراف‌های دانش عمومی (مانند DBpedia)
  - بدون نظارت (ویژگی‌ها کاملاً خودکار ایجاد شدند)
- **مدل آموخته‌شده:**
  - THE < 20 → TOP = true
  - پیش‌بینی‌کننده کاذب: متغیر هدف در میان ویژگی‌ها گنجانده شده بود!
- **نمونه‌های دیگر:**
  - Mark < 5 → passed = true
  - Sales > 1000000 → bestseller = true

شناسایی متغیرهای پیش‌بینی کاذب

- **تحلیل ساختار مدل‌های آموزش‌دیده:**
  - مجموعه‌های قاعده که تنها از یک قاعده تشکیل شده‌اند.
  - درخت‌های تصمیمی که تنها یک گره تصمیم‌گیری دارند.

- **فرآیند رفع عیب:**
  - شناسایی متغیر کاذب با بررسی وزن‌ها یا ریشه درخت
  - حذف ویژگی کاذب از مجموعه داده
  - تکرار فرآیند آموزش و ارزیابی

انواع داده‌های پشتیبانی‌نشده

- **همه الگوریتم‌های یادگیری از تمام انواع داده پشتیبانی نمی‌کنند:**
  - برخی الگوریتم‌ها (مانند SVM و شبکه‌های عصبی) قادر به پردازش مستقیم ویژگی‌های دسته‌ای/متنی نیستند و فقط بردار عددی می‌پذیرند.
  - برخی دیگر (مانند Naive Bayes استاندارد) تنها با مقادیر دسته‌ای یا گسسته به خوبی کار می‌کنند.

- **انواع داده‌های متداول نیازمند تبدیل:**
  - متغیرهای دسته‌ای و کیفی (Categorical Attributes)
  - متغیرهای عددی نیازمند گسسته‌سازی (Discretization)
  - داده‌های تاریخ و زمان (Date & Time)
  - متون آزاد و اسناد (Textual Data)

تبدیل ویژگی‌های دسته‌ای به عددی: ویژگی‌های ترتیبی

- **ویژگی‌های ترتیبی (Ordinal Attributes)**
  - ترتیب و توالی میان مقادیر دارای بار مفهومی است (مانند Grade = A, A-, B+, B, B-, C+, C, C-).
  - نگاشت متناظر به مقادیر عددی با حفظ ترتیب: A=8, A-=7, B+=6, B=5, B-=4, C+=3, C=2, C-=1

ID	Grade	...
371	A-	
433	B	



ID	Grade	...
371	7	
433	5	

- استفاده از چنین کدگذاری‌ای به مدل اجازه یادگیری قواعد معنادار را می‌دهد (مثلاً grade > 6 $\rightarrow$ excellent_student = true).
- **پیاده‌سازی در پایتون:** `OrdinalEncoder`

تبدیل ویژگی‌های دسته‌ای به عددی: ویژگی‌های اسمی

Conversion: Categorical to Numeric

- **ویژگی‌های اسمی و بدون ترتیب (Nominal Attributes):**
  - **کدگذاری یکتا (One-Hot Encoding):** برای هر مقدار v یک متغیر پرچم دودویی C_v ایجاد می‌شود که در صورت برابری ۱ و در غیر این صورت ۰ است.

ID	Color	..
371	red	
433	yellow	

→

ID	Color_red	Color_orange	Color_yellow	…
371	1	0	0	
433	0	0	1	

- **پیاده‌سازی در پایتون:** `OneHotEncoder`
- **حالت خاص – ویژگی‌های دودویی (Binary):** مانند student = yes, no
  - برای Student = yes → student_binary = 0
  - برای Student = no → student_binary = 1

تبدیل ویژگی‌های دسته‌ای با مقادیر پرشمار



- **مقادیر متعدد (Many Values):**
  - کد ایالت‌های آمریکا (50 مقدار)
  - کد شغل (7,000 مقدار، اما تنها چند مقدار پرتکرار)
- **رویکردها:**
  - دستی، با دانش زمینه (مثلاً گروه‌بندی ایالت‌ها)
  - استفاده از ویژگی‌های دودویی و سپس اعمال کاهش بعد

تبدیل مقادیر عددی به ترتیبی (گسسته‌سازی)

- **یادآوری: گسسته‌سازی برای درخت تصمیم (Discretization)**
  - مقادیر ویژگی (مثلاً سن افراد): $\{0, 4, 12, 16, 16, 18, 24, 26, 28\}$

- **گسسته‌سازی با بازه‌های هم‌اندازه (Equal-interval binning)** – مثلاً برای پهنای بازه ۱۰:
  - بازه ۱: $0, 4$ $[-\infty, 10)$
  - بازه ۲: $12, 16, 16, 18$ $[10, 20)$
  - بازه ۳: $24, 26, 28$ $[20, +\infty)$

- **گسسته‌سازی با بسامد یکسان (Equal-frequency binning)** – مثلاً برای تراکم ۳ نمونه در هر بازه:
  - بازه ۱: $0, 4, 12$ $[-\infty, 14)$
  - بازه ۲: $16, 16, 18$ $[14, 21)$
  - بازه ۳: $24, 26, 28$ $[21, +\infty)$

مدیریت ویژگی‌های تاریخ و زمان

- **تاریخ‌ها و زمان‌ها با فرمت‌های گوناگون ثبت می‌شوند:**
  - گام نخست: استانداردسازی و تجزیه متن تاریخ (Normalize & Parse)
- **تاریخ‌ها حامل اطلاعات جذاب و فراوانی هستند:**
  - مثال: تحلیل رفتار خرید مشتریان
  - زمان در طول روز (Time of day)
  - روز کاری در برابر تعطیلات آخر هفته (Weekday vs. Weekend)
  - ابتدا در برابر انتهای ماه (Begin vs. End of month)
  - خود ماه، فصل و فصل سال (Month, Quarter, Season)
- **پایتون:** استفاده از کتابخانه datetime

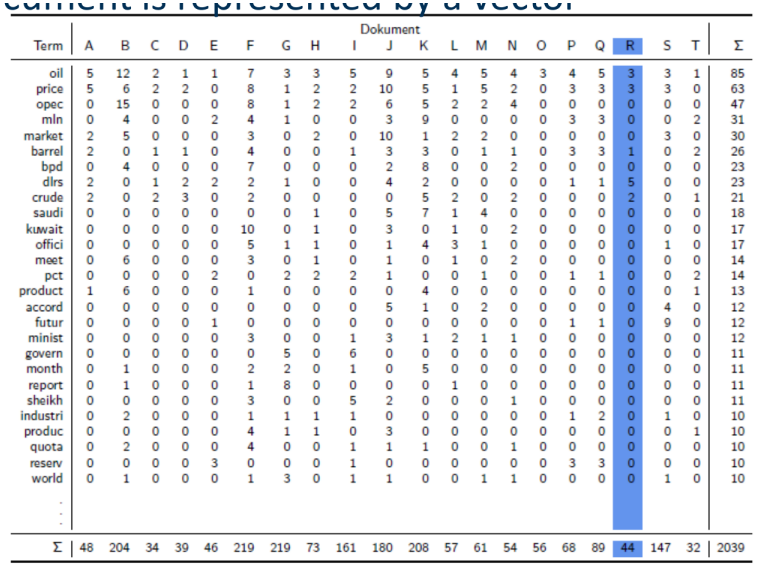
پیش‌پردازش ویژگی‌های متنی

- **مراحل استاندارد آماده‌سازی متن:**
  - **پاکسازی متن (Text Cleanup)** حذف علائم نگارشی، تگ‌های HTML و کاراکترهای زائد.
  - **توکن‌بندی (Tokenization)** شکستن متن به کلمات منفرد (Tokens).
  - **تبدیل به حروف کوچک (Lowercasing).**
  - **حذف کلمات ایست (Stopwords Removal)** حذف کلمات بسیار رایج فاقد بار اطلاعاتی (مانند حروف اضافه و ربط).
  - **ریشه‌یابی و لماتیزاسیون (Stemming / Lemmatization)** تبدیل واژگان مختلف به ریشه یکسان (مانند computes, computing → compute).

```python
from nltk.stem.porter import PorterStemmer

# Stem tokens
stemmer = PorterStemmer()
tokens = ['Jupiter', 'is', 'the', 'largest', 'gas', 'planet']
stems = []
for item in tokens:
    stems.append(stemmer.stem(item))
```

استخراج ویژگی: مدل کیسه کلمات (Bag-of-Words)



Term	Dokument																			Σ
	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	
oil	5	12	2	1	1	7	3	3	5	9	5	4	5	4	3	4	5	3	3	1	85
price	5	6	2	2	0	8	1	2	2	10	5	1	5	2	0	3	3	3	3	0	63
opec	0	15	0	0	0	8	1	2	2	6	5	2	2	4	0	0	0	0	0	0	47
mln	0	4	0	0	2	4	1	0	0	3	9	0	0	0	0	3	3	0	0	2	31
market	2	5	0	0	0	3	0	2	0	10	1	2	2	0	0	0	0	0	3	0	30
barrel	2	0	1	1	0	4	0	0	1	3	3	0	1	1	0	3	3	1	0	2	26
bpd	0	4	0	0	0	7	0	0	0	2	8	0	0	2	0	0	0	0	0	0	23
dlrs	2	0	1	2	2	2	1	0	0	4	2	0	0	0	0	1	1	5	0	0	23
crude	2	0	2	3	0	2	0	0	0	0	5	2	0	2	0	0	0	2	0	1	21
saudi	0	0	0	0	0	0	0	1	0	5	7	1	4	0	0	0	0	0	0	0	18
kuwait	0	0	0	0	0	10	0	1	0	3	0	1	0	2	0	0	0	0	0	0	17
offici	0	0	0	0	0	5	1	1	0	1	4	3	1	0	0	0	0	0	1	0	17
meet	0	6	0	0	0	3	0	1	0	1	0	1	0	2	0	0	0	0	0	0	14
pct	0	0	0	0	2	0	2	2	2	1	0	0	1	0	0	1	1	0	0	2	14
product	1	6	0	0	0	1	0	0	0	0	4	0	0	0	0	0	0	0	0	1	13
accord	0	0	0	0	0	0	0	0	0	5	1	0	2	0	0	0	0	0	4	0	12
futur	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	1	1	0	9	0	12
minist	0	0	0	0	0	3	0	0	1	3	1	2	1	1	0	0	0	0	0	0	12
govern	0	0	0	0	0	0	5	0	6	0	0	0	0	0	0	0	0	0	0	0	11
month	0	1	0	0	0	2	2	0	1	0	5	0	0	0	0	0	0	0	0	0	11
report	0	1	0	0	0	1	8	0	0	0	0	1	0	0	0	0	0	0	0	0	11
sheikh	0	0	0	0	0	3	0	0	5	2	0	0	0	1	0	0	0	0	0	0	11
industri	0	2	0	0	0	1	1	1	1	0	0	0	0	0	0	1	2	0	1	0	10
produc	0	0	0	0	0	4	1	1	0	3	0	0	0	0	0	0	0	0	0	1	10
quota	0	2	0	0	0	4	0	0	1	1	1	0	0	1	0	0	0	0	0	0	10
reserv	0	0	0	0	3	0	0	0	1	0	0	0	0	0	0	3	3	0	0	0	10
world	0	1	0	0	0	1	3	0	1	1	0	0	1	1	0	0	0	0	1	0	10
.																					
.																					
.																					
Σ	48	204	34	39	46	219	219	73	161	180	208	57	61	54	56	68	89	44	147	32	2039

- **اصول مدل کیسه کلمات (Bag-of-Words)**
  - هر کلمه یکتا در پیکره متنی تبدیل به یک بعد/ویژگی در فضا می‌شود.
  - ترتیب کلمات و ساختار گرامری جمله نادیده گرفته می‌شود.
  - هر سند متنی به صورت یک بردار در فضای ویژگی بازنمایی می‌شود.
- مدلی ساده، قدرتمند و بسیار پرکاربرد در بازیابی اطلاعات و دسته‌بندی اسناد.

روش‌های مختلف ساخت بردار ویژگی متنی

- **تکنیک‌های وزن‌دهی به کلمات درون بردار سند:**
  - **وقوع دودویی کلمه (Binary Term Occurrence)**
    - تنها حضور یا غیبت واژه در سند بررسی می‌شود (1 یا 0) – نظیر One-Hot Encoding.
    - در پایتون: `CountVectorizer(binary=True)`
  - **رخداد و بسامد واژه (Term Occurrence)**
    - تعداد تکرار واژه در سند؛ دارای چالش در صورت متفاوت بودن طول اسناد مختلف.
    - در پایتون: `CountVectorizer(binary=False)`
  - **فراوانی نسبی واژه (Term Frequency)**
    - نسبت تکرار واژه به کل کلمات موجود در همان سند (طول سند).
    - در پایتون: `TfidfVectorizer(use_idf=False)`
  - **وزن‌دهی TF-IDF** (جزئیات و فرمول‌ها در اسلاید بعدی)
    - در پایتون: `TfidfVectorizer()`

وزن‌دهی TF-IDF

- **سنجش وزن و اهمیت کلمات با معیار TF-IDF**
  - کوته‌نوشت Term Frequency – Inverse Document Frequency
  - ارزیابی اختصاصی بودن یک واژه در یک سند نسبت به کل پیکره متنی:

$$w_{ij} = tf_{ij} \times idf_i$$

  - **بسامد معکوس سند (IDF)**

$$idf_i = \log\left(\frac{N}{df_i}\right)$$

  - N: تعداد کل اسناد در پیکره (Corpus)
  - df_i: تعداد اسنادی که واژه t_i در آن‌ها حداقل یک‌بار ظاهر شده است.
- **ویژگی کلیدی:**
  - اعطای وزن بالاتر به کلمات نادر و تخصصی؛ وزن کمتر به کلمات رایج عمومی.
- **پیاده‌سازی در scikit-learn** (با هموارسازی برای پرهیز از تقسیم بر صفر):

$$idf_i = \log\left(\frac{1+N}{1+df_i}\right) + 1$$

معیارهای شباهت اسناد: ضریب جاکارد (Jaccard)

- **معیار شباهت جاکارد (Jaccard Similarity)**
  - معیار شباهت برای بردارهایی با ویژگی‌های دودویی نامتقارن (Asymmetric Binary)

$$\text{Jaccard}(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{M_{11}}{M_{01} + M_{10} + M_{11}}$$

- **کاربرد در کنار بردارهای وقوع دودویی (One-Hot Vectors)**
  - مقدار ۱ نشان‌دهنده حضور واژه در سند است.
  - مقدار ۰ نشان‌دهنده غیبت واژه در سند است.
  - در بیشتر اسناد، اکثر مقادیر صفر هستند چون هر سند تنها از بخش ناچیزی از کل دایره واژگان استفاده می‌کند.
  - غیبت مشترک واژه‌ها (M_{00}) نباید نقشی در افزایش شباهت دو متن داشته باشد!

محاسبه ضریب جاکارد: مثال عملی

	Saturn	is	the	gas	planet	with	rings	Jupiter	largest	Roman	god	of	sowing
d1	1	1	1	1	1	1	1	0	0	0	0	0	0
d2	0	1	1	1	1	0	0	1	1	0	0	0	0
d3	1	1	1	0	0	0	0	0	0	1	1	1	1

- **محاسبه شباهت‌های جاکارد بین اسناد سه‌گانه:**
  - $\text{Jaccard}(d_1, d_2) = \frac{4}{9} \approx 0.44$
  - $\text{Jaccard}(d_2, d_3) = \frac{2}{11} \approx 0.18$
  - $\text{Jaccard}(d_1, d_3) = \frac{3}{11} \approx 0.27$

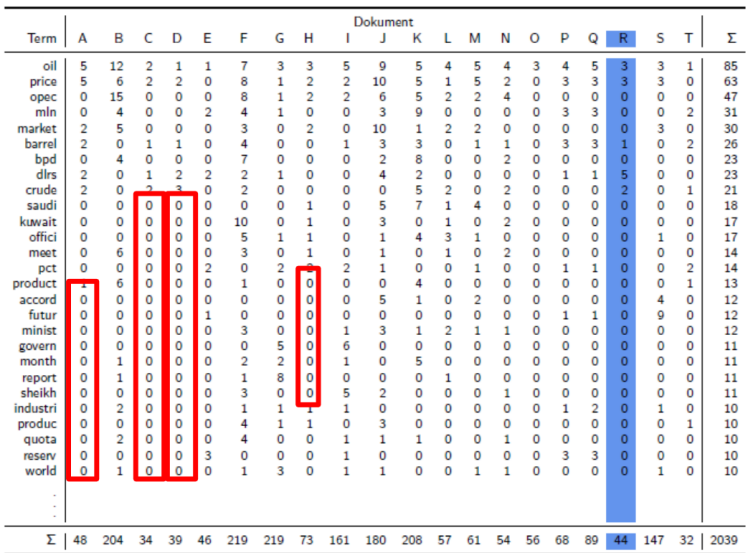
معیار شباهت کسینوسی (Cosine Similarity)

- **شباهت کسینوسی (Cosine similarity)**
  - معیار شباهت برای مقایسه بردارهای وزنی سند (مانند بردار بسامد یا TF-IDF)

$$\cos(d_1, d_2) = \frac{d_1 \cdot d_2}{\|d_1\| \, \|d_2\|}$$

  - که در آن $\cdot$ نشان‌دهنده ضرب داخلی بردارها ($a \cdot b = \sum_{i=1}^{n} a_i b_i$) و $\|d\|$ طول بردار ($\|d\| = \sqrt{\sum_{i=1}^{n} d_i^2}$) است.
- **مثال عددی (Example)**
  - $d_1 = (3, 2, 0, 5, 0, 0, 0, 2, 0, 0) \qquad d_2 = (1, 0, 0, 0, 0, 0, 0, 1, 0, 2)$
  - $d_1 \cdot d_2 = 3 \times 1 + 2 \times 0 + 0 \times 0 + 5 \times 0 + \cdots + 2 \times 1 + 0 \times 0 + 0 \times 2 = 5$
  - $\|d_1\| = (3^2 + 2^2 + 0^2 + 5^2 + 0^2 + 0^2 + 0^2 + 2^2 + 0^2 + 0^2)^{0.5} = \sqrt{42} \approx 6.481$
  - $\|d_2\| = (1^2 + 0^2 + 0^2 + 0^2 + 0^2 + 0^2 + 0^2 + 1^2 + 0^2 + 2^2)^{0.5} = \sqrt{6} \approx 2.245$
  - $\cos(d_1, d_2) = \frac{5}{6.481 \times 2.245} = \frac{5}{14.549} \approx 0.3150$

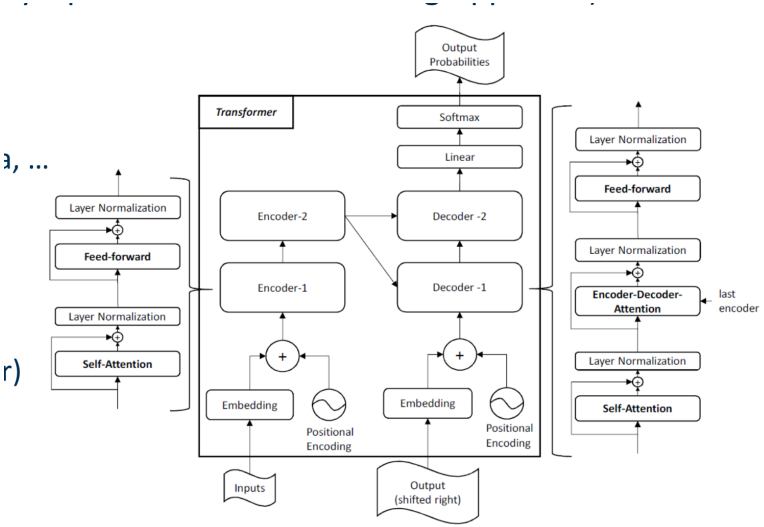
بازنمایی‌های چگال و خلوت (Dense and Sparse)



Term	Dokument																			
	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	Σ
oil	5	12	2	1	1	7	3	3	5	9	5	4	5	4	3	4	5	3	3	1	85
price	5	6	2	2	0	8	1	2	2	10	5	1	5	2	0	3	3	3	3	0	63
opec	0	15	0	0	0	8	1	2	2	6	5	2	2	4	0	0	0	0	0	0	47
mln	0	4	0	0	2	4	1	0	0	3	9	0	0	0	0	3	3	0	0	2	31
market	2	5	0	0	0	3	0	2	0	10	1	2	2	0	0	0	0	0	3	0	30
barrel	2	0	1	1	0	4	0	0	1	3	3	0	1	1	0	3	3	1	0	2	26
bpd	0	4	0	0	0	7	0	0	0	2	8	0	0	2	0	0	0	0	0	0	23
dlrs	2	0	1	2	2	2	1	0	0	4	2	0	0	0	0	1	1	5	0	0	23
crude	2	0	2	3	0	2	0	0	0	0	5	2	0	2	0	0	0	2	0	1	21
saudi	0	0	0	0	0	0	0	1	0	5	7	1	4	0	0	0	0	0	0	0	18
kuwait	0	0	0	0	0	10	0	1	0	3	0	1	0	2	0	0	0	0	0	0	17
offici	0	0	0	0	0	5	1	1	0	1	4	3	1	0	0	0	0	0	1	0	17
meet	0	6	0	0	0	3	0	1	0	1	0	1	0	2	0	0	0	0	0	0	14
pct	0	0	0	0	2	0	2	2	2	1	0	0	1	0	0	1	1	0	0	2	14
product	1	6	0	0	0	1	0	0	0	0	4	0	0	0	0	0	0	0	0	1	13
accord	1	0	0	0	0	0	0	0	0	5	1	0	2	0	0	0	0	0	4	0	12
futur	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	1	1	0	9	0	12
minist	0	0	0	0	0	3	0	0	1	3	1	2	1	1	0	0	0	0	0	0	12
govern	0	0	0	0	0	0	5	0	6	0	0	0	0	0	0	0	0	0	0	0	11
month	0	1	0	0	0	2	2	0	1	0	5	0	0	0	0	0	0	0	0	0	11
report	0	1	0	0	0	1	8	0	0	0	0	1	0	0	0	0	0	0	0	0	11
sheikh	0	0	0	0	0	3	0	0	5	2	0	0	0	1	0	0	0	0	0	0	11
industri	0	2	0	0	0	1	1	1	1	0	0	0	0	0	0	1	2	0	1	0	10
produc	0	0	0	0	0	4	1	1	0	3	0	0	0	0	0	0	0	0	0	1	10
quota	0	2	0	0	0	4	0	0	1	1	1	0	0	1	0	0	0	0	0	0	10
reserv	0	0	0	0	3	0	0	0	1	0	0	0	0	0	0	3	3	0	0	0	10
world	0	1	0	0	0	1	3	0	1	1	0	0	1	1	0	0	0	0	1	0	10
Σ	48	204	34	39	46	219	219	73	161	180	208	57	61	54	56	68	89	44	147	32	2039

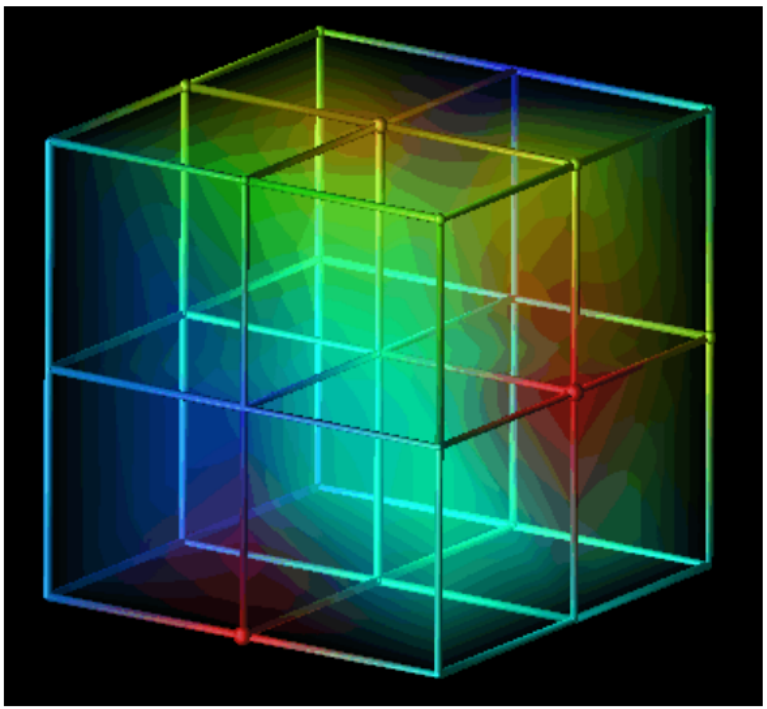
- **کیسه کلمات خلوت (Sparse) است:**
  - ابعاد بردار در حد ده‌ها هزار است.
  - بیشتر درایه‌ها صفر هستند.
- **بازنمایی چگال (Dense representation):**
  - تعبیه کلمات (Word embeddings)
  - برداری با ابعاد چند صدتایی

معماری ترنسفورمر (Transformer Architecture)



- **فقط رمزگذار (Encoder-only):**
  - BERT، ALBERT، RoBERTa
- **فقط رمزگشا (Decoder-only):**
  - مدل‌های زبانی بزرگ مانند GPT، LLaMA و ...
- **دنباله به دنباله (Seq2Seq):**
  - T-5 (Text-to-Text Transfer Transformer)
  - BART

ابعاد بالا (High Dimensionality)



- **مجموعه داده‌هایی با تعداد بسیار زیادی ویژگی:**
  - دسته‌بندی متون (هزاران کلمه)
  - پردازش و بینایی تصویر (میلیون‌ها پیکسل)
  - داده‌های بیان ژن و ژنومیک (ده‌ها هزار ژن با تعداد نمونه‌های کم)
- **پیامدهای ابعاد بالا:**
  - افزایش تصاعدی هزینه محاسباتی
  - خطر بسیار بالای بیش‌برازش (Overfitting)
  - ناتوانی در تجسم و تفسیر روابط توسط انسان

انتخاب زیرمجموعه ویژگی‌ها (Feature Subset Selection)

- **یک گام پیش‌پردازش حیاتی:**
  - ایده اصلی: تنها ویژگی‌های ارزشمند و با بار اطلاعاتی بالا نگه‌داشته شوند.
  - اصطلاح «ویژگی» (Feature) در ادبیات یادگیری ماشین معادل همان «صفت/ویژگی» (Attribute) است.
- **اهداف سه‌گانه انتخاب ویژگی:**
  - بهبود دقت و قدرت تعمیم مدل (جلوگیری از یادگیری نویز)
  - کاهش زمان آموزش و آزمایش الگوریتم‌ها
  - تسهیل درک، تفسیر و توضیح‌پذیری مدل برای تصمیم‌گیرندگان انسانی

دسته‌بندی اصلی: روش‌های فیلتری در برابر پوششی

- **تمایز بنیادین: روش‌های فیلتری در برابر روش‌های پوششی**
- **روش‌های فیلتری (Filter Methods)**
  - ارزیابی و رتبه‌بندی ویژگی‌ها بر مبنای معیارهای آماری مستقل از مدل یادگیری.
  - استفاده از معیارهای وزن‌دهی نظیر آزمون کای-دو (χ^2)، بهره اطلاعاتی (Information Gain)، و ضریب همبستگی.
  - انتخاب ویژگی‌های دارای بالاترین امتیاز وزنی.
  - سرعت محاسباتی بسیار بالا (خطی بر حسب تعداد ویژگی‌ها)، اما الزماً بهینه سراسری نیست.
- **نمونه کد پایتون (scikit-learn):**
  - انتخاب ۲۰ ویژگی برتر بر اساس آزمون آماری کای-دو:

```
X_f = SelectKBest(chi2, k=20).fit_transform(X, y)
```

روش‌های فیلتری: حذف ویژگی‌های زائد

- **حذف ویژگی‌های تکراری و زائد (Redundant Attributes)**
  - به عنوان مثال: ثبت دما همزمان بر حسب سلسیوس و فارنهایت.
  - ثبت ویژگی‌های متنی کاملاً هم‌رخداد (مانند نام «باراک» و «اوباما»).
- **معیارهای ارزیابی آماری در روش‌های فیلتری:**
  - ضریب همبستگی پیرسون / اسپیرمن بین ویژگی و متغیر هدف
  - معیار اطلاعات متقابل (Mutual Information)
  - آزمون آماری کای-دو (Chi-Square Test) برای ویژگی‌های گسسته
  - آستانه حداقل واریانس (Variance Threshold)
- **مزیت بزرگ:** سرعت محاسباتی فوق‌العاده بالا و مقیاس‌پذیری عالی.

روش‌های پوششی (Wrapper Methods)

- **اصول کارکرد روش‌های پوششی:**
  - یک مدل طبقه‌بند داخلی به عنوان جعبه سیاه ارزیاب به کار گرفته می‌شود.
  - مدل با زیرمجموعه‌های متفاوتی از ویژگی‌ها آموزش دیده و دقت آن ارزیابی می‌شود.
  - زیرمجموعه‌ای که بالاترین امتیاز اعتبارسنجی را کسب کند انتخاب می‌گردد.

- **چالش بنیادین:**
  - فضای جستجو نمایی است: برای n ویژگی، 2^n زیرمجموعه محتمل وجود دارد!
  - جستجوی جامع (Exhaustive Search) برای بیش از ۲۰ ویژگی غیرممکن است.

انتخاب پیش‌رو (Forward Selection)

- **الگوریتم انتخاب پیش‌رو حریصانه (Greedy Forward Selection)**
  ۱. با مجموعه ویژگی خالی آغاز کنید.
  ۲. حلقه تکرار:
     - به ازای هر ویژگی باقیمانده، آن را به طور موقت اضافه کنید و مدل را بسنجید.
     - ویژگی‌ای را که بیشترین بهبود در کارایی مدل را ایجاد کند به صورت دائمی اضافه کنید.
  ۳. شرط توقف: زمانی که افزودن هیچ ویژگی جدیدی موجب بهبود معنادار مدل نشود.

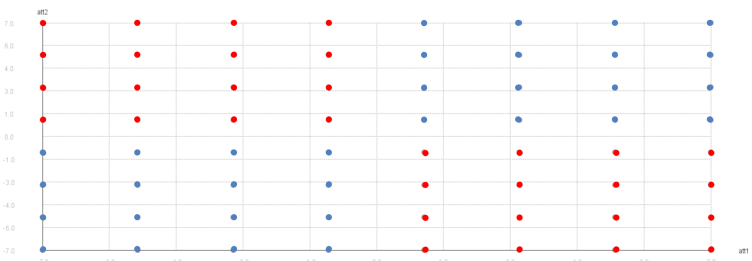
- **پیچیدگی محاسباتی:** از مرتبه $O(n^2)$ به جای $O(2^n)$، بسیار سریع‌تر اما ممکن است به بهینه محلی همگرا شود.

حذف پس‌رو (Backward Elimination)

- **الگوریتم حذف پس‌رو (Greedy Backward Elimination)**
  ۱. با مجموعه تمام ویژگی‌ها آغاز کنید.
  ۲. حلقه تکرار:
     - به ازای هر ویژگی موجود در مجموعه، آن را موقتاً حذف کرده و مدل را بسنجید.
     - ویژگی‌ای را که حذف آن کمترین افت کارایی (یا حتی بهبود مدل) را به همراه دارد حذف کنید.
  ۳. شرط توقف: زمانی که حذف هر یک از ویژگی‌های باقیمانده باعث افت فاحش در کارایی مدل گردد.

- **نکته:** قادر به در نظر گرفتن برهم‌کنش‌های اولیه بین تمام متغیرها است، اما در شروع برای ابعاد بزرگ بسیار کند است.

مجموعه داده صفحه شطرنجی (Checkerboard Dataset)



- **چالش تعاملات غیرخطی:**
  - درخت تصمیم و روش‌های پوششی به راحتی مرزهای این مسئله شطرنجی را یاد می‌گیرند.
  - اما اگر از روش فیلتری تک‌متغیره استفاده کنیم چه می‌شود؟
  - هیچ‌یک از دو بعد X یا Y به تنهایی همبستگی خطی با کلاس هدف ندارند!
  - روش‌های فیلتری ممکن است هر دو ویژگی ضروری را نادیده بگیرند!

پیاده‌سازی انتخاب ویژگی در پایتون (scikit-learn)

- **روش‌های پوششی ترتیبی با `SequentialFeatureSelector` :**
  - **انتخاب پیش‌رو (Forward Selection):**

```
SequentialFeatureSelector(direction='forward')
```

  - **حذف پس‌رو (Backward Elimination):**

```
SequentialFeatureSelector(direction='backward')
```

- **در صورت دسترسی به اهمیت ویژگی‌ها در مدل (feature_importances_):**
  - حذف بازگشتی ویژگی با اعتبارسنجی متقاطع:

```
RFECV(Recursive feature elimination with CV)
```

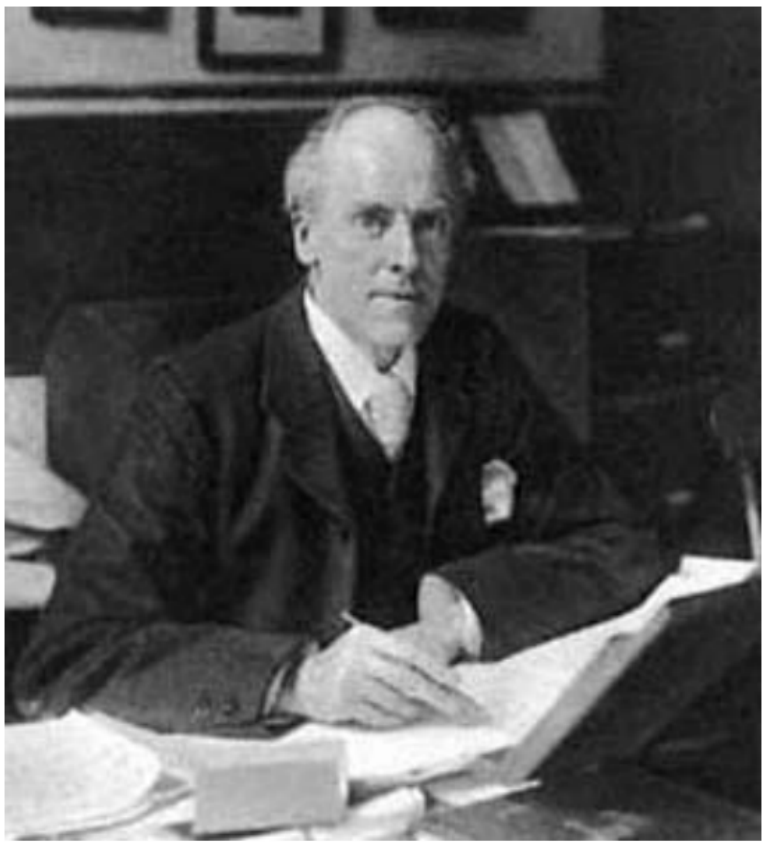
  - اجرای یک گام غربالگری بر مبنای اهمیت صفات:

```
SelectFromModel(estimator)
```

سایر رویکردهای انتخاب ویژگی

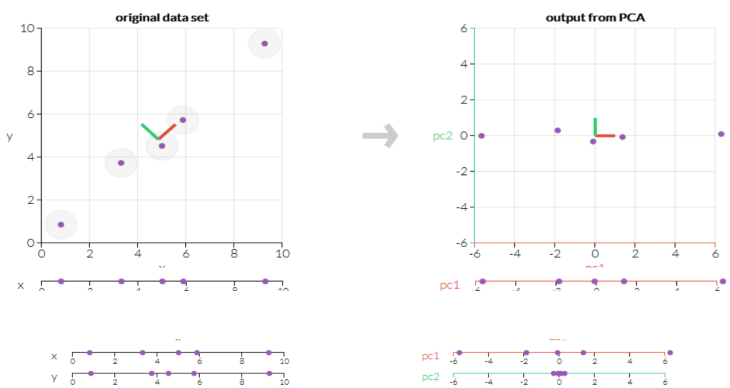
- **جستجوی جامع (Brute Force Search)**
  - تضمین یافتن بهترین زیرمجموعه ممکن، اما تنها تا حدود ۱۵ تا ۲۰ ویژگی قابل اجرا است.
- **الگوریتم‌های تکاملی و ژنتیک (Genetic / Evolutionary Algorithms)**
  - جستجوی هوشمندانه در فضای ترکیبیاتی با عملگرهای جهش و تقاطع کروموزوم‌ها.
- **روش‌های توکار (Embedded Methods)**
  - انتخاب ویژگی به عنوان بخشی ذاتی از فرآیند یادگیری مدل (مانند جریمه‌سازی Lasso / L1 و اهمیت ویژگی‌ها در درخت‌های تصمیم و Random Forest).

تحلیل مؤلفه‌های اصلی (PCA)



- **تاکنون روش‌های انتخاب ویژگی را بررسی کردیم:**
  - زیرمجموعه‌ای از ویژگی‌های موجود را انتخاب می‌کردیم.
  - هیچ ویژگی جدیدی ساخته نمی‌شد.
- **رویکرد استخراج ویژگی (Feature Extraction)**
  - ترکیب ویژگی‌های موجود برای ایجاد متغیرهای جدید و متراکم.
  - PCA (Principal Component Analysis) محبوب‌ترین روش خطی بدون نظارت برای کاهش ابعاد است.

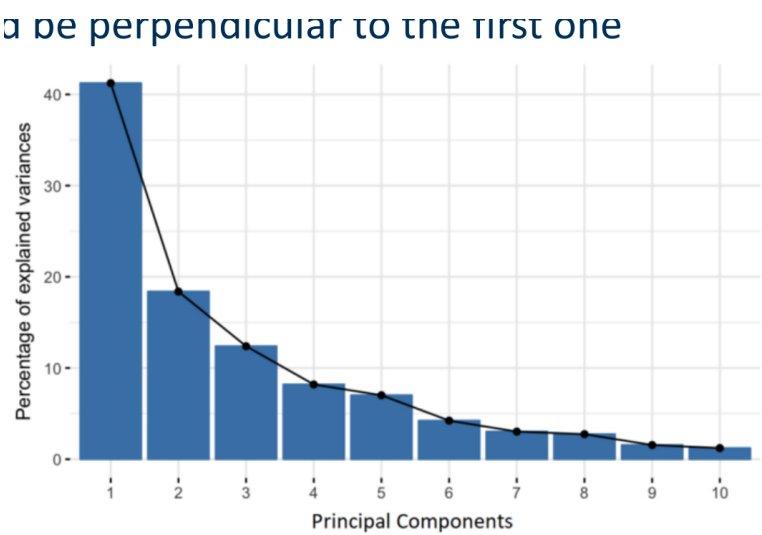
تحلیل مؤلفه‌های اصلی: ایده چرخش دستگاه مختصات



- **ایده بنیادین:**
  - تبدیل و چرخش دستگاه مختصات به گونه‌ای که هر محور جدید (مؤلفه اصلی) در راستای بیشترین پراکندگی و واریانس داده‌ها قرار گیرد.
  - محور اول (PC1): بیشترین واریانس داده را جذب می‌کند.
  - محور دوم (PC2): متعامد بر محور اول، بیشترین واریانس باقیمانده را مدل می‌کند.

ویژگی‌ها و کاربردهای مؤلفه‌های اصلی

- **مؤلفه‌های اصلی:**
  - ترکیبات خطی از ویژگی‌های اولیه هستند.
  - کاملاً ناهمبسته (Orthogonal) با یکدیگرند.
- **رویکرد کلی در کاربرد:**
  - نگه‌داشتن k مؤلفه نخست به نحوی که بخش عمده واریانس داده‌ها (مثلاً 95%) حفظ شود.
  - کاهش فضای چندصد بعدی به ۲ یا ۳ بعد برای تجسم داده‌ها (Visualization).



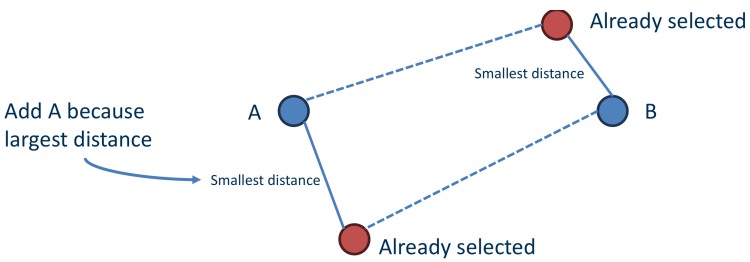
نمونه‌گیری مجدد (Sampling Revisited)

- **کاهش عرض در برابر کاهش ارتفاع مجموعه داده:**
  - انتخاب زیرمجموعه ویژگی‌ها عرض داده‌ها (تعداد ستون‌ها) را کاهش می‌دهد.
  - نمونه‌گیری ارتفاع داده‌ها (تعداد سطرها / رکوردها) را کاهش می‌دهد.

- **چرا نمونه‌گیری انجام می‌دهیم؟**
  - حجم داده‌ها بسیار فراتر از حافظه در دسترس است.
  - آزمایش و مقایسه سریع‌تر الگوریتم‌های مختلف در مراحل اولیه پروژه.

- **انواع نمونه‌گیری متداول:**
  - نمونه‌گیری تصادفی ساده (Simple Random Sampling)
  - نمونه‌گیری طبقه‌بندی‌شده (Stratified Sampling) برای حفظ نسبت کلاس‌ها

الگوریتم نمونه‌گیری کنارد-استون (Kennard-Stone)



- **هدف: انتخاب نمونه‌هایی با حداکثر پوشش فضای ویژگی.**
- **مراحل الگوریتم:**
  ۱. محاسبه فواصل دوبه‌دوی تمام نقاط در فضای ویژگی.
  ۲. انتخاب دو نقطه‌ای که بیشترین فاصله اقلیدسی را از یکدیگر دارند به عنوان نمونه‌های نخست.
  ۳. در هر مرحله بعدی، افزودن نقطه‌ای که بیشترین کمینه فاصله را از نقاط انتخاب‌شده قبلی دارد.

الگوریتم کنارد-استون: ویژگی‌ها و پیاده‌سازی

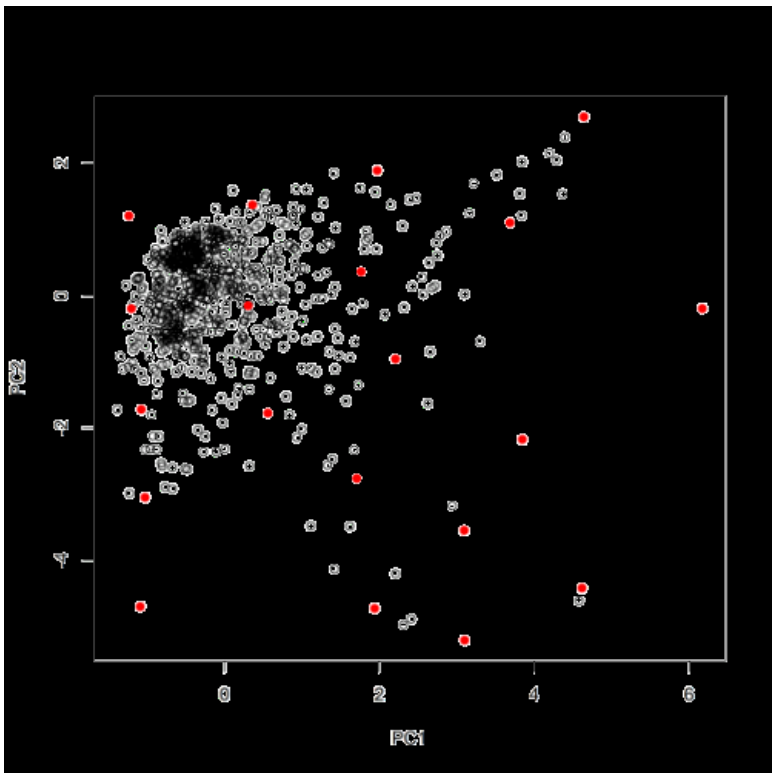
- **تضمین تنوع نقاط انتخاب‌شده:**
  - تضمین می‌کند که نقاط ناهمگن و متنوع به مجموعه نمونه اضافه شوند (افزایش تنوع نمونه‌ها).
  - پوشش کامل‌تر موارد گوشه‌ای و نادر (Corner Cases) در فضای ویژگی‌ها.
  - اما پتانسیل جذب نقاط غیرعادی و پرت (Outliers) نیز به مراتب بیشتر می‌شود.
  - توزیع احتمالاتی طبیعی داده‌ها ممکن است دستخوش تغییر گردد.

- **پیاده‌سازی در پایتون (Python)**
  - به طور پیش‌فرض در scikit-learn تعبیه نشده است.
  - نیاز به نصب بسته مستقل `kennard-stone` :

```
pip install kennard-stone
```

پیوند مخزن پایتون: https://pypi.org/project/kennard-stone/

مثال عملی نمونه‌گیری کنارد-استون



- **مزیت (Pro)**
  - بخش زیادی از موارد خاص، غیرعادی و لبه‌ای در نمونه پوشش داده می‌شوند.
- **عیب (Con)**
  - توزیع احتمالاتی طبیعی داده‌ها به کلی دستخوش تغییر می‌شود.
  - تمرکز نامتناسبی بر نقاط پرت و مرزی ایجاد می‌گردد.

برهم‌کنش استراتژی‌های نمونه‌گیری با الگوریتم‌ها

- **اثرات متقابل استراتژی نمونه‌گیری و نوع الگوریتم یادگیرنده:**
  - **مدل‌های متکی بر توزیع آماری (مانند بیز ساده / Naive Bayes)**
    - وابسته به برآورد درست احتمالات؛ نمونه‌گیری طبقه‌بندی‌شده (Stratified) کارایی بالاتری دارد.
  - **مدل‌های متکی بر مرزهای تفکیک (مانند درخت تصمیم / Decision Trees)**
    - حساسیت کمتر به توزیع کلی؛ پوشش نقاط لبه‌ای با کنارد-استون صحت مدل را بالا می‌برد.

Titanic Dataset
Filter: 50 training examples

	Decision Tree	Naive Bayes
Stratified	.727	**.752**
Kennard Stone	**.742**	.721

نکته‌ای پیرامون نمونه‌گیری در پروژه‌های واقعی

- **داده‌های آموزشی در پروژه‌های دنیای واقعی غالباً خود یک نمونه هستند:**
  - به عنوان نمونه: ارقام فروش ماه گذشته، گزارش‌های مالیاتی سال قبل، یا سوابق بیماران بستری در یک بیمارستان خاص.

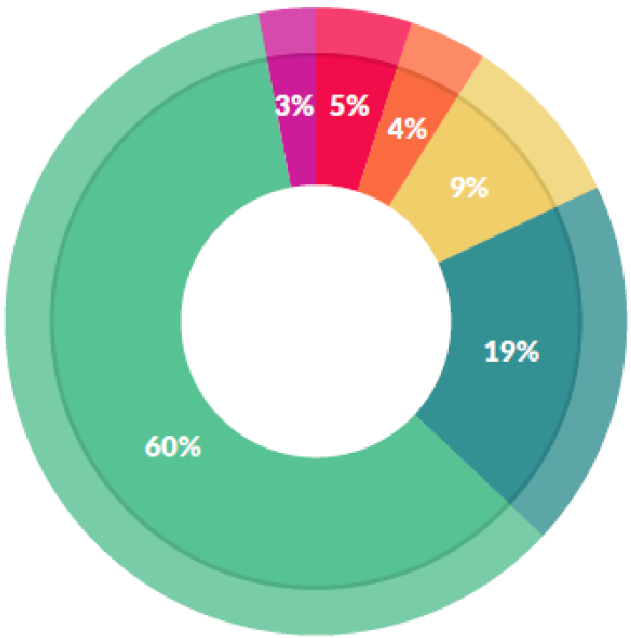
- **پرسش‌های اساسی که همواره باید مد نظر داشت:**
  - آیا نمونه فعلی واقعاً نماینده جامعه آماری آینده است؟
  - آیا پدیده تغییر توزیع داده‌ها در طول زمان (Data Drift / Concept Drift) رخ نداده است؟
  - آیا فرآیند گردآوری داده‌ها ناخواسته دچار سوگیری انتخاب (Selection Bias) نبوده است؟

جمع‌بندی: پیش‌پردازش داده‌ها

- **داده‌های خام دنیای واقعی همواره با چالش‌های عمده همراهند:**
  - مقادیر گمشده و ناتمام (Missing Values)
  - خطاها و داده‌های پرت (Errors & Outliers)
  - ابعاد بالا و نفرین ابعاد (High Dimensionality)
  - مقیاس‌های ناهمگون و انواع داده‌های پشتیبانی‌نشده

- **پیش‌پردازش خوب و علمی، پیش‌نیاز حیاتی موفقیت هر پروژه داده‌کاوی است.**
  - کیفیت مدل نهایی هرگز نمی‌تواند از کیفیت داده‌های ورودی فراتر رود!
  - قانون زرین داده‌کاوی: **Garbage In, Garbage Out**

آماده‌سازی داده‌ها



What data scientists spend the most time doing

- *Building training sets: 3%*
- *Cleaning and organizing data: 60%*
- *Collecting data sets; 19%*
- *Mining data for patterns: 9%*
- *Refining algorithms: 4%*
- *Other: 5%*

منبع: گزارش علم داده CrowdFlower 2016 – `http://visit.crowdflower.com/data-science-report.html`

یادآوری

Week	Wednesday (Offline Lecture)	Online Lecture	Thursday (Exercise)
10.02.2025	no lecture		Introduction to Python (13:45–15:15)
17.02.2025	Introduction to Data Mining		Intro
24.02.2025	Preprocessing		Preprocessing
03.03.2025	Classification 1	Nearest Centroids	Classification 1
10.03.2025	Classification 2	Comparing Classifiers	Classification 2
17.03.2025	Regression	Ensembles	Regression
24.03.2025	Clustering and Anomalies	Hierarchical Clustering	Clustering
31.03.2025	Feedback on project outlines	Time Series	Time Series

- **مطالب ارائه‌شده در کلاس‌های آنلاین:**
  - مرتبط با تمرین‌ها و آزمون پایان‌ترم هستند.

پرسش و پاسخ



آیا پرسشی دارید؟

بحث و تبادل نظر پیرامون مباحث
پیش‌پردازش

منابع و مراجع مطالعاتی برای این اسلایدها

- **پایتون (Python):**
  - جایگزینی مقادیر گمشده (Imputation):
    `https://scikit-learn.org/1.5/modules/impute.html`
  - پیش‌پردازش (Preprocessing):
    `https://scikit-learn.org/1.5/modules/preprocessing.html`
  - استخراج ویژگی از متن (Text feature extraction):
    `https://scikit-learn.org/1.5/modules/feature_extraction.html#text-feature-extraction`
  - انتخاب ویژگی (Feature Selection):
    `https://scikit-learn.org/1.5/modules/feature_selection.html`