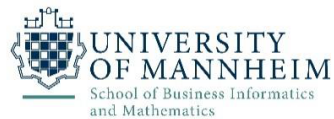
گروه علوم داده و وب

IE۵۰۰ داده‌کاوی

طبقه‌بندی داده‌ها – بخش دوم

Classification (Part 2)



دانشگاه مانهایم | نسخه 10.03.2025

سرفصل‌های آموزشی

Outline

- درختان تصمیم (Decision Trees) – [بررسی‌شده در بخش اول]
- بیش‌برازش (Overfitting) – [بررسی‌شده در بخش اول]
- معیارهای ارزیابی (Evaluation Metrics) – [بررسی‌شده در بخش اول]
- **طبقه‌بند بیز ساده (Naïve Bayes)**
- **ماشین‌های بردار پشتیبان (Support Vector Machines - SVM)**
- **شبکه‌های عصبی مصنوعی (Artificial Neural Networks - ANN)**
- **روش‌های ارزیابی مدل (Evaluation Methods)**
- **انتخاب و بهینه‌سازی فراپارامترها (Hyperparameter Selection)**

طبقه‌بند بیز ساده

Naïve Bayes Classifier

- یک روش طبقه‌بندی **احتمالاتی** مبتنی بر قضیه بیز (Bayes Theorem).
  - روشی کلاسیک و بسیار موفق در کاربردهای مختلف: پردازش زبان طبیعی (NLP)، سیستم‌های توصیه‌گر (Recommender Systems) و فیلتر هرزنامه.
- **هدف اصلی:** برآورد محتمل‌ترین برچسب کلاس برای یک نمونه یا رکورد ورودی داده‌شده.
- **فرمول‌بندی احتمالاتی مسئله طبقه‌بندی:**
  - در نظر گرفتن هر ویژگی A_i و برچسب کلاس C به عنوان متغیرهای تصادفی.
  - با داشتن بردار ویژگی‌های $(A_1, A_2, \ldots, A_n)$، هدف یافتن کلاسی مانند C است که احتمال شرطی زیر را بیشینه کند:

$$\arg\max_C P(C \mid A_1, A_2, \ldots, A_n)$$

- **مثال کاربردی:** آیا امروز گلف بازی کنیم یا خیر؟
  - $P(\text{Play} = \text{yes} \mid \text{Outlook} = \text{rainy}, \text{Temp} = \text{cool})$
  - $P(\text{Play} = \text{no} \mid \text{Outlook} = \text{rainy}, \text{Temp} = \text{cool})$

تاریخچه طبقه‌بند بیز

Thomas Bayes (1701–1761)

- **توماس بیز:** (Thomas Bayes)
  - ریاضی‌دان و کشیش بریتانیایی.
  - تلاش برای اثبات صوری و ریاضیاتی وجود خداوند با استفاده از محاسبات احتمالات.
- **قضیه بیز:** (Bayes Theorem)
  - یکی از مهم‌ترین و بنیادی‌ترین قضایای نظریه احتمالات و آمار کاربردی.
  - این نظریه برجسته تنها پس از درگذشت وی در سال ۱۷۶۳ توسط ریچارد پرایس منتشر گردید.



توماس بیز (۱۷۰۱–۱۷۶۱)

فرمول‌بندی قضیه بیز

Bayes Theorem Formulation

- **پرسش اساسی:** با مشاهده مجموعه ویژگی‌های A، احتمال تعلق به کلاس C چقدر است؟
  - این کمیت را **احتمال شرطی** یا احتمال پسین (Posterior Probability) می‌نامیم: $P(C \mid A)$.
- **سازوکار قضیه بیز:**
  - قضیه بیز احتمال شرطی $P(C \mid A)$ را با استفاده از احتمال معکوس آن $P(A \mid C)$ و احتمالات پایه‌ای $P(A)$ و $P(C)$ محاسبه می‌کند:

$$P(C \mid A) = \frac{P(A \mid C) \cdot P(C)}{P(A)}$$

- **کاربرد کلیدی:** زمانی که $P(C \mid A)$ مستقیماً در دسترس نیست، اما برآورد $P(A \mid C)$ (درست‌نمایی یا Likelihood) و $P(C)$ از داده‌های آموزشی بسیار آسان است.

احتمال پیشین در برابر احتمال پسین

Prior vs. Posterior Probability

- **احتمال پیشین** برای کلاس C (Prior Probability – $P(C)$):
  - احتمال وقوع کلاس C پیش از مشاهده ویژگی‌ها یا شواهد A.
  - به عنوان مثال، اگر در 70% تمام موارد گلف بازی کرده باشیم:

$$P(\text{Play} = \text{yes}) = 0.7$$

- **احتمال پسین** برای کلاس C (Posterior Probability – $P(C \mid A)$):
  - احتمال تعلق به کلاس C پس از مشاهده ویژگی‌های A (شواهد).
  - به عنوان مثال، اگر هوا بارانی و همراه با باد شدید باشد:

$$P(\text{Play} = \text{yes} \mid A) = 0.2$$

برآورد احتمال پیشین
Estimating the Prior Probability $P(C)$

- احتمال پیشین $P(C_j)$ به سادگی از طریق **فراوانی نسبی** هر کلاس در کل داده‌های آموزشی برآورد می‌شود:

$$P(C_j) = \frac{|D_{C_j}|}{|D|}$$

- در این رابطه:
  - $|D_{C_j}|$ برابر است با تعداد کل رکوردهای متعلق به کلاس C_j در مجموعه آموزش.
  - $|D|$ برابر است با تعداد کل رکوردهای آموزشی.

- **مثال بازی گلف** (مجموع داده‌های ۱۴ روز):
  - تعداد روزهای با پاسخ مثبت: ۹ روز $\implies P(\text{Play} = \text{yes}) = \frac{9}{14} \approx 0.643$
  - تعداد روزهای با پاسخ منفی: ۵ روز $\implies P(\text{Play} = \text{no}) = \frac{5}{14} \approx 0.357$

برآورد درست‌نمایی شرطی کلاس

Class-Conditional Probability $P(A \mid C)$

- **فرض بنیادین بیز «ساده»** (Conditional Independence Assumption):
  - فرض می‌شود تمام ویژگی‌های $A_1, A_2, \ldots, A_n$ به شرط داشتن کلاس C، **از یکدیگر از نظر آماری مستقل هستند.**

- بر این اساس، احتمال توأم به حاصل‌ضرب احتمالات شرطی تک‌تک ویژگی‌ها تبدیل می‌شود:

$$P(A \mid C_j) = P(A_1, A_2, \ldots, A_n \mid C_j) = \prod_{i=1}^{n} P(A_i \mid C_j)$$

- **مزیت بزرگ این فرض:**
  - به جای برآورد توزیع توأم چندمتغیره پیچیده، کافی است احتمال هر ویژگی منفرد را به تفکیک هر کلاس محاسبه کنیم:

$$P(A_i \mid C_j) = \frac{N_{i,j}}{|D_{C_j}|}$$

محاسبه احتمالات در مجموعه داده آب‌وهوا

Weather Dataset Frequency Tables

جدول داده‌های آموزش (۱۴ رکورد)

Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes
Rainy	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Sunny	Mild	High	False	No
Sunny	Cool	Normal	False	Yes
Rainy	Mild	Normal	False	Yes
Sunny	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Rainy	Mild	High	True	No

جداول فراوانی شرطی و احتمالات:

Attribute	Counts		Conditional Prob.	
	Yes	No	$P(A_i\|\text{Yes})$	$P(A_i\|\text{No})$
Outlook				
Sunny	2	3	$2/9$	$3/5$
Overcast	4	0	$4/9$	$0/5$
Rainy	3	2	$3/9$	$2/5$
Temperature				
Hot	2	2	$2/9$	$2/5$
Mild	4	2	$4/9$	$2/5$
Cool	3	1	$3/9$	$1/5$
Humidity				
High	3	4	$3/9$	$4/5$
Normal	6	1	$6/9$	$1/5$
Windy				
False	6	2	$6/9$	$2/5$
True	3	3	$3/9$	$3/5$

طبقه‌بندی یک رکورد جدید
Classifying an Unseen Record

- فرض کنید رکورد جدیدی با مشخصات زیر وارد سیستم شده است:

Outlook	Temp.	Humidity	Windy	Play
Sunny	Cool	High	True	**?**

- **محاسبه احتمال پسین برای کلاس Play = Yes به صورت زیر است:**

$$P(\text{yes} \mid A) = \frac{P(\text{Sunny}|\text{yes}) \cdot P(\text{Cool}|\text{yes}) \cdot P(\text{High}|\text{yes}) \cdot P(\text{True}|\text{yes}) \cdot P(\text{yes})}{P(A)}$$

$$P(\text{yes} \mid A) = \frac{\frac{2}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{9}{14}}{P(A)}$$

- مخرج کسر ($P(A)$) برای هر دو کلاس یکسان است و به عنوان ضریب نرمال‌سازی عمل می‌کند.

محاسبه درست‌نمایی و نرمال‌سازی

انتخاب کلاس برنده

- **درست‌نمایی کلاس‌های دوگانه (Likelihood)**

$$\text{Likelihood(yes)} = \frac{2}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{9}{14} = 0.0053$$

$$\text{Likelihood(no)} = \frac{3}{5} \times \frac{1}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{5}{14} = 0.0206$$

- **تبدیل به احتمالات استاندارد با نرمال‌سازی (Normalization)**

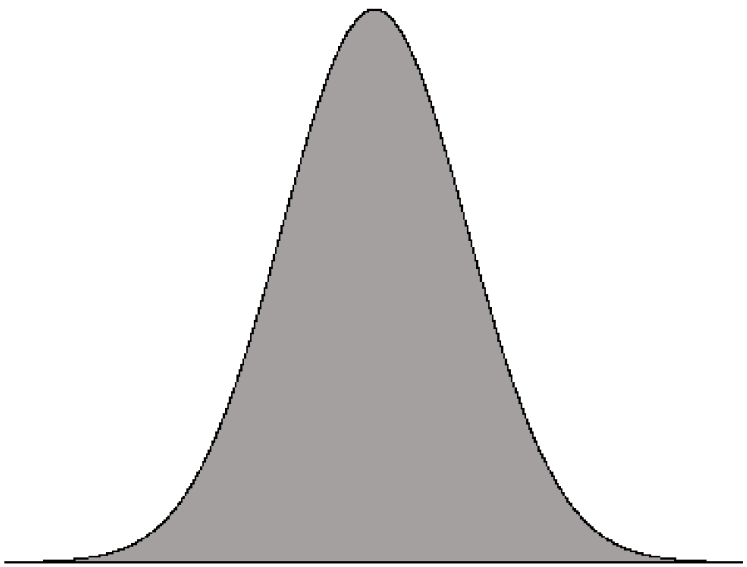
$$P(\text{yes}) = \frac{0.0053}{0.0053 + 0.0206} = 0.205 \quad (20.5\%)$$

$$P(\text{no}) = \frac{0.0206}{0.0053 + 0.0206} = 0.795 \quad (79.5\%)$$

- **تصمیم نهایی:** از آنجا که $P(\text{no}) > P(\text{yes})$، برچسب پیش‌بینی‌شده برای این روز **Play = No** خواهد بود.

مدیریت ویژگی‌های عددی و پیوسته

Handling Numerical Attributes



منحنی چگالی توزیع نرمال گوسی

- **رویکرد اول: گسسته‌سازی (Discretization)**
  - تبدیل مقادیر پیوسته به بازه‌ها پیش از یادگیری طبقه‌بند.
  - به عنوان مثال: $\text{Temp} = 37^\circ\text{C} \rightarrow$ "Hot" و $\text{Temp} = 21^\circ\text{C} \rightarrow$ "Mild".
- **رویکرد دوم: فرض توزیع نرمال گوسی**
  - فرض می‌شود ویژگی عددی به شرط کلاس از **توزیع نرمال** پیروی می‌کند.
  - برآورد میانگین (μ) و انحراف معیار (σ) از روی نمونه‌های آموزشی هر کلاس.
  - محاسبه $P(A_i \mid C_j)$ با تابع چگالی احتمال (PDF).

تابع چگالی احتمال توزیع نرمال

Gaussian Probability Density Function

- تابع چگالی احتمال (PDF) برای متغیر پیوسته x با توزیع نرمال:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- پارامترهای توزیع که از داده‌های آموزشی برآورد می‌شوند:
  - **میانگین نمونه** (μ):

$$\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

  - **انحراف معیار نمونه** (σ):

$$\sigma = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i-\mu)^2}$$

  - هر دو پارامتر به طور مستقیم از روی داده‌های آموزش برآورد می‌گردند.

محاسبه پارامترهای گوسی در داده‌های آب‌وهوا

برآورد μ و σ برای دما و رطوبت

- محاسبه میانگین و انحراف معیار برای ویژگی‌های عددی به تفکیک کلاس:

Attribute	μ(Yes)	σ(Yes)	μ(No)	σ(No)
Temperature	73.0	6.2	74.6	7.9
Humidity	79.1	10.2	86.2	9.7

- **نمونه محاسبه چگالی احتمال شرطی** برای دمای ۶۶ درجه در کلاس Yes به صورت زیر است:

$$f(\text{Temp} = 66 \mid \text{yes}) = \frac{1}{\sqrt{2\pi} \cdot 6.2} \exp\left(-\frac{(66-73)^2}{2 \cdot (6.2)^2}\right) \approx 0.0340$$

- مقدار چگالی به عنوان جانشین احتمال شرطی در فرمول بیز قرار می‌گیرد.

طبقه‌بندی روز جدید با ویژگی‌های پیوسته

اعمال توابع چگالی گوسی

- رکورد جدید با ویژگی‌های اسمی و عددی:

Outlook	Temp.	Humidity	Windy	Play
Sunny	66	90	True	?

- **محاسبه درست‌نمایی با استفاده از چگالی‌های گوسی:**

$$\text{Likelihood(yes)} = \frac{2}{9} \times 0.0340 \times 0.0221 \times \frac{3}{9} \times \frac{9}{14} = 0.000036$$

$$\text{Likelihood(no)} = \frac{3}{5} \times 0.0291 \times 0.0380 \times \frac{3}{5} \times \frac{5}{14} = 0.000136$$

- **احتمالات پسین پس از نرمال‌سازی:**

$$P(\text{yes}) = \frac{0.000036}{0.000036 + 0.000136} \approx 20.9\%, \quad P(\text{no}) \approx 79.1\%$$

- **نکته کلیدی:** در صورت غیرنرمال بودن داده‌ها، باید از توزیع دیگری استفاده کرد یا داده را گسسته‌سازی نمود.

مدیریت داده‌های مفقوده

Handling Missing Values in Naïve Bayes

- مقادیر مفقوده ممکن است در نمونه‌های آموزش یا نمونه‌های آزمون رخ دهند:
  - **در زمان آموزش** (Training): نمونه مفقود در شمارش فراوانی آن ویژگی لحاظ نمی‌شود، اما برای سایر ویژگی‌های موجود استفاده می‌گردد.
  - **در زمان طبقه‌بندی** (Classification): ویژگی مفقود از ضرب احتمالات شرطی کنار گذاشته می‌شود.
- **مثال: رکورد آزمون با ویژگی دمای نامشخص (Temp = ?)**

$$\text{Likelihood(yes)} = \frac{3}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{9}{14} = 0.0238$$

$$\text{Likelihood(no)} = \frac{1}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{5}{14} = 0.0343$$

- احتمالات پسین نرمال‌شده: $P(\text{yes}) = 41\%$ و $P(\text{no}) = 59\%$.

مسئله بسامد صفر و هموارسازی لاپلاس

Zero-Frequency Problem & Laplace Estimator

- **صورت مسئله:** اگر یک مقدار ویژگی در یک کلاس هرگز رخ نداده باشد:
  - مثلاً در داده‌های آموزش: $P(\text{Outlook} = \text{Overcast} \mid \text{no}) = \frac{0}{5} = 0$.
  - در نتیجه، کل حاصل‌ضرب درست‌نمایی صفر خواهد شد: $P(\text{no} \mid A) = 0$.
- **راه‌حل: برآوردگر لاپلاس (Laplace Estimator)**
  - افزودن مقدار ثابت ۱ به صورت و مقدار c (تعداد حالات ممکن ویژگی A) به مخرج کسر:

برآورد احتمال استاندارد:

$$P(A_i \mid C) = \frac{N_{ic}}{N_c}$$

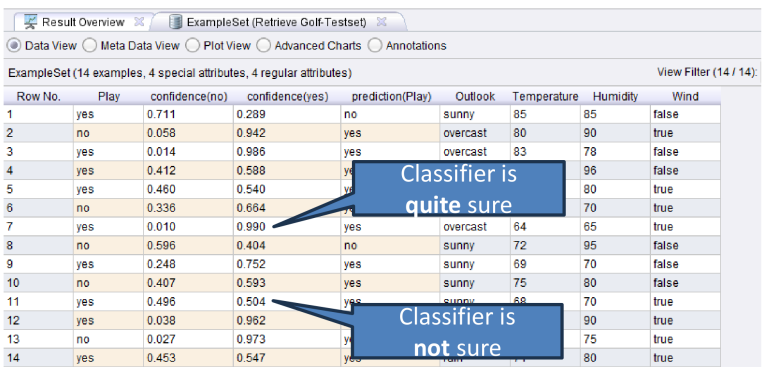
برآوردگر هموارسازی لاپلاس:

$$P(A_i \mid C) = \frac{N_{ic} + 1}{N_c + c}$$

- **مزیت:** احتمال هیچ حالتی دقیقاً صفر نمی‌شود و تخمین پایدار می‌گردد.

اطمینان مدل و پیاده‌سازی پایتون

Confidence & Scikit-learn Implementation



Row No.	Play	confidence(no)	confidence(yes)	prediction(Play)	Outlook	Temperature	Humidity	Wind
1	yes	0.711	0.289	no	sunny	85	85	false
2	no	0.058	0.942	yes	overcast	80	90	true
3	yes	0.014	0.986	yes	overcast	83	78	false
4	yes	0.412	0.588	yes			96	false
5	yes	0.460	0.540	yes			80	true
6	no	0.336	0.664	yes			70	true
7	yes	0.010	0.990	yes	overcast	64	65	true
8	no	0.596	0.404	no	sunny	72	95	false
9	yes	0.248	0.752	yes	sunny	69	70	false
10	no	0.407	0.593	yes	sunny	75	80	false
11	yes	0.496	0.504	yes	sunny	68	70	true
12	yes	0.038	0.962	yes			90	true
13	no	0.027	0.973	yes			75	true
14	yes	0.453	0.547	yes	rain	71	80	true

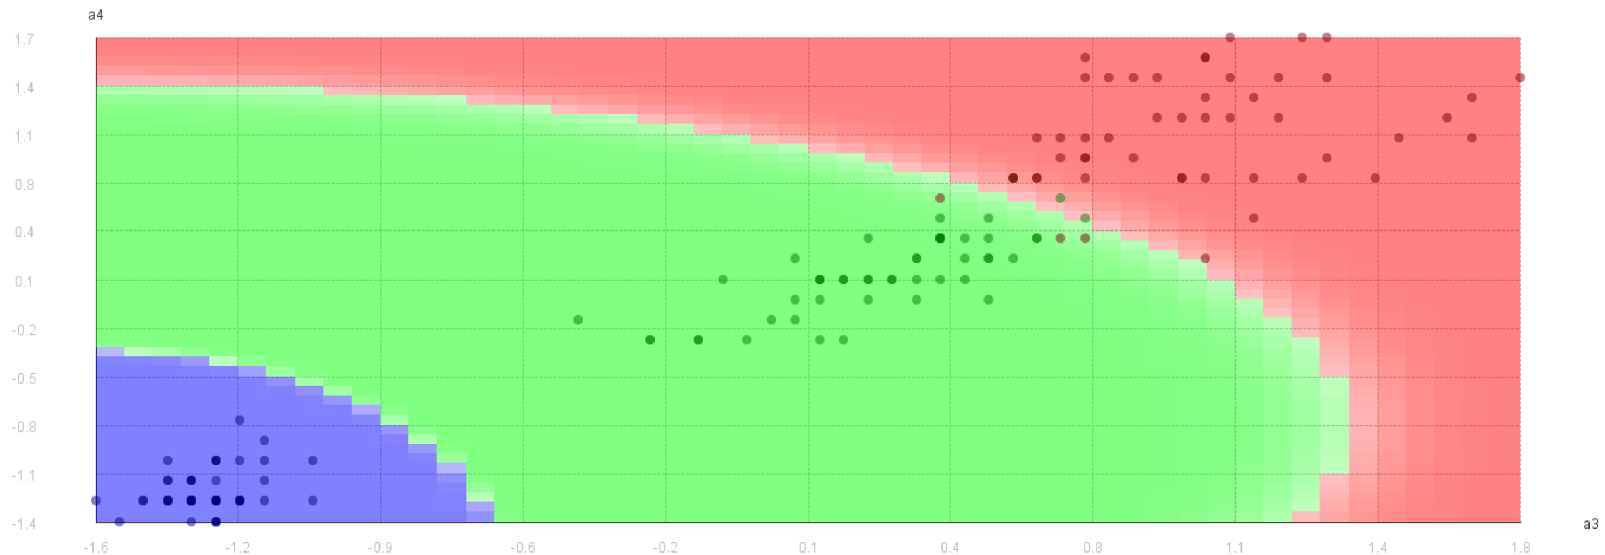
```
# Import Naive Bayes classifiers from scikit-learn
from sklearn.naive_bayes import MultinomialNB, GaussianNB

# Train classifier with Laplace smoothing (alpha=1.0)
estimator = MultinomialNB(alpha=1.0)
estimator.fit(preprocessed_training_data, training_labels)
```

مرزهای تصمیم طبقه‌بند بیز ساده

Decision Boundary of Naive Bayes Classifier

- نواحی منسجم و معمولاً بزرگ‌تر
- حاشیه‌ها و مرزهای نرم با نواحی عدم قطعیت
- شکل‌های دلخواه (اغلب به صورت منحنی)



تحلیل و جمع‌بندی بیز ساده

Naïve Bayes: Strengths & Limitations

- **کارایی شگفت‌انگیز در عمل:** حتی با نقض آشکار فرض استقلال ویژگی‌ها، اغلب عملکرد عالی ارائه می‌دهد زیرا فقط رتبه نسبی درست‌نمایی برای تصمیم‌گیری مهم است.
- **مقاومت در برابر نویز** (Noise Robustness): داده‌های پرت ایزوله اثر ناچیزی بر میانگین‌ها و توزیع کلی دارند.
- **مقاومت در برابر ویژگی‌های بی‌ارتباط** (Irrelevant Attributes): زیرا این ویژگی‌ها توزیعی تقریباً یکنواخت برای تمامی کلاس‌ها خواهند داشت.
- **حساسیت به ویژگی‌های تکراری** (Redundant Attributes): تکرار متغیرهای همبسته اثر یک ویژگی را مضاعف می‌کند (نیاز به انتخاب ویژگی).
- **مزایای فنی و محاسباتی بالا:**
  - **زمان آموزش:** تنها با یک‌بار پیمایش داده‌ها ($O(Nd)$).
  - **حافظه مصرفی:** بسیار اندک جهت ذخیره‌سازی ماتریس احتمالات.

ماشین‌های بردار پشتیبان

Support Vector Machines - SVM

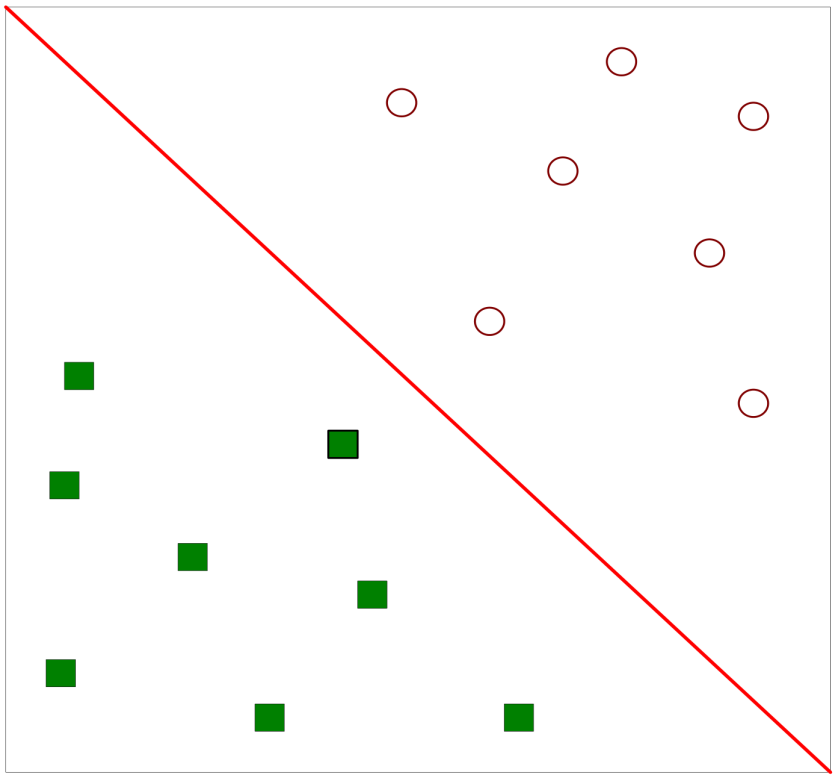
- ماشین‌های بردار پشتیبان (SVM) الگوریتم‌هایی قدرتمند برای یادگیری **طبقه‌بندهای خطی** هستند:
  - مسائل دوکلاسه (یک کلاس مثبت و یک کلاس منفی).
  - آموزش بر روی نمونه‌های با ویژگی‌های پیوسته (Continuous Attributes).

- **ویژگی‌های کلیدی SVM:**
  - کارایی بسیار بالا به‌ویژه در داده‌های با ابعاد بالا (High-dimensional Data).
  - ابداع توسط ولادیمیر واپنیک (V. Vapnik) و همکاران در دهه ۱۹۷۰ و گسترش در سال ۱۹۹۲.

ابرصفحه خطی جداکننده

مفهوم مرز تصمیم در SVM

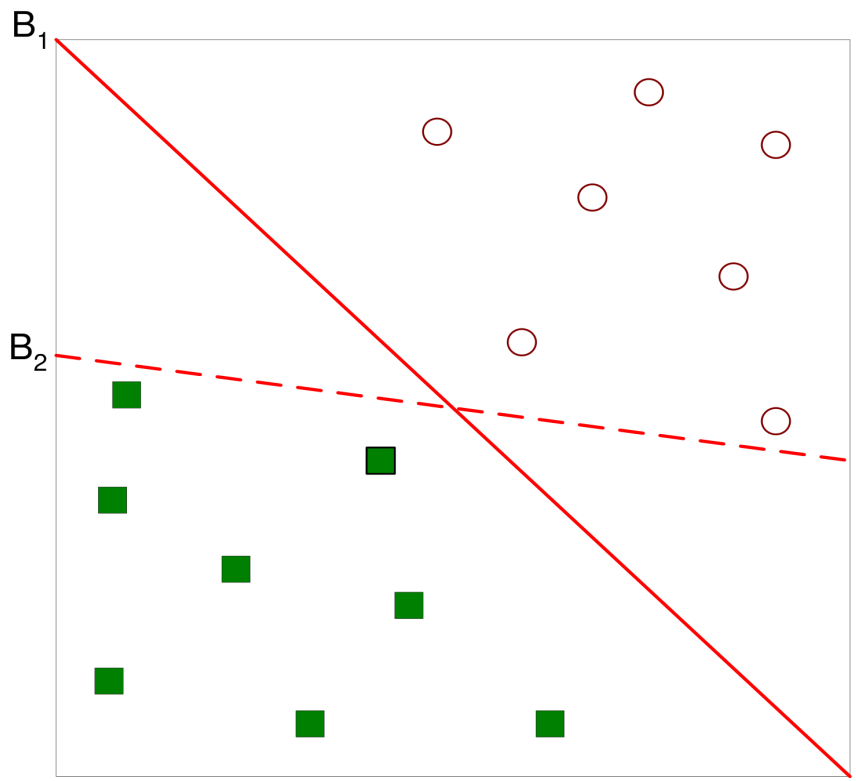
- هدف: یافتن یک **ابرصفحه خطی** (Linear Hyperplane) که نمونه‌های دو کلاس را به درستی از یکدیگر تفکیک کند.



کدام ابرصفحه برتر است؟

Which Hyperplane is better?

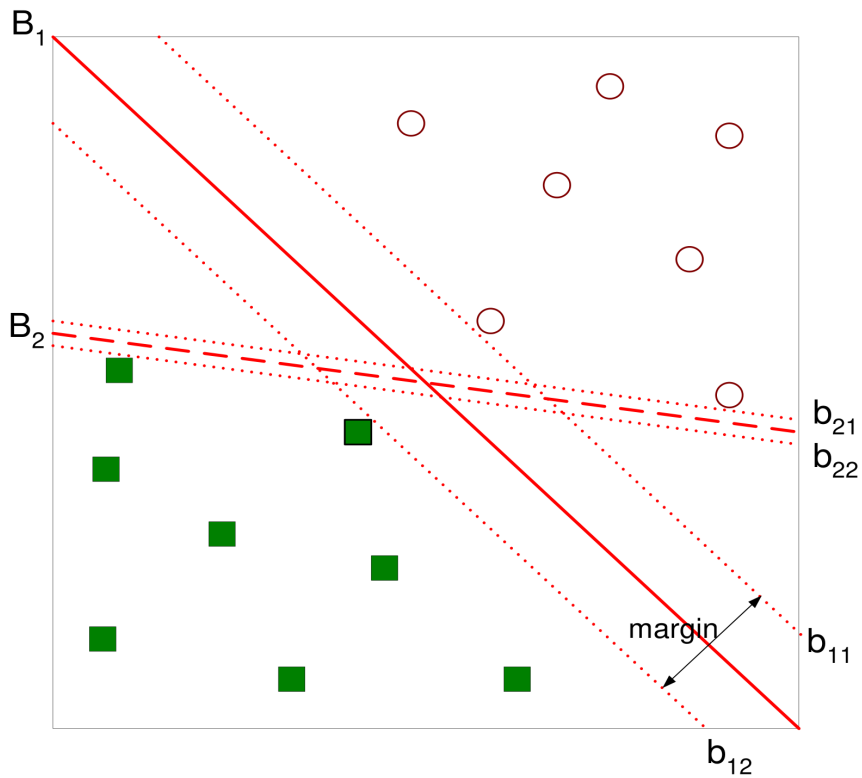
- کدام ابرصفحه بهتر است؟ B_1 یا B_2؟ مفهوم «بهتر» چگونه تعریف می‌شود؟



کدام ابرصفحه برتر است؟

بیشینه‌سازی حاشیه (Maximal Margin)

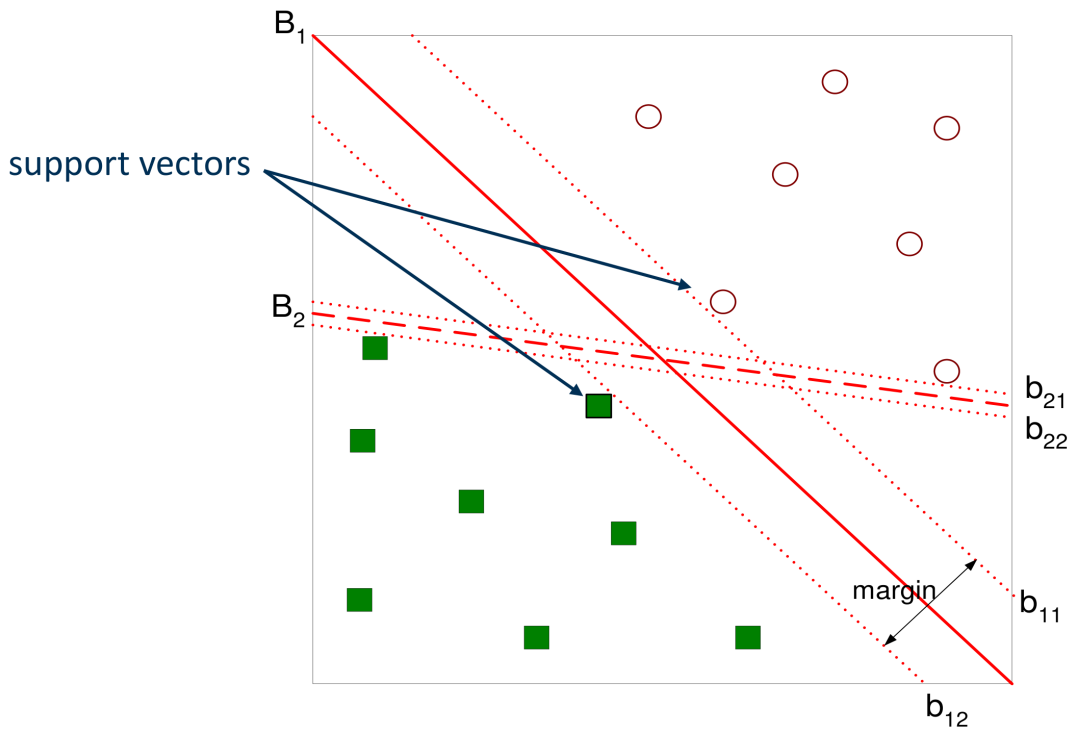
- ابرصفحه‌ای را بیابید که **حاشیه (Margin)** تا نزدیک‌ترین نقاط را بیشینه کند تا از بیش‌برازش جلوگیری شود $\Longrightarrow$ ابرصفحه B_1 از B_2 برتر است.



کدام ابرصفحه برتر است؟

نقش بردارهای پشتیبان (Support Vectors)

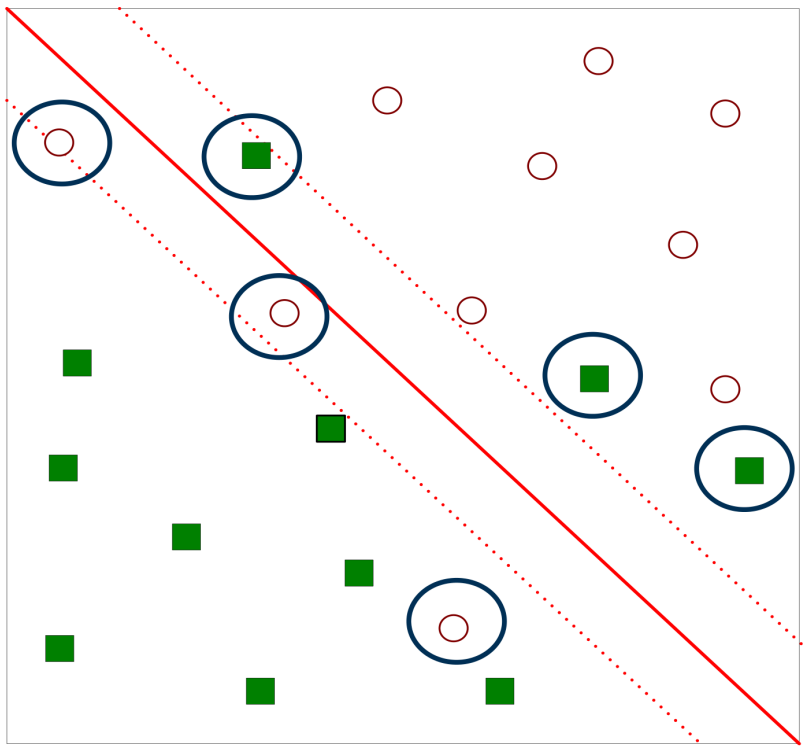
- **بردارهای پشتیبان** (Support Vectors): نزدیک‌ترین نقاط آموزشی به ابرصفحه تصمیم هستند که موقعیت و جهت مرز تصمیم را به طور کامل تعیین می‌کنند.



داده‌های تفکیک‌ناپذیر خطی

متغیرهای کمکی (Slack Variables) و حاشیه نرم

- در صورت هم‌پوشانی داده‌ها یا وجود نویز، تفکیک خطی محض ممکن نیست.
- **راه‌حل:** معرفی **متغیرهای کمکی** (ξ_i) در رابطه بهینه‌سازی که برای هر نمونه ناقض مرز جریمه تعیین می‌کند.

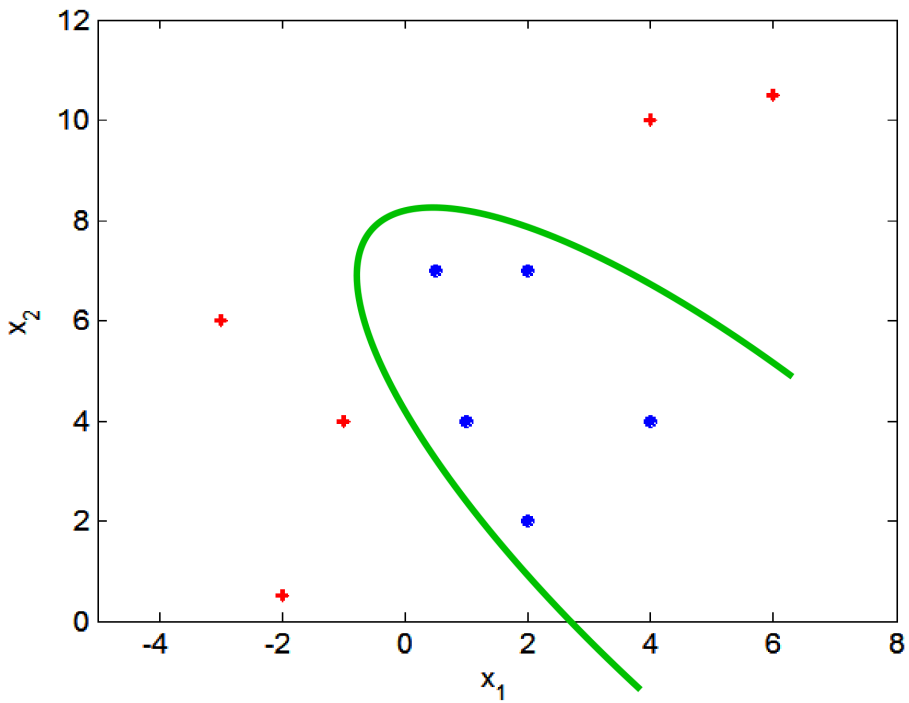


ماشین‌های بردار پشتیبان غیرخطی

چالش مرزهای غیرخطی

- چه رخ می‌دهد اگر مرز تصمیم در فضای ویژگی‌ها ذاتاً غیرخطی باشد؟

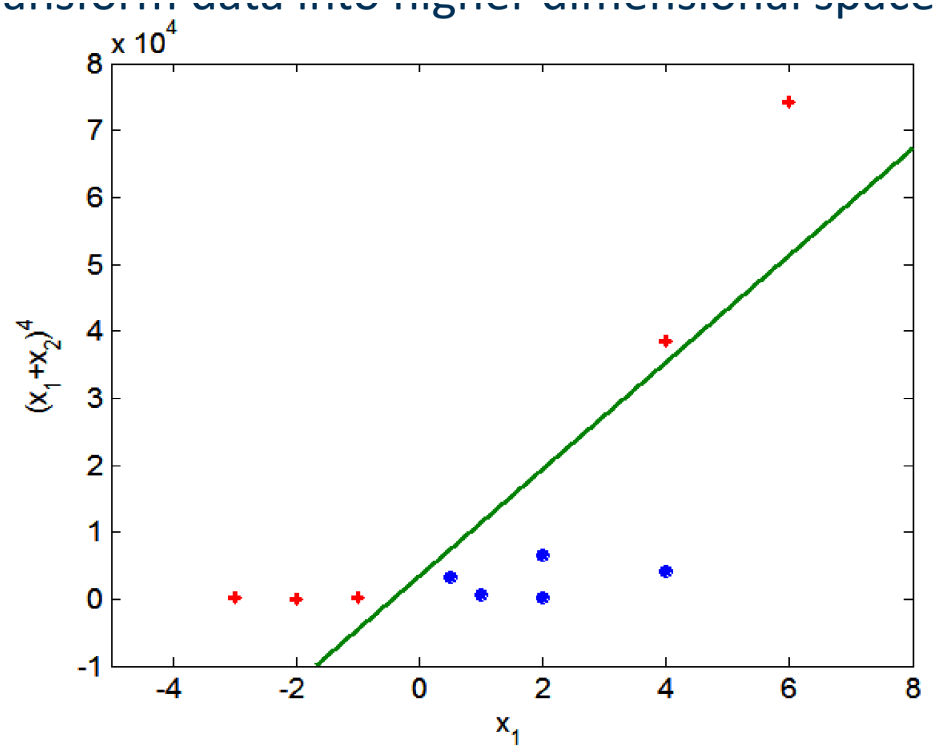
What if decision boundary is not linear?



نگاشت به فضای با ابعاد بالاتر

Feature Space Transformation

- نگاشت داده‌های غیرقابل تفکیک خطی در فضای اولیه به یک فضای ابعاد بالاتر با تابع $\Phi(x)$ که در آن داده‌ها به صورت خطی جداپذیر می‌گردند.



ترفند کرنل و پیاده‌سازی پایتون

The Kernel Trick & Scikit-learn

- نگاشت صریح به فضای ابعاد بالا از نظر محاسباتی بسیار سنگین است.
- **ترفند کرنل** (Kernel Trick): محاسبات ضرب داخلی مستقیماً در همان فضای ابعاد پایین با تابع کرنل انجام می‌شود ($K(x, z) = \langle \Phi(x), \Phi(z) \rangle$).
  - انواع توابع کرنل رایج: چندجمله‌ای (Polynomial)، پایه شعاعی گاوسی (RBF).
- **پیاده‌سازی در پایتون** (scikit-learn):

```
# Import Support Vector Classifier
from sklearn.svm import SVC

# Train SVM classifier with RBF kernel and penalty C=1.0
estimator = SVC(C=1.0, kernel='rbf')
estimator.fit(scaled_training_data, training_labels)
```

تنظیم سیستماتیک فراپارامترهای الگوریتم SVM

Systematic SVM Parameter Tuning

- به جای آزمون تصادفی چند کرنل و پارامتر، هسو و همکاران روشی سیستماتیک پیشنهاد می‌دهند:
  ۱. **مقیاس‌بندی خطی** تمام ویژگی‌ها در بازه $[-1, +1]$ یا $[0, 1]$.
  ۲. استفاده از **کرنل پایه شعاعی** (RBF Kernel).
  ۳. **اعتبارسنجی متقاطع** برای یافتن بهترین مقادیر C و γ در دنباله‌های با رشد نمایی:

$$C \in \{2^{-5}, 2^{-3}, \ldots, 2^{15}\}, \quad \gamma \in \{2^{-15}, 2^{-13}, \ldots, 2^{3}\}$$

  ۴. آموزش مدل نهایی روی کل داده‌های آموزش با بهترین مقادیر C و γ.
  ۵. **ارزیابی نهایی** روی مجموعه آزمون (Test).

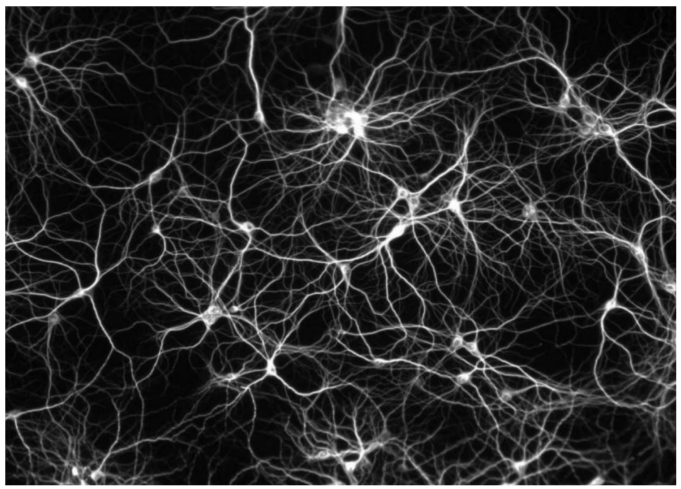
Chih-Wei Hsu, Chih-Chung Chang, and Chih-Jen Lin: A Practical Guide to Support Vector Classification

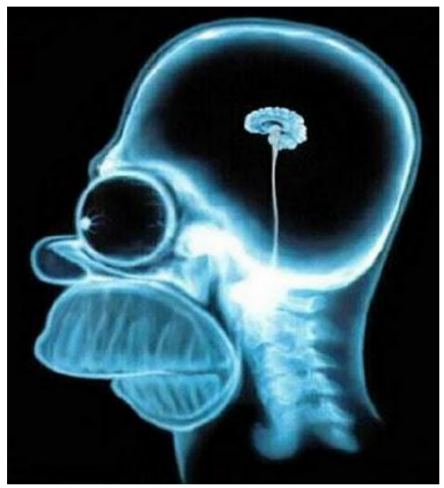
شبکه‌های عصبی مصنوعی

Artificial Neural Networks - ANN

- **الهام‌گیری زیستی:**
  - الهام گرفته از ساختار مغز انسان؛ یکی از قدرتمندترین سامانه‌های پردازش موازی و یادگیری جهان.
  - شبکه‌ای متشکل از میلیاردها نورون به‌هم‌پیوسته که از طریق سیناپس‌ها سیگنال‌های الکتریکی و شیمیایی را مبادله می‌کنند.

  - one of the most powerful super computers in the world



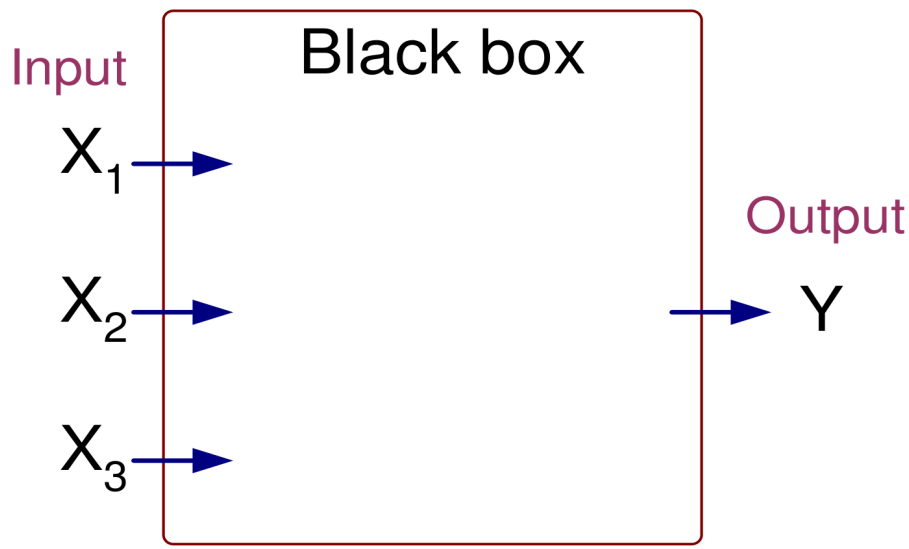


برازش تابع بر داده‌های آموزش

مفهوم پرسپترون اولیه

- تابع مطلوب: خروجی Y برابر با 1 است اگر و تنها اگر **حداقل دو ورودی از سه ورودی** برابر با 1 باشند.

X_1	X_2	X_3	Y
1	0	0	0
1	0	1	1
1	1	0	1
1	1	1	1
0	0	1	0
0	1	0	0
0	1	1	1
0	0	0	0



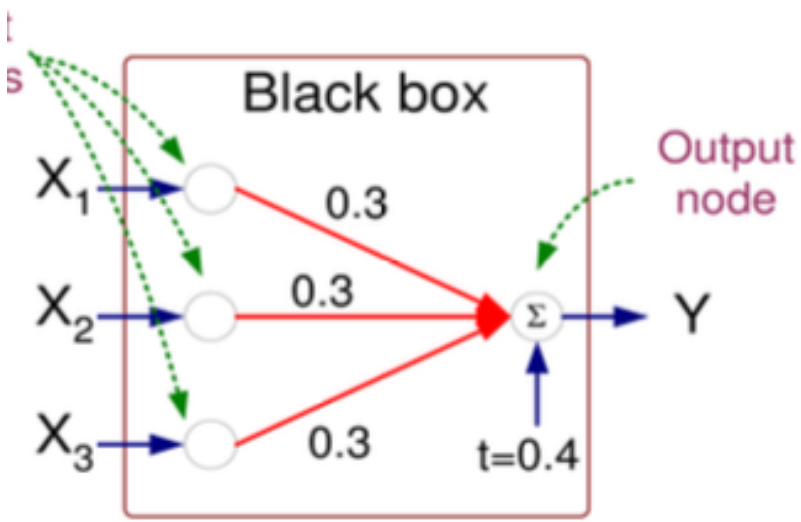
وزن‌دهی و آستانه تصمیم در پرسپترون

مدل‌سازی ریاضی نورون

- با تنظیم وزن‌های $w_i = 0.3$ و حد آستانه $t = 0.4$، معادله تصمیم به صورت زیر است:

$$Y = I(0.3X_1 + 0.3X_2 + 0.3X_3 - 0.4 > 0)$$

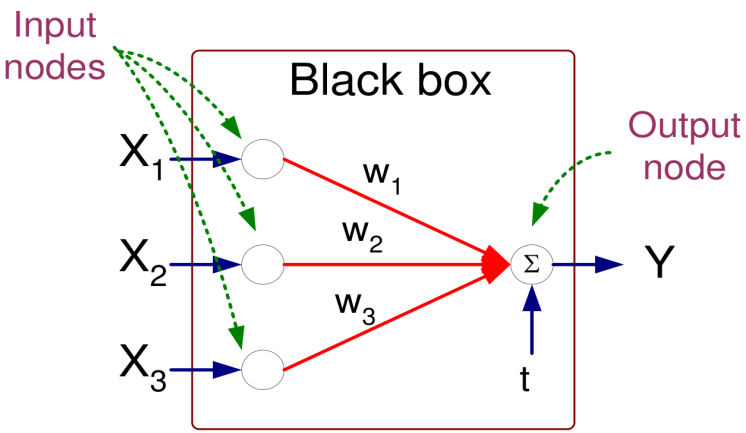
که در آن $I(z) = 1$ اگر شرط z برقرار باشد، و در غیر این صورت 0 است.



شبکه‌های عصبی مصنوعی

مدل پرسپترون (Perceptron Model)

- مدلی متشکل از گره‌های به‌هم‌پیوسته (نورون‌ها) و اتصالات وزن‌دار.
- گره خروجی، مجموع وزن‌دار مقادیر ورودی را طبق وزن یال‌ها محاسبه می‌نماید.
- **تصمیم طبقه‌بندی:** مقایسه گره خروجی با مقدار آستانه t:

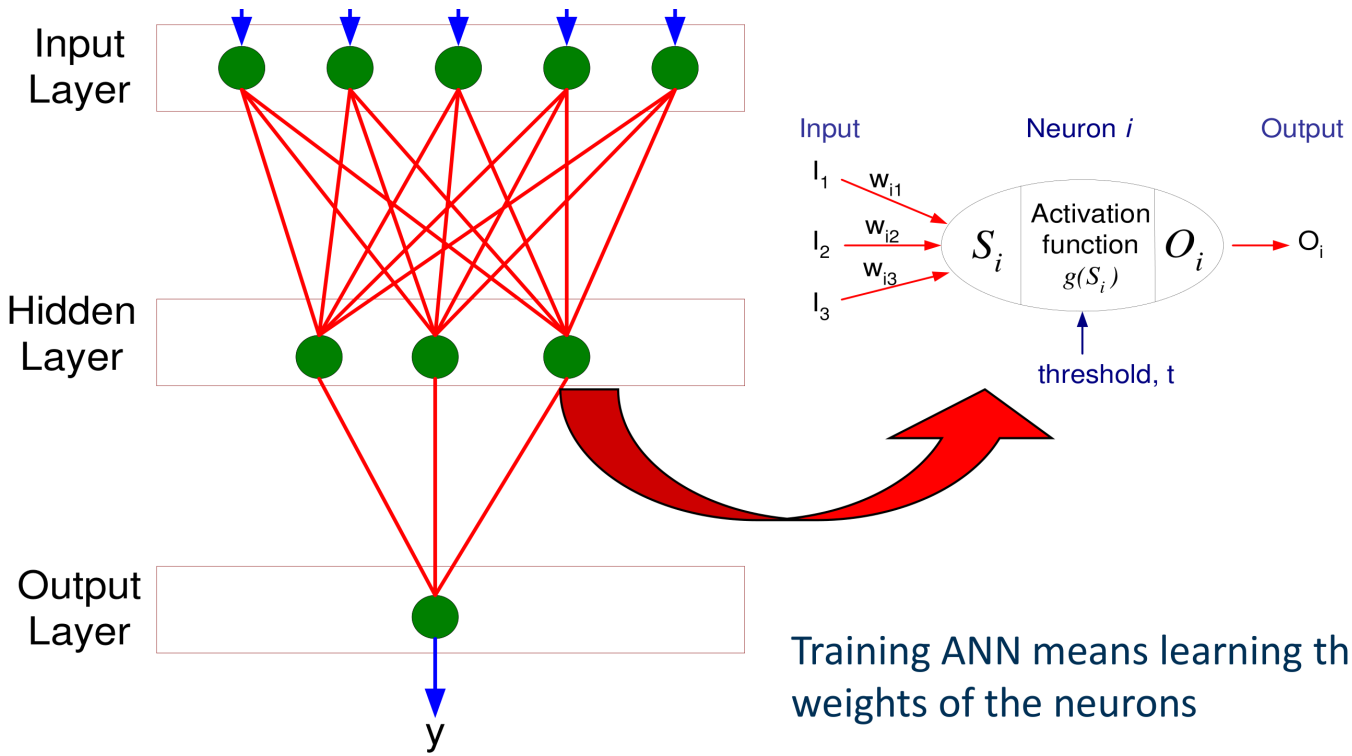


$$Y = I\left(\sum_{i=1}^{k} w_i X_i - t > 0\right)$$

شبکه‌های عصبی چندلایه

Multi-Layer Artificial Neural Networks (MLP)

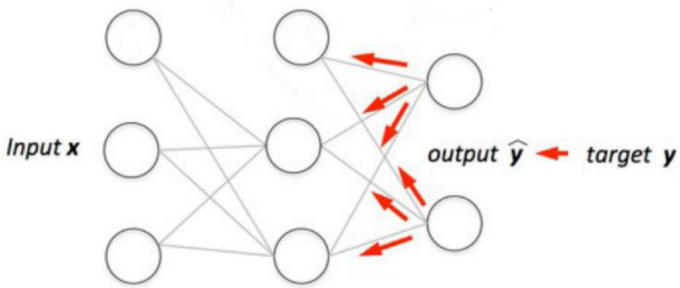
- معماری شامل لایه ورودی (Input)، لایه‌های پنهان (Hidden Layers) و لایه خروجی (Output).
- **یادگیری در شبکه عصبی:** بهینه‌سازی و تنظیم وزن‌های اتصالات میان نورون‌ها است.



Training ANN means learning the weights of the neurons

الگوریتم آموزش شبکه‌های عصبی

Backpropagation Algorithm




```
from sklearn.neural_network
  import MLPClassifier
clf = MLPClassifier(
  hidden_layer_sizes=(100,),
  learning_rate_init=0.1)
clf.fit(X_train, y_train)
```

۱. **مقداردهی اولیه وزن‌ها** $(w_0, w_1, \ldots, w_k)$ به صورت تصادفی یا با مقادیر از پیش آموزش‌دیده.

۲. **تنظیم بازگشتی وزن‌ها** برای بیشترین تطابق با برچسب‌های واقعی آموزش:

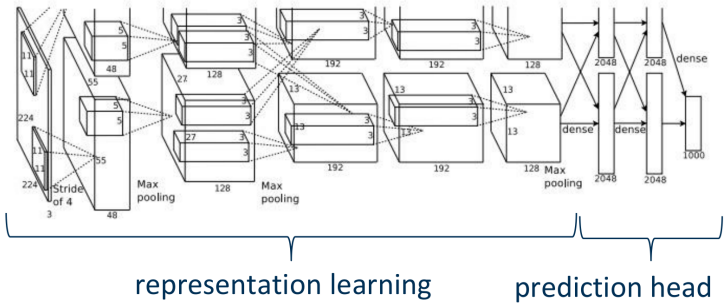
- **تابع هدف:** کمینه‌سازی خطای مجموع مربعات (SSE) به صورت $E = \sum_i [Y_i - f(w_i, X_i)]^2$
- استفاده از الگوریتم **پس‌انتشار خطا** (Backpropagation) بر پایه گرادیان کاهشی.
- کنترل سرعت همگرایی با **نرخ یادگیری** (Learning Rate).

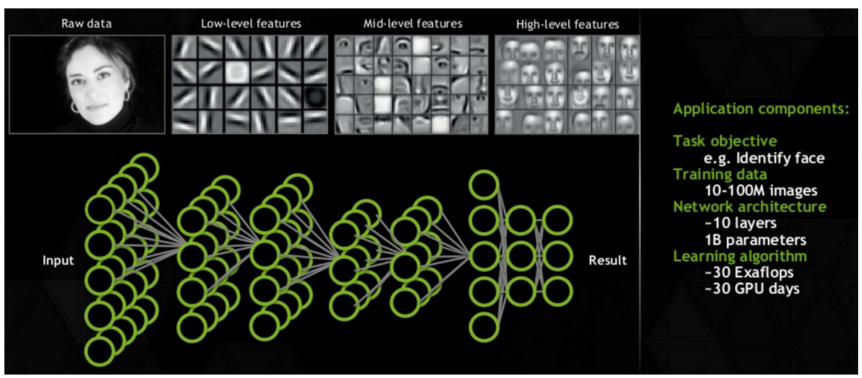
مروری بر مدل‌های یادگیری عمیق

Overview: Deep Learning Architectures

- **شبکه‌های عصبی پیچشی** (CNNs): مدل‌های استاندارد در بینایی ماشین و پردازش تصویر.
- **مدل‌های زبانی از پیش آموزش‌دیده** (Pre-trained Models): نظیر BERT بر پایه ترنسفورمرها.
- **مدل‌های زایشی** (Generative Models): مدل‌های تولید متن و تصویر نظیر GPT-3، T5 و DALL-E.
- **مدل‌های زبانی دستورپذیر** (Instruct Models): سامانه‌های هوشمند تعاملی نظیر ChatGPT مبتنی بر RLHF.

شبکه‌های عصبی پیچشی
Convolutional Neural Networks (CNNs)





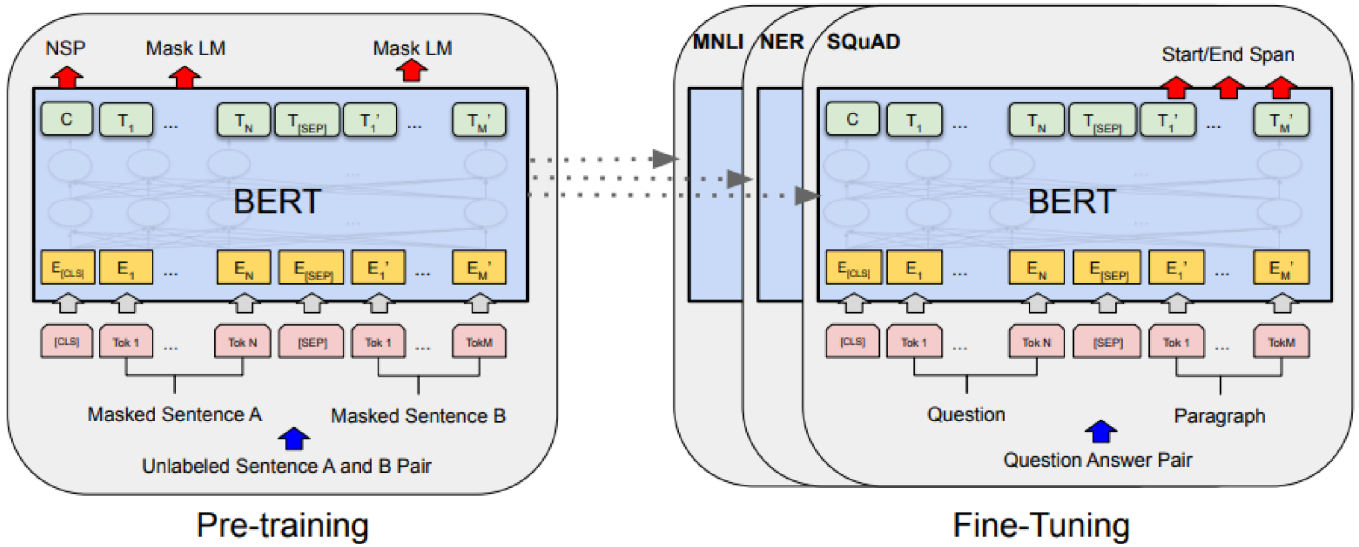
- ابداع‌شده در حوزه بینایی ماشین (Computer Vision).
- **ترکیب دو مؤلفه کلیدی:**
  ۱. **یادگیری بازنمایی:** لایه‌های پیچش (Conv) و ادغام (Pooling).
  ۲. **سر پیش‌بینی** (Prediction Head): لایه‌های کاملاً متصل (Dense).
- کاهش تعداد متغیرها با لایه‌های پیچش و ادغام.
- **ظرفیت بالای مدل نیازمند:**
  - حجم بالای داده‌های آموزش
  - منابع سخت‌افزاری و زمان پردازش GPU زیاد

مدل‌های زبانی از پیش‌آموزش‌دیده

Pre-Trained Language Models (BERT)

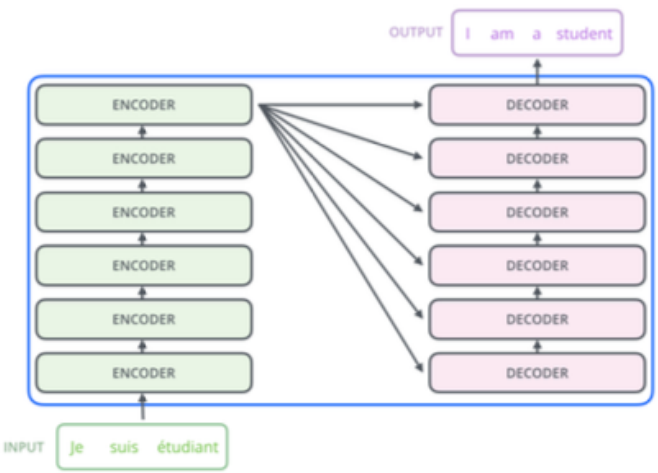
- معرفی پارادایم نوین **پیش‌آموزش و سپس تنظیم دقیق** (Pre-training & Fine-tuning):
  - پیش‌آموزش بر روی پیکره‌های متنی عظیم بدون نظارت انسانی.
  - مدل BERT-base با ۱۱۰ میلیون پارامتر و یادگیری بازنمایی دوجهته.
- برتری قاطع بر تمامی روش‌های سنتی در اکثر آزمون‌های پردازش زبان طبیعی.

- Outperform previous models on most NLP tasks



مدل‌های زایشی

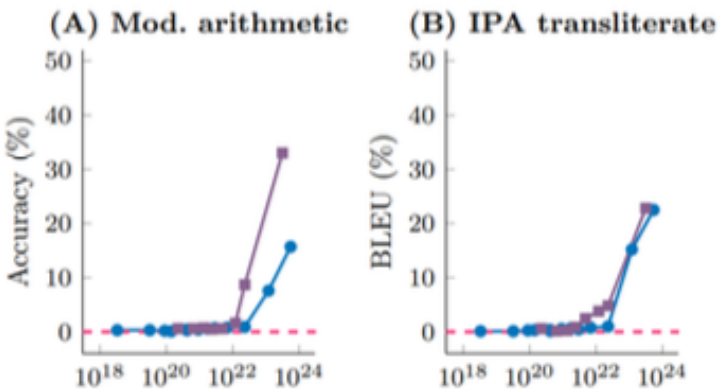
Generative Models (Transformers, GPT, DALL-E)



- استفاده از معماری ترنسفورمر برای تولید متن یا تصویر بر پایه تعبیه توالی‌ها.
- **مدل‌های متنی:** GPT-3 و T5.
- **مدل‌های تصویری:** DALL-E و Stable Diffusion.
- پیش‌آموزش روی داده‌های عظیم (Web crawls، ImageNet).
- مقیاس مدل‌ها: ۵ تا ۱۷۵ میلیارد پارامتر (دسترسی عمدتاً از طریق API).

مدل‌های زبانی دستورپذیر

Instruct Language Models & RLHF



- پس از پیش‌آموزش روی متون عظیم، مدل‌های دستورپذیر با جفت‌های «دستور/پاسخ» تنظیم دقیق می‌شوند.
- عملکرد چندنمونه‌ای (Few-shot) در گستره وسیعی از وظایف (BIG-bench).
- **ظهور توانمندی‌های نوپدید:**
  - مدل‌ها وظایفی را انجام می‌دهند که مستقیماً برای آن‌ها آموزش ندیده‌اند (Emergent Abilities).
- طراحی اعلان (Prompt Design) و یادگیری درون‌متنی عملکرد را تعیین می‌کنند.

ارزیابی مدل‌های طبقه‌بندی

Model Evaluation: Generalization Performance

- **پرسش بنیادین در ارزیابی مدل:**
  - یک مدل تا چه اندازه در طبقه‌بندی رکوردهای جدید و نادیده (Unseen Records) موفق عمل می‌کند؟ (**کارایی تعمیم** یا Generalization Performance).

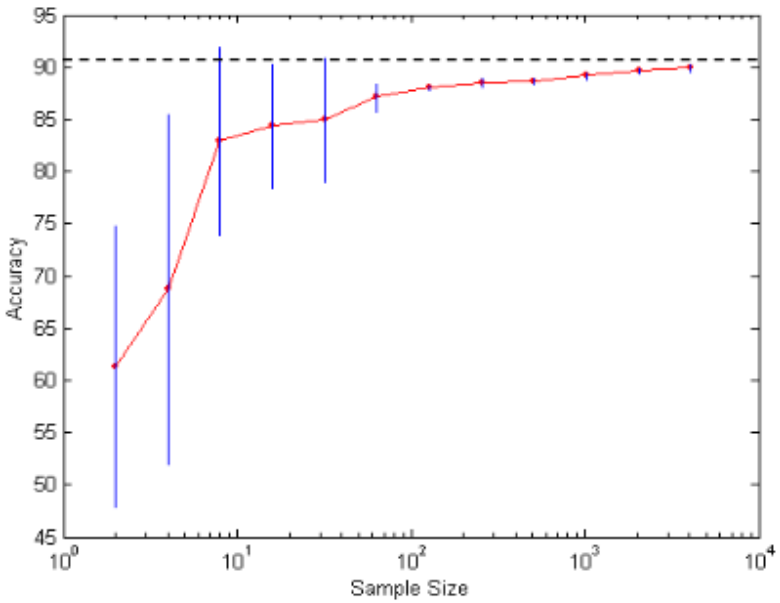
- **معیارهای ارزیابی در برابر روش‌های ارزیابی:**
  - **معیارهای ارزیابی:** (Evaluation Metrics) چگونه کیفیت عملکرد یک مدل را با اعداد و مقادیر کمی بسنجیم؟ (صحت، دقت، بازخوانی، F_1، منحنی ROC).
  - **روش‌های ارزیابی:** (Evaluation Methods) چگونه نمونه‌های داده را تفکیک کنیم تا تخمینی **قابل‌اعتماد و بدون سوگیری** از کارایی تعمیم به دست آوریم؟

رویکرد عمومی تفکیک داده

قاعده زرین ارزیابی مدل

- تفکیک رکوردهای برچسب‌دار به دو زیرمجموعه مجزا: **مجموعه آموزش (Training Set)** و **مجموعه آزمون (Test Set)**.
- **قاعده زرین و حیاتی در علم داده:**
  - **هرگز و تحت هیچ شرایطی، مدلی را روی داده‌های آموزش‌دیده ارزیابی نکنید!**
  - ارزیابی روی داده‌های آموزش به دلیل برازش مدل، معیاری کاملاً غیرواقع‌بینانه و بیش‌ازحد خوش‌بینانه از عملکرد روی داده‌های آینده خواهد داد.
  - باید جداسازی فیزیکی و منطقی کاملی میان داده‌های آموزش و آزمون وجود داشته باشد.
- **روش‌های تفکیک متداول:**
  - روش نگه‌داشت (Holdout Method)
  - زیرنمونه‌گیری تصادفی (Random Subsampling)
  - اعتبارسنجی متقاطع (Cross-Validation)

منحنی یادگیری
Learning Curve



- منحنی یادگیری تغییرات صحت مدل را با **افزایش حجم داده‌های آموزشی** نشان می‌دهد.
- **نتایج کلیدی:**
  - اگر عملکرد مدل پایین یا ناپایدار است، داده‌های آموزشی بیشتری اضافه کنید.
  - ترجیح بر این است که داده‌های برچسب‌دار را بیشتر به آموزش اختصاص دهیم تا آزمون.
- **چالش عملی:** برچسب‌گذاری نمونه‌های اضافی نیازمند نیروی انسانی متخصص و هزینه مالی بالاست.

روش نگه‌داشت

Holdout Method

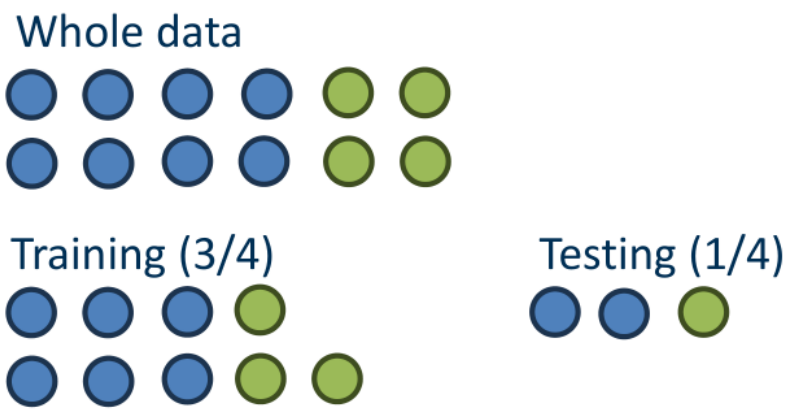
- **روش نگه‌داشت:** بخش معینی از داده‌های برچسب‌دار را صرفاً برای آزمون ذخیره کرده و از مابقی جهت آموزش استفاده می‌کند:
  - زمانی به کار می‌رود که **حجم زیادی از داده‌های نمونه** در دسترس باشد.
- **نسبت‌های معمول تفکیک:** 2/3 به 1/3 (یا ترجیحاً 80% به 20%).



- در **مجموعه‌داده‌های نامتعادل**، نمونه‌های تصادفی ممکن است نماینده مناسبی نباشند:
  - حضور اندک یا عدم حضور کلاس اقلیت (کلاس مثبت) در آموزش یا آزمون.

نمونه‌گیری طبقه‌بندی‌شده
Stratified Sampling

- **نمونه‌گیری طبقه‌بندی‌شده** (Stratified Sample): نمونه‌گیری از هر کلاس به صورت کاملاً مستقل انجام می‌شود تا رکوردهای کلاس اقلیت در تمام نمونه‌ها حضور داشته باشند:
  - اطمینان از اینکه هر کلاس با نسبت‌های تقریباً یکسان در هر دو زیرمجموعه حضور دارد.
  - سایر ویژگی‌ها نیز می‌توانند مبنای طبقه‌بندی قرار گیرند (مانند جنسیت، سن و غیره).



زیرنمونه‌گیری تصادفی

Random Subsampling

- برآورد روش نگه‌داشت را می‌توان با تکرار فرآیند با زیرنمونه‌های مختلف قابل‌اعتمادتر کرد:
  - در هر تکرار، درصد معینی به صورت تصادفی برای آموزش انتخاب می‌شود.
  - میانگین عملکرد تکرارهای مختلف به دست می‌آید.



- همچنان کاملاً بهینه نیست زیرا مجموعه‌های آزمون ممکن است هم‌پوشانی داشته باشند:
  - برخی داده‌های پرت ممکن است همواره در مجموعه‌های آزمون قرار گیرند.
  - نمونه‌های مهم برای یادگیری ممکن است مکرراً فقط در مجموعه آزمون بیفتند.

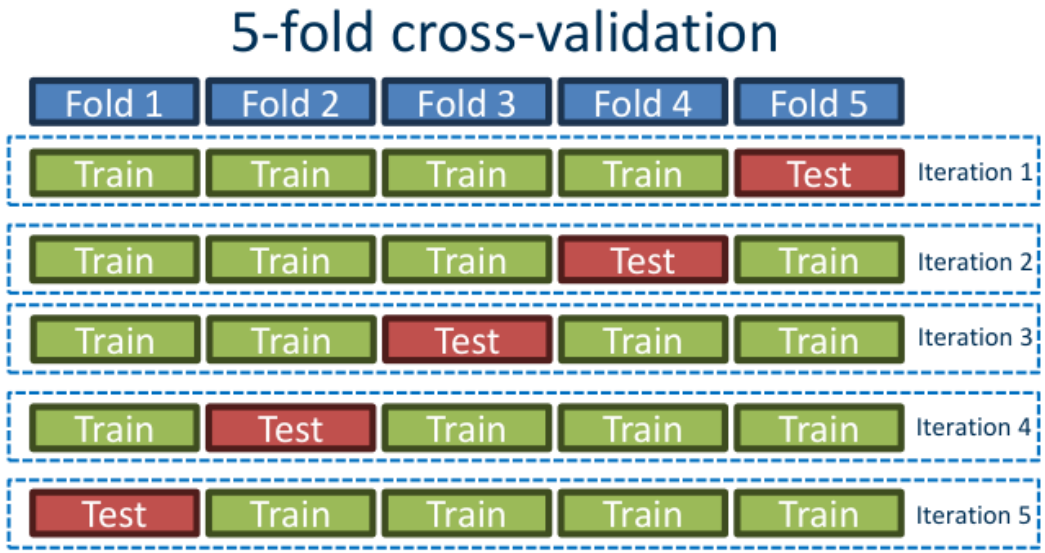
روش تک‌نمونه نگه‌داشته
Leave-One-Out (LOO)

- حالت حدی اعتبارسنجی: در هر گام، مدل روی $N-1$ نمونه آموزش دیده و روی تنها **یک نمونه** ارزیابی می‌شود (تکرار N بار برای تمامی رکوردهای داده).
- **مزایا:** دقیق‌ترین برآورد ممکن با کمترین سوگیری، و حداکثر بهره‌برداری از داده‌ها برای آموزش.
- **چالش محاسباتی عظیم:**
  - در مجموعه داده با یک میلیون نمونه، اگر آموزش هر مدل تنها ۱ دقیقه زمان ببرد، اجرای روش LOO نزدیک به ۲ سال طول خواهد کشید!

اعتبارسنجی متقاطع k-Fold

k-Fold Cross-Validation

- تعادلی بهینه میان دقت تخمین روش LOO و زمان اجرای منطقی.
- **مرحله اول:** داده‌ها به k زیرمجموعه مساوی و مجزا (Folds) با نمونه‌گیری طبقه‌بندی‌شده افراز می‌شوند.
- **مرحله دوم:** در k تکرار، هر زیرمجموعه یک بار برای آزمون و $k-1$ زیرمجموعه باقیمانده برای آموزش به کار می‌روند؛ نهایتاً میانگین خطاها محاسبه می‌شود.



انتخاب مقدار k و پیاده‌سازی در پایتون

Cross-Validation in Scikit-Learn

- **انتخاب مقدار پیش‌فرض** ($k = 10$): تجربیات گسترده نشان داده $k = 10$ تعادل بسیار عالی از نظر واریانس و سوگیری برآورد خطا فراهم می‌کند.
- در مدل‌های بسیار بزرگ و سنگین امروزی، مقادیر کمتر نظیر $k = 5$ (مقدار پیش‌فرض scikit-learn) ترجیح داده می‌شود.
- **پیاده‌سازی نمونه‌گیری طبقه‌بندی‌شده (Stratified) در پایتون:**

```
from sklearn.model_selection import StratifiedKFold,
cross_val_score

# Configure stratified 10-fold split with shuffling
cross_val = StratifiedKFold(n_splits=10, shuffle=True,
random_state=42)

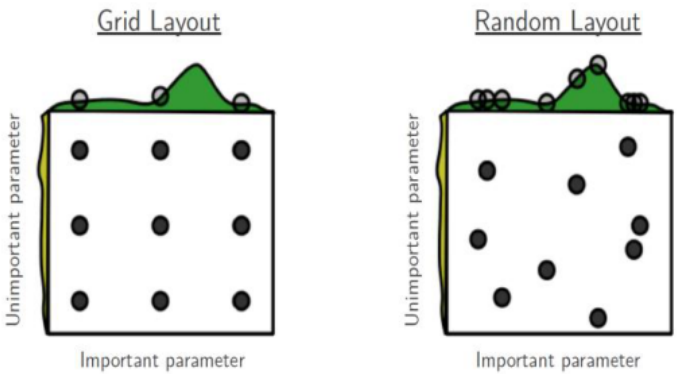
# Compute cross-validation accuracy across all 10 folds
accuracy = cross_val_score(estimator, data, target,
cv=cross_val, scoring='accuracy')
```

انتخاب فراپارامترها
Hyperparameter Selection

- **فراپارامتر** (Hyperparameter): پارامتری است که فرآیند یادگیری الگوریتم را هدایت کرده و مقدار آن **پیش از آغاز یادگیری** توسط کاربر تعیین می‌شود:
  - آستانه هرس در درختان تصمیم (Pruning Thresholds)
  - ضرایب C و γ در ماشین‌های بردار پشتیبان (SVM)
  - نرخ یادگیری (Learning Rate) و تعداد لایه‌ها و نورون‌های پنهان در شبکه‌های عصبی
- **پارامترها** (Parameters): مقادیری هستند که مستقیماً در طول فرآیند آموزش و از روی داده‌ها یاد گرفته می‌شوند (مانند وزن‌های نورون‌ها w_i یا ضرایب ابرصفحه).

بهینه‌سازی فراپارامترها

جستجوی شبکه‌ای در برابر جستجوی تصادفی



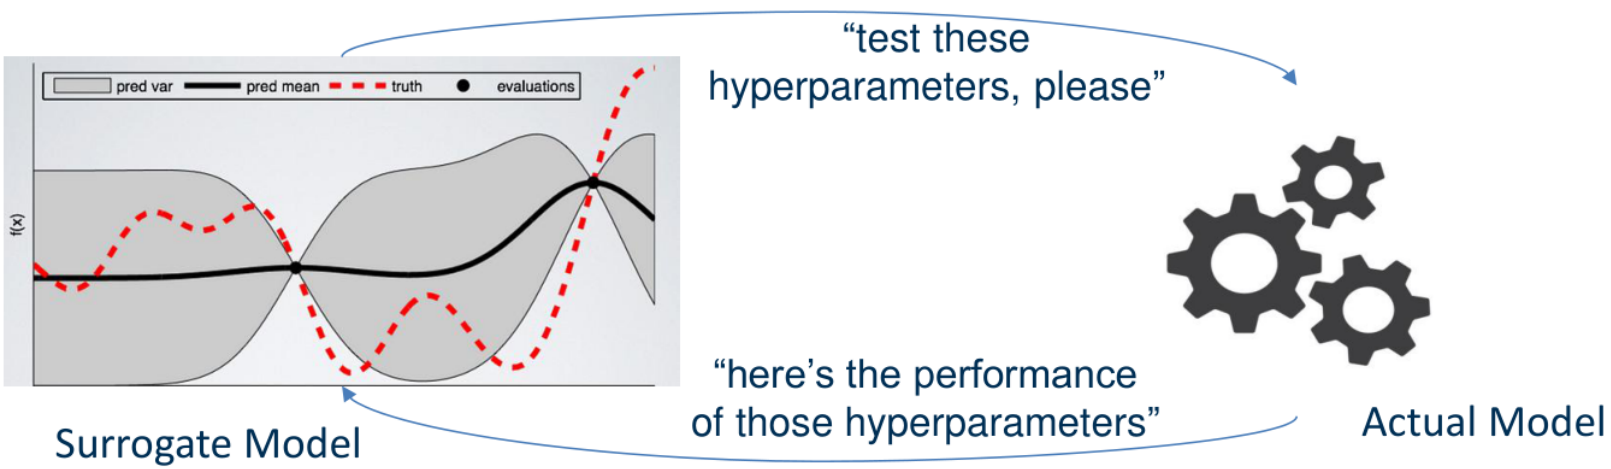
- **هدف:** یافتن ترکیبی از فراپارامترها با کمترین خطای تعمیم مدل.
- **روش‌های تعیین ترکیبات پارامتری:**
  - **جستجوی شبکه‌ای** (Grid Search): آزمون تمامی ترکیبات ممکن در بازه‌های گسسته.
  - **جستجوی تصادفی** (Random Search): نمونه‌برداری تصادفی از فضای مقادیر.
- **یافته برگسترا و بنجیو (۲۰۱۲):**
  - جستجوی شبکه‌ای نقاط بهینه حساس را به سادگی از دست می‌دهد.
  - جستجوی تصادفی با هزینه محاسباتی برابر، نتایج بسیار بهتری می‌دهد.

Bergstra & Bengio: Random Search for Hyper-Parameter Optimization, JMLR, 2012

بهینه‌سازی بیزی فراپارامترها

Bayesian Optimization

- **جستجوی تکاملی** (Evolutionary Search): حفظ ترکیباتی از پارامترها که در تکرارهای پیشین کارایی مناسبی داشته‌اند.
- **بهینه‌سازی بیزی** (Bayesian Optimization):
  - تبدیل تنظیم فراپارامتر به یک مسئله یادگیری ماشین مستقل (پیش‌بینی امتیاز بر اساس پارامترها).
  - مدل جانشین (Surrogate Model) بر پایه فرایندهای گاوسی امتیاز ارزیابی مدل اصلی را پیش‌بینی می‌کند.
  - هدایت هوشمندانه جستجو به سمت امیدبخش‌ترین نواحی.



مسئله انتخاب مدل

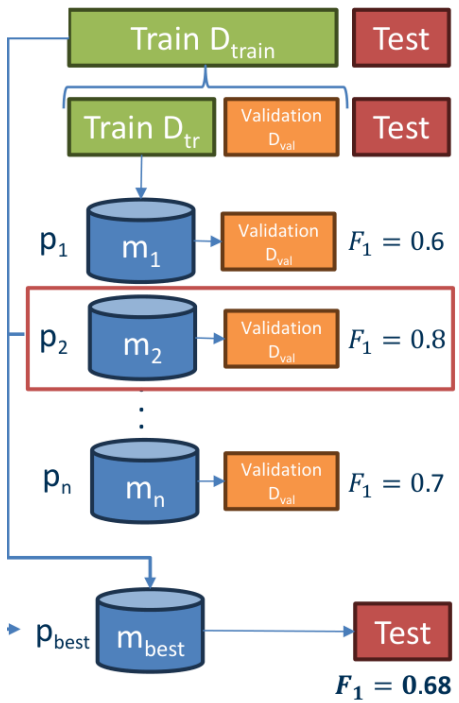
Model Selection

- **وضعیت فعلی:**
  - تعیین کردیم چه ترکیباتی از فراپارامترها باید آزموده شوند.
  - در عمل اغلب صدها ترکیب فراپارامتر آموزش داده می‌شوند (علت اصلی نیاز به محاسبات ابری).

- **چالش اساسی انتخاب مدل** (Model Selection):
  - از میان تمام مدل‌های آموزش‌دیده $\mathcal{M}$، چگونه مدل بهینه m_{best} را انتخاب کنیم که بهترین تعمیم را روی داده‌های نادیده داشته باشد؟
  - **پرسش کلیدی:** این ارزیابی و انتخاب مدل روی چه داده‌هایی باید انجام گیرد؟

انتخاب مدل با مجموعه اعتبارسنجی

Model Selection Using a Validation Set



- **اصل تفکیک:** داده‌های انتخاب مدل باید کاملاً از داده‌های آزمون نهایی مجزا باشند، وگرنه مدل به داده آزمون بیش‌برازش می‌شود.
- **گام‌های پنج‌گانه:**
  ۱. تفکیک D_{train} به داده آموزش D_{tr} و داده اعتبارسنجی D_{val}.
  ۲. آموزش مدل‌های m_i روی D_{tr} با ترکیبات فراپارامتری p_i.
  ۳. انتخاب بهترین پارامتر p_{best} با آزمون روی D_{val}.
  ۴. آموزش مدل نهایی m_{best} روی کل داده‌های D_{train} با p_{best}.
  ۵. ارزیابی مدل نهایی m_{best} روی مجموعه آزمون (Test Set).

انتخاب مدل با اعتبارسنجی متقاطع

Model Selection Using Cross-Validation

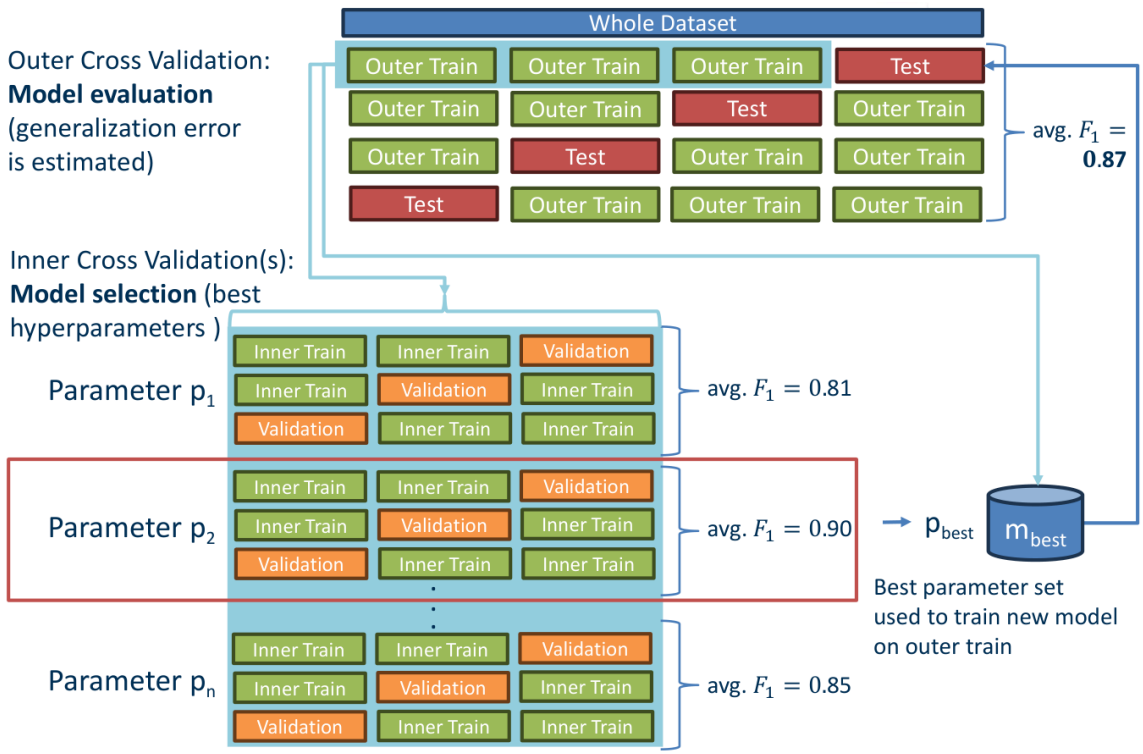
- اهداف کلیدی در انتخاب مدل:
  ۱. اطمینان از اینکه تمامی نمونه‌ها یک بار برای اعتبارسنجی استفاده شوند.
  ۲. استفاده حداکثری از داده‌های برچسب‌دار برای آموزش.
- هر دو هدف با استفاده از **اعتبارسنجی متقاطع برای انتخاب مدل** برآورده می‌شوند:



اعتبارسنجی متقاطع تودرتو

Nested Cross-Validation

- تفکیک دو حلقه متقاطع: حلقه درونی جهت **انتخاب مدل** و حلقه بیرونی جهت **ارزیابی تعمیم**.



اعتبارسنجی متقاطع تودرتو در پایتون

Nested Cross-Validation in Scikit-Learn

- پیاده‌سازی حرفه‌ای با ترکیب `GridSearchCV` و `cross_val_score` به صورت زیر انجام می‌شود:

```
from sklearn.model_selection import GridSearchCV,
cross_val_score
from sklearn.svm import SVC

# 1. Define hyperparameter search grid
parameter_grid = {'C': [1, 10, 100, 1000], 'gamma': [0.001,
0.01, 0.1, 1]}

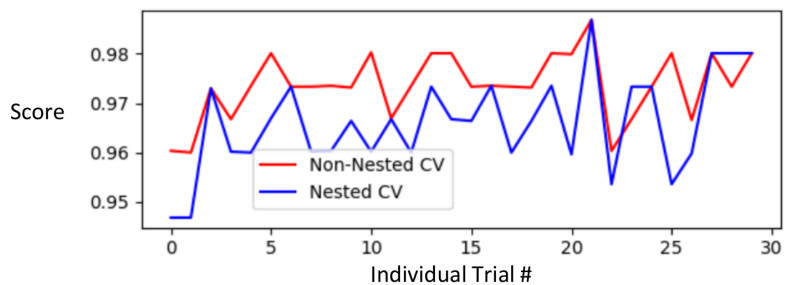
# 2. Inner CV: Model selection via GridSearchCV (5 folds)
estimator_svm = SVC(kernel='rbf')
estimator_gs = GridSearchCV(estimator_svm, parameter_grid,
scoring='accuracy', cv=5)

# 3. Outer CV: Unbiased model evaluation (5 folds)
accuracy_cv = cross_val_score(estimator_gs, dataset, labels,
cv=5, scoring='accuracy')
```

جمع‌بندی رویکردهای انتخاب مدل

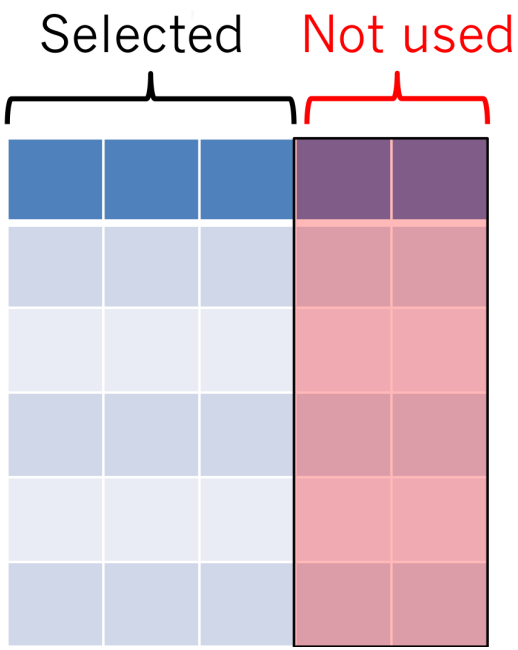
مقایسه هزینه محاسباتی و دقت تخمین

- **ارزیابی مدل با اعتبارسنجی یا CV:** از مجموعه آزمون فقط **یک‌بار** جهت برآورد نهایی خطا استفاده کنید!
- هرچه مدل‌های بیشتری آموزش داده شوند، برآورد خطای تعمیم دقیق‌تر و واقع‌بینانه‌تر خواهد بود.



- **سناریوی مقایسه** (۱۰۰ ترکیب پارامتر با اعتبارسنجی ۵ فولد درونی و بیرونی):
  - **مجموعه اعتبارسنجی:** $|P| + 1 = 100 + 1 = \mathbf{101}$ مدل آموزش‌دیده
  - **اعتبارسنجی متقاطع ساده:** $|\text{folds}| \times |P| + 1 = 5 \times 100 + 1 = \mathbf{501}$ مدل آموزش‌دیده
  - **اعتبارسنجی تودرتو** (Nested CV):
    $|\text{folds}_{\text{outer}}| \times (|\text{folds}_{\text{inner}}| \times |P| + 1) = 5 \times 501 = \mathbf{2505}$ مدل

انتخاب ویژگی
Feature Selection



- برخی روش‌ها انتخاب ویژگی را به صورت خودکار انجام می‌دهند (مانند درخت تصمیم، جنگل تصادفی و SVM).
- عملکرد سایر روش‌ها به شدت وابسته به زیرمجموعه ویژگی‌های ورودی است (مانند k-NN و بیز ساده).
- **رویکردهای جستجوی خودکار ویژگی:**
  - **انتخاب پس‌رو** (Backward): شروع با همه ویژگی‌ها و حذف گام‌به‌گام.
  - **انتخاب پیش‌رو** (Forward): شروع از بهترین ویژگی منفرد و افزودن متوالی.
- استفاده از **اعتبارسنجی متقاطع تودرتو** جهت تخمین دقیق خطای تعمیم.

دستورالعمل‌های بهینه‌سازی فراپارامتر و انتخاب مدل

Best Practices Summary

- **انتخاب فراپارامترها:** همواره بهینه‌سازی فراپارامترها را اجرا کنید؛ در غیر این صورت نمی‌توانید ادعا کنید که یک الگوریتم برای داده‌های شما کارایی ندارد.
- **انتخاب ویژگی:** بررسی کنید که آیا الگوریتم منتخب به انتخاب ویژگی نیاز دارد یا خیر، و در صورت نیاز جستجوی پیش‌رو/پس‌رو انجام دهید.
- **انتخاب مدل:** در حالت استاندارد از **اعتبارسنجی متقاطع تودرتو** استفاده کنید؛ در صورت کمبود زمان، فضای جستجو را محدود کرده یا از تقسیم تک‌مرحله‌ای (Train/Val/Test) استفاده نمایید.
- **نکته طلایی در داده‌های نامتعادل:** فقط داده‌های آموزشی را متوازن (Balance) کنید و هرگز توزیع داده‌های آزمون را تغییر ندهید!

ویدیوها و سخنرانی‌های آنلاین
Online Lectures



no lecture		Introduction to (13:45–15:15)
Introduction to Data Mining		Intro
Preprocessing		Preprocessing
Classification 1	Nearest Centroids	Classification 1
Classification 2	Comparing Classifiers	Classification 2
Regression	Ensembles	Regression
Clustering and Anomalies	Hierarchical Clustering	Clustering
Feedback on project outlines	Time Series	Time Series
Association Analysis		Association Ana

- مطالب تکمیلی این هفته پیرامون **مقایسه عملکرد و آزمون‌های آماری مقایسه طبقه‌بندها** است.
- مشاهده سخنرانی‌های آنلاین و درک مفاهیم آن برای حل تمرین‌ها و موفقیت در آزمون پایانی **الزامی و حیاتی** می‌باشد.

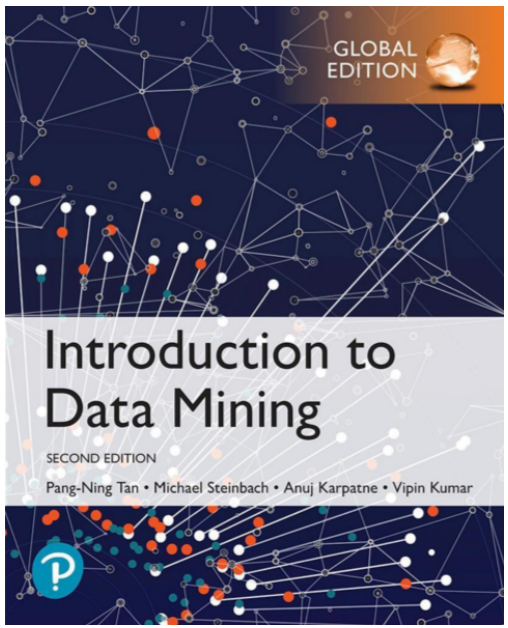
پرسش و پاسخ

Questions & Discussion



مراجع و منابع این مجموعه اسلاید

Literature & Recommended Reading



- **مرجع اصلی درس:**

Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, Vipin Kumar:
Introduction to Data Mining, 2nd Edition, Pearson.

- **فصول مرتبط در کتاب مرجع:**
  - **فصل 6.4:** بیز ساده (Naïve Bayes)
  - **فصل 6.9:** ماشین‌های بردار پشتیبان (SVM)
  - **فصل‌های 6.7 و 6.8:** شبکه‌های عصبی (ANN)
  - **فصل 3.5:** انتخاب مدل (Model Selection)
  - **فصل 3.7:** حضور فراپارامترها (Hyper-Parameters)