گروه علوم داده و وب

داده‌کاوی (IE500)

فصل ۱: مقدمه و ساختار درس



UNIVERSITY OF MANNHEIM
School of Business Informatics and Mathematics

معرفی مدرس درس

Dr. Sven Hertling



- **دکتر اسون هرتلینگ** (Dr. Sven Hertling)
  - استاد مدعو و جانشین کرسی علوم داده (Substitute Professor for Data Science)
- **حوزه‌های پژوهشی:**
  - ادغام گراف‌های دانش (Knowledge Graph Integration)
  - ترکیب گراف‌های دانش با مدل‌های زبانی بزرگ (KGs with LLMs)
  - استخراج اطلاعات (Information Extraction)
- **اتاق:** B6 26, B0.21
- **ایمیل:** sven.hertling@uni-mannheim.de
- **مسئولیت:** ارائه جلسات تئوری و اصلی درس (Lectures)

معرفی دستیاران آموزشی

M.Sc. Andreea Iana



- **آندریا یانا** (M.Sc. Andreea Iana)
  - پژوهشگر و دستیار تحقیق (Graduate Research Associate)
- **حوزه‌های پژوهشی:**
  - سامانه‌های توصیه‌گر (Recommender Systems)
  - بازیابی اطلاعات (Information Retrieval)
  - پردازش زبان طبیعی (Natural Language Processing)
- **اتاق:** B6 26, B 0.18
- **ایمیل:** andreea.iana@uni-mannheim.de
- **مسئولیت:** تدریس یکی از گروه‌های تمرین و هدایت پروژه‌های دانشجویی

معرفی دستیاران آموزشی

M.Sc. Franz Krause



- **فرانتس کراوزه** (M.Sc. Franz Krause)
  - پژوهشگر و دستیار تحقیق (Graduate Research Associate)
- **حوزه‌های پژوهشی:**
  - کاربردهای یادگیری ماشین روی داده‌های پیوندی (ML on Linked Data)
  - پویایی بازنمایی‌های تعبیه گراف دانش (KG Embeddings)
  - کاربرد و استقرار گراف دانش در محیط‌های صنعتی
  - نظریه گراف کاربردی (Applied Graph Theory)
- **اتاق:** B6 26, B 0.02
- **ایمیل:** franz.krause@uni-mannheim.de
- **مسئولیت:** تدریس یکی از گروه‌های تمرین و هدایت پروژه‌های دانشجویی

معرفی دستیاران آموزشی

M.Sc. Aaron Steiner



- **آرون اشتاینر** (M.Sc. Aaron Steiner)
  - پژوهشگر و دستیار تحقیق (Graduate Research Associate)
- **حوزه‌های پژوهشی:**
  - تطبیق موجودیت‌ها با مدل‌های زبانی (Entity Matching using LLMs)
  - تنظیم دقیق مدل‌های زبانی بزرگ (Fine-tuning LLMs)
  - ادغام داده‌ها (Data Integration)
- **اتاق:** B6 26, C 1.04
- **ایمیل:** aaron.steiner@uni-mannheim.de
- **مسئولیت:** تدریس یکی از گروه‌های تمرین و هدایت پروژه‌های دانشجویی

سازماندهی درس – جلسات کلاس تئوری



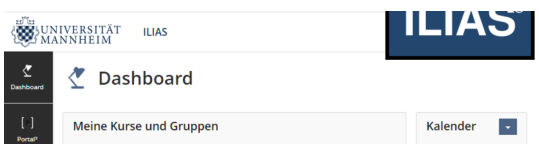
- **ثبت‌نام** (Registration)
  - ثبت‌نام رسمی از طریق پورتال Portal2
  - عضویت خودکار در سامانه آموزشی ILIAS

- **کلاس درس تئوری** (Lecture)
  - **زمان:** چهارشنبه‌ها، ساعت 11:45 – 10:15
  - **مکان:** اتاق B144، ساختمان 5,6 A بخش B
  - معرفی اصول و روش‌های بنیادین داده‌کاوی
  - نحوه ارزیابی و اعتبارسنجی مدل‌های آموخته‌شده
  - ارائه مثال‌های کاربردی و سناریوهای واقعی در صنعت

سازماندهی درس – منابع و سامانه‌های آموزشی







- **وب‌سایت رسمی درس** (Course Webpage)
  - ارائه اطلاعات به‌روز، اسلایدهای آموزشی و ویدیوهای درس
  - https://www.uni-mannheim.de/dws/teaching/

- **سامانه آموزش الکترونیکی ILIAS**
  - پیوند: https://ilias.uni-mannheim.de/
  - دریافت تمرین‌ها و مجموعه‌داده‌ها
  - تالارهای گفتگو و پرسش‌وپاسخ (Discussion Forum)
  - تحویل پروژه‌های تیمی و جلسات راهنمایی مربیان

سازماندهی درس – جلسات آموزش برخط



Week	Wednesday (Offline Lecture)	Online Lecture	Thursday (Exercise)
10.02.2025	no lecture		Introduction to Python (13:45–15:15)
17.02.2025	Introduction to Data Mining		Intro
24.02.2025	Preprocessing		Preprocessing
03.03.2025	Classification 1	Nearest Centroids	Classification 1
10.03.2025	Classification 2	Comparing Classifiers	Classification 2
17.03.2025	Regression	Ensembles	Regression
24.03.2025	Clustering and Anomalies	Hierarchical Clustering	Clustering
31.03.2025	Feedback on project outlines	Time Series	Time Series
07.04.2025	Association Analysis and Subgroup Discovery		Association Analysis
14.04.2025	Easter Break		Easter Break
21.04.2025	Easter Break		Easter Break
28.04.2025	Project feedback session	Multi Model Data	Public holiday
05.05.2025	Project feedback session		Project Work
12.05.2025	Project feedback session		Project Work
19.05.2025	Project Work		**Project Presentations**
26.05.2025	Q&A		Public holiday



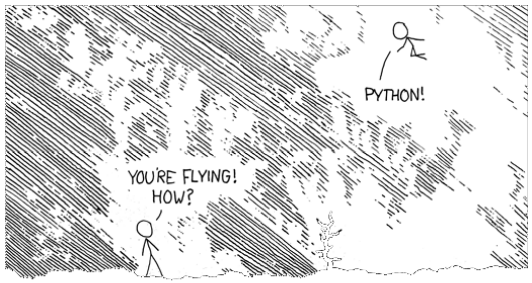
- **کلاس‌های مجازی** (Online Lecture)
  - بخش رسمی و الزامی از برنامه آموزشی درس
  - پوشش سرفصل‌های مکمل داده‌کاوی
  - کاملاً مرتبط با مباحث تمرین‌ها و سؤالات آزمون نهایی
  - امکان مرور چندباره و یادگیری با سرعت شخصی

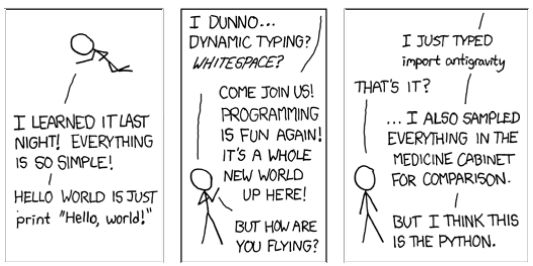
سازماندهی درس – گروه‌های حل تمرین



- **جلسات تمرین عملی** (Exercise Groups)
  - آزمایش و کار با داده‌های واقعی در زبان پایتون (Python)
- **زمان و مکان جلسات (محتوا یکسان است – فقط در یک گروه شرکت کنید)**
  - پنج‌شنبه، ساعت 10:15 – 11:45، اتاق A104، ساختمان B6, 26 بخش A (Aaron)
  - پنج‌شنبه، ساعت 12:00 – 13:30، اتاق A104، ساختمان B6, 26 بخش A (Andreea/Franz)
  - پنج‌شنبه، ساعت 13:45 – 15:15، اتاق A104، ساختمان B6, 26 بخش A (Andreea/Franz)

کارگاه مقدماتی برنامه‌نویسی پایتون





- **جلسه توجیهی پایتون:**
  - پنج‌شنبه هفته گذشته، ساعت 13:45 – 15:15 برگزار گردید
- **سرفصل‌های ارائه‌شده:**
  - نصب و راه‌اندازی محیط (Anaconda, Jupyter Notebooks)
  - معرفی فلسفه طراحی زبان پایتون
  - ساختارهای پایه‌ای برنامه‌نویسی و پردازش داده در پایتون
- **پشتیبانی و رفع اشکال:**
  - راهنمایی در پیکربندی و پاسخ به پرسش‌های دانشجویان
  - اسلایدهای آموزشی خودآموز در وب‌سایت درس در دسترس است

استفاده از ChatGPT در جلسات تمرین

- **در جلسات تمرین از ChatGPT به صورت هدفمند بهره خواهیم برد برای:**
  - **تحلیل روش‌ها و پارامترها:** هم‌اندیشی درباره انتخاب الگوریتم مناسب و تنظیم هایپرپارامترها در سناریوهای مختلف
  - **تولید و خطایابی کد:** نوشتن اسکریپت‌های پایتون و رفع اشکال سریع‌تر در آزمایش‌ها



OpenAI

سازماندهی درس – پروژه عملی دانشجویی



- **اجرای پروژه گروهی** (Project Work)
  - تیم‌های 6 نفره برای اجرای جامع یک پروژه داده‌کاوی واقعی
  - انتخاب آزاد مجموعه‌داده و مسئله (تعدادی داده نیز پیشنهاد می‌شود)
  - نگارش گزارش علمی فشرده و ارائه نتایج

- **مهلت‌های قطعی تحویل** (Deadlines)
  - **تشکیل و ثبت تیم‌ها:** یکشنبه، 16 مارس، ساعت 23:59
  - **ارسال پروپوزال پروژه** (Proposal) – یکشنبه، 23 مارس، ساعت 23:59
  - **ارسال گزارش نهایی پروژه** – یکشنبه، 18 مه، ساعت 23:59
  - **ارسال فایل ارائه** (PDF) – چهارشنبه، 21 مه، ساعت 23:59

سازماندهی درس – مشخصات آزمون کتبی

- **تاریخ و زمان برگزاری:** پنج‌شنبه، 12 ژوئن 2025 (Thursday, 12th June 2025)
- **مدت زمان آزمون:** 60 دقیقه
- **ساختار آزمون:** 6 سؤال تشریحی (6 Open Questions)
  - **سنجش درک مفهومی:** بررسی تسلط عمیق دانشجو بر مباحث تمام فصول اصلی درس
  - **تشریح منطق الگوریتم‌ها:** نیازمند توضیح چرایی و چگونگی کارکرد متدها
  - **رفتار متدها در شرایط خاص:** بررسی چگونگی واکنش الگوریتم‌ها به الگوها و نویز داده‌ها
  - **محاسبات ساده عددی:**
    - دانستن فرمول‌های اصلی الزامی است
    - نیازی به ماشین‌حساب نیست (محاسبات ساده و ذهنی است)

سازماندهی درس – ضوابط آزمون و نمره‌دهی

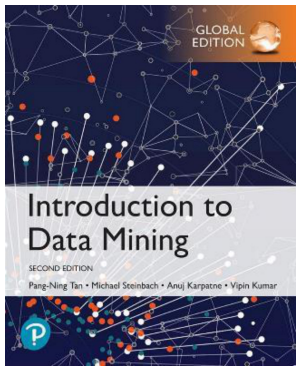
- **تنها یک نوبت آزمون در هر نیم‌سال:**
  - چون این درس در هر دو ترم (پاییز و بهار) ارائه می‌گردد
  - نوبت بعدی امتحان در پایان نیم‌سال آینده خواهد بود (بدون آزمون جبرانی یا Retake در این ترم!)
- **شرایط عدم قبولی:**
  - در صورت مردودی، باید هم پروژه و هم آزمون را در ترم آینده مجدداً از نو بگذرانید
  - متأسفانه امکان انتقال نمره پروژه به ترم بعد وجود ندارد
- **ترکیب نمره نهایی** (Final Grade)
  - **آزمون کتبی** (Written Exam) – 75%
  - **گزارش پروژه** (Project Report) – 20%
  - **ارائه شفاهی پروژه** (Presentation) – 5%

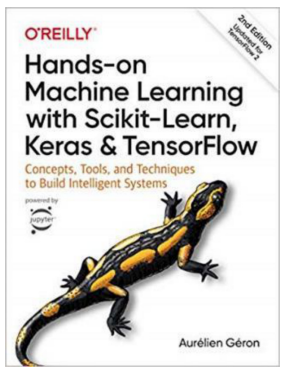
برنامه زمان‌بندی جلسات درس

- **تقویم آموزشی ترم:**
  - کلیه تاریخ‌ها، مباحث هفتگی و زمان تحویل فازهای پروژه
  - تمام به‌روزرسانی‌ها به صورت برخط در صفحه خانگی درس قرار می‌گیرد
  - لطفاً به طور منظم وب‌سایت درس را بررسی فرمایید

Week	Wednesday (Lecture)	Thursday (Exercise)
10.02.2025	no lecture	Introduction to Python (13:45–15:15)
17.02.2025	Introduction to Data Mining	Intro
24.02.2025	Preprocessing	Preprocessing
03.03.2025	Classification 1	Classification 1
10.03.2025	Classification 2	Classification 2
17.03.2025	Regression	Regression
24.03.2025	Clustering and Anomalies	Clustering
31.03.2025	Feedback on project outlines	Project Work
07.04.2025	Association Analysis and Subgroup Discovery	Association Analysis
14.04.2025	Easter Break	Easter Break
21.04.2025	Easter Break	Easter Break
28.04.2025	Project feedback session	Public holiday
05.05.2025	Project feedback session	Project Work
12.05.2025	Project feedback session	Project Work
19.05.2025	Project Work	**Project Presentations**
26.05.2025	Q&A	Public holiday

کتاب‌های مرجع درس



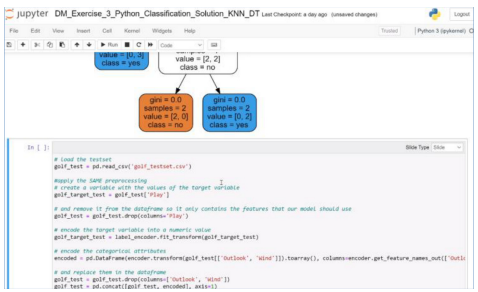


- **کتاب اصلی داده‌کاوی:**
  - Pang-Ning Tan, Michael Steinbach, Vipin Kumar
  - Introduction to Data Mining، 2nd Edition
  - انتشارات Pearson / Addison Wesley
- **کتاب عملی یادگیری ماشین:**
  - Aurélien Géron
  - Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow
  - ویرایش دوم یا سوم، انتشارات O'Reilly، 2019 یا 2022
- **مستندات پایتون:**
  - https://scikit-learn.org/stable/user_guide.html

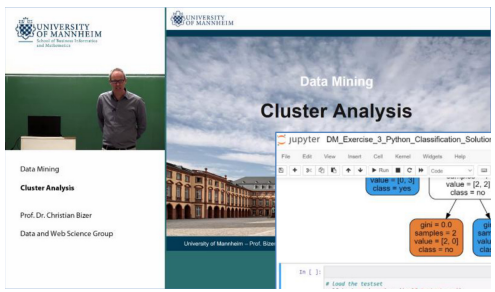
ویدیوها و ضبط‌های آموزشی

- **ویدیوهای ضبط‌شده کلاس‌ها و تمرین‌ها:**
  - پیوند: https://www.uni-mannheim.de/dws/teaching/lecture-videos (نیازمند اتصال به VPN دانشگاه)
  - ویدیوهای درس تئوری توسط هایکو پاولهایم (HWS 2020) و کریستین بیتزر (FSS 2020)
  - ویدیوهای حل تمرین توسط رالف پیترز (FSS 2022)

- **یادآوری مهم:** اسلایدها و سرفصل‌ها سالانه بازنگری می‌شوند؛ لذا مباحث کلاس فعلی ملاک ارزیابی است.







پرسش و پاسخ

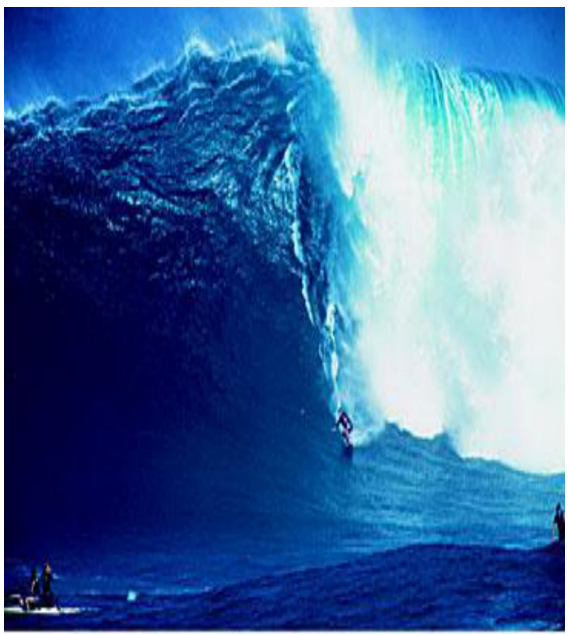
آیا درباره ساختار درس سؤالی دارید؟



داده‌کاوی چیست؟

- **جمع‌آوری پیوسته و انبوه داده‌ها:**
  - داده‌های عظیمی درباره تمامی ابعاد زندگی و حرفه ما ثبت می‌شوند
  - این داده‌ها حاوی الگوها و روندهای بسیار ارزشمند و پنهانی هستند

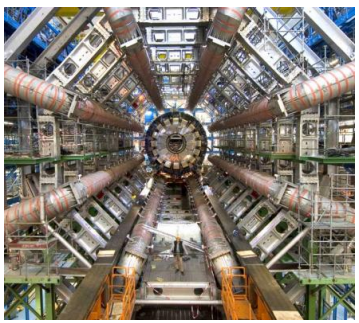
- **داده‌کاوی** (Data Mining) به ما کمک می‌کند تا
  ۱. این الگوهای پنهان را کشف کنیم (Discover patterns)
  ۲. از آن‌ها برای تصمیم‌گیری هوشمندانه در تمام ارکان جامعه بهره ببریم:
     - کسب‌وکار، اقتصاد و صنایع تولیدی
     - علوم بنیادین، محاسباتی و مهندسی
     - پزشکی، سلامت و زیست‌فناوری
     - حاکمیت و تصمیم‌گیری‌های دولتی
     - تصمیم‌گیری‌های روزمره شهروندان

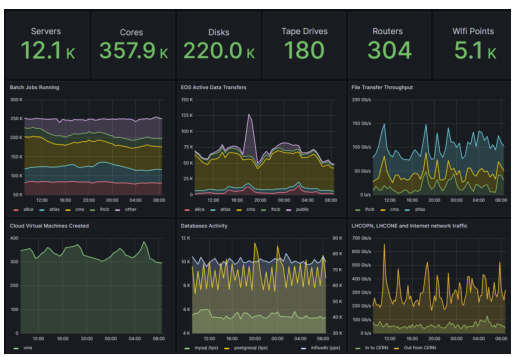


موج سهمگین داده‌ها در عصر اطلاعات

ما در داده‌ها غرق شده‌ایم...

مرکز پژوهش‌های هسته‌ای اروپا (CERN)



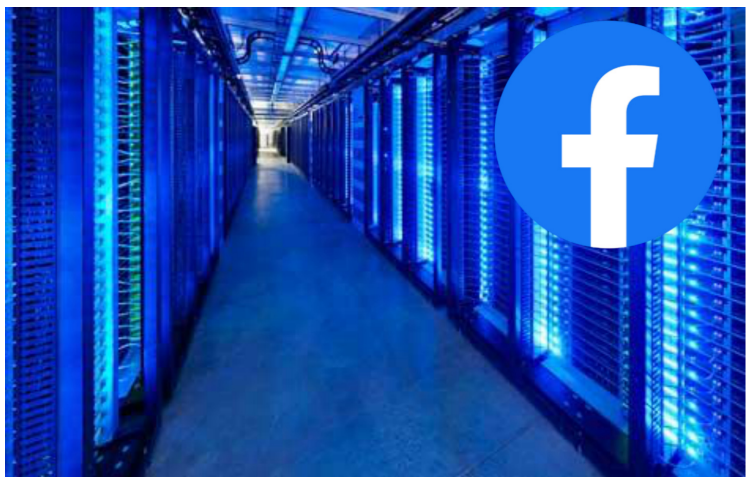


- **برخورددهنده بزرگ هادرونی** (LHC)
  - تولید هفتگی 45 پتابایت داده جدید (February 2024)
  - آرشیو بیش از 820 پتابایت داده روی نوارهای مغناطیسی
  - دسترسی به بیش از 1005 پتابایت فضای دیسک پرسرعت (August 2024)

- **هدف اصلی داده‌کاوی:**
  - کشف ذرات، الگوهای نادر و پدیده‌های ناشناخته فیزیکی در آزمایش‌ها

ما در داده‌ها غرق شده‌ایم...

شبکه‌های اجتماعی و کلان‌داده (Facebook)

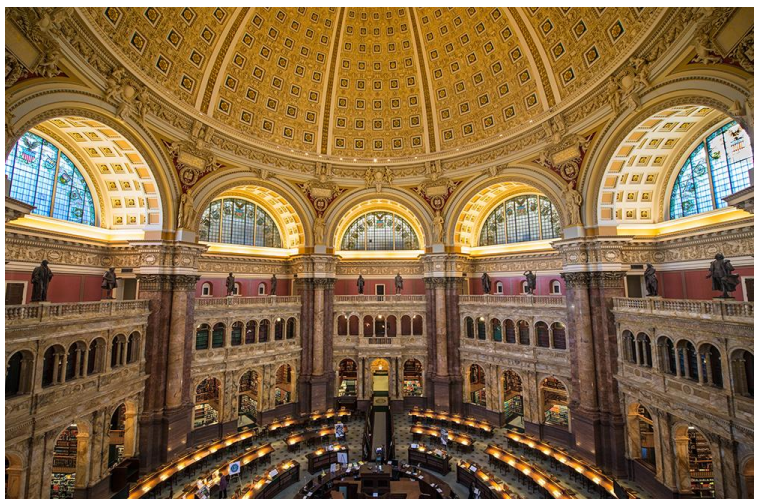




- **حجم اطلاعات فیس‌بوک:**
  - تولید روزانه 4 پتابایت داده خام جدید توسط کاربران
  - انباشت بیش از 300 پتابایت در انبار داده فیس‌بوک (Data Warehouse)
- **پیش‌بینی و تحلیل الگوها:**
  - پیش‌بینی علایق، رفتار و کنش‌های بیش از 1 میلیارد کاربر در سراسر جهان

ما در داده‌ها غرق شده‌ایم...

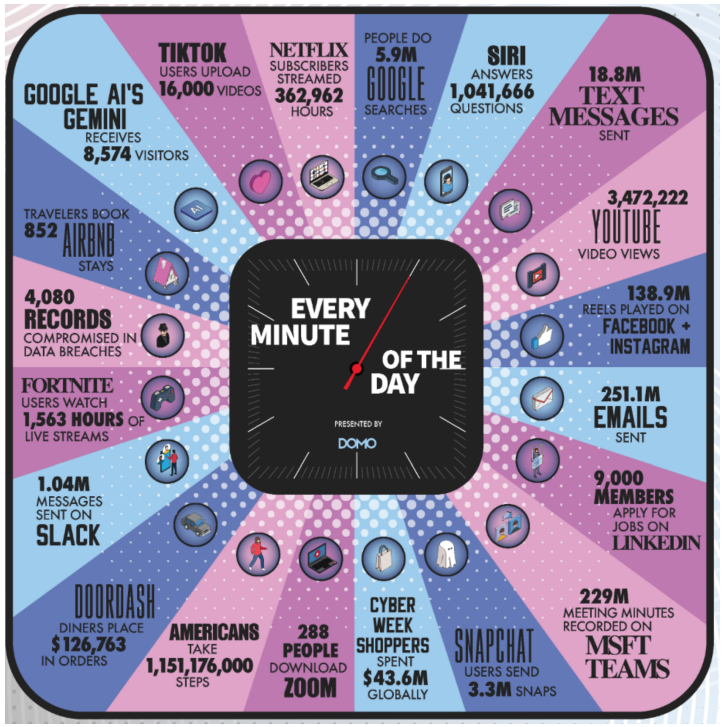
کتابخانه کنگره آمریکا (US Library of Congress)



- **حجم محتوای متنی دیجیتال:**
  - نگهداری بیش از 235 ترابایت اسناد متنی آرشیوشده
- **اهداف کشف دانش و الگوها:**
  - استخراج توزیع موضوعی اسناد و متون (Topic Distributions)
  - تحلیل شبکه‌های استناد علمی (Citation Networks)
- **آموزش مدل‌های هوش مصنوعی:**
  - آموزش مدل‌های زبانی بسیار بزرگ (Large Language Models)

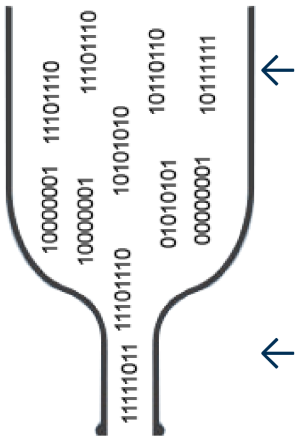
ما در داده‌ها غرق شده‌ایم...

داده‌ها هرگز نمی‌خوابند (Data Never Sleeps 12)



حجم تبادل اطلاعات در هر دقیقه از اینترنت (گزارش دوازدهم شرکت Domo)

غرق در داده‌ها... اما تشنه دانش!



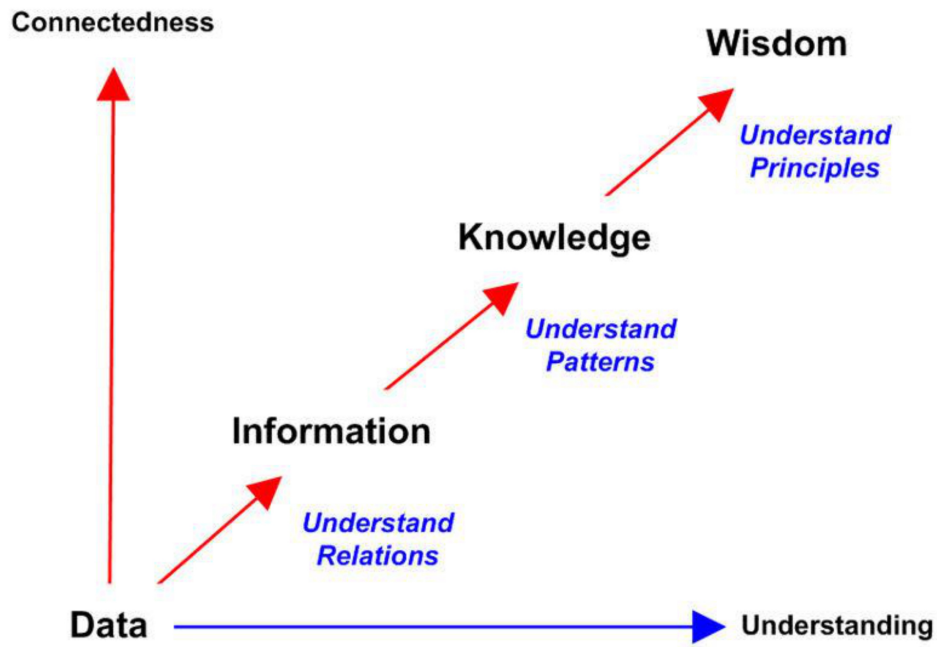
← **نرخ سرسام‌آور تولید داده‌ها**

← **نرخ ادراک و درک داده‌ها توسط انسان**

تفسیر دستی داده‌ها عملاً غیرممکن است!

- **ما به دنبال کشف الگوها هستیم، نه صرفاً انباشت داده‌های خام!**
- **روش‌های داده‌کاوی به ما کمک می‌کنند تا:**
  - الگوهای جذاب و معنادار را در حجم انبوه داده‌ها کشف کنیم
  - بر پایه این الگوها تصمیم‌گیری‌های دقیق و هوشمندانه اتخاذ نماییم

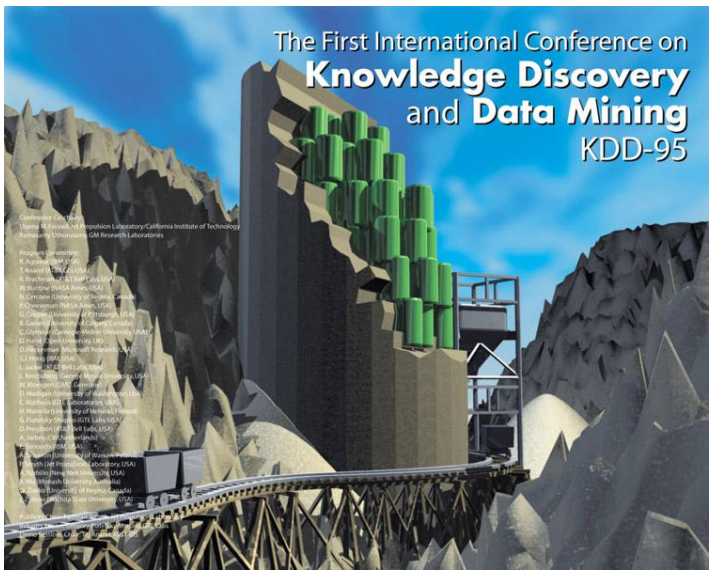
هرم تبدیل داده به حکمت (DIKW)



منبع: بلینجر، کاسترو و میلز – سلسله‌مراتب داده (Data)، اطلاعات (Information)، دانش (Knowledge) و حکمت (Wisdom)

تعریف داده‌کاوی – تمثیل استخراج طلا

- **ایده بنیادین: کوه‌هایی از داده**
  - مشابه کاوش در معادن برای کشف رگه‌های ارزشمند طلا از دل تن‌ها خاک و سنگ
  - داده‌کاوی به معنای جستجو و استخراج دانش ارزشمند از دل کوه‌های عظیم داده است



تعریف رسمی داده‌کاوی

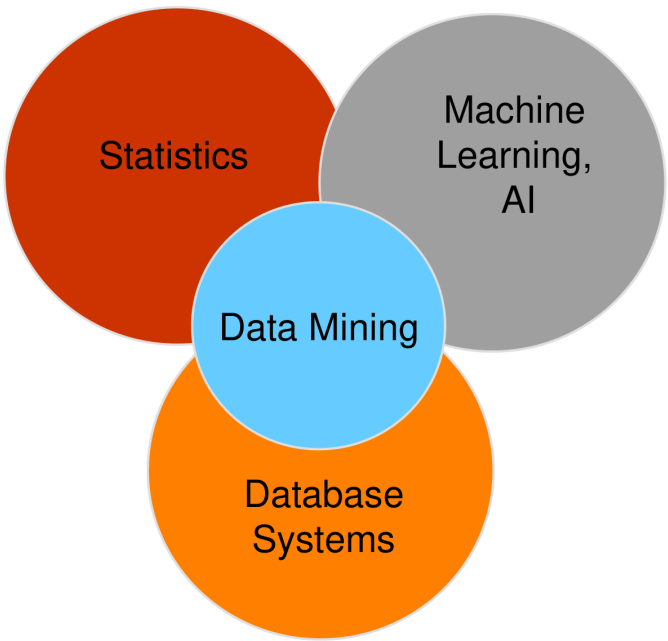
Fayyad et al., 1996

- **تعریف رسمی فیاض و همکاران** (1996)

«داده‌کاوی فرآیندی **غیربدیهی** (non-trivial) برای شناسایی الگوهای **معتبر** (valid)، **بدیع و نوظهور** (novel)، **بالقوه سودمند** (potentially useful) و در نهایت **قابل‌فهم** (ultimately understandable) در داده‌ها است.»

- **اهداف سه‌گانه روش‌های داده‌کاوی:**
  ۱. **کشف الگوها:** شناسایی الگوهای جذاب در مقادیر انبوه داده‌ها
  ۲. **پشتیبانی از تصمیم:** کمک به تصمیم‌گیری انسان با عرضه این الگوها
  ۳. **پیش‌بینی:** تخمین نتیجه یک مشاهده آینده بر مبنای الگوهای کشف‌شده

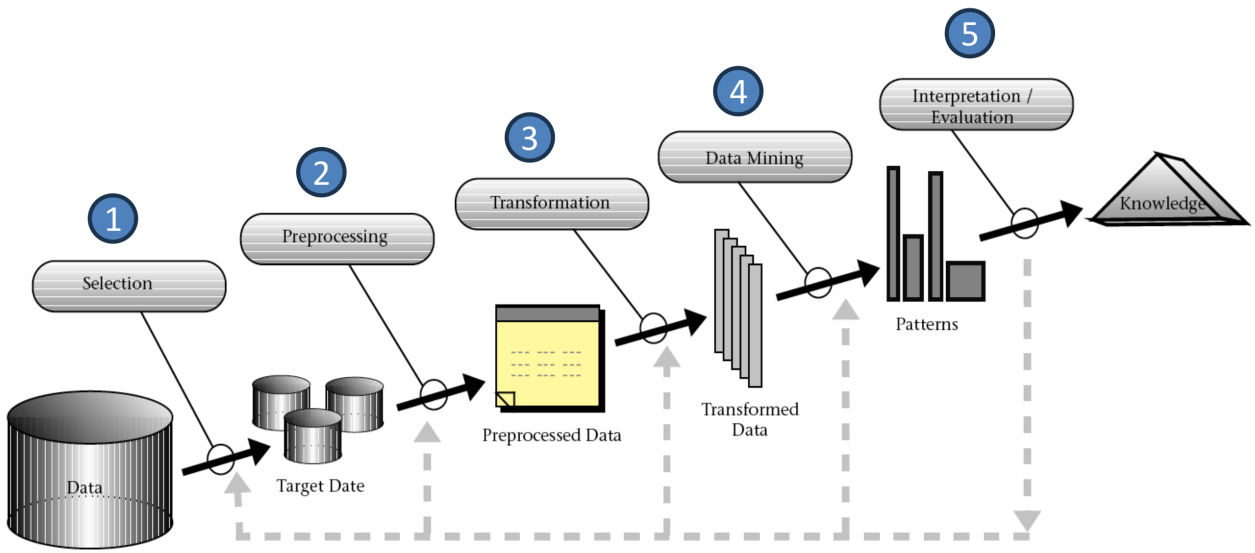
خاستگاه و علوم شکل‌دهنده داده‌کاوی



- **ترکیبی هم‌افزا از چند شاخه علمی:**
  - آمار و احتمالات (Statistics)
  - یادگیری ماشین و هوش مصنوعی (Machine Learning, AI)
  - سامانه‌های مدیریت پایگاه‌داده (Database Systems)
- **چرا روش‌های سنتی آماری پاسخگو نیستند؟**
  - حجم بسیار عظیم داده‌ها (Large amount of data)
  - ابعاد بالا و متغیرهای متعدد (High dimensionality)
  - ماهیت ناهمگون و توزیع‌شده داده‌ها (Heterogeneous, distributed)

فرآیند کشف دانش در داده‌ها (KDD)

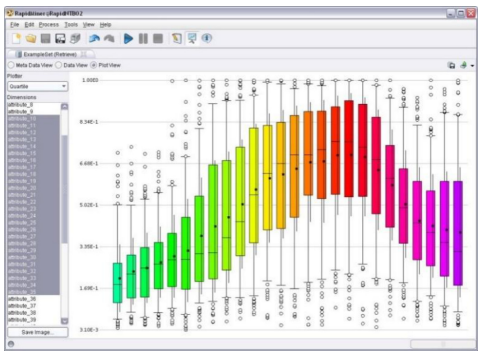
- **مدل کلاسیک فرآیند کشف دانش در پایگاه‌های داده** (Fayyad et al., 1996)

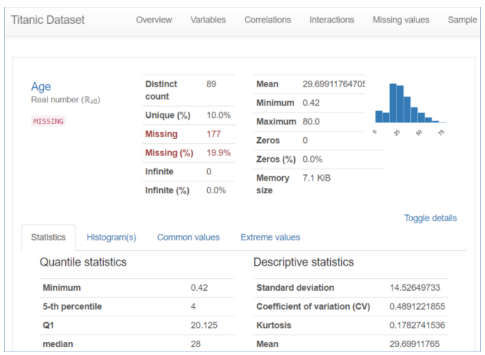


پنج گام اصلی: انتخاب ← پیش‌پردازش ← تبدیل داده‌ها ← داده‌کاوی ← ارزیابی و تفسیر

گام اول – انتخاب و اکتشاف داده‌ها

Selection and Exploration





- **انتخاب داده‌ها (Selection)**
  - چه داده‌هایی در دسترس داریم؟
  - کدام بخش از داده‌ها برای مسئله مد نظر مفید و مرتبط هستند؟
  - از کیفیت، پیشینه و اعتبار داده‌ها چه می‌دانیم؟
- **اکتشاف و پروفایل‌سازی (Exploration / Profiling)**
  - کسب درک و شهود اولیه از ساختار مجموعه‌داده
  - محاسبه آماره‌های توصیفی (میانگین، واریانس، چارک‌ها)
  - مصورسازی و رسم نمودارهای توزیع ویژگی‌ها
  - شناسایی داده‌های پرت (Outliers)، مقادیر گمشده و رکوردهای تکراری

گام‌های دوم و سوم – پیش‌پردازش و تبدیل داده‌ها

Preprocessing and Transformation

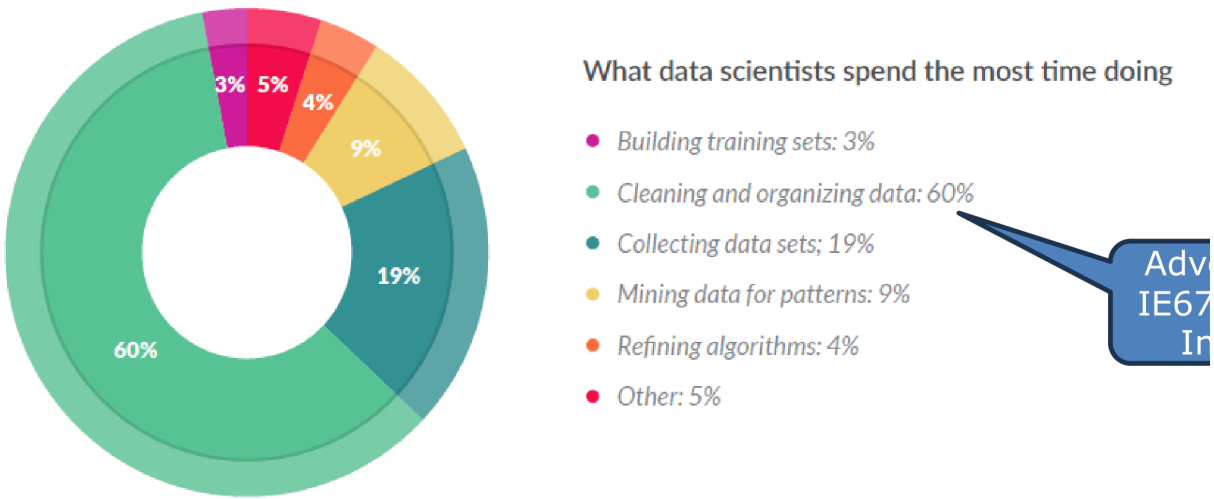


- **تبدیل به فرمت سازگار با الگوریتم‌های داده‌کاوی:**
  - ابعاد ویژگی‌ها: بازنمایی داده با کمترین تعداد مشخصه مناسب
  - مقیاس ویژگی‌ها: اسمی (Nominal)، ترتیبی (Ordinal)، عددی پیوسته
  - حجم داده: هماهنگی با توان محاسباتی و حافظه

- **تکنیک‌های کلیدی مهندسی داده:**
  - گسسته‌سازی و باینری‌کردن متغیرها
  - انتخاب ویژگی (Feature Selection) و کاهش ابعاد (PCA)
  - تبدیل متن به بردارهای وزنی و تعبیه‌ها (Embeddings)
  - تجمیع داده‌ها (Aggregation) و نمونه‌برداری (Sampling)
  - ادغام داده‌ها از منابع ناهمگون سازمانی

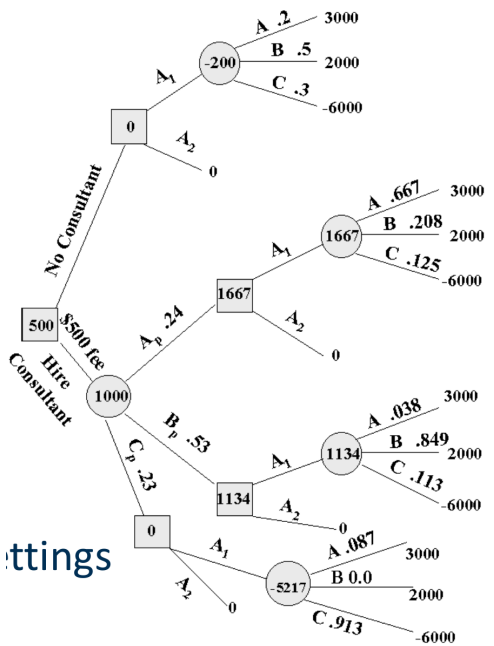
اهمیت و زمان‌بری پیش‌پردازش داده‌ها

- **آماده‌سازی داده‌ها، کلید ساخت مدل‌های معتبر:**
  - کیفیت مدل نهایی مستقیماً وابسته به کیفیت داده‌های ورودی است.
  - طبق گزارش معتبر شرکت CrowdFlower، پاک‌سازی و ادغام داده‌ها حدود **70% – 80%** از زمان و انرژی متخصصان را به خود اختصاص می‌دهد!
- **درس مرتبط در دانشگاه مانهایم:** IE670 Web Data Integration



گام چهارم – داده‌کاوی و یادگیری مدل

Data Mining



- **ورودی:** داده‌های پیش‌پردازش‌شده
- **خروجی:** الگوها و مدل‌های استخراج‌شده

- **فرآیند تکرارشونده و چرخه‌ای:**
  1. اعمال الگوریتم داده‌کاوی روی داده‌ها
  2. ارزیابی عملکرد و کارایی مدل یا الگوها
  3. اصلاح و تکرار چرخه:
     - آزمایش با هایپرپارامترهای مختلف
     - امتحان روش‌ها و الگوریتم‌های جایگزین
     - بازنگری در پیش‌پردازش و مهندسی ویژگی‌ها
     - افزایش کمیت و کیفیت داده‌های آموزش
     - ترکیب نتایج مدل‌های مختلف (Ensemble)

گام پنجم – تفسیر، ارزیابی و ارزش‌آفرینی

Interpretation / Evaluation





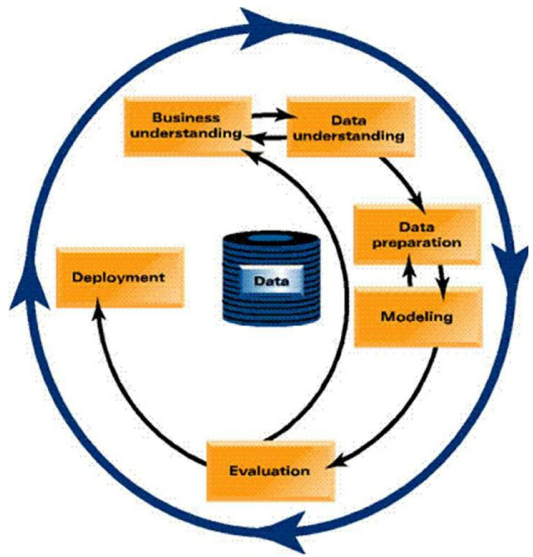


- **خروجی فرآیند داده‌کاوی:**
  - الگوهای کشف‌شده (Patterns)
  - مدل‌های آماری و ریاضیاتی (Models)
- **هدف غایی: خلق ارزش واقعی برای سازمان:**
  - کسب بینش عمیق و دانش عملیاتی (Gain Knowledge)
  - اتخاذ تصمیم‌های آگاهانه‌تر و بهینه (Better Decisions)
  - افزایش درآمد و کاهش هزینه‌ها (Increase Revenue)

استقرار مدل و چرخه فرآیندی CRISP-DM

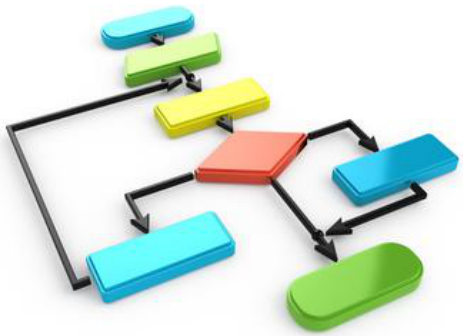
Deployment & CRISP-DM Process Model

- **به‌کارگیری عملیاتی مدل در بستر سیستم‌ها و فرآیندهای کسب‌وکار**
- **تکرار مداوم چرخه به منظور پایش، نگهداری و بهبود مستمر عملکرد مدل**



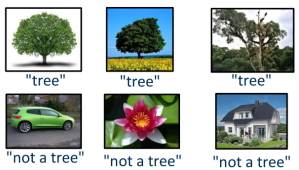
مدل فرآیندی استاندارد کریسپ (CRISP-DM Process Model)

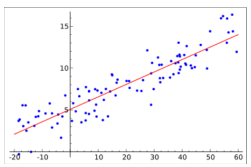
وظایف و کاربردهای داده‌کاوی

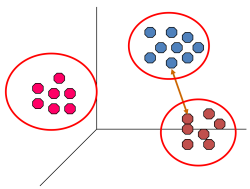


- **وظایف توصیفی** (Descriptive Tasks)
  - کشف الگوها و ساختارهای پنهان در بطن داده‌ها
  - **مثال:** کدام کالاها معمولاً همراه با یکدیگر خریداری می‌شوند؟
- **وظایف پیش‌بینانه** (Predictive Tasks)
  - تخمین مقادیر نامعلوم یک متغیر هدف بر اساس مشاهدات گذشته
  - **مثال:** آیا کاربر روی تبلیغ آنلاین کلیک خواهد کرد؟
- **اصطلاحات متناظر در یادگیری ماشین:**
  - توصیفی ≡ Unsupervised Learning (یادگیری بدون نظارت)
  - پیش‌بینانه ≡ Supervised Learning (یادگیری بانظارت)

چهار دسته اصلی وظایف داده‌کاوی



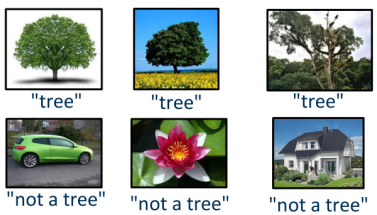






- **دسته‌بندی** (Classification) **[Predictive]**
  - پیش‌بینی برچسب‌های کیفی یا رده‌ها (وظیفه پیش‌بینانه)
- **رگرسیون** (Regression) **[Predictive]**
  - تخمین مقادیر کمی و عددی پیوسته (وظیفه پیش‌بینانه)
- **تحلیل خوشه‌بندی** (Cluster Analysis) **[Descriptive]**
  - گروه‌بندی داده‌های مشابه بدون برچسب (وظیفه توصیفی)
- **تحلیل وابستگی** (Association Analysis) **[Descriptive]**
  - کشف قوانین هم‌آیی میان اقلام سبد خرید (وظیفه توصیفی)

مسئله دسته‌بندی
Classification



- **تعریف هدف:**
  - تخصیص دقیق رکوردهای جدید و دیده‌نشده به یکی از کلاس‌های از پیش تعیین‌شده با بالاترین دقت ممکن.
- **رویکرد یادگیری:**
  - با داشتن مجموعه‌ای از داده‌های آموزشی (Training Set):
    - هر رکورد شامل مجموعه‌ای از ویژگی‌ها (Attributes) است.
    - یکی از ویژگی‌ها، برچسب کلاس هدف (Class Label) است.
  - برازش مدلی که برچسب کلاس را به عنوان تابعی از سایر ویژگی‌ها پیش‌بینی کند:

$$y = f(\mathbf{x}) = f(x_1, x_2, \ldots, x_d)$$

مثال شهودی مسئله دسته‌بندی

تشخیص درخت (Tree) از غیر درخت (Not a Tree)

نمونه‌های مثبت (کلاس درخت – "tree")



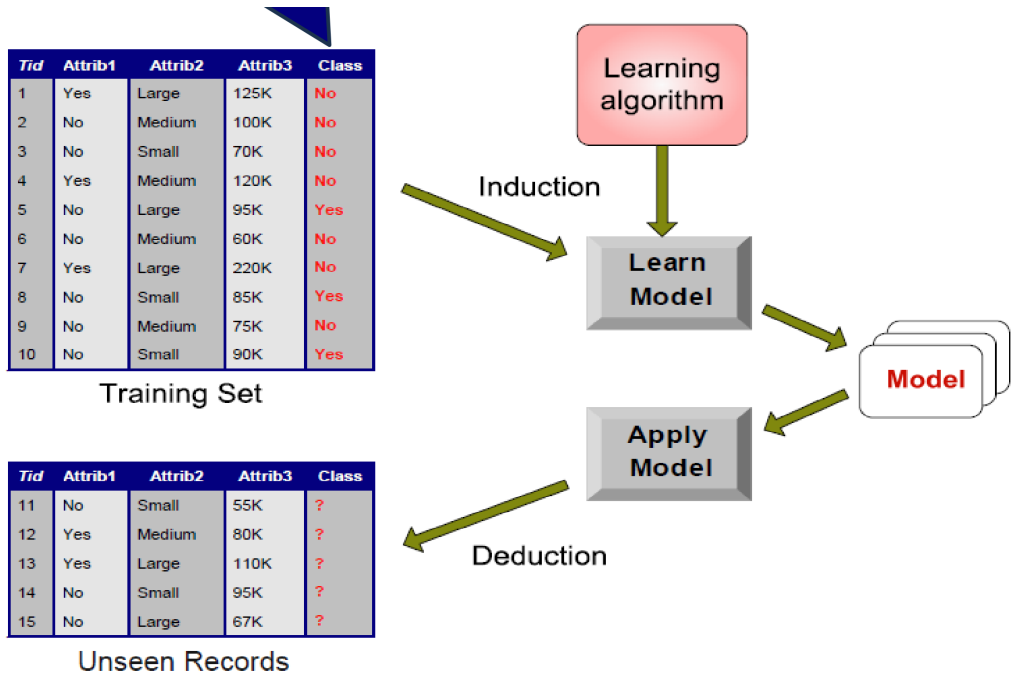


نمونه‌های منفی (کلاس غیر درخت – "not a tree")





جریان کاری و مراحل مدل‌سازی دسته‌بندی



آموزش مدل روی داده‌های برچسب‌دار و ارزیابی روی داده‌های آزمون برای پیش‌بینی برچسب ناشناخته

کاربردهای عملی دسته‌بندی

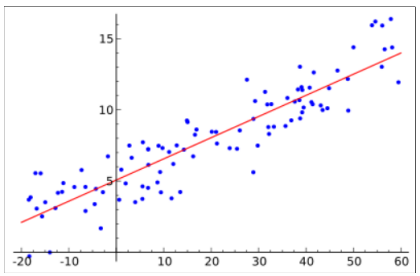


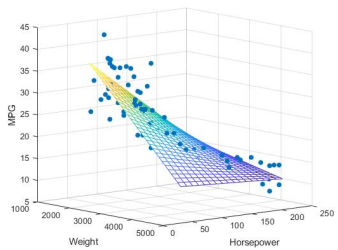




- **ارزیابی ریسک اعتباری بانکی** (Credit Risk)
  - **ویژگی‌ها:** سن، سطح درآمد، بدهی‌های جاری، سابقه مالی
  - **کلاس:** اعطای وام توسط بانک؟ (بله / خیر)
- **تشخیص ایمیل‌های هرزنامه** (SPAM Detection)
  - **ویژگی‌ها:** کلمات متن، فیلدهای هدر ایمیل، فرستنده
  - **کلاس:** ایمیل عادی (Ham) یا هرزنامه (Spam)
- **کشف تقلب در اظهارنامه‌های مالیاتی** (Tax Fraud)
  - **ویژگی‌ها:** ارقام و نسبت‌های مالیاتی اظهارشده
  - **کلاس:** سوءاستفاده مالیاتی؟ (نیازمند بازرسی / عادی)

مسئله رگرسیون (Regression)

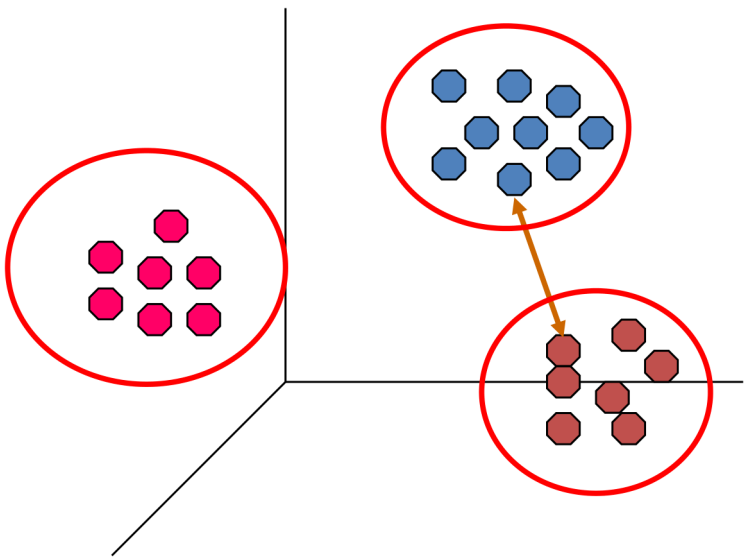




- **پیش‌بینی متغیرهای عددی و پیوسته:**
  - تخمین مقدار یک ویژگی پیوسته بر پایه سایر متغیرها
  - برازش مدل‌های رگرسیون خطی یا غیرخطی
- **نمونه‌های کاربردی:**
  - پیش‌بینی قیمت مسکن، خودرو یا ارزش دارایی‌ها
  - پیش‌بینی حجم فروش بر پایه بودجه تبلیغاتی
  - تخمین مصرف سوخت خودرو (MPG) بر پایه وزن و توان

- **تفاوت بنیادین با دسته‌بندی:** رگرسیون متغیر پیوسته عددی را تخمین می‌زند، در حالی که دسته‌بندی برای برچسب‌های کیفی و گسسته به کار می‌رود.

تحلیل خوشه‌بندی (Cluster Analysis)

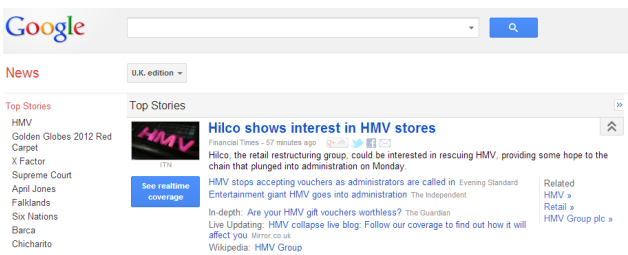


- **تعریف هدف:**
  - گروه‌بندی داده‌ها بر مبنای شباهت ذاتی:
  - شباهت بیشینه میان اعضای درون هر خوشه
  - شباهت کمینه میان اعضای خوشه‌های مجزا
- **معیارهای شباهت** (Similarity Measures)
  - فاصله اقلیدسی برای متغیرهای پیوسته
  - شباهت کسینوسی یا جاکارد
- **اهداف بهینه‌سازی:**
  - کمینه‌سازی فواصل درون‌خوشه‌ای (Intra-cluster)
  - بیشینه‌سازی فواصل بین‌خوشه‌ای (Inter-cluster)

کاربردهای عملی خوشه‌بندی



- **کاربرد اول – بخش‌بندی بازار** (Market Segmentation)
  - شناسایی خوشه‌های مشتریان با رفتار مشابه
  - طراحی کمپین‌های تبلیغاتی متناسب برای هر بخش



- **کاربرد دوم – خوشه‌بندی اسناد متنی** (Document Clustering)
  - گروه‌بندی خودکار اخبار بر مبنای واژگان
  - نمونه: تجمیع اخبار در اخبار گوگل (Google News)

تحلیل وابستگی (Association Analysis)

- **صورت مسئله:** تراکنش‌های سبد خرید شامل مجموعه‌ای از اقلام
- **هدف:** کشف مجموعه‌های مکرر و استخراج قوانین وابستگی جهت پیش‌بینی

شناسه (TID)	اقلام خریداری‌شده (Items)
۱	Bread, Coke, Milk
۲	Beer, Bread
۳	Beer, Coke, Diaper, Milk
۴	Beer, Bread, Diaper, Milk
۵	Coke, Diaper, Milk

مجموعه‌های مکرر (Frequent Itemsets)

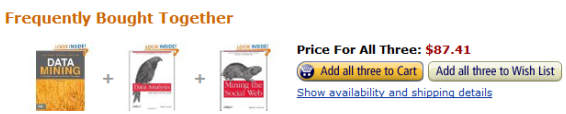
{Diaper, Milk, Beer}
{Milk, Coke}

قوانین وابستگی (Association Rules)

$\{Diaper, Milk\} \rightarrow \{Beer\}$
$\{Milk\} \rightarrow \{Coke\}$

کاربردهای عملی قواعد وابستگی

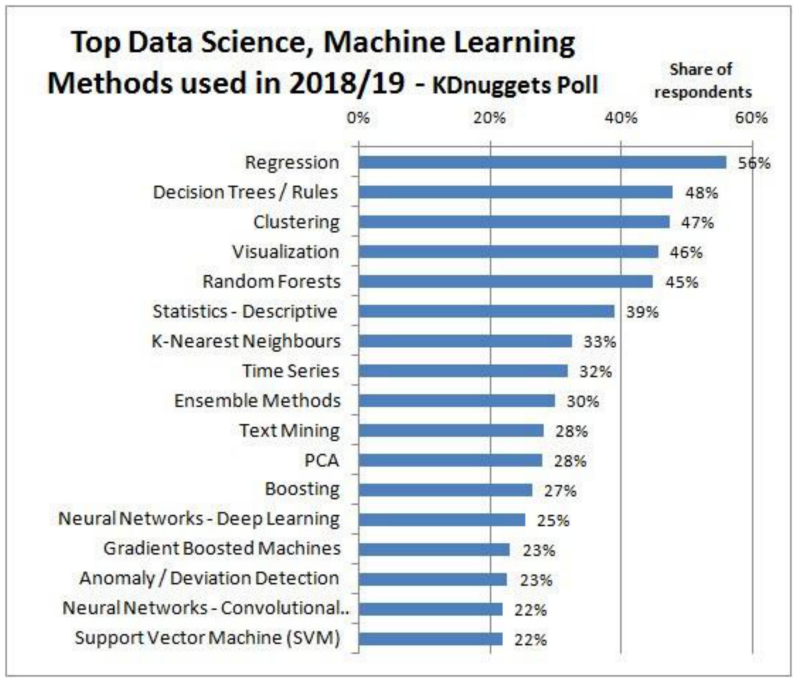




- **مدیریت چیدمان قفسه‌ها** (Shelf Management)
  - شناسایی کالاهایی که با هم خریده می‌شوند
  - پردازش داده‌های بارکدخوان صندوق فروشگاه
- **ترفیع فروش و پیشنهادهای مکمل** (Sales Promotion)
  - طراحی تخفیف‌های ترکیبی روی اقلام مرتبط
  - پیشنهاد خودکار اقلام مکمل در فروشگاه اینترنتی

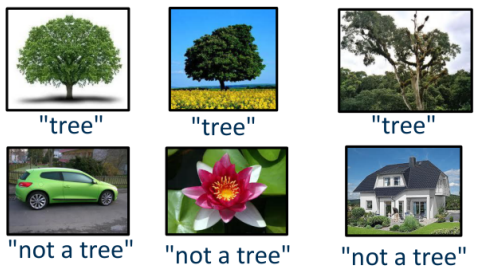
کدام روش‌ها در عمل بیشترین کاربرد را دارند؟

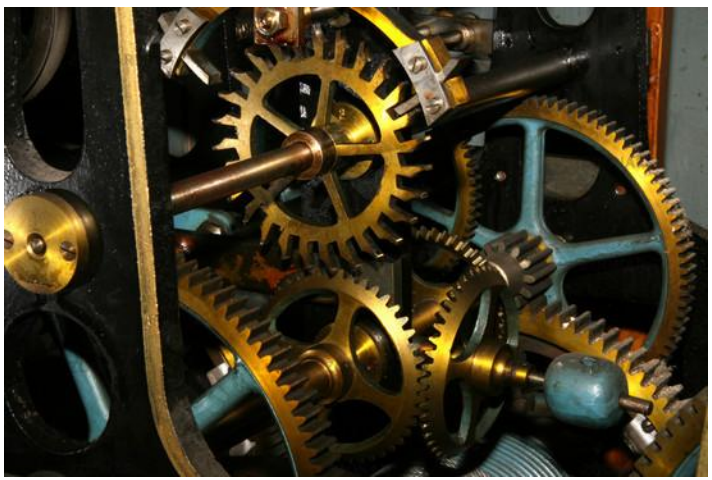
- **نظرسنجی معتبر پایگاه KDnuggets از فعالان صنعت داده:**



رگرسیون، درخت‌های تصمیم و خوشه‌بندی همچنان در صدر پرکاربردترین متدهای صنعتی قرار دارند

خانواده الگوریتم‌های دسته‌بندی



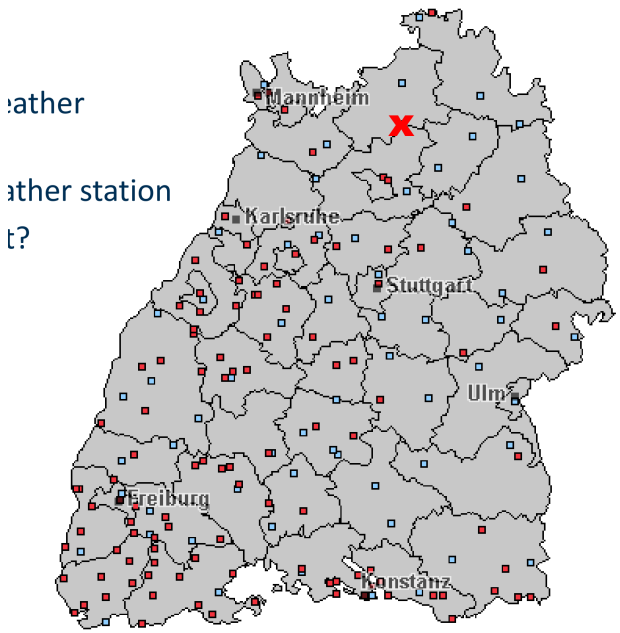


- **ماهیت یادگیری دسته‌بندی:**
  - به رایانه مجموعه‌ای از مثال‌های برچسب‌دار ارائه می‌شود.
  - رایانه یاد می‌گیرد رکوردهای جدید (بدون برچسب) را دسته‌بندی کند.

- **مهم‌ترین الگوریتم‌ها:**
  - نزدیک‌ترین همسایگان (k-Nearest-Neighbors)
  - درخت‌های تصمیم (Decision Trees)
  - بیز ساده (Naïve Bayes)
  - ماشین‌های بردار پشتیبان (SVM)
  - شبکه‌های عصبی مصنوعی (ANN)
  - یادگیری عمیق (Deep Learning)

الگوریتم نزدیک‌ترین همسایگان (k-NN)

طرح مسئله پیش‌بینی آب‌وهوا

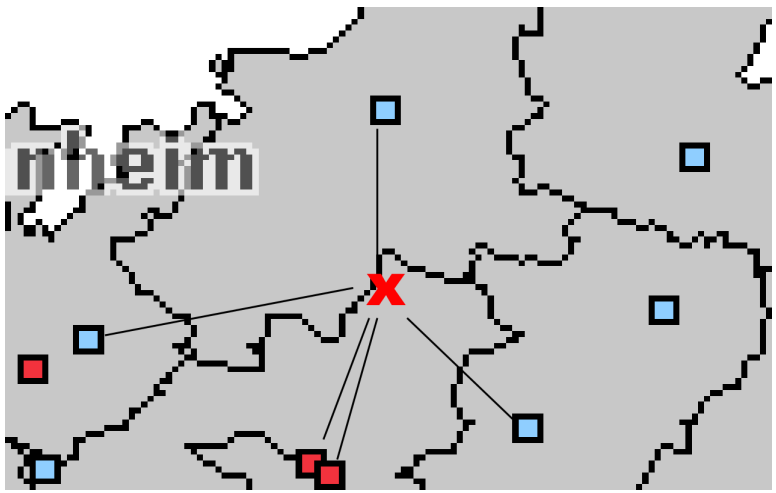


- **صورت مسئله:**
  - قصد داریم وضعیت هوای فعلی را در نقطه‌ای مشخص (علامت x) پیش‌بینی کنیم.
  - در این نقطه مشخص هیچ ایستگاه هواشناسی مستقر نیست!
  - چگونه می‌توانیم این پیش‌بینی را با دقت انجام دهیم؟

- **علائم راهنما:**
  - **قرمز:** آفتابی (Sunny)
  - **آبی:** ابری (Cloudy)

الگوریتم نزدیک‌ترین همسایگان (k-NN)

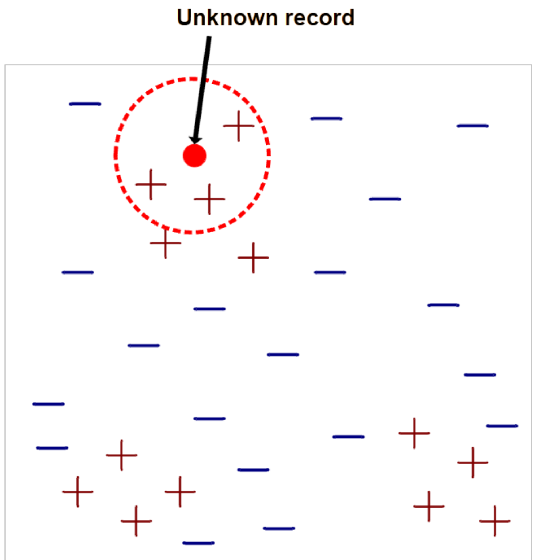
ایده اصلی و شهود حل مسئله



- **ایده بنیادین:**
  - استفاده از میانگین یا رأی اکثریت نزدیک‌ترین ایستگاه‌ها!
- **مثال عددی با** $k = 5$
  - 2 ایستگاه آفتابی (قرمز)
  - 3 ایستگاه ابری (آبی)
  - $\Rightarrow$ **نتیجه پیش‌بینی: ابری (Cloudy)**
- **نام‌گذاری روش:**
  - k تعداد همسایگان بررسی‌شده است ($k = 5$).
  - «نزدیکی» دلالت بر مجاورت در فضای ویژگی‌ها (اینجا فاصله جغرافیایی) دارد.

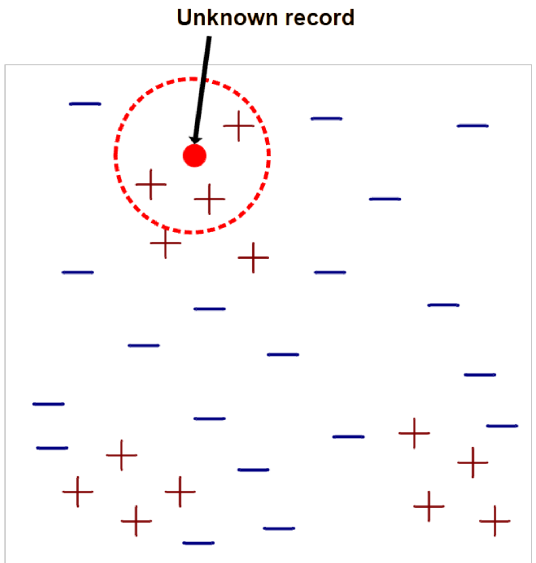
سه پیش‌نیاز اصلی دسته‌بند k-NN

- **برای پیاده‌سازی دسته‌بند k-NN به سه مؤلفه نیاز است:**
  ۱. **مجموعه رکوردهای آموزشی** – داده‌های ذخیره‌شده با برچسب‌های معتبر کلاس
  ۲. **معیار فاصله** (Distance Metric) – تابعی برای محاسبه فاصله بین رکوردها
  ۳. **تعیین پارامتر** *k* – تعداد نزدیک‌ترین همسایگان برای رأی‌گیری



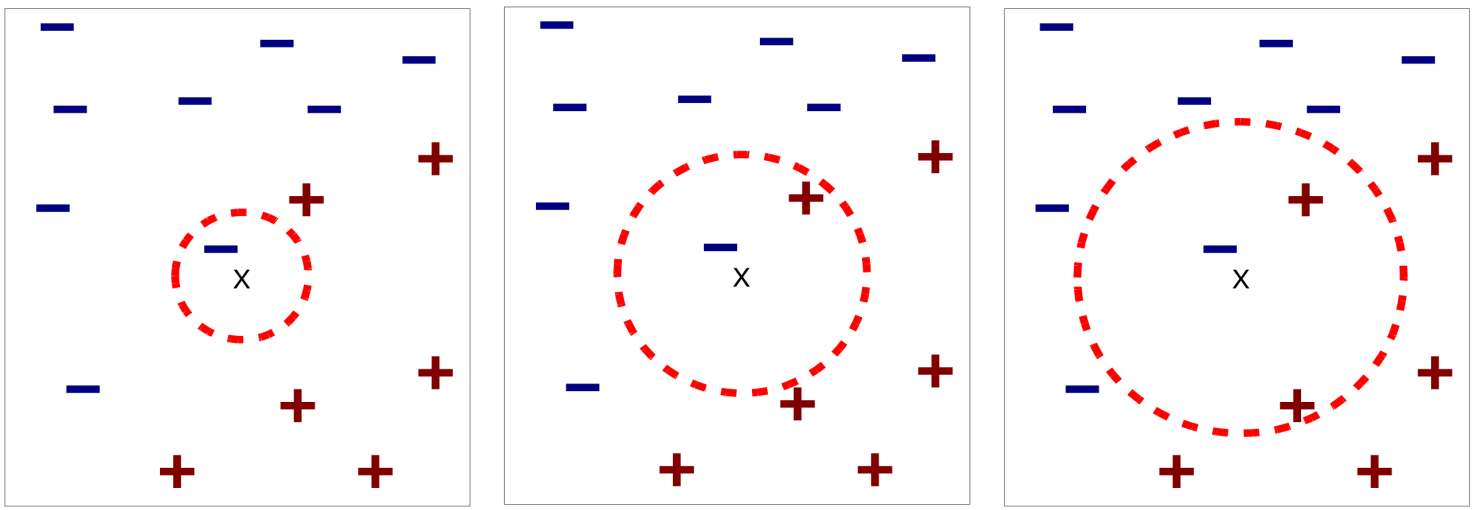
مراحل الگوریتم دسته‌بندی k-NN

۱. محاسبه فاصله نقطه جدید تا تمام نمونه‌های آموزشی
۲. مرتب‌سازی و انتخاب k نمونه دارای کمترین فاصله
۳. برچسب‌گذاری نقطه جدید با برچسب‌های این k همسایه:
   - **رأی اکثریت ساده** (Majority Vote)
   - **رأی وزن‌دار با معکوس فاصله** (Distance-Weighted)



نمونه‌هایی از انتخاب همسایگان در الگوریتم k-NN

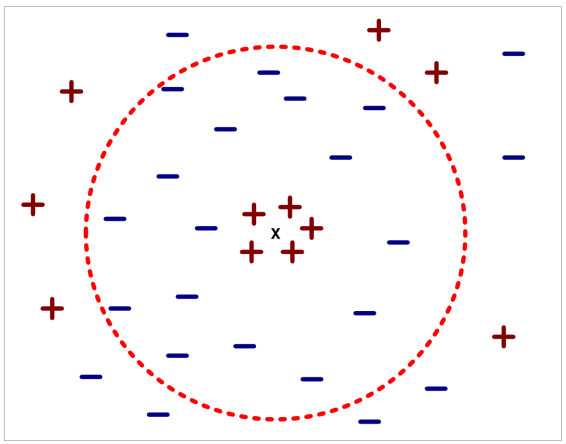
- **تعریف همسایگی:** همسایگان نزدیک برای یک نمونه داده x، نقاطی از داده‌ها هستند که کمترین فاصله را تا x دارند.



(a) 1-nearest neighbor (b) 2-nearest neighbor (c) 3-nearest neighbor

انتخاب مقدار بهینه برای پارامتر k

- **اگر مقدار k بسیار کوچک باشد (مانند $k = 1$) –** مدل به‌شدت به نویزها و داده‌های پرت حساس شده و دچار بیش‌برازش (Overfitting) می‌گردد.
- **اگر مقدار k بسیار بزرگ باشد:** ناحیه همسایگی گسترده شده و نقاطی از کلاس‌های دیگر در تصمیم اثر می‌گذارند.



قاعده تجربی (Rule of Thumb) – ارزیابی مقادیر k در بازهٔ 1 تا 20 به کمک اعتبارسنجی متقاطع.

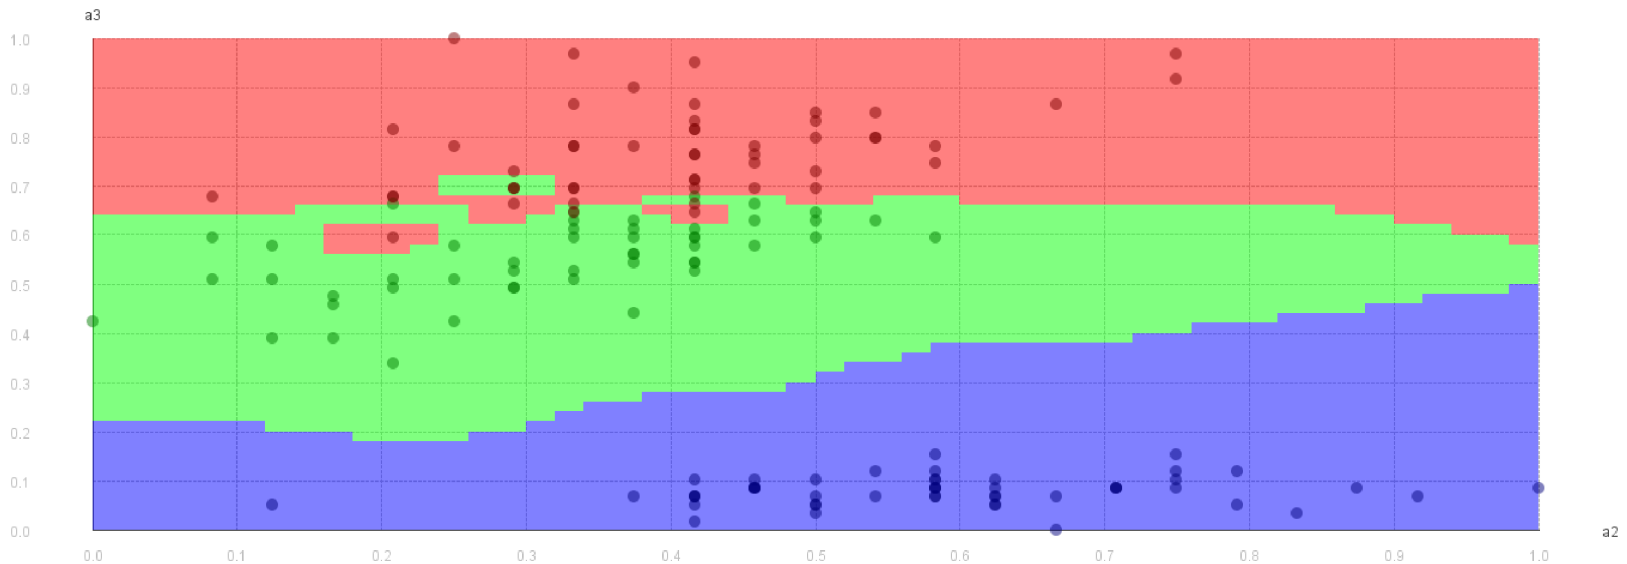
تحلیل و ارزیابی دسته‌بند k-NN

- **نقاط قوت و دقت بالا:**
  - در بسیاری از مسائل دسته‌بندی عملکرد بسیار چشمگیری دارد (مانند بازشناسی نوری حروف OCR).
  - قادر است مرزهای تصمیم‌گیری پیچیده و غیرموازی با محورها را به‌خوبی مدل‌سازی کند (برخلاف درخت‌های تصمیم ساده).

- **چالش‌ها و ملاحظات عملی:**
  - **سرعت کند در زمان آزمون** (Lazy Learner) – مدل‌سازی قبلی ندارد و در لحظه پیش‌بینی باید با تمام داده‌های آموزشی مقایسه شود.
  - **حساسیت به مقیاس و فاصله:** نیاز به نرمال‌سازی متغیرها و انتخاب وزن مناسب برای ویژگی‌ها.

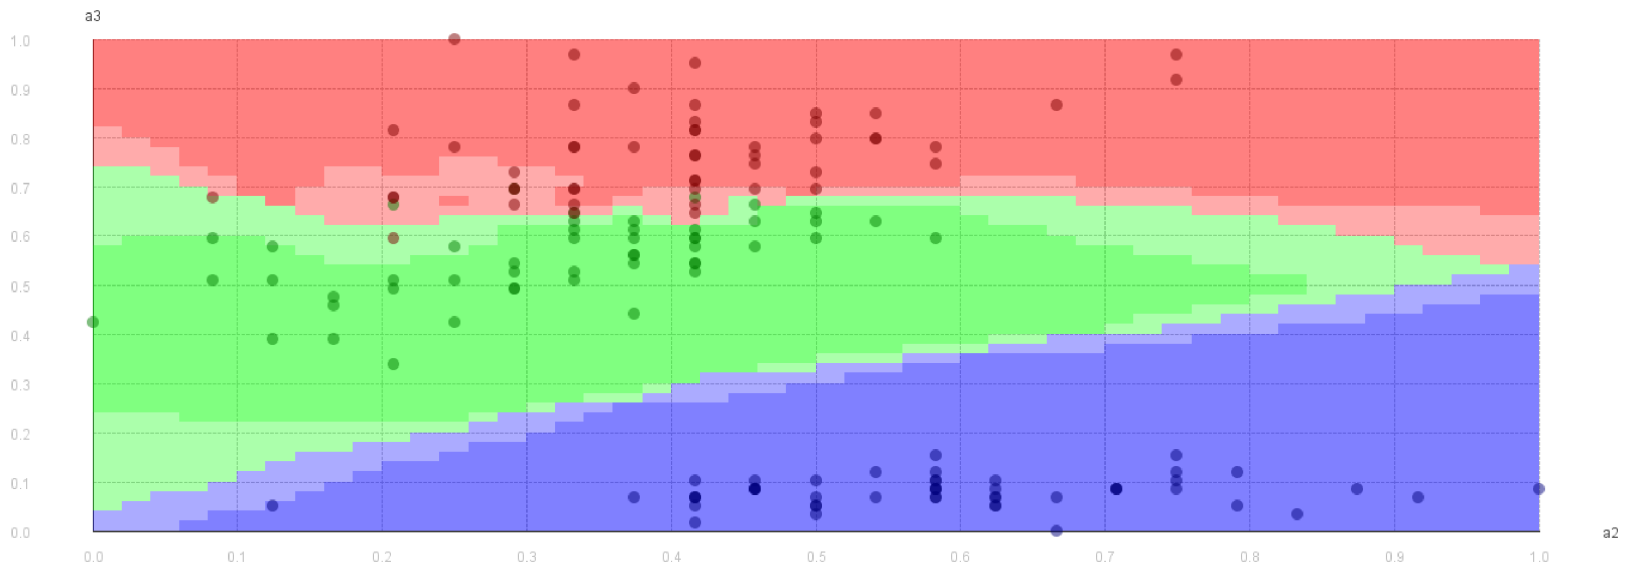
مرزهای تصمیم‌گیری در دسته‌بند k-NN (حالت $k = 1$)

- در حالت $k = 1$، تک‌تک نقاط نویز مستقیماً مرزهای تصمیم‌گیری را تغییر داده و ساختار پیچیده ایجاد می‌کنند:



مرزهای تصمیم‌گیری در دسته‌بند k-NN (حالت $k = 3$)

- با افزایش تعداد همسایگان به $k = 3$، مرزها هموارتر شده و اثر نویزها تا حد زیادی کاهش می‌یابد:



آنچه در این درس خواهید آموخت



- **وظایف اصلی و رایج داده‌کاوی:**
  - پیش‌پردازش، پاک‌سازی و مهندسی داده‌ها
  - الگوریتم‌های دسته‌بندی و پیش‌بینی
  - تکنیک‌های خوشه‌بندی و تحلیل بدون نظارت
  - کاوش قوانین وابستگی و سبد خرید
- **مهارت‌های عملی و نظری:**
  - درک ریاضی و منطق پشت الگوریتم‌ها
  - نحوه و شرایط کاربرد هر متد در مسائل واقعی
  - تفسیر درست و علمی خروجی‌ها و شاخص‌های ارزیابی

پایان جلسه و گام‌های بعدی

با سپاس از توجه شما

آیا پرسش یا ابهامی باقی مانده است؟

در جلسه آینده: مبانی آماده‌سازی، کاوش و پیش‌پردازش داده‌ها

UNIVERSITY OF MANNHEIM
School of Business Informatics and Mathematics