دانشگاه مانهایم | گروه علوم داده و وب

طبقه‌بندی داده‌ها (بخش ۱)

IE500 داده‌کاوی



نسخه 16.09.2024

سرفصل مطالب

- **درخت‌های تصمیم (Decision Trees)**
  - ساختار درخت، مرزهای تصمیم، الگوریتم هانت و روش‌های تفکیک
- **معیار خلوص جینی (Gini Impurity Index)**
  - فرمول ریاضی، نحوه محاسبه برای ویژگی‌های اسمی، ترتیبی و پیوسته
- **پدیده بیش‌برازش (Overfitting)**
  - علل، نشانه‌ها، تیغ اوکام و راهکارهای پیشگیری (هرس اولیه و یادگیری جمعی)
- **الگوریتم‌های یادگیری جمعی (Ensembles)**
  - جنگل‌های تصادفی (Random Forest) و XGBoost
- **معیارهای ارزیابی مدل (Evaluation Metrics)**
  - ماتریس درهم‌ریختگی، صحت، دقت، بازخوانی، معیار F1، ارزیابی هزینه‌محور و منحنی‌های ROC

مقدمه‌ای بر طبقه‌بندی داده‌ها

تعریف هدف اصلی

- **هدف اصلی:** یادگیری یک مدل برای تشخیص و شناسایی یک مفهوم (برای نمونه: «درخت»)



"tree"



"tree"



"tree"



"not a tree"



"not a tree"



"not a tree"

مقدمه‌ای بر طبقه‌بندی

یادگیری مفهوم و چالش‌های تعمیم



- **مثال: یادگیری یک مفهوم جدید، مثلاً «درخت»**
  - مشاهده نمونه‌های مثبت و منفی (داده‌های آموزش Training data)
  - استخراج یک مدل؛ برای مثال: «درختان، گیاهان بزرگ و سبزرنگی هستند»
- **هدف: طبقه‌بندی نمونه‌های ندیده و جدید (Unseen instances)**



Warning:
Models are only approximating examples!
Not guaranteed to be correct or complete!

گردش کار طبقه‌بندی داده‌ها

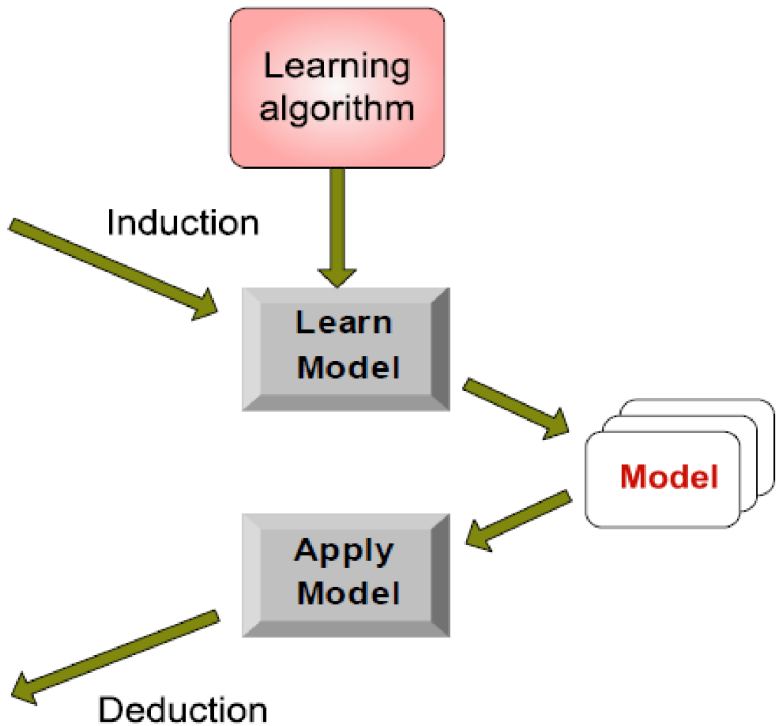
چرخه کامل یادگیری و ارزیابی

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Training Set

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

Unseen Records



یادگیری تنبل در برابر یادگیری مشتاق
Lazy vs. Eager Learning

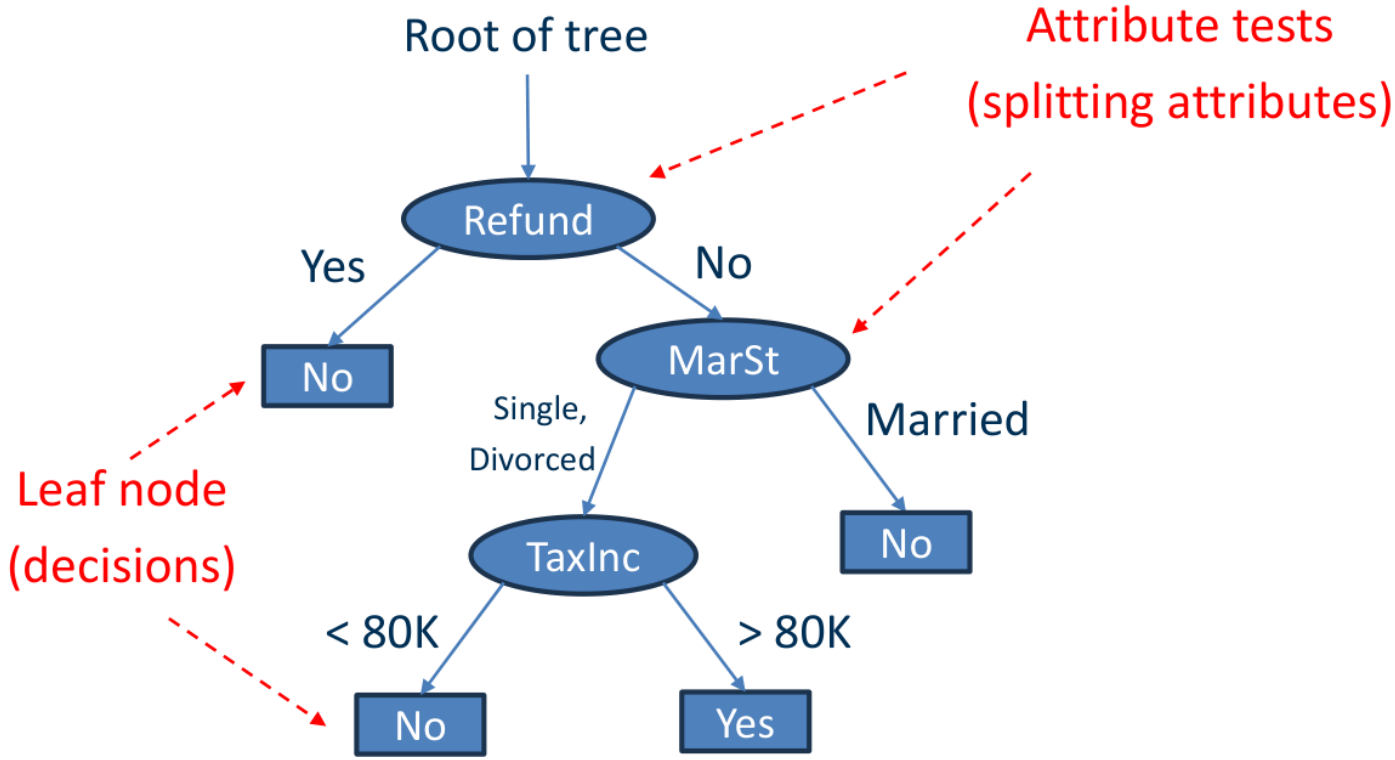
- **یادگیری تنبل:** (Lazy Learning)
  - روش‌های مبتنی بر نمونه (Instance-based) مانند الگوریتم k-NN
  - هیچ مدلی را از پیش به صورت صریح استخراج و ذخیره نمی‌کنند.
  - فرآیند «یادگیری» و محاسبات تنها در زمان تقاضا برای طبقه‌بندی یک رکورد جدید انجام می‌شود.
  - **تک‌هدف:** پیش‌بینی برچسب رکوردهای جدید با حداکثر دقت ممکن.

- **یادگیری مشتاق:** (Eager Learning)
  - یک مدل صریح و ساختاریافته پیش از رسیدن داده‌های جدید ساخته می‌شود.
  - **دو هدف اساسی:**
    ۱. طبقه‌بندی دقیق رکوردهای نامشاهده‌شده و جدید
    ۲. درک و تحلیل ساختار حوزه کاربرد به شکلی قابل‌تفسیر برای انسان (Explainable AI)
  - **نمونه‌های بارز:** درخت‌های تصمیم (Decision Trees)، رگرسیون لجستیک

طبقه‌بندهای درخت تصمیم

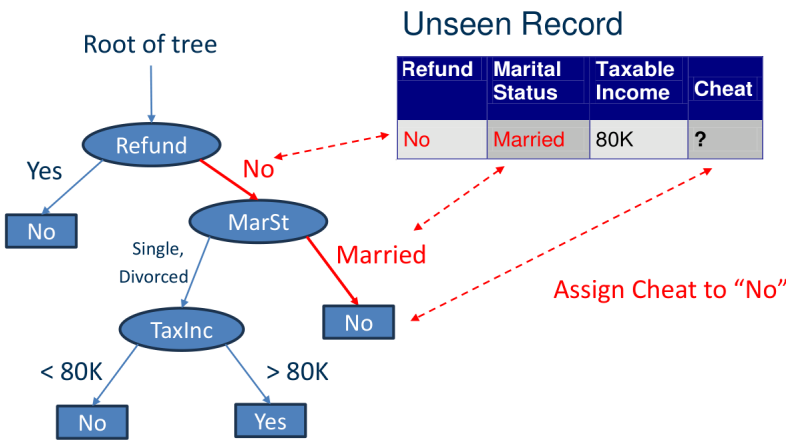
Decision Tree Classifiers

- **تعریف:** درخت تصمیم ساختاری سلسله‌مراتبی است که یک رویه منسجم را برای اتخاذ تصمیم طبقه‌بندی کدگذاری می‌کند.



اعمال درخت تصمیم بر داده‌های جدید

مسیر ارزیابی یک رکورد نامشاهده‌شده



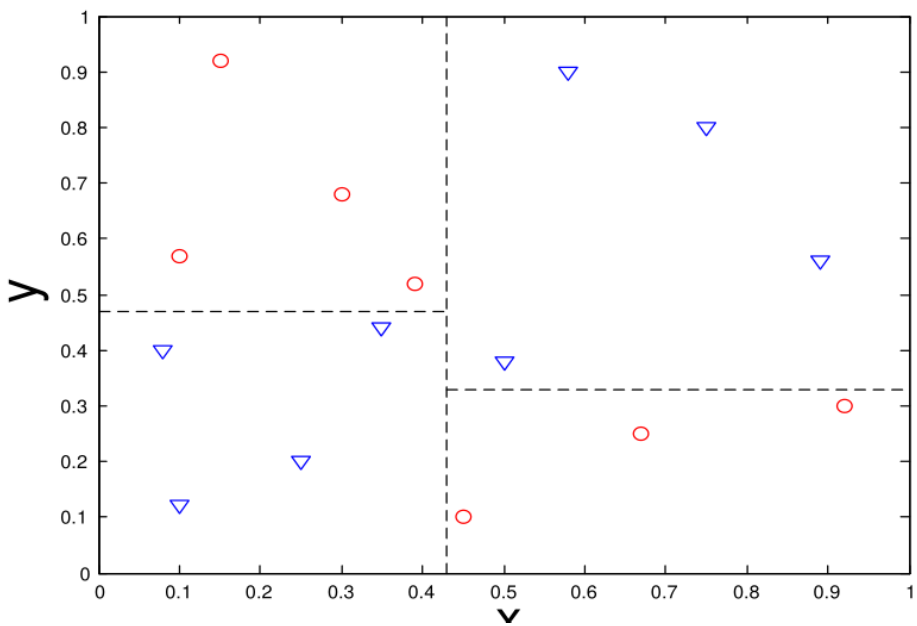
رکورد نامشاهده‌شده (Unseen Record)

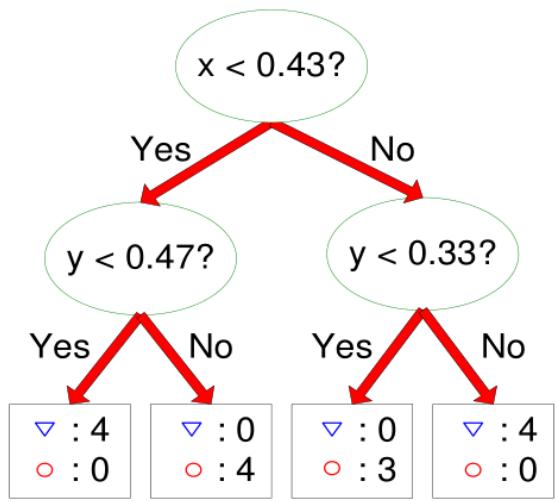
Cheat	Taxable	Marital	Refund
؟	۸۰K	Married	No

- **ردگیری گام‌به‌گام:**
  ۱. آزمون ریشه (Refund) – مقدار برابر `No` است → شاخه راست
  ۲. آزمون دوم (Marital) – وضعیت `Married` است → شاخه چپ
  ۳. رسیدن به گره برگ: اختصاص برچسب **Cheat = "No"**

مرزهای تصمیم در درخت تصمیم
Decision Boundaries

- **تعامد با محورها:** مرزهای تصمیم در درخت‌های تصمیم همواره موازی با محورهای مختصات هستند (Axis-parallel)؛ زیرا هر شرط آزمون در هر مرحله تنها یک ویژگی را به تنهایی بررسی می‌کند.





یادگیری و القای درخت تصمیم
Learning a Decision Tree

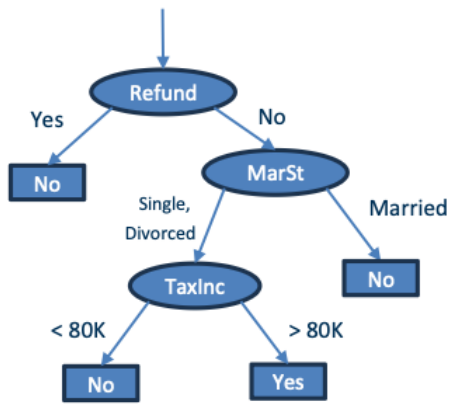
- **چالش بهینه‌سازی:** یافتن درخت تصمیم بهینه سراسری از نظر محاسباتی یک مسئله NP-hard است.
- **استراتژی تقسیم و حل:** الگوریتم‌ها از یک رویکرد (Divide and Conquer) حریصانه (Greedy)، بالا به پایین (Top-down) و افراز بازگشتی برای ساخت یک درخت منطقی استفاده می‌کنند.

- **الگوریتم‌های ارائه‌شده:**
  - الگوریتم هانت (Hunt's)
  - الگوریتم ID3
  - الگوریتم C4.5
  - الگوریتم CHAID

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Training Data

Learning Algorithm

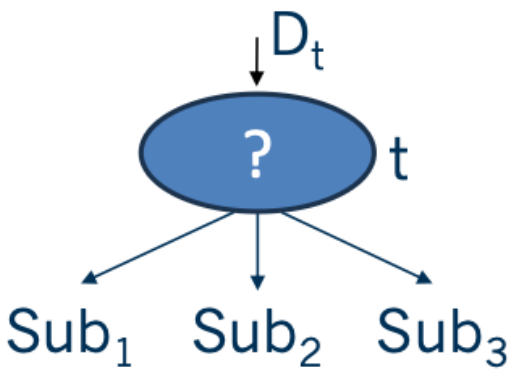


Model: Decision Tree

الگوریتم هانت
Hunt's Algorithm

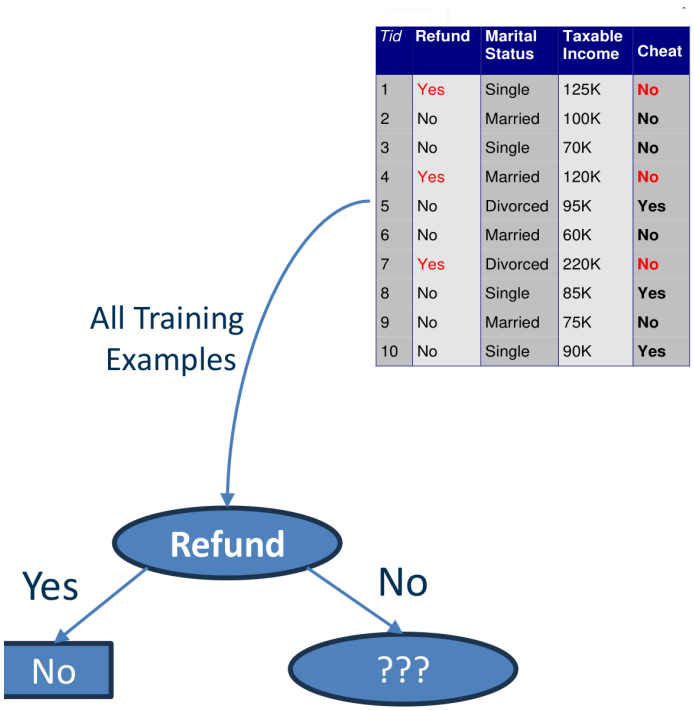
- فرض کنید D_t مجموعه نمونه‌های آموزشی باشد که به گره t می‌رسند.
- **تولید گره برگ یا آزمون ویژگی:**
  - اگر تمام رکوردهای D_t به یک کلاس واحد y_t تعلق داشته باشند، آنگاه t یک **گره برگ** با برچسب y_t خواهد بود.
  - اگر D_t شامل رکوردهایی از بیش از یک کلاس باشد، از یک **آزمون ویژگی** برای تفکیک داده‌ها به زیرمجموعه‌های با خلوص بالاتر استفاده می‌شود.
- **انتخاب آزمون بهینه:** برای تمام آزمون‌های ممکن، خلوص محاسبه شده و آزمونی که خالص‌ترین افراز را بدهد برگزیده می‌شود.
- این رویه به صورت **بازگشتی** بر روی هر زیرمجموعه اعمال می‌شود.

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes



الگوریتم هانت – گام ۱

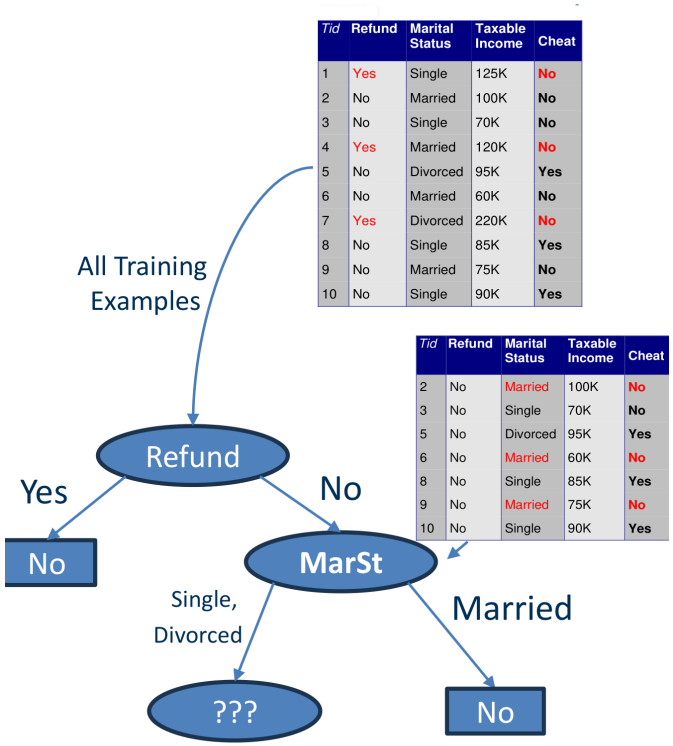
انتخاب اولین تفکیک خلوص



- **محاسبه خلوص زیرمجموعه‌ها** برای تمام ویژگی‌ها:
  - خلوص تفکیک روی بازپرداخت (Refund)
  - خلوص تفکیک روی وضعیت تأهل (Marital Status)
  - خلوص تفکیک روی درآمد مشمول مالیات (Taxable Income)
- **نتیجه:** تفکیک بر اساس ویژگی Refund خالص‌ترین زیرمجموعه‌ها را ایجاد می‌کند.

الگوریتم هانت – گام ۲

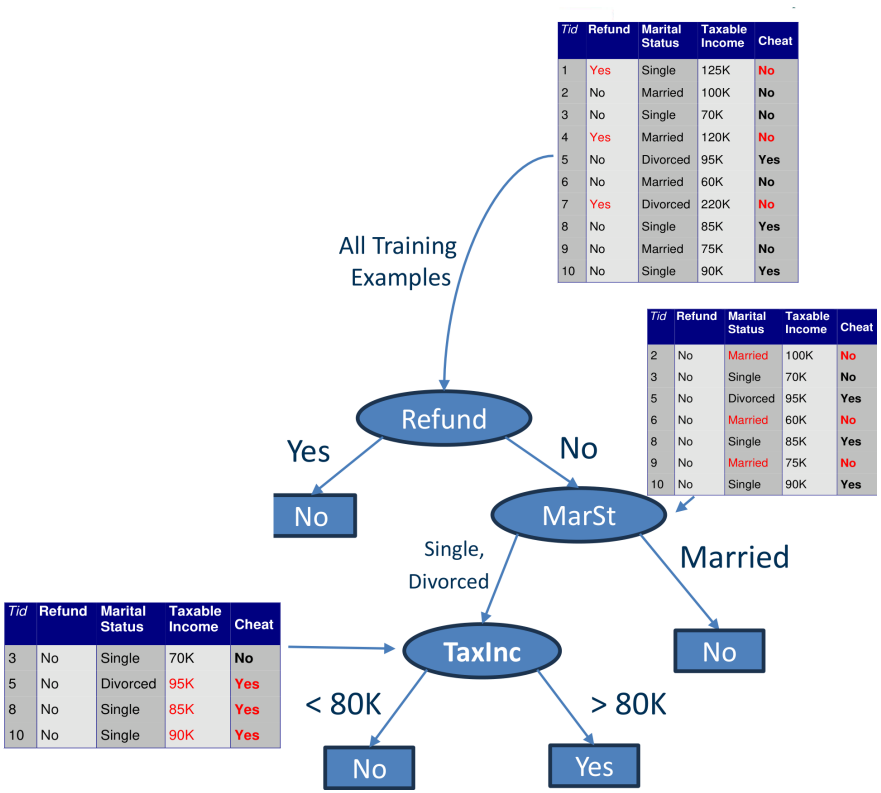
تفکیک رکوردهای شاخه Refund = No



- بررسی ۷ رکورد با شرط `Refund = No`
- آزمون مجدد ویژگی‌های باقیمانده بر روی این زیرمجموعه
- **نتیجه:** تفکیک بر اساس وضعیت تأهل (Marital Status) بالاترین خلوص را دارد
  - افراد متأهل (Married) همه Cheat = No (برگ خالص)
  - مجرد و طلاق‌گرفته: نامتعادل (نیازمند انشعاب بیشتر)

الگوریتم هانت – گام ۳

تکمیل درخت و خالص‌سازی تمامی برگ‌ها



Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Tid	Refund	Marital Status	Taxable Income	Cheat
2	No	Married	100K	No
3	No	Single	70K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Tid	Refund	Marital Status	Taxable Income	Cheat
3	No	Single	70K	No
5	No	Divorced	95K	Yes
8	No	Single	85K	Yes
10	No	Single	90K	Yes

- بررسی رکوردهای زیرمجموعه Single / Divorced (۴ رکورد)
- تفکیک روی درآمد مشمول مالیات (Taxable Income)

$$\text{Income} < 80\text{K} \implies \text{Cheat} = -\text{No}$$

$$\text{Income} \geq 80\text{K} \implies \text{Cheat} = -\text{Yes}$$

- **شرط توقف:** تمام گره‌ها خالص شده و الگوریتم خاتمه می‌یابد.

چالش‌های کلیدی در القای درخت تصمیم

Tree Induction Issues

- **مسئله اول: چگونگی تفکیک نمونه‌ها (How to split records?)**
  - نحوه تعریف شرایط آزمون برای انواع ویژگی‌ها:
    - ویژگی‌های اسمی (Nominal)
    - ویژگی‌های ترتیبی (Ordinal)
    - ویژگی‌های عددی و پیوسته (Continuous)
  - انتخاب بهترین شرط تفکیک از میان گزینه‌های کاندید (معیارهای ناخالصی)
- **مسئله دوم: چگونگی توقف الگوریتم (Stopping condition)**
  - توقف زمانی که تمامی نمونه‌های یک گره به کلاس یکسانی تعلق داشته باشند.
  - توقف زمانی که مقادیر تمام ویژگی‌ها برای نمونه‌های باقیمانده یکسان باشد.
  - توقف زودهنگام (Early Stopping) جهت مقابله با بیش‌برازش.

تفکیک ویژگی‌های اسمی
Splitting of Nominal Attributes

- **تفکیک چندگانه (Multi-way split):** ایجاد به تعداد مقادیر مجزای ویژگی:



- **تفکیک دوتایی (Binary split):** افراز به دو زیرمجموعه با $2^{k-1} - 1$ حالت ممکن:



تفکیک ویژگی‌های ترتیبی
Splitting of Ordinal Attributes

- **تفکیک چندگانه (Multi-way split):** ایجاد به تعداد مقادیر مجزا:

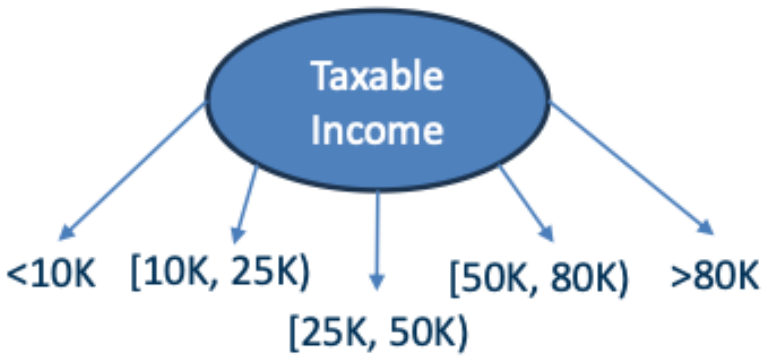


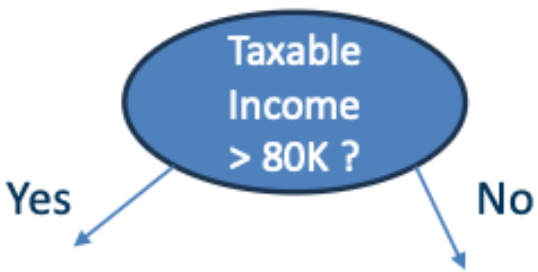
- **تفکیک دوتایی (Binary split):** افراز به دو زیرمجموعه **با حفظ ترتیب مقادیر**:



تفکیک ویژگی‌های عددی و پیوسته

Splitting of Continuous Attributes



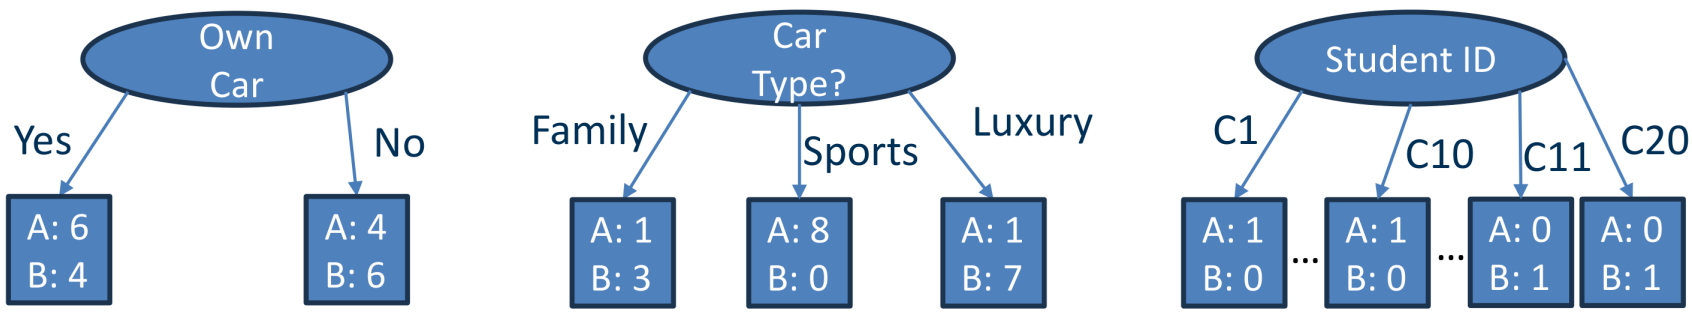


- **تفکیک چندگانه با گسسته‌سازی:** (Discretization)
  - تبدیل مقادیر پیوسته به بازه‌های ترتیبی (مانند $[10, 25)$، $[25, 50)$، $[50, 80)$)
  - رویکردهای فاصله‌های ایستا یا تطبیقی
- **تفکیک دوتایی:** (Binary Decision)
  - انتخاب یک آستانه بهینه v به شکل آزمون $A < v$ در برابر $A \geq v$
  - بررسی تمام مقادیر میانی کاندید برای بیشینه‌سازی خلوص

تعیین بهترین تفکیک

مقایسه شرایط آزمون رقیب

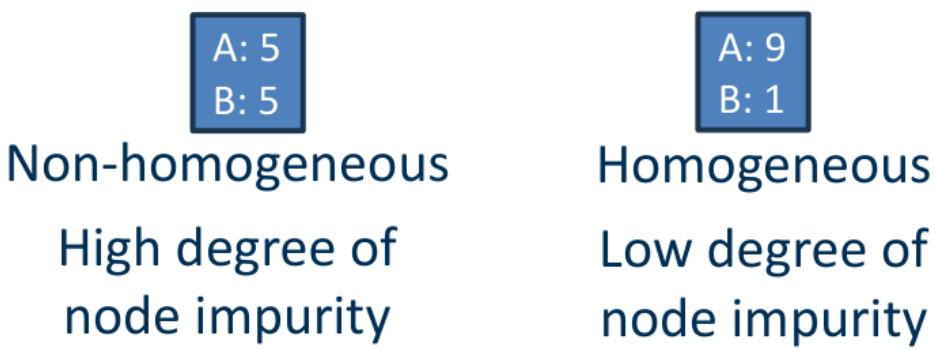
- **وضعیت اولیه گره والد:** داده‌های ورودی شامل ۱۰ نمونه با توزیع $C_1 : 6$ و $C_2 : 4$ است.
- کدام ویژگی داده‌ها را به خالص‌ترین زیرمجموعه‌ها تفکیک می‌کند؟



خلوص و همگنی گره‌ها

مبنای انتخاب شرط تفکیک

- **گره‌های همگن (خالص):** گره‌هایی که اکثریت یا تمام نمونه‌های آن‌ها متعلق به یک کلاس واحد هستند.
  - در این گره‌ها عدم قطعیت حداقل بوده و خطای طبقه‌بندی بسیار کم یا صفر است.
- **گره‌های ناهمگن (ناخالص):** گره‌هایی با توزیع یکنواخت از کلاس‌های مختلف؛ پیش‌بینی در این گره‌ها بسیار غیرقابل اعتماد است.
- **نیاز به معیار ریاضی:** برای مقایسه دقیق آزمون‌ها به یک معیار کمّی برای اندازه‌گیری **ناخالصی (Impurity)** نیاز داریم.



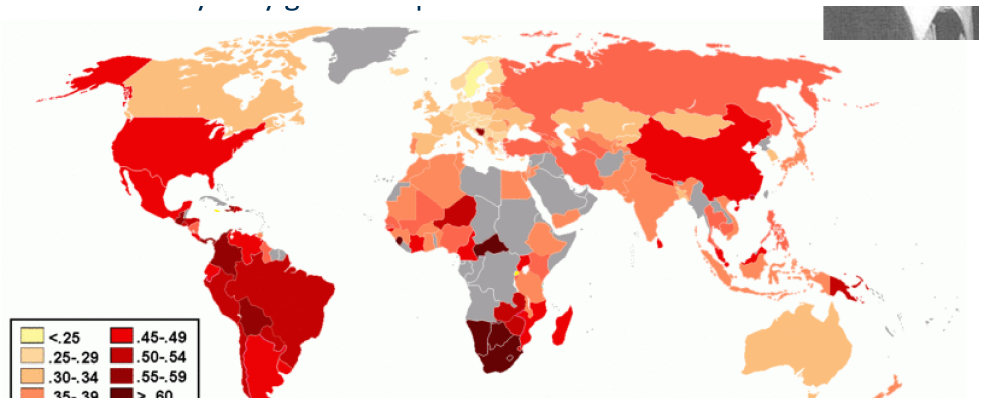
شاخص جینی

Gini Index

- **پیشینه تاریخی:** نام‌گذاری به افتخار **کورادو جینی (Corrado Gini، ۱۸۸۵–۱۹۶۵)**، آماردان برجسته ایتالیایی.
- **کاربرد در اقتصاد:** اندازه‌گیری توزیع ثروت و نابرابری درآمد:
  - عدد ۱: یک نفر کل ثروت را دارد (نابرابری مطلق)
  - عدد ۰: تمام افراد سهم کاملاً برابری دارند (برابری مطلق)



کورادو جینی



معیار ناخالصی جینی

Measure of Impurity: GINI

- **فرمول ریاضی شاخص جینی برای گره مفروض t:**

$$\text{GINI}(t) = 1 - \sum_j [p(j|t)]^2$$

که در آن $p(j|t)$ نسبت رکوردهای متعلق به کلاس j در گره t است.

- **حداقل ناخالصی (0.0):** تمام رکوردها متعلق به یک کلاس هستند (بیشترین اطلاعات).
- **حداکثر ناخالصی ($1 - 1/n_c$):** نمونه‌ها به طور مساوی میان کلاس‌ها تقسیم شده‌اند (کمترین اطلاعات).



مثال‌های عددی محاسبه ناخالصی جینی

Examples for Computing GINI

- محاسبه شاخص جینی برای ۳ گره با درجات خلوص مختلف:

A	0
B	6

$$P(A) = \frac{0}{6} = 0 \qquad P(B) = \frac{6}{6} = 1$$

$$Gini(t) = 1 - P(A)^2 - P(B)^2 = 1 - 0 - 1 = 0$$

A	1
B	5

$$P(A) = \frac{1}{6} \qquad P(B) = \frac{5}{6}$$

$$Gini(t) = 1 - \left(\frac{1}{6}\right)^2 - \left(\frac{5}{6}\right)^2 = 0.278$$

A	2
B	4

$$P(A) = \frac{2}{6} \qquad P(B) = \frac{4}{6}$$

$$Gini(t) = 1 - \left(\frac{2}{6}\right)^2 - \left(\frac{4}{6}\right)^2 = 0.444$$

تفکیک بر مبنای شاخص جینی

Splitting Based on GINI

- هنگامی که گره p به k افراز (گره فرزند) تقسیم می‌شود، کیفیت تفکیک به صورت زیر محاسبه می‌گردد:

$$\text{GINI}_{\text{split}} = \sum_{i=1}^{k} \frac{n_i}{n} \text{GINI}(i)$$

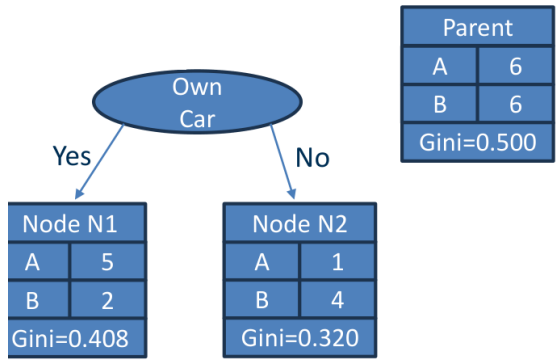
که در آن n_i تعداد رکوردهای گره فرزند i و n تعداد کل رکوردهای گره والد p است.

- **شهود ریاضی:** (Intuition) شاخص جینی هر افراز بر اساس اندازه نسبی آن وزن‌دهی می‌شود.
- تفکیکی که کمترین مقدار $\text{GINI}_{\text{split}}$ را به همراه داشته باشد، به عنوان تفکیک برنده برگزیده می‌شود.

محاسبه جینی برای تفکیک دوگانه

مثال گام‌به‌گام

- افراز داده‌ها بر اساس ویژگی مالکیت خودرو (`Own Car`)



- **محاسبه جینی کل تفکیک:**

$$\text{GINI}_{\text{split}} = \frac{7}{12} \times 0.408 + \frac{5}{12} \times 0.320 = \mathbf{0.371}$$

- **بهبود خلوص:** (Purity Gain)

$$\text{Gain} = \text{GINI}_{\text{parent}} - \text{GINI}_{\text{split}} = 0.500 - 0.371 = \mathbf{0.129}$$

- در صورت استفاده از آنتروپی، این مقدار **بهره اطلاعات (Information Gain)** نامیده می‌شود.

ویژگی‌های دسته‌ای: محاسبه شاخص جینی

Categorical Attributes: Computing Gini

- برای هر مقدار مجزا، شمارش کلاس‌ها انجام شده و حالات تفکیک مقایسه می‌شوند:

Multi-way split

	Car Type		
	Family	Sports	Luxury
A	1	2	1
B	4	1	1
Gini=0.393			

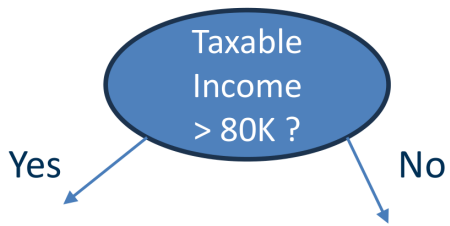
Two-way split
(find best partition of values)

	Car Type	
	{Sports, Luxury}	Family
A	3	1
B	2	4
Gini=0.400		

	Car Type	
	{Sports}	{Family, Luxury}
A	2	2
B	1	5
Gini=0.419		

ویژگی‌های پیوسته: راهکار ارزیابی

Continuous Attributes: Computing Gini



Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

- استفاده از تصمیم‌گیری‌های دوگانه بر مبنای یک مقدار آستانه ($A < v$ در برابر $A \geq v$)
- **تعداد گزینه‌های تفکیک:** برابر با تعداد مقادیر مجزای ویژگی در داده‌ها
- هر آستانه تفکیک ماتریس شمارش کلاس متناظر با خود را دارد.
- **روش ساده اما ناکارآمد:** پویش کل پایگاه‌داده برای تک‌تک مقادیر و محاسبه مجدد جینی (دارای تکرار زائد و کند).

ویژگی‌های پیوسته: الگوریتم محاسباتی سریع

Continuous Attributes: Efficient Computation

- **رویه کارآمد ۳ مرحله‌ای:**
  ۱. مرتب‌سازی رکوردهای آموزشی بر اساس مقادیر ویژگی ($O(N \log N)$)
  ۲. پویش خطی مقادیر و به‌روزرسانی تدریجی ماتریس شمارش و جینی در زمان $O(1)$
  ۳. انتخاب موقعیت تفکیکی که کمترین شاخص جینی را حاصل می‌کند.

Sorted Values →
Split Positions →

	Taxable Income																					
	60		70		75		85		90		95		100		120		125		220			
	55		65		72		80		87		92		97		110		122		172		230	
	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>
Yes	0	3	0	3	0	3	0	3	1	2	2	1	3	0	3	0	3	0	3	0	3	0
No	0	7	1	6	2	5	3	4	3	4	3	4	3	4	4	3	5	2	6	1	7	0
Gini	0.420		0.400		0.375		0.343		0.417		0.400		***0.300***		0.343		0.375		0.400		0.420	

ویژگی‌های پیوسته: محاسبه شاخص جینی

Continuous Attributes: Computing Gini Index

- **نکته کلیدی:** محاسبه شاخص جینی تنها برای موقعیت‌هایی که برچسب کلاس تغییر می‌کند، کفایت می‌کند!

Cheat	No		No		No		Yes		Yes		Yes		No		No		No		No	
	Taxable Income																			
	60		70		75		85		90		95		100		120		125		220	
	55		65		72		80		87		92		97		110		122		172		230	
	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>
Yes	0	3	0	3	0	3	0	3	1	2	2	1	3	0	3	0	3	0	3	0	3	0
No	0	7	1	6	2	5	3	4	3	4	3	4	3	4	4	3	5	2	6	1	7	0
Gini	0.420		0.400		0.375		0.343		0.417		0.400		*0.300*		0.343		0.375		0.400		0.420	

بحث و ارزیابی درخت‌های تصمیم
Discussion of Decision Trees

مزایای کلیدی (Advantages)

- **هزینه کم ساخت:** الگوریتم سریع و محاسبات سبک
- **سرعت بسیار بالا در تست:** طبقه‌بندی آنی رکوردهای جدید
- **تفسیرپذیری شفاف:** ساختار شفاف و قابل فهم (White-box)
- **بی‌نیازی از مقیاس‌بندی:** عدم نیاز به نرمال‌سازی داده‌ها
- **مقاومت در برابر ویژگی‌های هرز:** عدم تأثیرپذیری از ویژگی‌های نامرتبط

محدودیت‌ها و معایب (Disadvantages)

- **مرزهای موازی محورها:** تقریب پلکانی نامناسب برای مرزهای تصمیم مورب یا غیرخطی پیچیده
- **ناپایداری و واریانس بالا:** تغییرات جزئی در داده‌های آموزش می‌تواند ساختار کل درخت را دگرگون کند.
- **آسیب‌پذیری در برابر نویز:** تمایل شدید به بیش‌برازش (Overfitting) در صورت رشد آزادانه

مقایسه درخت‌های تصمیم و الگوریتم k-NN

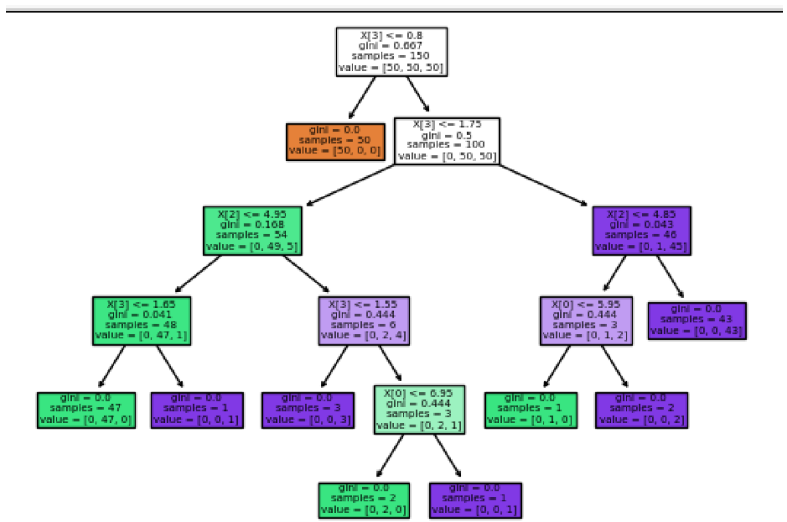
Comparing Decision Trees and k-NN

معیار مقایسه	درخت تصمیم (Decision Tree)	نزدیک‌ترین همسایگی (k-NN)
نوع رویکرد یادگیری	مشتاق (Eager) – ساخت مدل صریح سراسری	تنبل (Lazy) – عدم ساخت مدل تا زمان آزمون
شکل مرزهای تصمیم	خطوط متعامد و موازی با محورها (Axis-parallel)	مرزهای دلخواه، پیوسته و منعطف (Arbitrary)
هزینه محاسباتی تست	بسیار سریع و سبک: $O(\text{depth})$	سنگین و وابسته به کل داده‌ها: $O(N \cdot D)$
تفسیرپذیری	بسیار بالا؛ قابل فهم و نمایش در قالب درخت	پایین؛ جعبه سیاه مبتنی بر فاصله
حساسیت به مقیاس	کاملاً نامتغیر در برابر تغییر مقیاس ویژگی‌ها	بسیار حساس به نرمال‌سازی و مقیاس متغیرها
ویژگی‌های نامرتبط	مقاومت بالا با نادیده گرفتن در شاخه‌ها	افت شدید دقت به دلیل لعنت ابعاد

القای درخت تصمیم در پایتون

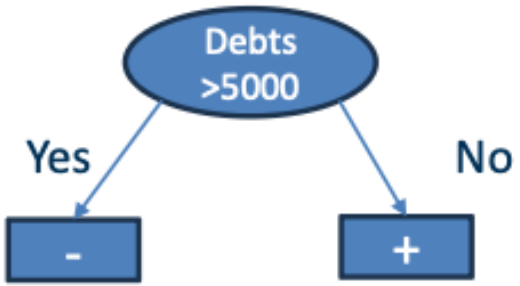
Tree Induction in Python (scikit-learn)

```
from sklearn.tree import DecisionTreeClassifier, plot_tree
# Train classifier
dt_learner = DecisionTreeClassifier(criterion='gini', max_depth=10)
dt_learner.fit(preprocessed_training_data, training_labels)
# Use classifier to predict labels
prediction = dt_learner.predict(preprocessed_unseen_data)
# Plot the decision tree
plot_tree(dt_learner)
```



مسئله بیش‌برازش در عمل: درخت اول

Practical Issue: Overfitting (Tree 1)

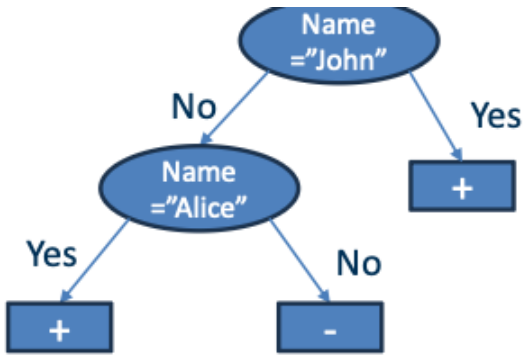


- **نمونه کاربردی:** پیش‌بینی رتبه اعتباری مشتریان (Credit Rating)
- یک ساختار درخت تصمیم ممکن:

Name	Net Income	Job status	Debts	Rating
John	40000	employed	0	+
Mary	38000	employed	10000	-
Stephen	21000	self-employed	20000	-
Eric	2000	student	10000	-
Alice	35000	employed	4000	+

مسئله بیش‌برازش در عمل: درخت دوم

Practical Issue: Overfitting (Tree 2)



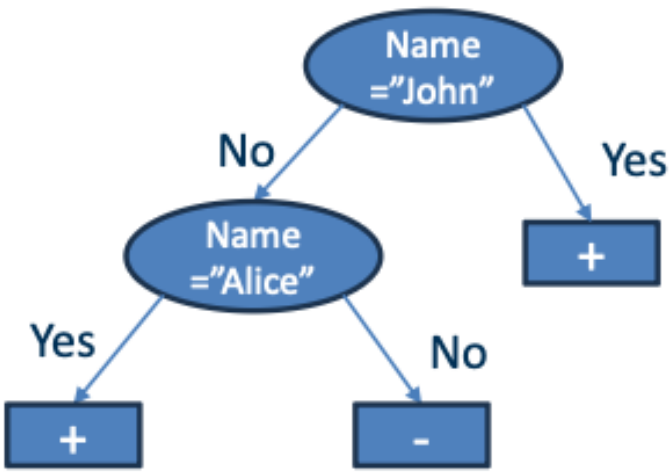
- **همان مسئله**، اما با ساختار جایگزین و شاخه‌بندی بر اساس نام افراد:

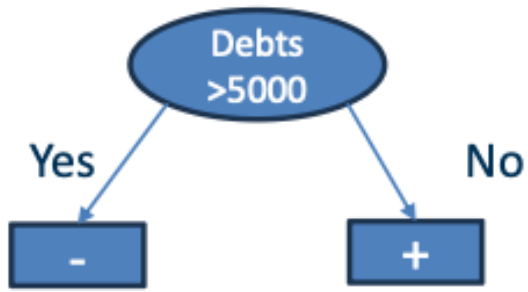
Name	Net Income	Job status	Debts	Rating
John	40000	employed	0	+
Mary	38000	employed	10000	-
Stephen	21000	self-employed	20000	-
Eric	2000	student	10000	-
Alice	35000	employed	4000	+

مسئله بیش‌برازش در عمل: مقایسه دو درخت

Practical Issue: Overfitting

- **هر دو درخت به یک اندازه خوب به نظر می‌رسند:**
  - تمام نمونه‌های آموزش را با دقت کامل و صحت 100% طبقه‌بندی می‌کنند.
- **شما کدام درخت را ترجیح می‌دهید؟**





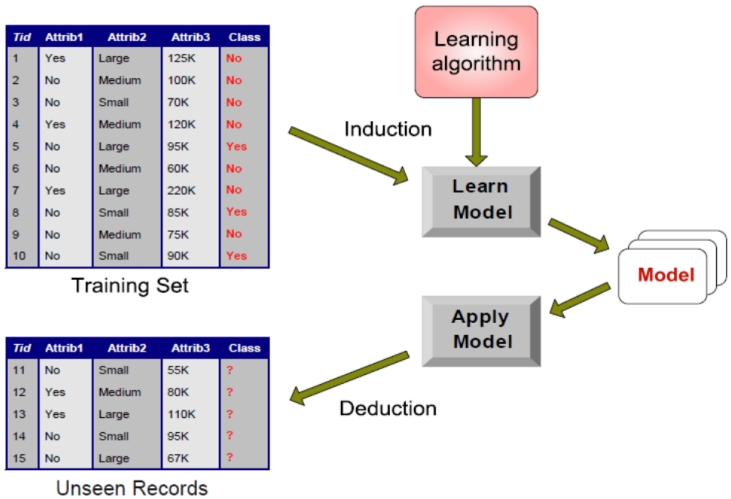
تیغ اوکام
Occam's Razor

- **پیشینه:** منسوب به **ویلیام اوکام (William of Ockham، ۱۲۸۷–۱۳۴۷)**، فیلسوف نامی سده‌های میانه.
- **قاعده اصیل:** «تعداد موجودات نباید فراتر از ضرورت افزایش یابد».
- **کاربرد در یادگیری ماشین:**
  - «در میان مدل‌هایی که دقت برابری دارند، همواره ساده‌ترین مدل ارجح است».
  - درختی با ساختار کم‌عمق‌تر و شاخه‌های کمتر، شانس بسیار بالاتری برای تعمیم به داده‌های نادیده دارد.



ویلیام اوکام (۱۲۸۷–۱۳۴۷)

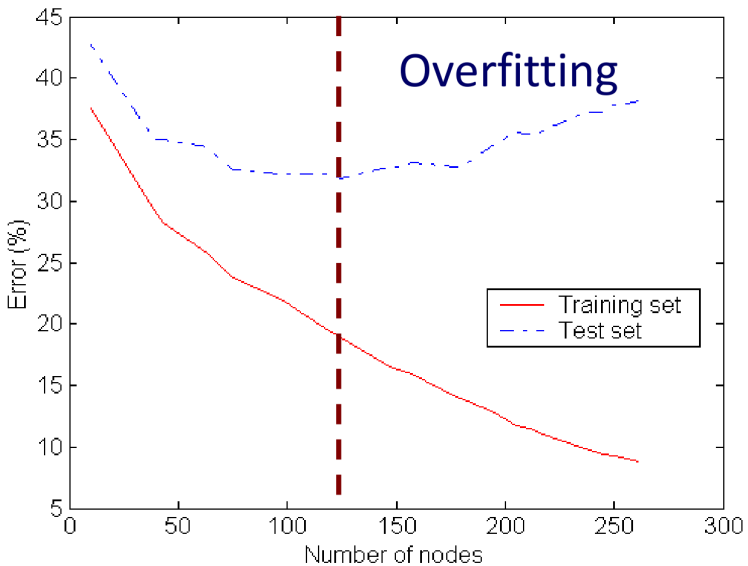
جداسازی داده‌های آموزش و آزمون
Training and Testing Data



- **خطای آموزش فریبنده است:** ارزیابی مدل با همان داده‌هایی که در آموزش استفاده شده‌اند، منجر به برآوردی به شدت خوش‌بینانه و نادرست می‌شود.
- **لزوم تفکیک مستقل:** ارزیابی واقعی عملکرد تعمیم (Generalization) تنها با اعمال مدل بر روی داده‌های آزمون مجزا که مدل هرگز ندیده است امکان‌پذیر است.

بیش‌برازش: نشانه‌ها و علل

Overfitting: Symptoms and Causes

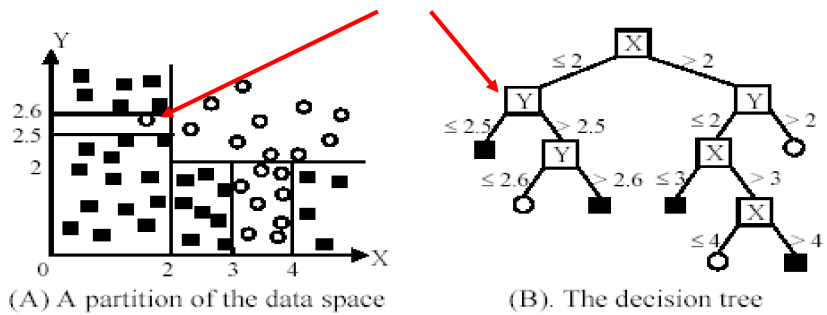


- **نشانه‌ها:** (Symptoms)
  - عمق بیش از حد درخت و شاخه‌بندی‌های ریز
  - خطای نزدیک به صفر در آموزش ولی خطای بالا در آزمون
- **علل اصلی:** (Causes)
  - وجود نویز و داده‌های پرت در مجموعه آموزش
  - تعداد اندک نمونه‌های آموزشی نسبت به پیچیدگی فضا

بیش‌برازش و نویز داده‌ها
Overfitting and Noise

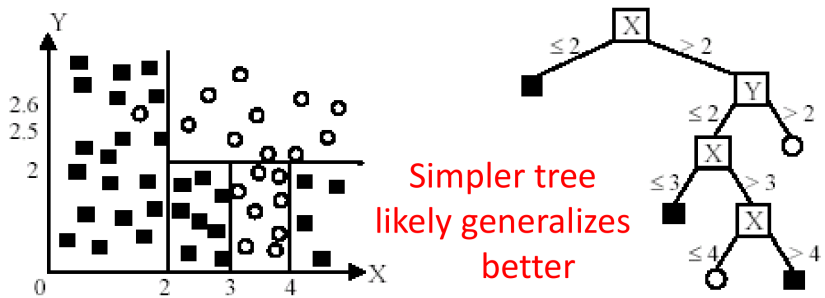
- انطباق وسواسی مرزهای تصمیم بر روی نمونه‌های منفرد نویز موجب تخریب مرز واقعی کلاس‌ها می‌شود:

مدل بیش‌برازش‌شده (برازش نویز)



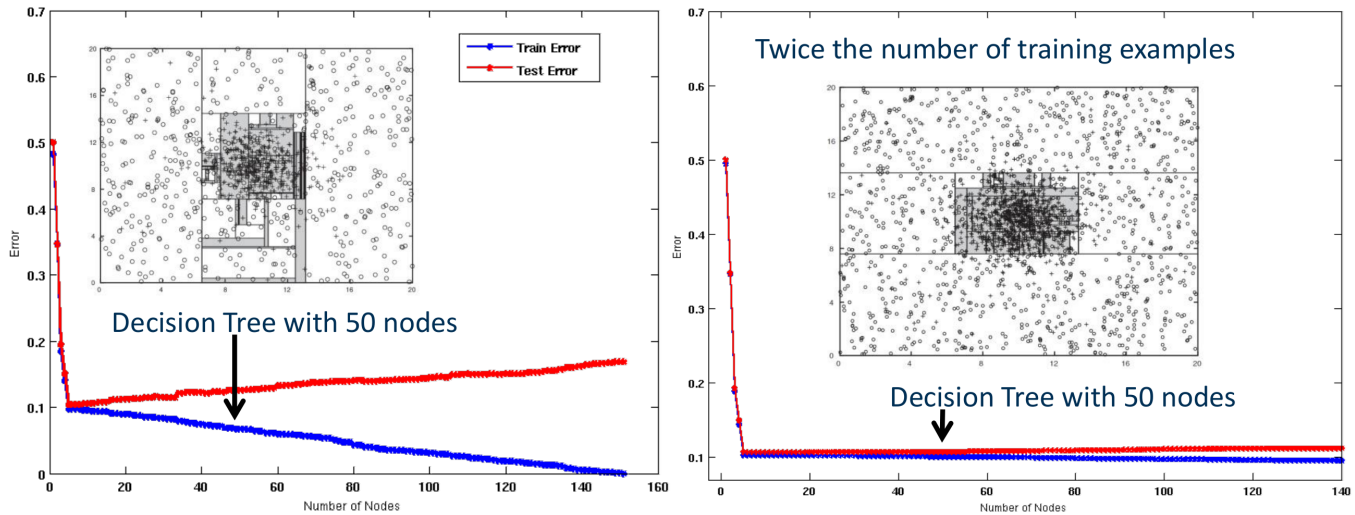
(A) A partition of the data space (B). The decision tree

مدل ساده‌تر (تعمیم‌پذیری بالا)



پیشگیری از بیش‌برازش: افزایش حجم داده‌های آموزش

Prevention 1: Use More Training Data



- در صورت ناکافی بودن داده‌های آموزش، با افزایش عمق درخت، خطای آزمون به سرعت اوج می‌گیرد.
- افزایش حجم داده‌های آموزش، فاصله میان خطای آموزش و آزمون را به حداقل رسانده و از بیش‌برازش جلوگیری می‌کند.

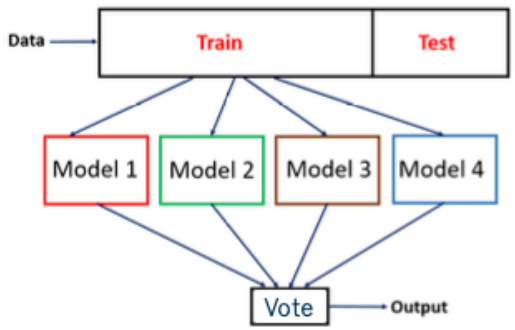
پیشگیری از بیش‌برازش: پیش‌هرس درخت

Prevention 2: Pre-Pruning

- **ایده اصلی:** متوقف کردن رشد درخت پیش از آنکه بیش از حد عمیق و منشعب شود (تیغ اوکام).
- **شرایط توقف عادی (بدون هرس):**
  - تمام نمونه‌های موجود در گره متعلق به یک کلاس باشند.
  - مقادیر تمام ویژگی‌ها برای نمونه‌های باقیمانده یکسان باشد.
- **معیارهای پیش‌هرس زودهنگام:** (Pre-Pruning)
  - تعیین سقف برای بیشینه عمق درخت (`max_depth`)
  - حداقل نمونه لازم برای انشعاب گره (`min_samples_split`)
  - حداقل نمونه لازم در هر برگ (`min_samples_leaf`)
  - توقف در صورت عدم دستیابی به حداقل بهبود ناخالصی (`min_impurity_decrease`)

پیشگیری از بیش‌برازش: روش‌های جمعی
Prevention 3: Ensembles

- **یادگیری جمعی (Ensemble):** آموزش چندین مدل پایه
- **رأی‌گیری جمعی (Voting):** رأی‌گیری میان مدل‌ها برای تصمیم نهایی



- **ایده خرد جمعی (Wisdom of the Crowds) در دسته‌بندی:**
  - یک کلاسیفایر منفرد ممکن است بر یک جنبه متمرکز شده یا به نویز حساس باشد.
  - مدل‌های متنوع جنبه‌های مختلف را فرا گرفته و خطاهای تصادفی یکدیگر را خنثی می‌کنند.

الگوریتم‌های یادگیری جمعی درخت‌ها
Tree Ensemble Algorithms

- **جنگل تصادفی (Random Forest – برایمن، ۱۹۹۷)**
  - ترکیب درخت‌های مستقل با استفاده از بگینگ و انتخاب تصادفی ویژگی‌ها
  - `sklearn.ensemble.RandomForestClassifier`
- **افزایش گرادیانی درخت‌ها (Gradient Tree Boosting – فریدمن، ۱۹۹۹)**
  - بهینه‌سازی ترتیبی با تمرکز بر تصحیح خطای مراحل پیشین
  - `sklearn.ensemble.GradientBoostingClassifier`
- **بوستینگ منظم‌شده و بسیار مقیاس‌پذیر:** (XGBoost)
  - سیستم فوق‌سریع و توزیع‌شده با کنترل دقیق پیچیدگی مدل (Regularization)

جنگل تصادفی

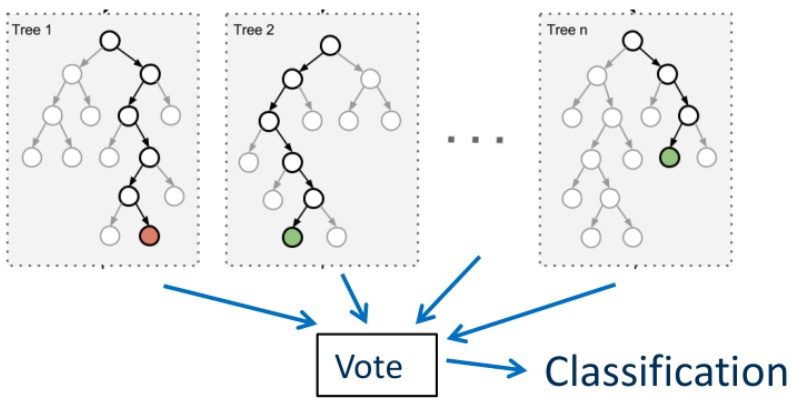
Random Forest

- **مفهوم:** مجموعه‌ای متشکل از صدها درخت تصمیم مستقل که طبقه‌بندی نهایی را با رأی اکثریت انجام می‌دهند.

- **ایجاد استقلال و تنوع میان درخت‌ها با دو سازوکار تصادفی:**

۱. **بگینگ داده‌ها:** (Data Bagging) هر درخت بر روی یک نمونه‌گیری تصادفی همراه با جایگذاری (Bootstrap) آموزش می‌بیند.

۲. **انتخاب تصادفی ویژگی‌ها:** (Feature Subsampling) در هر گره، تنها زیرمجموعه تصادفی کوچکی از ویژگی‌ها (معمولاً $\sqrt{p}$) آزمون می‌شود.



جنگل تصادفی در پایتون

Random Forest in Python

- جنگل‌های تصادفی به دلیل کاهش چشمگیر واریانس، معمولاً عملکردی به مراتب برتر از تک‌درخت ارائه می‌دهند.
- پیاده‌سازی در کتابخانه `scikit-learn` :

```
from sklearn.ensemble import RandomForestClassifier

# Train classifier
forest_estimator = RandomForestClassifier(n_estimators=100,
criterion='gini', max_depth=None)
forest_estimator.fit(preprocessed_training_data,
training_labels)

# Use classifier to predict labels
prediction = forest_estimator.predict(preprocessed_unseen_data)
```

الگوریتم XGBoost – تابع هدف منظم‌شده

eXtreme Gradient Boosting

- **سیستم مقیاس‌پذیر برای یادگیری مجموعه‌ای از درخت‌ها:**

$$\text{Obj}(\Theta) = L(\Theta) + \Omega(\Theta)$$

تابع زیان آموزش: $L(\Theta)$

- کیفیت پیش‌بینی و برازش بر داده‌ها
- کمینه‌سازی آن منجر به مدل‌های پیش‌بینانه قوی می‌شود.

جمله منظم‌سازی: $\Omega(\Theta)$

- جریمه پیچیدگی ساختار درخت‌ها
- کمینه‌سازی آن منجر به مدل‌های ساده و پایدار می‌شود.

- **بهینه‌سازی‌های سیستمی:** محاسبات خارج از حافظه (Out-of-core)، موازی‌سازی و بهینه‌سازی حافظه پنهان (Cache-aware).

الگوریتم XGBoost – یادگیری افزایشی و منظم‌سازی

Additive Training and Regularization

- **یادگیری افزایشی:** (Additive Training)

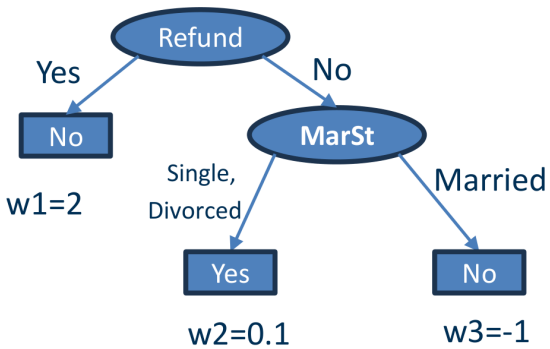
$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i)$$

در هر مرحله یک درخت جدید برای تصحیح خطای باقیمانده اضافه می‌شود.

- **تعریف پیچیدگی درخت تصمیم:**

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2$$

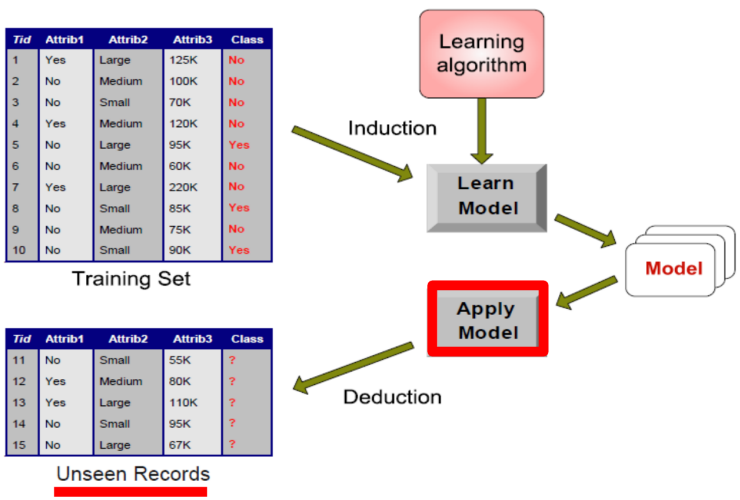
- T: تعداد گره‌های برگ درخت
- w_j: امتیاز (وزن) هر گره برگ



$$\Omega(\Theta) = y3 + \tfrac{1}{2}\lambda(4+0.01+1)$$

$$\Omega(\Theta) = \gamma \cdot 3 + \tfrac{1}{2}\lambda(4 + 0.01 + 1)$$

ارزیابی مدل‌های طبقه‌بندی
Model Evaluation



- **پرسش بنیادین:** مدل ساخته‌شده در طبقه‌بندی رکوردهای جدید و نادیده چقدر موفق است؟ (Generalization Performance)
- **موضوع این بخش: معیارهای ارزیابی**
  - عملکرد مدل را چگونه به شکل کمّی اندازه بگیریم؟
  - کدام معیار برای مسائل نامتوازن یا حساس به هزینه مناسب است؟

ماتریس درهم‌ریختگی
Confusion Matrix

- تمرکز بر توان پیش‌بینی مدل با بررسی نمونه‌های درست و نادرست:
  - مسئله دوکلاسه (کلاس مثبت / منفی)
  - **واژه اول:** (True / False) درستی پیش‌بینی (اگر پیش‌بینی درست باشد True، در غیر این صورت False)
  - **واژه دوم:** (Positive / Negative) وابسته به برچسب پیش‌بینی‌شده توسط مدل

		کلاس پیش‌بینی‌شده (Predicted)	
		Class = Yes	**Class = No**
Actual	**Class = Yes**	**مثبت واقعی (TP)** True Positives	**منفی کاذب (FN)** False Negatives
	Class = No	**مثبت کاذب (FP)** False Positives	**منفی واقعی (TN)** True Negatives

معیارهای پایه ارزیابی عملکرد
Metrics for Performance Evaluation

صحت کلی (Accuracy)

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

نسبت تمام پیش‌بینی‌های درست به کل نمونه‌ها

نرخ مثبت واقعی (TPR / Recall)

$$\text{TPR} = \frac{TP}{TP + FN}$$

کسری از مثبت‌های واقعی که به درستی کشف شدند

نرخ خطا (Error Rate)

$$\text{Rate Error} = 1 - \text{Accuracy}$$

نرخ مثبت کاذب (FPR)

$$\text{FPR} = \frac{FP}{FP + TN}$$

کسری از منفی‌ها که به اشتباه مثبت پیش‌بینی شدند

صحت مطلوب چقدر است؟
What is a Good Accuracy?

- یعنی چه زمانی کار آموزش به پایان رسیده است؟
  - در صحت 75%؟ 90%؟ 95%؟
- بستگی به درجه سختی مسئله دارد!
- **خط مبنا (Baseline)** – حدس ساده‌لوحانه (Naive Guessing)
  - همواره کلاس اکثریت را پیش‌بینی کنیم
- **مقایسه کنید:**
  - پیش‌بینی پرتاب سکه با صحت 50%
  - پیش‌بینی پرتاب تاس با صحت 50%
  - پیش‌بینی اعداد قرعه‌کشی لوتو (۶ از ۴۹) با صحت 50%

محدودیت صحت در داده‌های نامتوازن

Limitation of Accuracy: Unbalanced Data

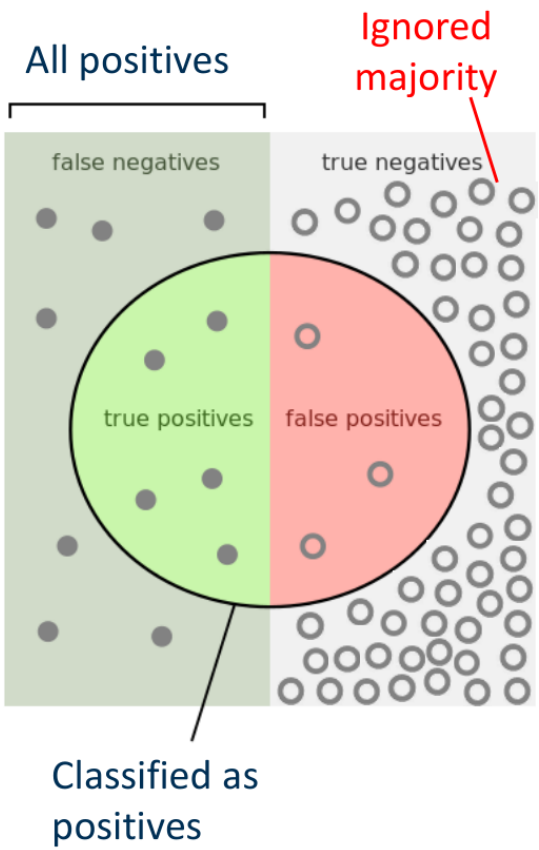
- کلاس‌ها اغلب فراوانی بسیار نابرابری دارند:
  - تشخیص تقلب: 98% تراکنش‌ها عادی، 2% تقلب
  - تجارت الکترونیک: 99% بازدیدکنندگان خرید نمی‌کنند، 1% خرید می‌کنند

- یک مسئله دوکلاسه را در نظر بگیرید:
  - تعداد نمونه‌های منفی = 9,990، تعداد نمونه‌های مثبت = 10
  - اگر مدل تمام نمونه‌ها را متعلق به کلاس منفی پیش‌بینی کند:

$$\text{Accuracy} = \frac{9990}{10000} = 99.9\%$$

  - صحت کاملاً گمراه‌کننده است زیرا مدل **حتی یک نمونه مثبت را هم کشف نکرده است!**

دقت و بازخوانی
Precision and Recall



- **دقت (Precision):**

$$p = \frac{TP}{TP + FP}$$

از میان مواردی که مثبت طبقه‌بندی شدند، چه کسری واقعاً مثبت هستند؟

- **بازخوانی (Recall):**

$$r = \frac{TP}{TP + FN}$$

کدام کسر از کل نمونه‌های مثبت، به درستی طبقه‌بندی شده‌اند؟

دقت و بازخوانی: یک نمونه مسئله‌ساز

Precision and Recall – A Problematic Case

ماتریس درهم‌ریختگی نمونه

	واقعی +	واقعی -
پیش‌بینی +	$TP = 1$	$FP = 0$
پیش‌بینی -	$FN = 99$	$TN = 1000$

- $\text{Precision} = \frac{1}{1+0} = \mathbf{100\%}$
- $\text{Recall} = \frac{1}{1+99} = \mathbf{1\%}$

تحلیل نتیجه

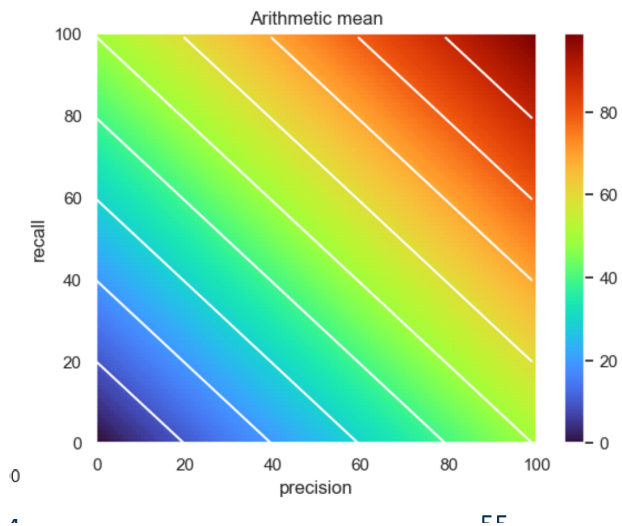
- مدل دقت 100% دارد زیرا هیچ نمونه منفی را اشتباهاً مثبت پیش‌بینی نکرده است!
- اما ۹۹ مورد مثبت از ۱۰۰ مورد را کاملاً از دست داده است (Recall = 1%)!
- **نتیجه:** نیازمند معیاری هستیم که دقت و بازخوانی را با هم ترکیب کند و فقط در صورت بالا بودن هر دو، مقدار بزرگی داشته باشد.

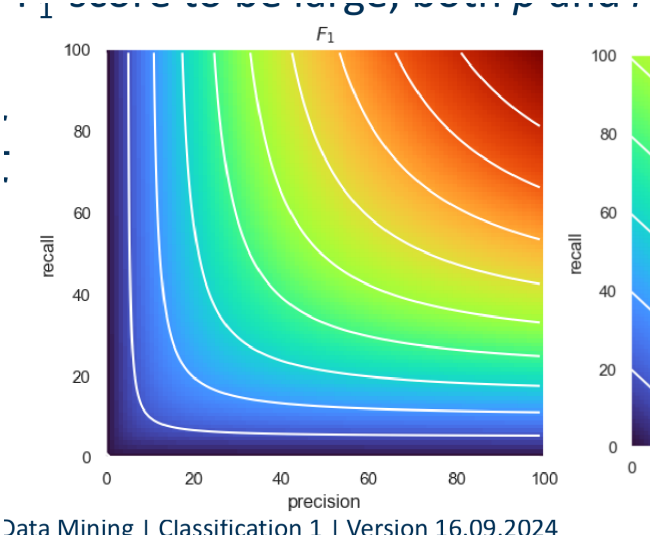
معیار F_1
F1-Measure

- **تعریف:** معیار F_1 میانگین همساز (Harmonic Mean) دقت و بازخوانی است:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **خاصیت میانگین همساز:** همواره به مقدار کوچکتر گرایش دارد؛ بنابراین برای بالا بودن F_1، باید **هم دقت و هم بازخوانی هم‌زمان بالا باشند.**

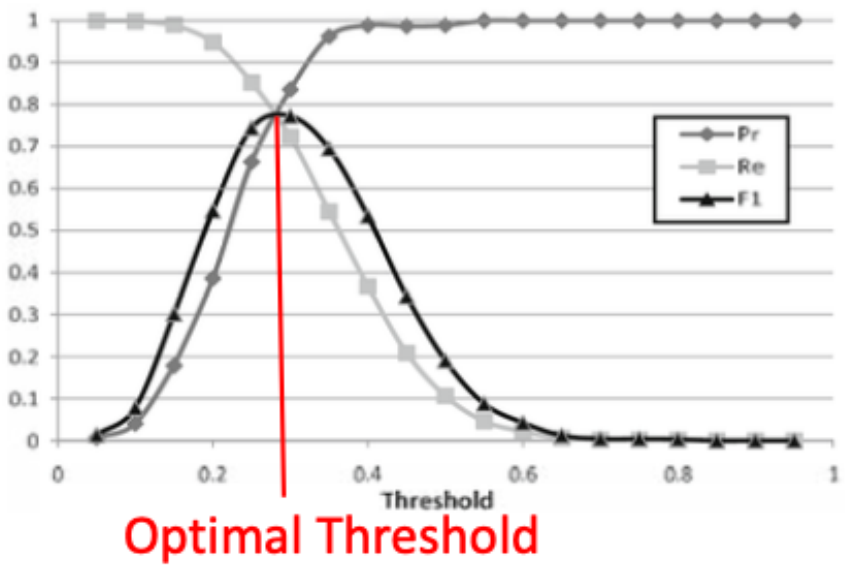




نمودار معیار F_1 و آستانه بهینه

F1-Measure Graph

- با تغییر آستانه تصمیم‌گیری:
  - آستانه پایین: بازخوانی بالا ولی دقت پایین
  - آستانه سخت‌گیرانه: دقت بالا ولی بازخوانی پایین
- نقطه بهینه با بیشینه‌سازی نمره F_1 تعیین می‌شود:

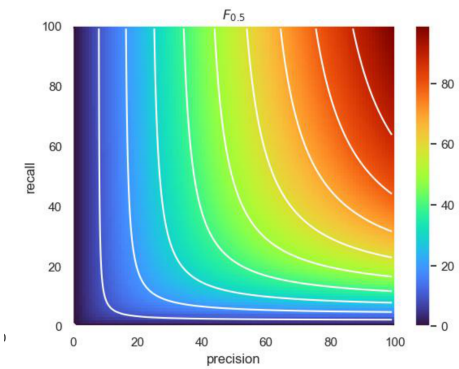


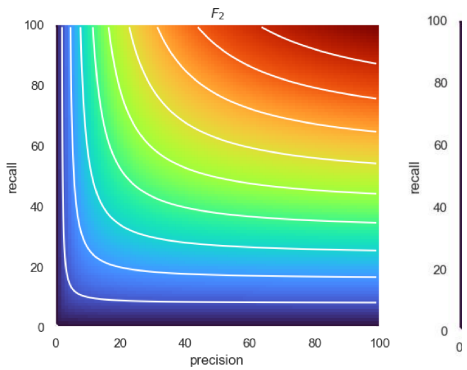
معیار تعمیم‌یافته F_β
F-beta Measure

- وزن‌دهی انعطاف‌پذیر به دقت در برابر بازخوانی:

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{(\beta^2 \cdot \text{Precision}) + \text{Recall}}$$

- اگر $\beta = 2$: بازخوانی اهمیت بالاتری دارد (تشخیص بیماری یا کلاهبرداری).
- اگر $\beta = 0.5$: دقت اهمیت بالاتری دارد (سامانه‌های پیشنهادگر یا فیلتر هرزنامه).





ارزیابی مدل مبتنی بر ماتریس هزینه

Cost-Sensitive Model Evaluation

- تخصیص هزینه برای هر خطا (Cost for each error)
- **مورد کاربرد:** تشخیص تقلب در کارت‌های اعتباری
  - ندیدن تراکنش‌های متقلبانه بسیار پرهزینه است (*FN*).
  - هشدارهای اشتباه هزینه اندکی دارند (*FP*).

ماتریس هزینه (Cost Matrix)

Predicted		
No	**Yes**	**Actual**
۱۰۰	۱-	**Yes**
۰	۱	**No**

مدل M۱ (Model M1)

No	Yes	
۳۸	۱۶۲	**Yes**
۲۴۰	۱۶۰	**No**

صحت: 67% (Accuracy)

هزینه: 3798 (Cost) (⇐ **مدل برتر**)

مدل M۲ (Model M2)

No	Yes	
۴۵	۱۵۵	**Yes**
۳۹۵	۵	**No**

صحت (Accuracy) – 92%

هزینه (Cost) – 4,350

منحنی‌های ROC

Receiver Operating Characteristic

- الگوریتم‌های طبقه‌بندی معمولاً یک **نمره اطمینان (Confidence Score)** ارائه می‌دهند (مانند سهم همسایگان موافق در k-NN یا احتمال در بیز ساده).
- منحنی ROC مصورسازی رابطه میان نرخ مثبت واقعی (*TPR*) و نرخ مثبت کاذب (*FPR*) در ازای تغییر پیوسته آستانه اطمینان است.
- **رویه رسم منحنی ROC (Drawing a ROC Curve)**

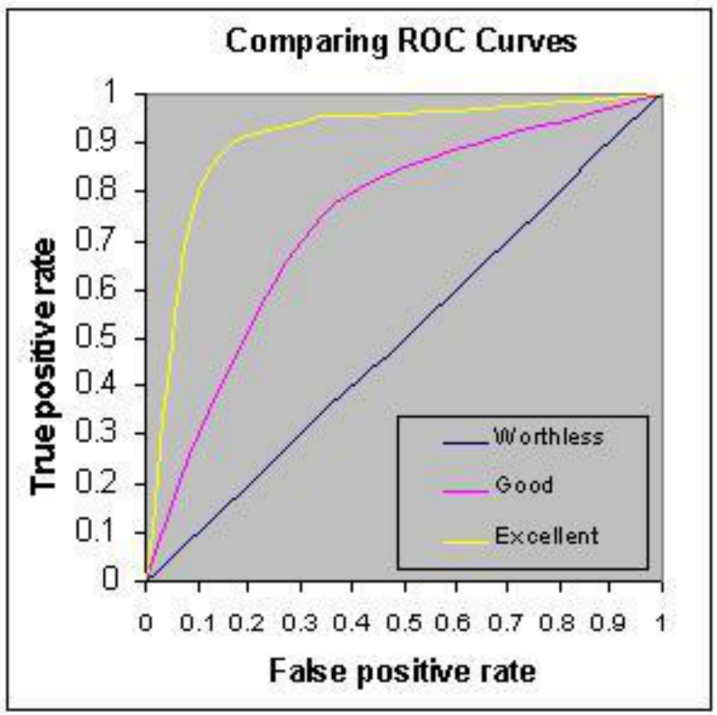
۱. رکوردهای آزمون را بر اساس نمره اطمینان از بیشترین به کمترین مرتب کنید.

۲. نمونه‌ها را به ترتیب ارزیابی کرده و منحنی را رسم نمایید:

- در صورت پیش‌بینی درست (نمونه مثبت) – **یک گام به سمت بالا** رسم کنید ($TPR \uparrow$).
- در صورت پیش‌بینی نادرست (نمونه منفی) – **یک گام به سمت راست** رسم کنید ($FPR \uparrow$).

تفسیر منحنی‌های ROC و معیار AUC

Interpreting ROC Curves



- **نتیجه ایده‌آل:** تمام رکوردهای مثبت نمره اطمینان بالاتری از رکوردهای منفی داشته باشند (منحنی کاملاً منطبق بر محور چپ و بالا).
- **هر چه شیب تندتر، مدل برتر:** خط قطری نشان‌دهنده حدس کاملاً تصادفی با $AUC = 0.5$ است.
- **مقایسه الگوریتم‌ها:** اگر منحنی مدل A بالای منحنی B قرار گیرد، مدل A در تمام آستانه‌ها برتر است.
- **معیار سطح زیر منحنی:** (AUC) عددی بین 0.5 تا 1.0 برای مقایسه کل توان تفکیک مدل.

ویدیوهای آموزشی آنلاین
Online Lectures

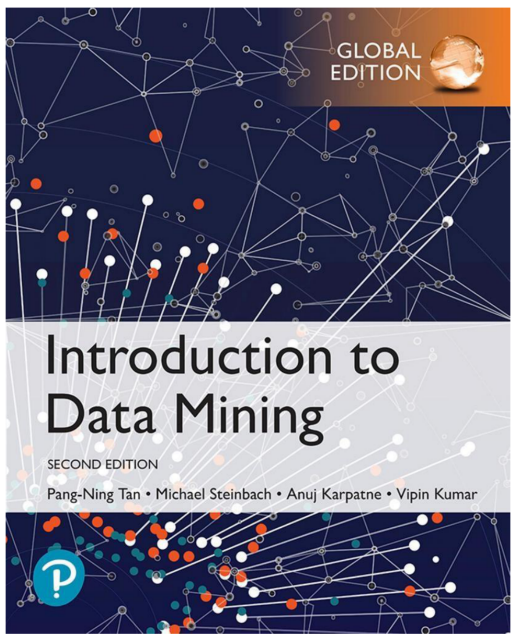
- **اهمیت ویدیوهای مکمل:**
  - برای حل تمرین‌های عملی هفتگی و آزمون پایان‌ترم، مشاهده ویدیوهای برخط درس الزامی است.
  - بررسی جزئیات پیاده‌سازی و شبیه‌سازی الگوریتم‌ها با مثال‌های متعدد

Week	Wednesday (Offline Lecture)	Online Lecture (see Ilias Course)	Thursday (Exercise)
10.02.2025	no lecture		Introduction to Python (13:45–15:15)
17.02.2025	Introduction to Data Mining		Intro
24.02.2025	Preprocessing		Preprocessing
03.03.2025	Classification 1	Nearest Centroids	Classification 1
10.03.2025	Classification 2	Comparing Classifiers	Classification 2
17.03.2025	Regression	Ensembles	Regression
24.03.2025	Clustering and Anomalies	Hierarchical Clustering	Clustering
31.03.2025	Feedback on project outlines	Time Series	Time Series
07.04.2025	Association Analysis and Subgroup Discovery		Association Analysis

پرسش و پاسخ
Questions?



منابع و مراجع این مجموعه اسلاید
Literature for this Slideset



- Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, Vipin Kumar:
  Introduction to Data Mining.
  2nd Edition. Pearson.

- **فصل‌های مرتبط در کتاب:**
  - **فصل ۳: طبقه‌بندی** (Chapter 3: Classification)
    - بخش ۳.۳: طبقه‌بند درخت تصمیم (Decision Tree)
    - بخش ۴.۳: بیش‌برازش (Overfitting)
  - **بخش ۶.۱۰.۶: جنگل‌های تصادفی** (Random Forests)