UNIVERSITY OF MANNHEIM
School of Business Informatics and Mathematics

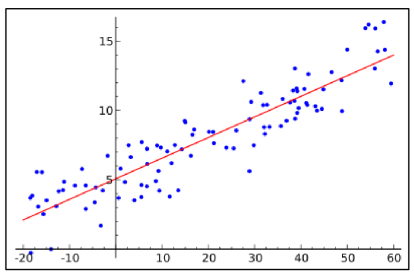
دانشگاه مانهایم • گروه علوم داده و وب

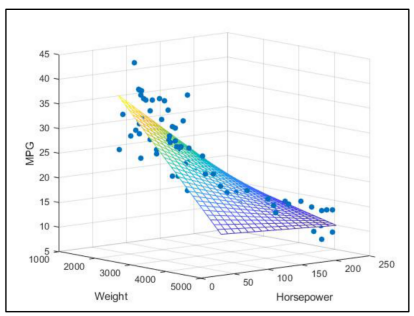
داده‌کاوی (IE500)

فصل پنجم: رگرسیون (Regression)

نسخه 15.03.2025

رگرسیون چیست؟
What is Regression?





- **رگرسیون (Regression)**
  - **هدف:** پیش‌بینی یک مقدار عددی پیوسته (Numerical Value).
  - از میان مجموعه‌ای از مقادیر ممکن که می‌تواند نامتناهی باشد.
- متغیری که پیش‌بینی می‌شود، **متغیر وابسته (Dependent Variable)** نام دارد و با $\hat{y}$ نمایش داده می‌شود.
- سایر متغیرها، **متغیرهای توصیفی یا مستقل (Explanatory / Independent)** نامیده شده و با بردار $X = (x_1, x_2, \ldots, x_n)$ نمایش داده می‌شوند.

مسئله رگرسیون و مقایسه با طبقه‌بندی
The Regression Problem vs. Classification

- **مثال‌ها** (Examples)

پیش‌بینی آب‌وهوا (Weather)

- وابسته: سرعت باد یا دمای هوا.
- توصیفی: دما، رطوبت، تغییر فشار جو.

بازار مسکن (House Market)

- وابسته: قیمت نهایی خانه.
- توصیفی: تعداد اتاق‌ها، فاصله تا حمل‌ونقل عمومی، مساحت حیاط.

- **رگرسیون در مقایسه با طبقه‌بندی** (Regression vs. Classification)
  - **طبقه‌بندی:** (Classification) الگوریتم همه برچسب‌های ممکن را می‌شناسد (مانند بله/خیر، کم/متوسط/زیاد). تمام برچسب‌ها در داده‌های آموزش آمده‌اند و خروجی همیشه یکی از همین برچسب‌هاست.
  - **رگرسیون** (Regression): الگوریتم مقادیری از داده‌ها را می‌شناسد (مانند $18^\circ C$ و $21^\circ C$). مقدار پیش‌بینی‌شده می‌تواند مقداری جدید خارج از داده‌های آموزشی باشد (مانند $20^\circ C$).

گذار از طبقه‌بندی به رگرسیون
Switching from Classification to Regression

- بسیاری از رویکردهای طبقه‌بندی را می‌توان (با اعمال اصلاحاتی) برای مسائل رگرسیون نیز به کار گرفت.
- در ادامه این فصل، هر یک از این رویکردها بررسی خواهند شد:
  - **k نزدیک‌ترین همسایه:** k-Nearest-Neighbors $\rightarrow$ k-NN Regression
  - **درخت‌های تصمیم:** Decision Trees $\rightarrow$ Regression / Model Trees
  - **شبکه‌های عصبی مصنوعی:** ANNs $\rightarrow$ ANNs for Regression

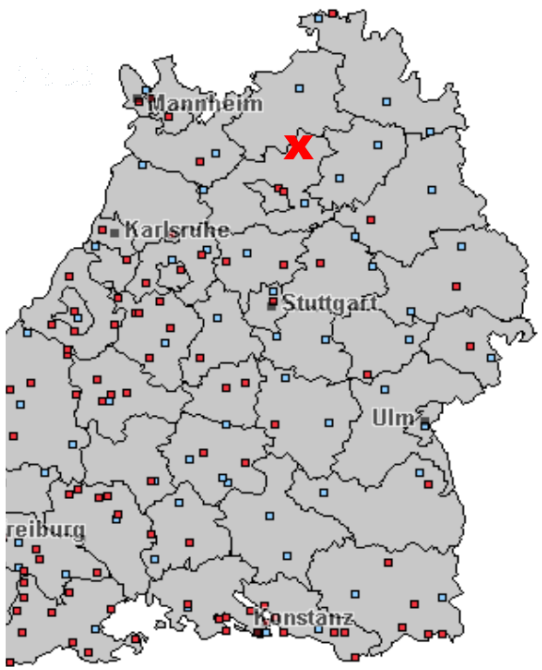
سرفصل مطالب فصل رگرسیون

Course Outline

- رگرسیون k-NN برای رگرسیون (KNN for Regression)
- معیارهای ارزیابی رگرسیون (Evaluation Metrics)
- درخت‌های رگرسیون و درخت‌های مدل (Regression Trees, Model Trees)
- رگرسیون خطی، ریج و لاسو (Linear, Ridge / Lasso Regression)
- رگرسیون هم‌نوا یا ایزوتونیک (Isotonic Regression)
- رگرسیون چندجمله‌ای (Polynomial Regression)
- رگرسیون محلی (Local Regression)
- شبکه‌های عصبی برای رگرسیون (ANNs for Regression)
- موازنه بایاس و واریانس (The Bias/Variance Tradeoff)

بیان مسئله در رگرسیون k نزدیک‌ترین همسایه

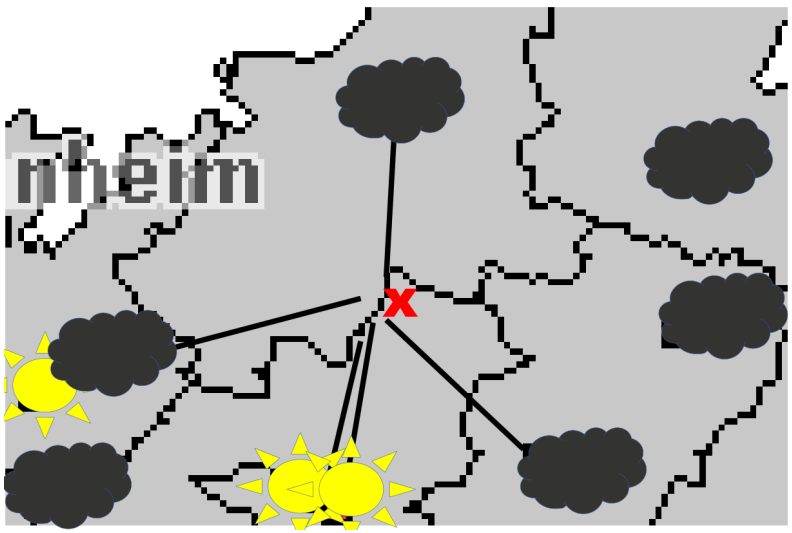
K-Nearest-Neighbors Regression



- **بیان مسئله:** (Problem)
  - پیش‌بینی دمای هوا در یک موقعیت جغرافیایی خاص (x).
  - در نقطه‌ای که هیچ ایستگاه هواشناسی در آنجا مستقر نیست!
  - چگونه می‌توان چنین پیش‌بینی پیوسته‌ای را انجام داد؟
- ایده طبیعی: استفاده از اطلاعات نزدیک‌ترین ایستگاه‌های هواشناسی مجاور.

یادآوری: طبقه‌بندی k نزدیک‌ترین همسایه

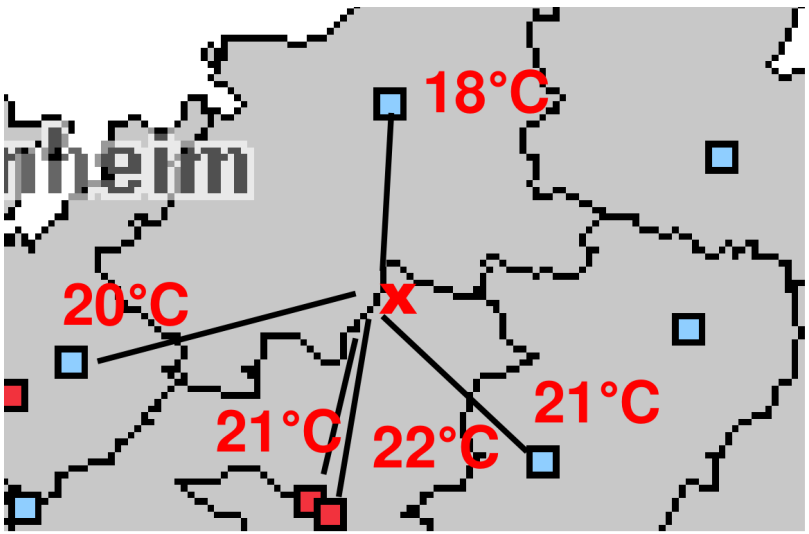
Recap: K-Nearest-Neighbors Classification



- **ایده در طبقه‌بندی:** رأی‌گیری اکثریت (Majority Vote) میان نزدیک‌ترین ایستگاه‌ها.
- **مثال طبقه‌بندی:**
  - ۳ ایستگاه: ابری (Cloudy)
  - ۲ ایستگاه: آفتابی (Sunny)
  - **نتیجه رأی‌گیری:** ابری (Cloudy)
- پارامتر k تعداد همسایگان مدنظر را تعیین می‌کند ($k = 5$).
- «نزدیکی» بر مبنای مجاورت جغرافیایی یا فاصله اقلیدسی تعریف می‌شود.

برآورد عددی در رگرسیون k نزدیک‌ترین همسایه

K-Nearest-Neighbors Regression



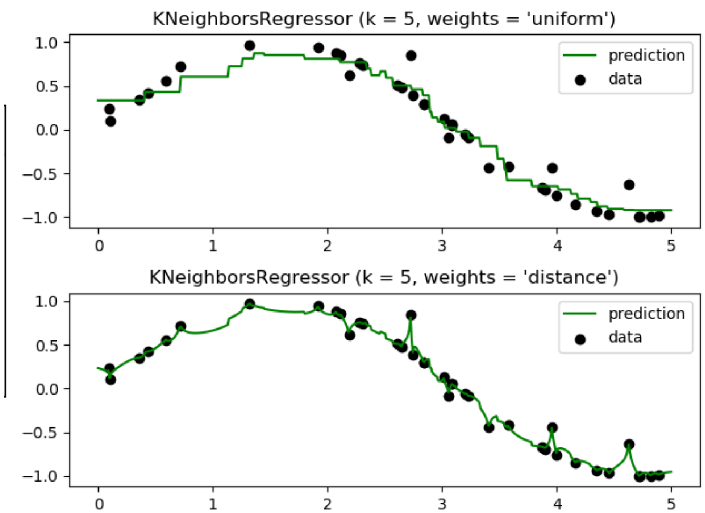
- **ایده در رگرسیون:** استفاده از **میانگین عددی** مقادیر ایستگاه‌های مجاور.
- **مثال محاسباتی** ($k = 5$):
  - دماهای ثبت‌شده:
    $18\,^\circ\mathrm{C}, 20\,^\circ\mathrm{C}, 21\,^\circ\mathrm{C}, 22\,^\circ\mathrm{C}, 21\,^\circ\mathrm{C}$

$$\hat{y} = \frac{18 + 20 + 21 + 22 + 21}{5} = \mathbf{20.4}\,^\circ\mathrm{C}$$

- **میانگین‌گیری وزنی بر اساس فاصله:**
  ایستگاه‌های نزدیک‌تر وزن بیشتری در تعیین مقدار خروجی دارند.

پیاده‌سازی رگرسیون k نزدیک‌ترین همسایه در پایتون

K-NN Regression in Scikit-Learn




```
from sklearn.neighbors import KNeighborsRegressor

# 1. Create and fit KNN regressor
estimator = KNeighborsRegressor(n_neighbors=15)
estimator.fit(training_set_X,
training_dependent_y)

# 2. Predict for unseen examples
y_hat = estimator.predict(test_set_X)
```

- **وزن‌دهی یکنواخت** (uniform)؛ میانگین ساده حسابی مقادیر همسایگان.
- **وزن‌دهی بر مبنای فاصله** (distance)؛ اختصاص وزن بیشتر بر مبنای معکوس فاصله نمونه‌ها.

معیارهای ارزیابی خطا (MAE, MSE, RMSE)

Evaluation Metrics: Error Measures

- **میانگین قدرمطلق خطا:** (MAE) میانگین اختلاف بین مقدار پیش‌بینی (p_i) و مقدار واقعی (a_i) است.

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|p_i - a_i|$$ (هم‌مقیاس با دامنه مسئله، مانند دما)

- **میانگین مربعات خطا:** (MSE) خطاهای بزرگ‌تر را با شدت بیشتری جریمه می‌کند.

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(p_i - a_i)^2$$

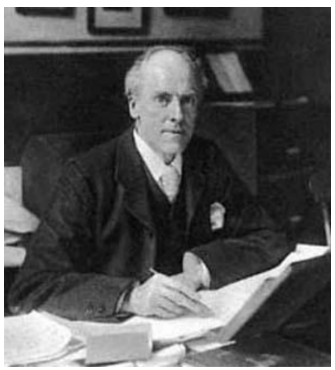
- **جذر میانگین مربعات خطا:** (RMSE) دارای مقیاس یکسان با متغیر هدف و تأکید بیشتر بر خطاهای بزرگ.

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(p_i - a_i)^2}$$ (هم‌مقیاس با دامنه مسئله)

مقدار پیش‌بینی‌شده: (Predicted) p_i | **مقدار واقعی:** (Actual) a_i

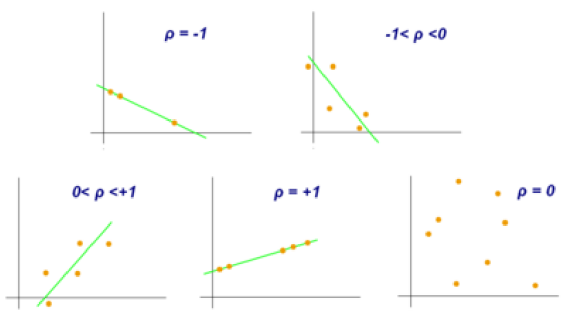
معیارهای ارزیابی: ضریب همبستگی پیرسون

Pearson's Correlation Coefficient (PCC)



Karl Pearson (1857–1936)

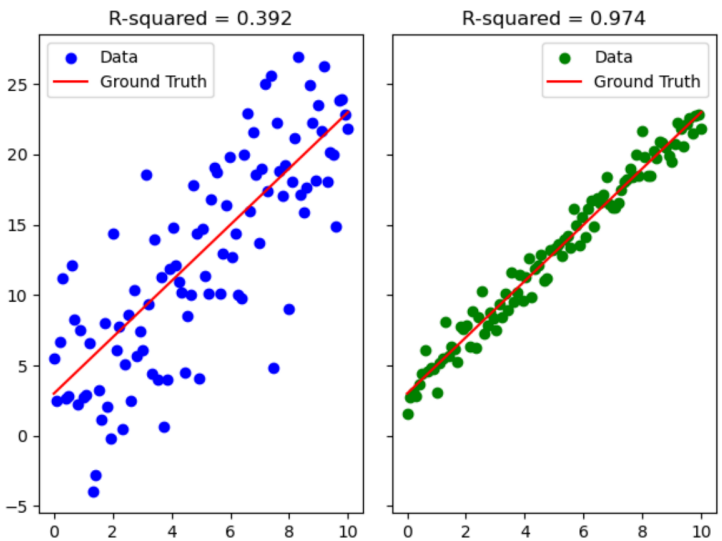
- مقدار نرمال‌شده در بازه $[-1, 1]$
- امتیاز بالا زمانی حاصل می‌شود که:
  - مقادیر واقعی بزرگ، پیش‌بینی‌های بزرگ دریافت کنند.
  - مقادیر واقعی کوچک، پیش‌بینی‌های کوچک دریافت کنند.
- **هشدار مهم:** ضریب پیرسون نسبت به مقیاس **ناوردا** (Scale-Invariant) است!
  - درآمد واقعی برابر $1, $2, $3
  - درآمد پیش‌بینی‌شده برابر $1,000, $2,000, $3,000
  - نتیجه به دست آمده: $\text{PCC} = 1$ (علیرغم اختلاف فاحش در مقادیر مطلق!)



$$\text{PCC} = \frac{\sum_{i=1}^{n}(p_i - \bar{p})(a_i - \bar{a})}{\sqrt{\sum_{i=1}^{n}(p_i - \bar{p})^2} \cdot \sqrt{\sum_{i=1}^{n}(a_i - \bar{a})^2}}$$

معیارهای ارزیابی: ضریب تعیین

Coefficient of Determination (R^2)



- مقداری نرمال‌شده در بازه $[0, 1]$ (برای مدل‌های معقول).
- بیانگر سهمی از کل تغییرات متغیر وابسته y که توسط متغیرهای توصیفی X تبیین‌پذیر است:

$$R^2 = \frac{\sum_{i=1}^{n}(p_i - \bar{a})^2}{\sum_{i=1}^{n}(a_i - \bar{a})^2} = \frac{\text{ESS}}{\text{TSS}}$$

- **تفسیر مقادیر R^2:**
  - به ازای $R^2 = 1$: مدل ایده‌آل؛ کل پراکندگی y به طور کامل توسط X توضیح داده شده است.
  - به ازای $R^2 = 0$: مدل در حد خط پایه (میانگین $\bar{a}$) عمل می‌کند.

درخت‌های رگرسیون

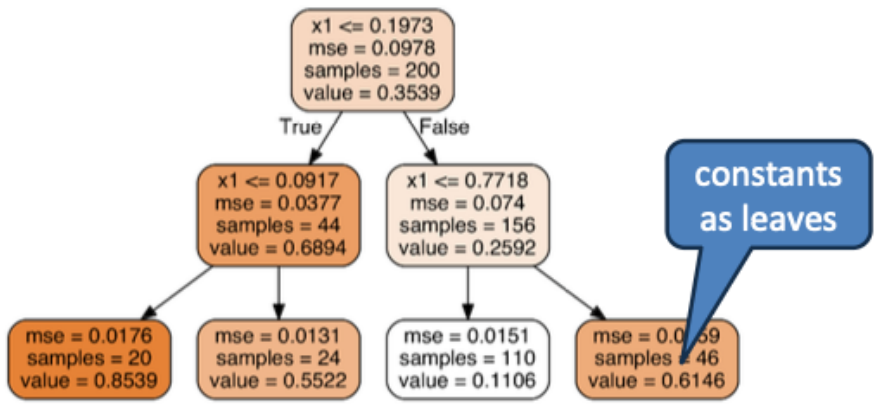
Regression Trees

- ایده اصلی یادگیری و به‌کارگیری درخت‌های تصمیم، برای مسائل رگرسیون نیز قابل تعمیم است.
- **تفاوت‌ها با درخت تصمیم در طبقه‌بندی:**

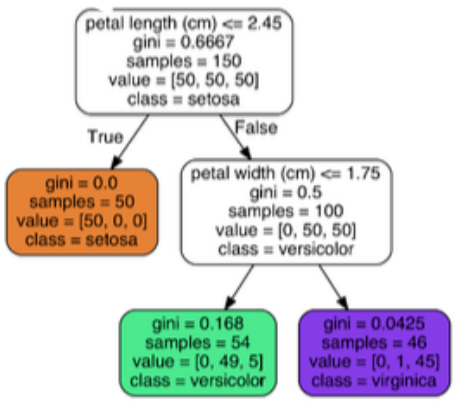
۱. **معیار تفکیک:** تفکیک‌ها با هدف بیشینه‌سازی کاهش خطا (MSE) انجام می‌شوند (نه شاخص GINI).

۲. **پیش‌بینی در برگ‌ها:** خروجی هر برگ، میانگین مقادیر نمونه‌های آموزشی حاضر در آن برگ است.

درخت رگرسیون (Regression Tree)

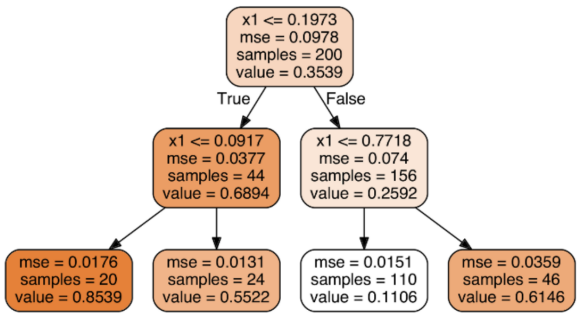


درخت تصمیم (Decision Tree)



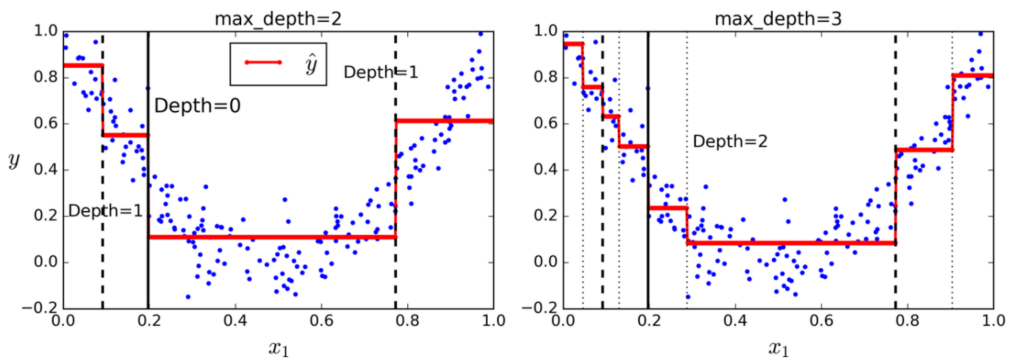
عمق درخت رگرسیون و افراز فضا

Regression Trees: Depth & Partitioning

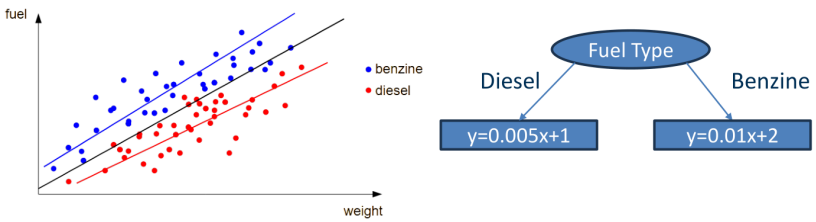


- پارامترهای پیش‌هرس (Pre-pruning) میزان برازش درخت با داده‌های آموزشی را مشخص می‌کنند:
  - به عنوان مثال پارامتر `max_depth`.
- **مدل حاصل:** یک **تابع تکه‌ای-ثابت** بر روی فضای ویژگی‌ها است:

Piecewise Constant Function

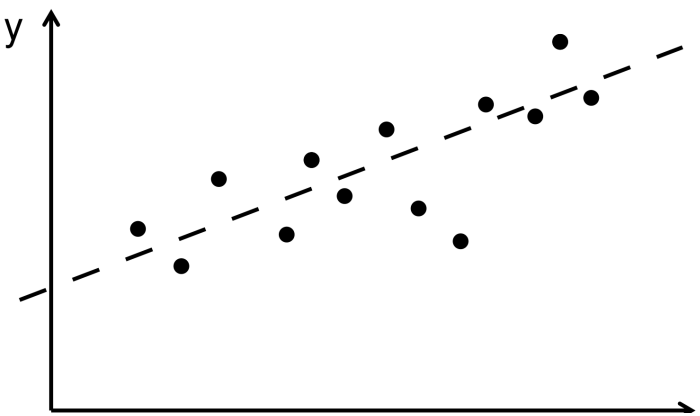


درخت‌های مدل
Model Trees



- **ایده:** تفکیک اولیه داده‌ها به شکلی که ارتباط در هر بخش «خطی‌تر» شود.
  - **مثال:** مصرف سوخت بر حسب وزن خودرو.
- **به جای مقدار ثابت در هر برگ:** یک تابع رگرسیون خطی آموزش داده می‌شود.
- **نحوه پیش‌بینی:** پیمایش ساختار درخت تا رسیدن به برگ متناظر، سپس ارزیابی تابع رگرسیون همان برگ.
- **مدل حاصل: تابع تکه‌ای-خطی (Piecewise Linear).**

رگرسیون خطی
Linear Regression



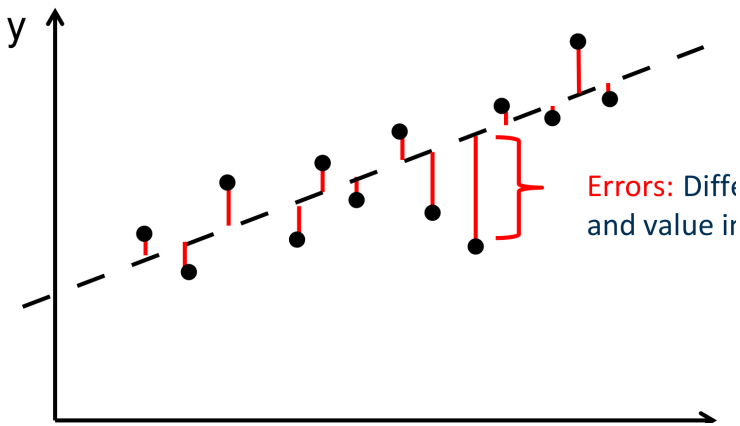
- **چگونه تابع رگرسیون خطی را یاد بگیریم؟**
- **فرض اساسی:** متغیر هدف y وابستگی (تقریباً) خطی به متغیرهای توصیفی X دارد.
- **برای تجسم دوبعدی** (یک متغیر مستقل x در رگرسیون ساده):

$$f(x) = w_0 + w_1 x$$

- **در واقعیت:** بردار ویژگی‌های چندگانه $X = (x_1, \ldots, x_n)$ (رگرسیون خطی چندمتغیره).

برازش تابع رگرسیون: روش کمترین مربعات

Least-Squares Approach: Simple Linear Regression



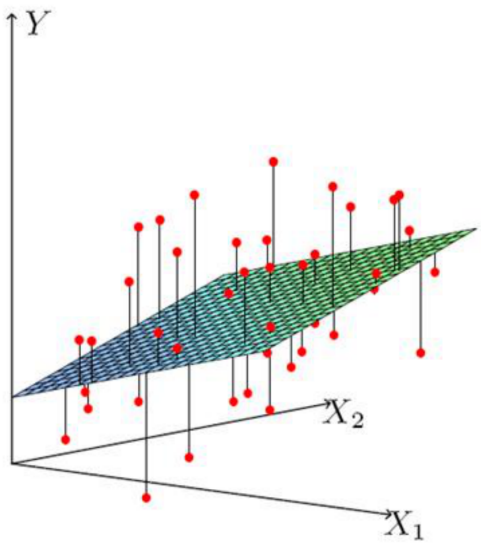
- هدف یافتن بردار وزن‌های $W = (w_0, w_1)$ برای تابع $f(x) = w_0 + w_1 x$ است که مجموع مربعات خطا را کمینه کند:

$$\text{SSE} = \sum_{i=1}^{n} (y_i - f(x_i))^2$$

- **باقیمانده‌ها** (Residuals)؛ اختلاف میان مقدار تخمین‌زده‌شده توسط مدل و مقدار واقعی داده آموزش:

$$e_i = y_i - f(x_i)$$

رگرسیون خطی چندمتغیره
Multiple Linear Regression



- برازش ابرصفحهٔ رگرسیون برای n متغیر توصیفی:

$$\hat{y}(X) = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

- کمینه‌سازی معیار SSE (مجموع مربعات خطا):

$$\text{SSE} = \sum_{i=1}^{n} (y_i - \hat{y}(X_i, W))^2$$

- حل تحلیلی به کمک معادلهٔ نرمال ماتریسی:

$$W = (X^T X)^{-1} X^T Y$$

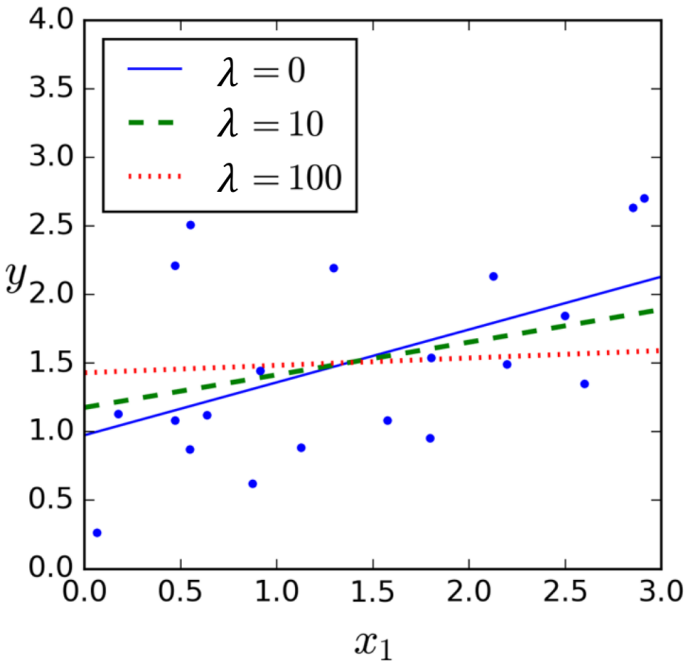
رگرسیون خطی و بیش‌برازش
Linear Regression and Overfitting



- فرض کنید دو مدل رگرسیونی برای یک پدیده ارائه شده است:
  - مدل اول: استفاده از ۵ متغیر برای تبیین پدیده.
  - مدل دوم: استفاده از ۱۰۰ متغیر برای همان داده‌ها!
- کدام مدل ارجح است؟
- **یادآوری تیغ اوکام:** (Occam's Razor) از میان دو نظریه که پدیده‌ای یکسان را توضیح می‌دهند، همواره مدل ساده‌تر (با متغیرهای کمتر) ترجیح داده می‌شود.

رگرسیون ریج

Ridge Regression (L_2 Regularization)



- رویکردی بر پایه کمترین مربعات که با کوچک نگه‌داشتن وزن‌ها (W) از بیش‌برازش جلوگیری می‌کند.
- افزودن جریمه مربعی به وزن‌ها (Penalty):

$$\min_W \sum_{i=1}^{n} (y_i - \hat{y}(X_i, W))^2 + \lambda \sum_{j=1}^{m} w_j^2$$

- **نقش فراپارامتر λ در مدل:**
  - به ازای $\lambda = 0$: رگرسیون خطی معمولی (OLS) بدون جریمه.
  - برای مقادیر بزرگ λ: انقباض ضرایب به سمت صفر (Shrinkage).

رگرسیون لاسو

Lasso Regression (L_1 Regularization)

- رگرسیون ریج ضرایب را کوچک می‌کند اما دقیقاً صفر نمی‌سازد.
- **رگرسیون لاسو:** ضرایب ویژگی‌های غیرضروری را دقیقاً به **صفر** کاهش می‌دهد (انتخاب ویژگی توکار).
- تابع هدف بهینه‌سازی لاسو با جریمه قدرمطلق:

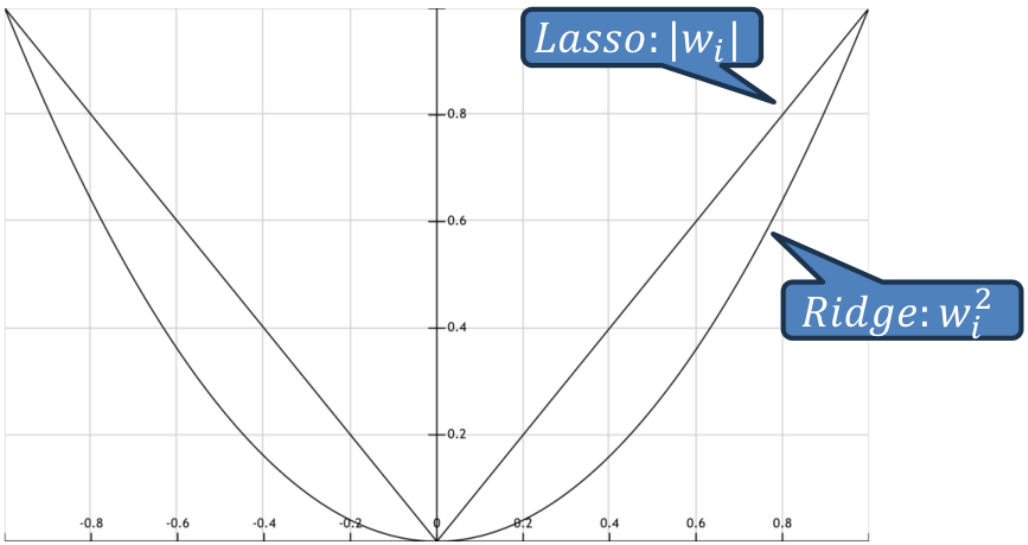
$$\min_{W} \sum_{i=1}^{n} (y_i - \hat{y}(X_i, W))^2 + \lambda \sum_{j=1}^{m} |w_j|$$

- **رفتار حدی فراپارامتر λ در مدل:**
  - به ازای $\lambda = 0$: بدون منظم‌سازی (رگرسیون خطی معمولی) $\rightarrow$ خطر بیش‌برازش (Overfitting).
  - وقتی $\lambda \rightarrow \infty$: میل تمام وزن‌ها به سمت صفر $\rightarrow$ کم‌برازش شدید (Underfitting).

مقایسه هندسی لاسو و ریج

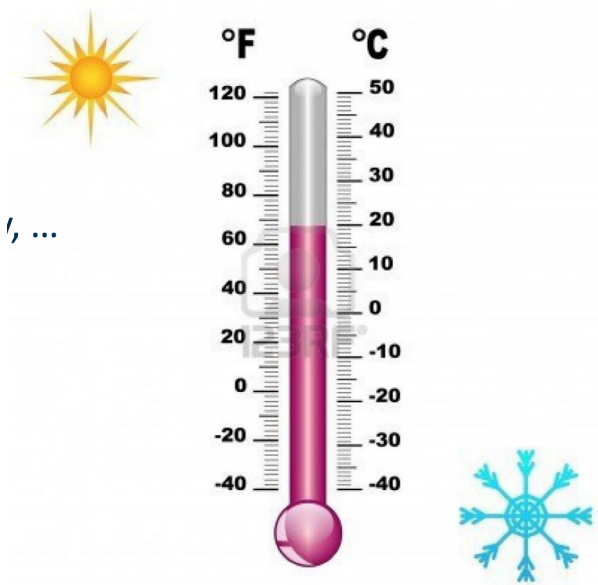
Lasso vs. Ridge Regression: Geometry

- در لاسو، برای مقادیر $|w_i|$ نزدیک به صفر، شیب جریمه خطی بزرگتر از جریمه مربعی ریج باقی می‌ماند.
- به همین دلیل، فرآیند بهینه‌سازی وزن‌های کم‌اهمیت را دقیقاً روی محورها بر صفر منطبق می‌سازد (Sparsity).



مقایسه هندسی: لوزی (مدل Lasso با جریمه خطی) در برابر دایره (مدل Ridge با جریمه مربعی)

درون‌یابی در برابر برون‌یابی
Interpolation vs. Extrapolation

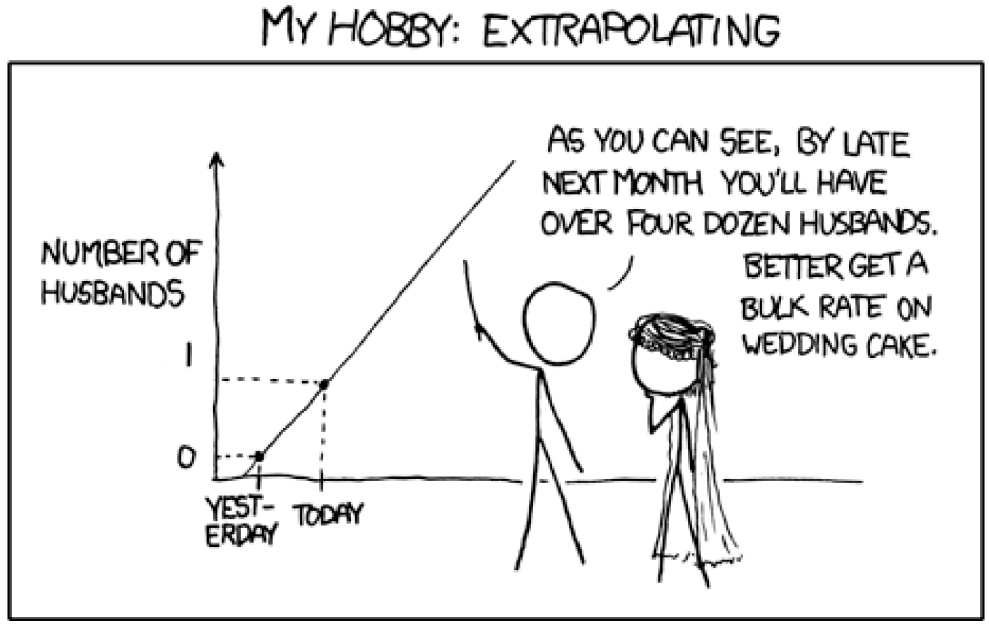


- **داده‌های آموزش:** مشاهدات روزانه هواشناسی (دما، سرعت باد، رطوبت) در بازه $[-15°C, 32°C]$.
- **رگرسیون درون‌یاب** (Interpolating) تنها مقادیری در محدوده بازه آموزشی داده‌ها پیش‌بینی می‌کند.
- **رگرسیون برون‌یاب** (Extrapolating) قادر است مقادیر فراتر یا خارج از بازه دیده‌شده را نیز پیش‌بینی نماید.

درون‌یابی به عنوان رویکردی «امن»

Interpolation as a Safe Strategy

- رگرسیون‌های درون‌یاب عموماً «امن» تلقی می‌شوند، زیرا فقط مقادیر منطقی و باورپذیر را تخمین می‌زنند.



چه زمانی برون‌یابی ضروری است؟

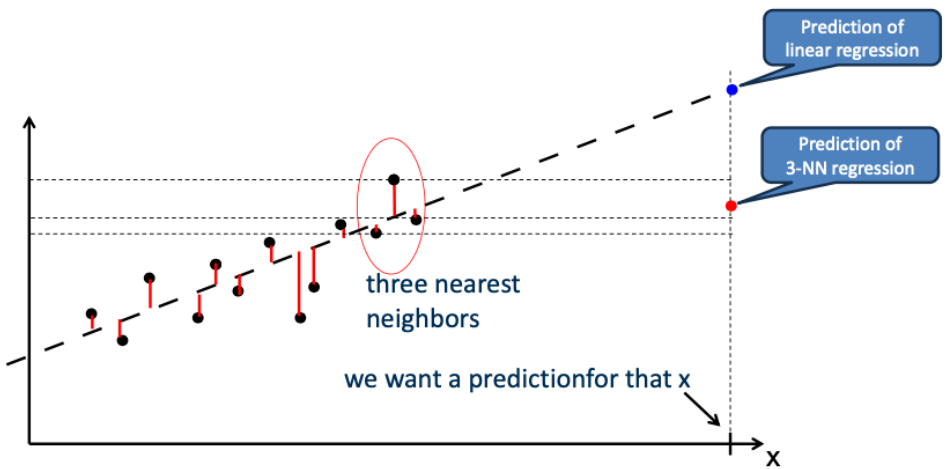
When Extrapolation is Needed



- گاهی اوقات تنها پیش‌بینی‌های برون‌یابی جذاب و کاربردی هستند:
  - سطح آب دریاها تا سال ۲۰۵۰ چقدر افزایش خواهد یافت؟
  - دمای راکتور در یک سناریوی اضطراری تا چه میزانی بالا می‌رود؟
- در این کاربردها، مدل‌های درون‌یاب صرفاً مقادیر گذشته را بازگو کرده و ناتوان خواهند بود.

مقایسه رگرسیون خطی و رگرسیون k نزدیک‌ترین همسایه

Linear Regression vs. K-NN Regression



- **رگرسیون خطی:**
  - برون‌یابی می‌کند
  - Extrapolates
- **رگرسیون k نزدیک‌ترین همسایه:**
  - درون‌یابی می‌کند
  - Interpolates
- **درخت‌های رگرسیون:**
  - درون‌یابی می‌کنند
  - Interpolates

پیش‌بینی خط پایه در رگرسیون

Baseline Prediction

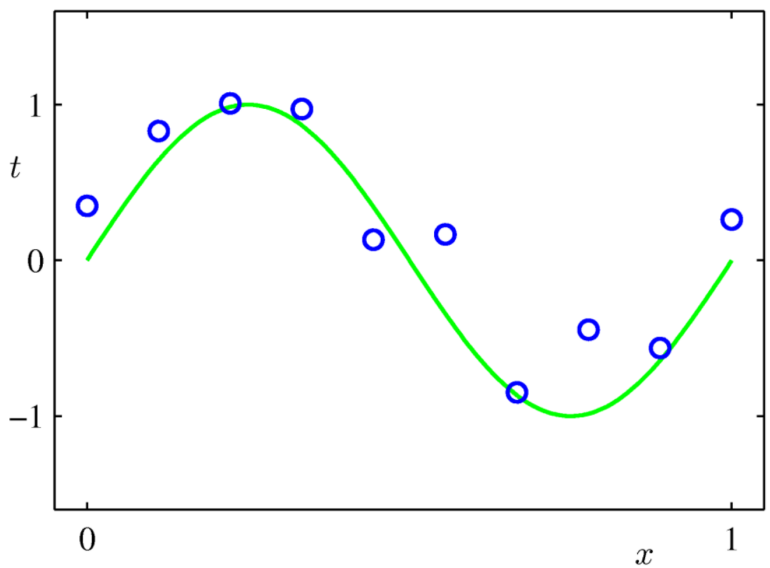
- **در طبقه‌بندی:** پیش‌بینی فراوان‌ترین برچسب (Majority Class).
- **در رگرسیون:** پیش‌بینی با مقادیر خلاصه آماری:
  - میانگین داده‌ها (Average / Mean)
  - میانه داده‌ها (Median)
  - مد داده‌ها (Mode)
- در هر صورت: این روش‌ها فقط درون‌یابی انجام می‌دهند.
- این مدل‌های ساده خط پایه‌ای قوی برای سنجش ارزش مدل‌های پیچیده هستند.



THE PROBLEM WITH AVERAGING STAR RATINGS

مسائل غیرخطی در رگرسیون

Non-linear Problems



- بسیاری از فرآیندهای واقعی از برازش خط مستقیم پیروی نمی‌کنند.
- **راهکارهای اساسی مدل‌سازی غیرخطی:**
  - **رگرسیون هم‌نوا یا ایزوتونیک** (Isotonic)؛ برای توابع غیرخطی اما یکنواخت (صعودی یا نزولی).
  - **رگرسیون چندجمله‌ای** (Polynomial)؛ برای برازش منحنی‌های پیچیده و غیریکنواخت.

رگرسیون هم‌نوا (ایزوتونیک)
Isotonic Regression

- **حالت خاص:** تابع هدف **یکنواخت یا هم‌نوا (Monotonous)** است.
- اگر $x_1 \leq x_2$ باشد، آنگاه رابطه $f(x_1) \leq f(x_2)$ ارضا می‌شود:

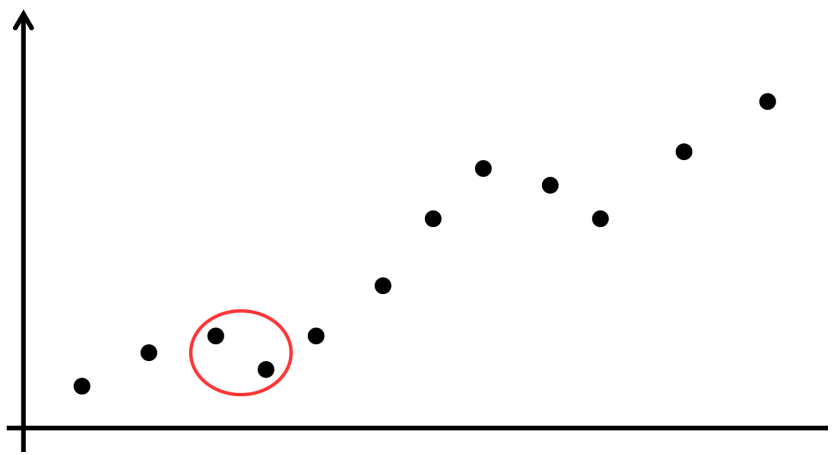
$$x_1 \leq x_2 \implies f(x_1) \leq f(x_2)$$

- برای این دسته از مسائل، الگوریتم‌های بهینه‌سازی بسیار سریعی توسعه یافته است.
- **ساده‌ترین و پرکاربردترین روش: الگوریتم تجمیع متجاوزان مجاور (Pool Adjacent Violators Algorithm - PAVA).**

الگوریتم تجمیع متجاوزان مجاور: گام ۱

Pool Adjacent Violators: Step 1

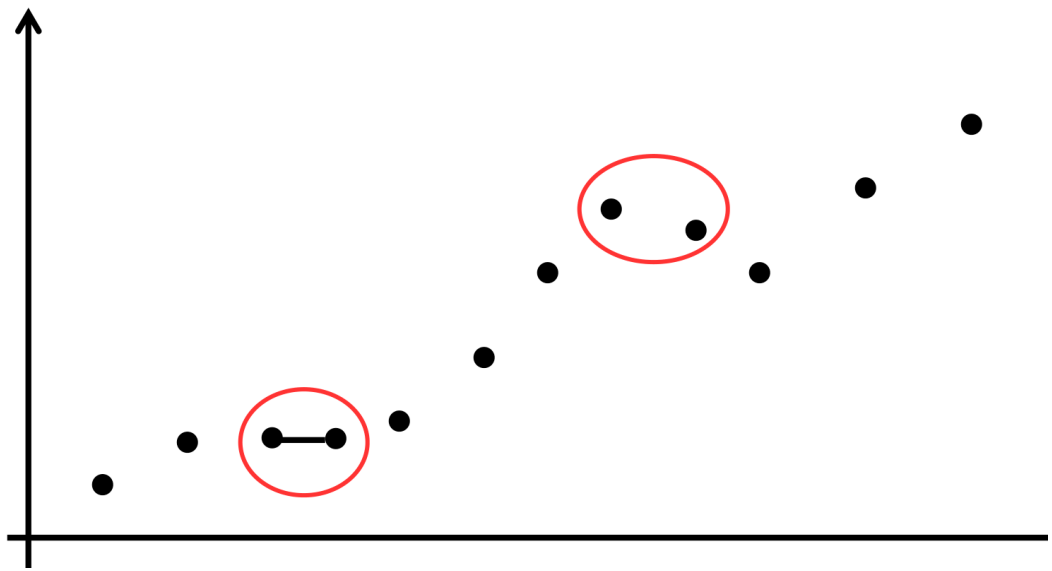
- شناسایی متجاوزان مجاور (Adjacent Violators)؛ نقاطی که در آن‌ها $f(x_i) > f(x_{i+1})$.
- جایگزینی با مقادیر $f'(x_i) = f'(x_{i+1})$ به گونه‌ای که مجموع مربعات خطا کمینه شود.
- تجمیع نقاط (اصطلاحاً Pool)، به طوری که از این پس به عنوان یک نقطه واحد در نظر گرفته می‌شوند.
- تکرار تا زمانی که هیچ متجاوز مجاوری باقی نماند.



الگوریتم تجمیع متجاوزان مجاور: گام ۲

Pool Adjacent Violators: Step 2

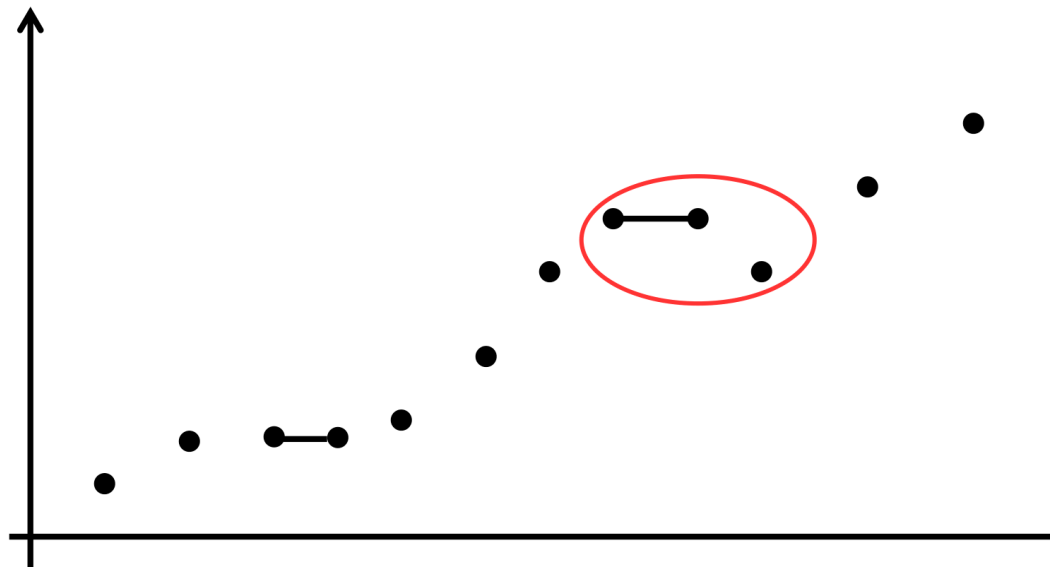
- ادغام نقاط مرحله قبل و یافتن جفت متجاوز مجاور بعدی.
- محاسبه میانگین جدید جهت حفظ بهینگی مجموع مربعات خطا.



الگوریتم تجمیع متجاوزان مجاور: گام ۳

Pool Adjacent Violators: Step 3

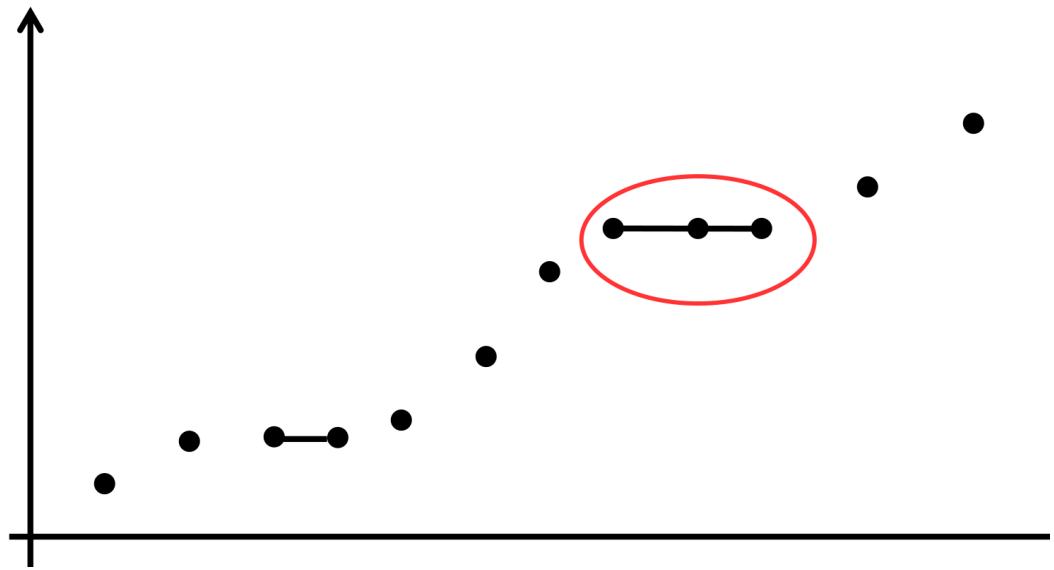
- ادامه فرآیند تجمیع بلوک‌ها به سمت راست محور متغیر توصیفی.



الگوریتم تجمیع متجاوزان مجاور: گام ۴

Pool Adjacent Violators: Step 4

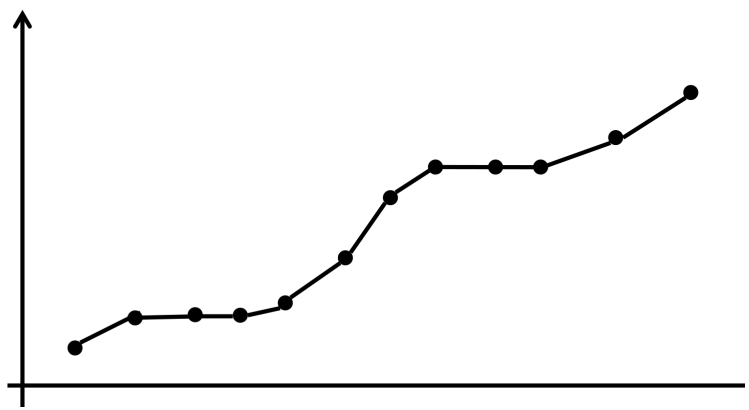
- آخرین مرحله رفع نقض شرط یکنوایی و برقراری شرط صعودی برای تمام نقاط.



رگرسیون هم‌نوا: تابع برازش نهایی

Piecewise Linear / Step Interpolation

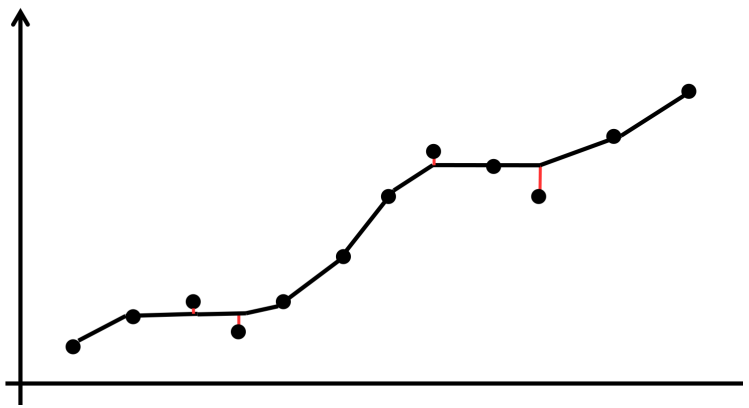
- پس از بازآرایی و تجمیع تمامی نقاط به گونه‌ای که شرط یکنوایی برای همه نقاط ارضا شود:
- اتصال نقاط حاصل با یک **تابع تکه‌ای-خطی یا پله‌ای** یکنواخت.



رگرسیون هم‌نوا: مقایسه با نقاط اصلی

Comparison to Original Points

- **تشکیل کفه یا فلات** (Plateaus)؛ در بخش‌هایی از داده‌ها که اولیه غیریکنواخت بوده‌اند، پله‌های افقی پدید می‌آید.
- در عین حال، میانگین مربعات خطا (MSE) در کل داده‌ها تحت قید یکنوایی کمینه می‌شود.

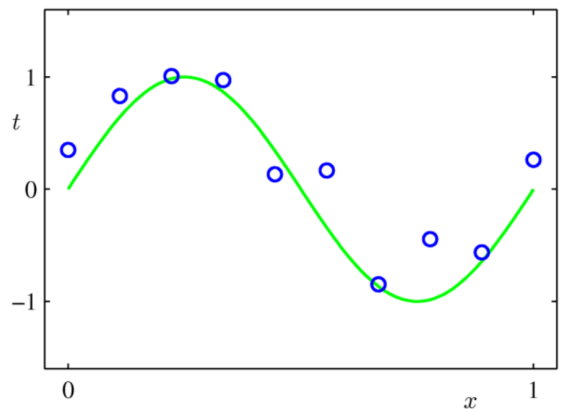


رگرسیون هم‌نوا در پایتون
Isotonic Regression in Scikit-Learn

- کتابخانه: `from sklearn.isotonic import IsotonicRegression`
- **پارامتر** `increasing` **:**
  - `True` : قید صعودی یکنواخت | `False` : قید نزولی یکنواخت.
  - `'auto'` : تعیین خودکار بهترین جهت بر اساس کمینه‌سازی خطا.
- **پارامتر** `out_of_bounds` **(نحوه مدیریت مقادیر نادیده** x**):**
  - `'clip'` : استفاده از کمترین/بیشترین مقدار y در داده‌های آموزش.
  - `'nan'` : تخصیص مقدار نامعتبر NaN.
  - `'raise'` : پرتاب خطا (Exception).

مسائل غیرخطی و غیریکنواخت

Non-linear, Non-monotonous Problems

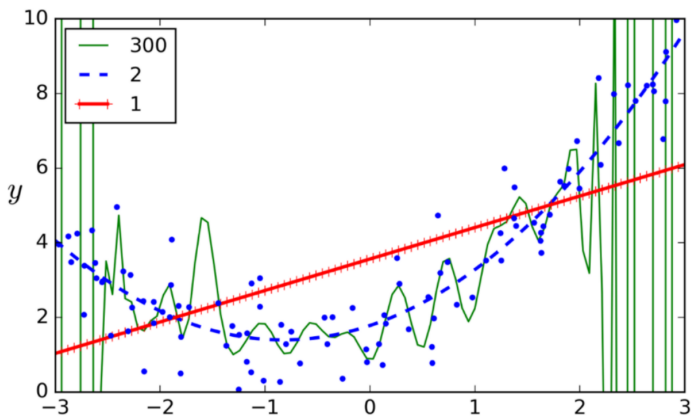


- اگر تابع هدف هم غیرخطی و هم غیریکنواخت باشد، چه کنیم؟
- **اعمال تبدیل بر روی متغیرهای توصیفی X به این صورت:**
  - تبدیلات ریاضی مانند $\log(x)$، $\exp(x)$، $\sqrt{x}$، x^2 و غیره.
  - **تبدیل چندجمله‌ای** (Polynomial) به فرم زیر:

$$y = w_0 + w_1 x + w_2 x^2 + w_3 x^3$$

رگرسیون چندجمله‌ای
Polynomial Regression

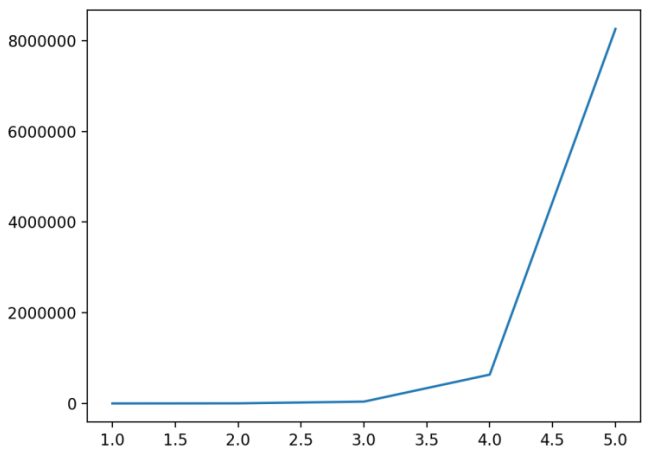
$$\hat{y}(x, \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \cdots + w_d x^d = \sum_{j=0}^{d} w_j x^j$$



- تعمیم گسترده و پرکاربرد رگرسیون خطی.
- برازش همچنان با همان روش کمترین مربعات خطی (OLS) صورت می‌گیرد!
- **چالش اصلی:** تمایل شدید به بیش‌برازش در درجات بالای d.
- **راهکارها:**
  - کاهش درجهٔ d
  - افزایش حجم داده‌های آموزش

انفجار ابعاد در رگرسیون چندجمله‌ای چندمتغیره

Curse of Dimensionality in Polynomial Features



- تعداد ویژگی‌های چندجمله‌ای درجهٔ d برای دیتاستی با f ویژگی از مرتبهٔ $\mathcal{O}(f^d)$ رشد می‌کند!
- **مثال با ۳ ویژگی** x, y, z **و درجهٔ** $d = 3$:
  - درجهٔ ۲ (6 ویژگی): $x^2, y^2, z^2, xy, xz, yz$
  - درجهٔ ۳ (10 ویژگی): $x^3, y^3, z^3, x^2y, \ldots$
- برای داده‌هایی با ۶۰ ویژگی اولیه، در درجات بالاتر صدها هزار ویژگی جدید پدید می‌آید.

رگرسیون چندجمله‌ای و خطر بیش‌برازش

Polynomial Regression & Overfitting

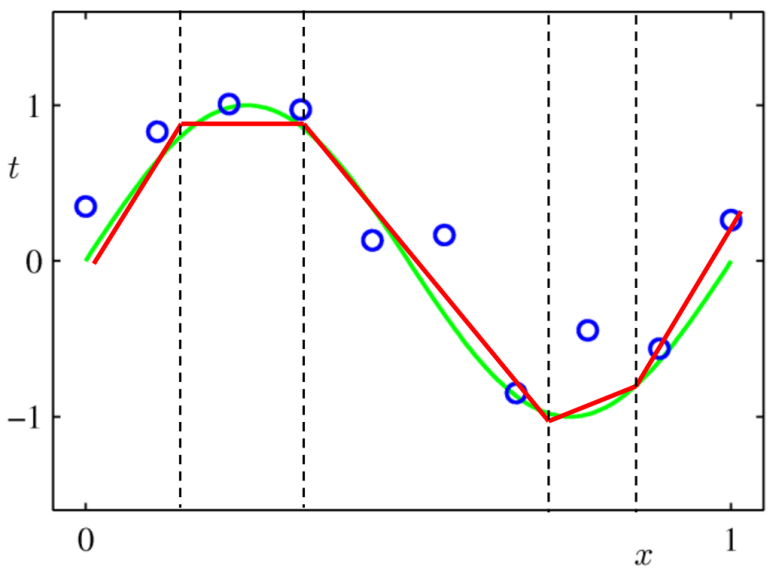
- **چرا مجموعه‌های ویژگی بسیار بزرگ خطرناک هستند؟**
- بیش‌برازش را مانند «حفظ کردن» (Memorization) داده‌ها در نظر بگیرید.
- با ۱۰۰۰ متغیر و ۱۰۰۰ نمونه، مدل می‌تواند هر نمونه را با ترکیب یکتایی از ویژگی‌ها حفظ کند!
- اما با ۲ متغیر برای ۱۰۰۰ نمونه، مدل ناچار به «انتزاع» و یادگیری الگوی واقعی می‌شود.
- **قاعده سرانگشتی طلایی:** ابعاد دیتاست هرگز نباید عریض‌تر از طول آن باشد (Never wider than long)!

Python

```python
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import LinearRegression

poly_features = PolynomialFeatures(degree=2, include_bias=False).fit_transform(X, y)
estimator = LinearRegression()
estimator.fit(poly_features, y)
```

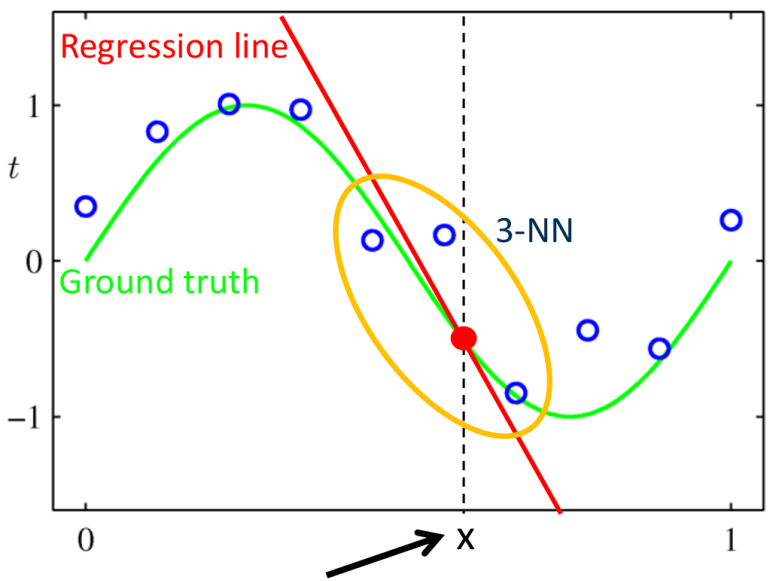
رگرسیون محلی
Local Regression



- **فرض اساسی:** مسائل غیرخطی در همسایگی‌های محلی کوچک تقریباً خطی هستند.
- **ایده اصلی:**
  - برازش یک خط رگرسیون به صورت کاملاً محلی.
  - انجام محاسبات صرفاً برای همان نقطه آزمون در زمان درخواست (Lazy Learning).

گام‌های رگرسیون محلی

Local Regression Algorithm (KNN + Linear Regression)



- ترکیبی هوشمندانه از k نزدیک‌ترین همسایه و رگرسیون خطی:
  ۱. برای نقطه ورودی جدید، k همسایه نزدیک‌تر را بازیابی کن.
  ۲. یک مدل رگرسیون خطی محلی فقط روی این k همسایه آموزش بده.
  ۳. با استفاده از مدل محلی، مقدار y را برای نقطه ورودی تخمین بزن.

مزایا و معایب رگرسیون محلی

Discussion of Local Regression

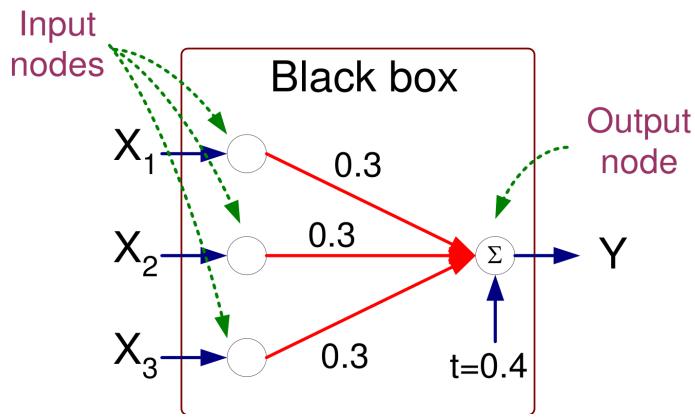
- **مزایا:**
  - انطباق بسیار عالی بر الگوها و روندهای غیرخطی پیچیده.
  - تقریب محلی بسیار دقیق‌تر از میانگین‌گیری ساده در رگرسیون k-NN.
- **معایب و چالش‌ها:**
  - **هزینه محاسباتی بالا در زمان پیش‌بینی:** (Slow at runtime) به ازای هر نمونه آزمون، باید نزدیک‌ترین همسایه‌ها جستجو شده و یک مدل خطی از نو حل شود!

شبکه‌های عصبی برای رگرسیون: یادآوری طبقه‌بندی

ANNs: Recap for Classification

- **یادآوری:** چگونه از شبکه‌های عصبی در طبقه‌بندی استفاده کردیم؟

Y	X_3	X_2	X_1
۰	۰	۰	۱
۱	۱	۰	۱
۱	۰	۱	۱
۱	۱	۱	۱
۰	۱	۰	۰
۰	۰	۱	۰
۱	۱	۱	۰
۰	۰	۰	۰



$$Y = I(0.3X_1 + 0.3X_2 + 0.3X_3 - 0.4 > 0)$$

که در آن: $I(z) = \begin{cases} 1 & \text{اگر } z \text{ درست باشد} \\ 0 & \text{در غیر این صورت} \end{cases}$

شبکه‌های عصبی: خروجی پیوسته رگرسیون

ANNs: Continuous Output Prediction

- تابع $I(z)$ برای تفکیک دو کلاس به کار می‌رفت:

$$Y = I(0.3X_1 + 0.3X_2 + 0.3X_3 - 0.4 > 0)$$

که در آن: $I(z) = \begin{cases} 1 & \text{اگر } z \text{ درست باشد} \\ 0 & \text{در غیر این صورت} \end{cases}$

- با این حال، می‌توانیم به سادگی از **ترکیب خطی درونی** برای پیش‌بینی یک مقدار عددی پیوسته (بین ۰ و ۱) استفاده کنیم:

$$\hat{Y} = 0.3X_1 + 0.3X_2 + 0.3X_3 - 0.4$$

  - خروجی این فرمول یک عدد حقیقی پیوسته بدون محدودیت کلاس است.

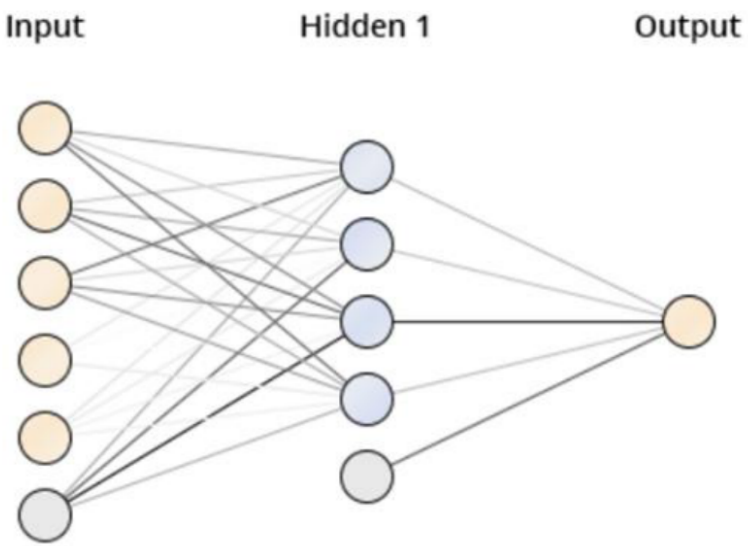
تغییرات شبکه عصبی در حالت رگرسیون

ANNs: What Has Changed for Regression?

- **تابع فعال‌سازی لایه خروجی:** عدم استفاده از حد آستانه یا سیگموئید در گره نهایی؛ خروجی به شکل تابع همانی (Identity / Linear) باقی می‌ماند.
- **داده‌های آموزش:** بردار متغیرهای ورودی به همراه یک متغیر هدف **پیوسته عددی** (به جای برچسب گسسته کلاس).
- **تابع خطا و یادگیری:** به جای خطای طبقه‌بندی یا آنتروپی متقاطع، از **میانگین مربعات خطا (MSE)** به عنوان تابع هزینه استفاده می‌شود.

شبکه‌های عصبی چندلایه برای رگرسیون غیرخطی

Multi-Layer Neural Networks for Regression



- با یک تک‌نورون فقط می‌توان مدل‌های خطی را برازش کرد (ترکیب خطی متغیرهای ورودی).
- **حل مسائل پیچیده غیرخطی:**
  - افزودن **لایه‌های پنهان (Hidden Layers)** با توابع فعال‌سازی غیرخطی (ReLU، Sigmoid).
  - قضیه تقریب عام: قابلیت یادگیری و تقریب هر تابع پیوسته دلخواه!

موازنه بایاس و واریانس

The Bias/Variance-Tradeoff

- هدف ما یادگیری مدل‌هایی با قابلیت تعمیم بالا (Generalization) به داده‌های نادیده است.
- خطای تعمیم هر مدل از مجموع **سه مؤلفه اساسی** تشکیل شده است:

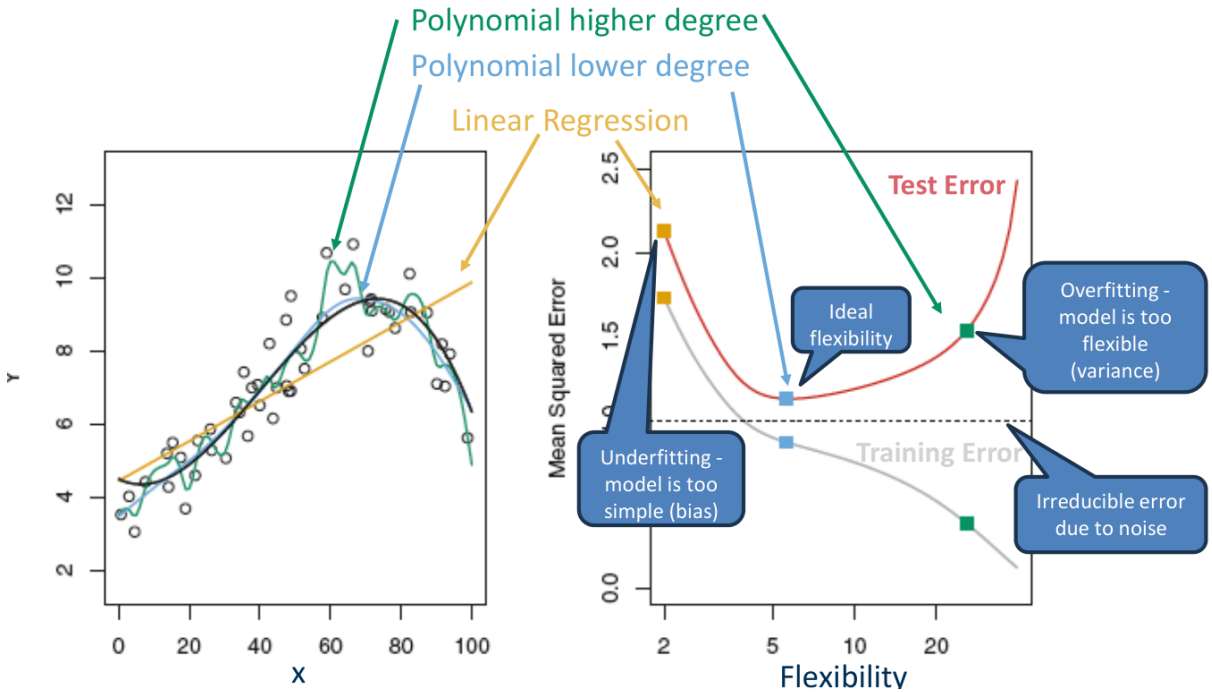
$$\mathbb{E}[(y - \hat{f}(x))^2] = \text{Bias}[\hat{f}(x)]^2 + \text{Var}[\hat{f}(x)] + \sigma^2$$

  - **بایاس یا اریبی** (Bias): ناشی از فرض‌های ساده‌انگارانه مدل (کم‌برازش مدل‌های بسیار ساده).
  - **واریانس** (Variance): ناشی از حساسیت بیش‌ازحد مدل به نوسانات کوچک داده‌های آموزش (بیش‌برازش مدل‌های بسیار منعطف).
  - **خطای کاهش‌ناپذیر** (Irreducible Error - σ^2): نوفه ذاتی داده‌ها (تنها با پالایش سنسورها و پاکسازی داده‌ها کم می‌شود).

انعطاف‌پذیری مدل و منحنی موازنه

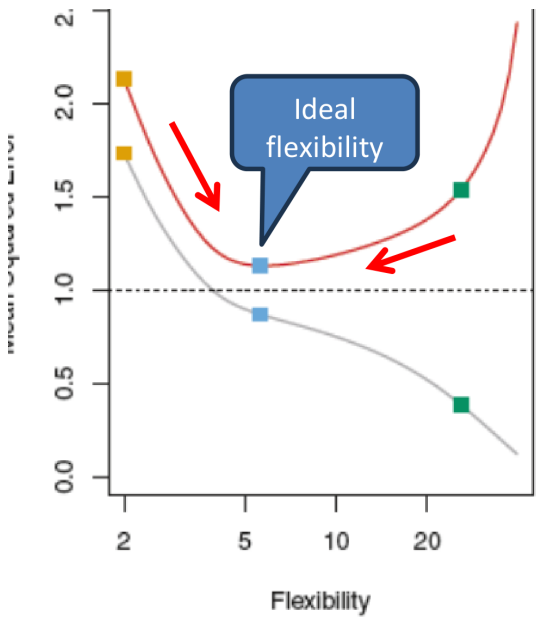
Model Flexibility and the Tradeoff Curve

- سه مدل با انعطاف‌پذیری متفاوت برای برازش یک تابع:



یافتن انعطاف‌پذیری بهینه

Selecting Method & Hyperparameters

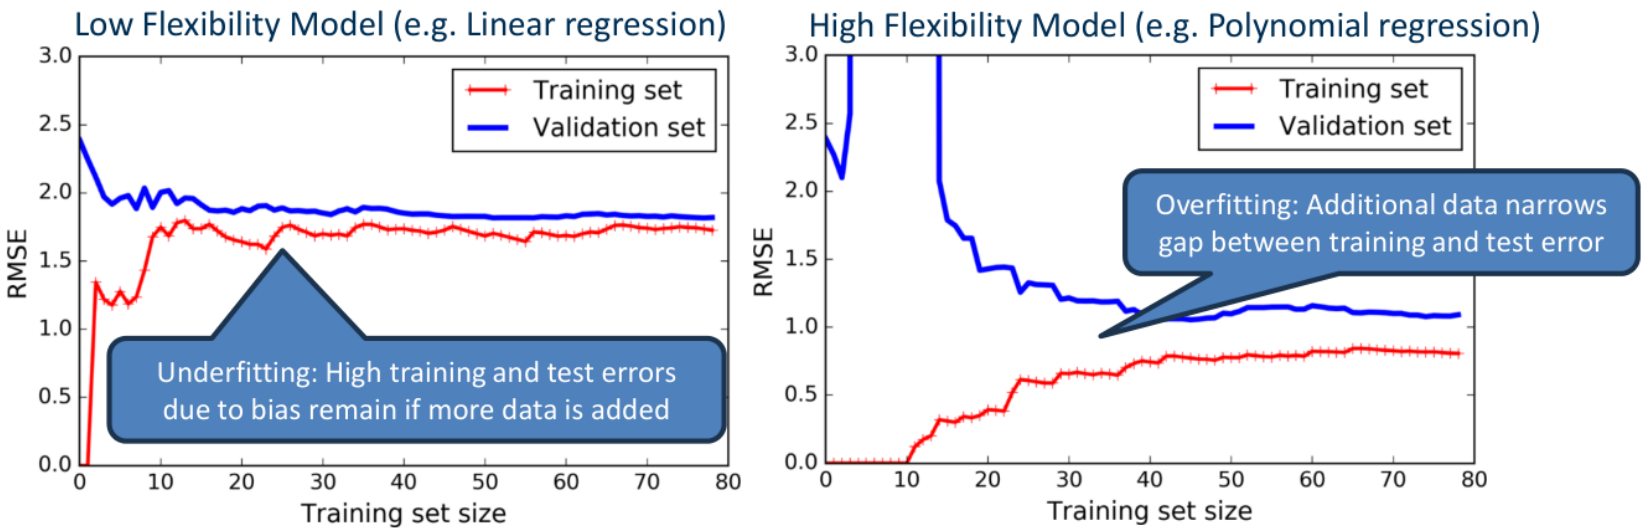


- **یافتن نقطه تعادل بهینه بایاس و واریانس با:**
  - آزمودن الگوریتم‌های یادگیری مختلف (خطی، چندجمله‌ای، درخت تصمیم، شبکه‌های عصبی).
  - تنظیم فراپارامترها (درجه چندجمله‌ای، ضریب جریمه ریج، عمق درخت، لایه‌های پنهان).
- **سه راهکار دیگر برای بهبود مدل:**
  - افزایش حجم داده‌های آموزش (More Data)
  - افزودن موارد حدی چالش‌برانگیز (Corner Cases)
  - پاکسازی نوفه از داده‌های آموزش (Data Cleansing)

منحنی‌های یادگیری در کم‌برازش و بیش‌برازش

Learning Curves for Under- and Overfitting Models

- تجسم خطای آموزش و خطای آزمون برای اندازه‌های مختلف مجموعه‌های آموزش:
  - در مدل‌های بیش‌برازش، شکاف میان خطای آموزش و آزمون با افزودن داده‌های بیشتر کاهش می‌یابد.
  - دسترسی به داده‌های بیشتر به ما اجازه استفاده از مدل‌های منعطف‌تر (نظیر یادگیری عمیق) را می‌دهد.



تبدیل دوطرفه طبقه‌بندی و رگرسیون

From Classification to Regression and Back

- ابتدا با طبقه‌بندی آشنا شدیم و پرسیدیم چگونه می‌توان از طبقه‌بندی به رگرسیون رسید؟
- **پرسش معکوس:** آیا می‌توان از الگوریتم‌های رگرسیون برای طبقه‌بندی استفاده نمود؟
- **رویکرد تبدیل:**
  - برای طبقه‌بندی دودویی: کدگذاری مثبت به عنوان 1.0 و منفی به عنوان 0.0.
  - یادگیری مدل رگرسیون بر روی این مقادیر عددی.
  - پیش‌بینی کلاس منفی برای بازه $(-\infty, 0.5]$ و مثبت برای بازه $(0.5, \infty)$.
- به طور مشابه برای داده‌های ترتیبی (Ordinal) نظیر ضعیف/متوسط/خوب.
- مسائل چندکلاسه غیرترتیبی پیچیده‌تر بوده و نیازمند رویکرد یک‌در-برابر-همه (One-vs-Rest) هستند.

جمع‌بندی فصل رگرسیون

Summary: Key Takeaways

- **رگرسیون** (Regression)؛ پیش‌بینی مقادیر پیوسته عددی به جای کلاس‌های گسسته.
- **ارزیابی مدل‌ها:** معیارهای MAE، MSE، RMSE، ضریب تعیین (R^2) و همبستگی پیرسون (PCC).
- **روش‌ها و الگوریتم‌های مطرح:**
  - رگرسیون k-NN، درخت‌های رگرسیون و درخت‌های مدل (M5).
  - رگرسیون خطی با منظم‌سازی ریج (L_2) و لاسو (L_1).
  - رگرسیون هم‌نوا (Isotonic) با الگوریتم PAVA، رگرسیون چندجمله‌ای و رگرسیون محلی.
  - شبکه‌های عصبی چندلایه (ANNs) با لایه خروجی خطی.
- **عملکرد موفق در داده‌های نادیده:** انتخاب روشی با انعطاف‌پذیری بهینه (موازنه بایاس-واریانس) و بهره‌گیری از داده‌های متنوع و باکیفیت.

کلاس‌های تکمیلی آنلاین
Online Lectures

- مطالب تکمیلی این هفته پیرامون **روش‌های تجمیعی (Ensembles)** است.
- کلاس‌های آنلاین برای تمرین‌ها و امتحانات پایان‌ترم حائز اهمیت ویژه هستند.

Week	Wednesday (Offline Lecture)	Online Lecture (see Ilias Course)	Thursday (Exercise)
10.02.2025	no lecture		Introduction to Python (13:45–15:15)
17.02.2025	Introduction to Data Mining		Intro
24.02.2025	Preprocessing		Preprocessing
03.03.2025	Classification 1	Nearest Centroids	Classification 1
10.03.2025	Classification 2	Comparing Classifiers	Classification 2
17.03.2025	Regression	Ensembles	Regression
24.03.2025	Clustering and Anomalies	Hierarchical Clustering	Clustering
31.03.2025	Feedback on project outlines	Time Series	Time Series
07.04.2025	Association Analysis and Subgroup Discovery		Association Analysis

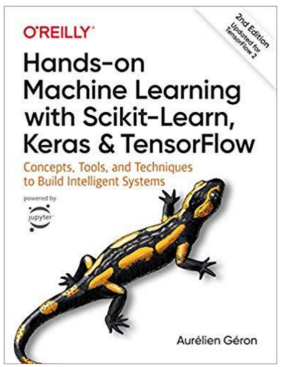
پرسش و پاسخ

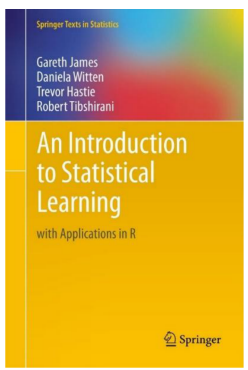
Discussion & Questions



منابع و مراجع مطالعاتی فصل

Literature for this Slideset





- **حل مسائل عملی رگرسیون با پایتون:**

Aurélien Géron: *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (Chapter 4)

- **مبانی نظری و تحلیل ریاضی رگرسیون:**

Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani: *An Introduction to Statistical Learning* (Chapters 3, 7, 8)