UNIVERSITY OF MANNHEIM
School of Business Informatics and Mathematics

دانشگاه مانهایم • گروه علوم داده و وب

# داده‌کاوی (IE500)

## فصل ششم: خوشه‌بندی (Clustering)

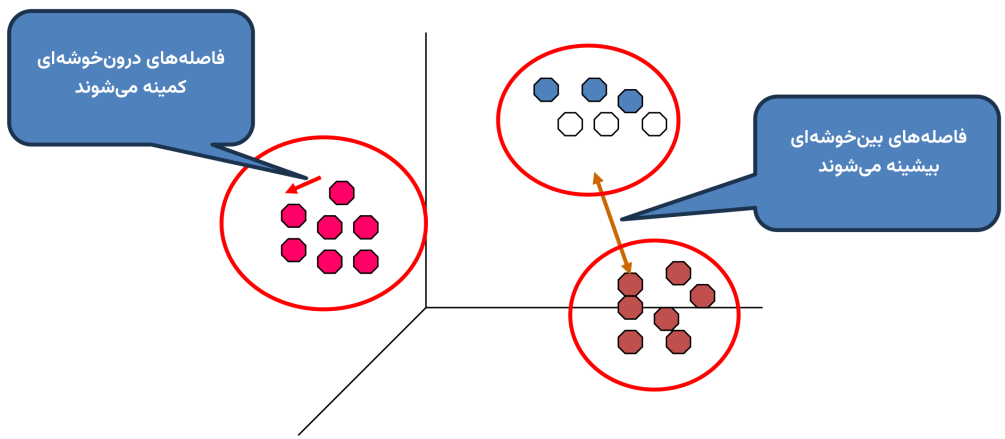
نسخه 23.03.2025

# سرفصل مطالب
Outline

- **تحلیل خوشه چیست؟** (What is Cluster Analysis?)
- **خوشه‌بندی K-Means** (K-Means Clustering)
- **خوشه‌بندی مبتنی بر چگالی (DBSCAN)** (Density-based Clustering - DBSCAN)
- **معیارهای مجاورت و شباهت** (Proximity Measures)
- **تشخیص ناهنجاری و داده‌های پرت** (Anomaly Detection)
  - رویکردهای آماری (Statistical Approaches)
  - رویکردهای مبتنی بر فاصله و چگالی (Distance & Density-based Approaches)

# تحلیل خوشه چیست؟
## What is Cluster Analysis?

- **تعریف:** یافتن گروه‌هایی از اشیاء به‌گونه‌ای که اشیاء درون یک گروه:
  - **بسیار شبیه** به یکدیگر باشند (Intra-cluster similarity).
  - و با اشیاء متعلق به سایر گروه‌ها **متفاوت** باشند (Inter-cluster dissimilarity).
- **هدف اصلی:** دستیابی به درک و بینش عمیق‌تر از ساختار ذاتی داده‌ها (Data Understanding).



# تحلیل خوشه به عنوان یادگیری بدون‌ناظر

Cluster Analysis as Unsupervised Learning

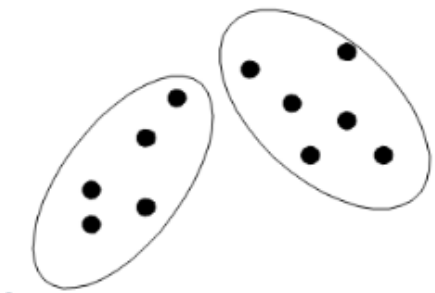
## یادگیری باناظر (Supervised)

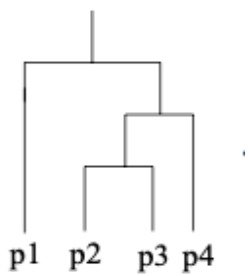
- کشف الگوهایی برای اتصال ویژگی‌ها به ویژگی هدف (Target / Class).
- مجموعه کلاس‌ها از پیش **معلوم و مشخص** است.
- برچسب‌ها توسط ناظر انسانی یا ثبت قبلی ارائه می‌شوند.
- هدف اصلی: **پیش‌بینی** برچسب هدف برای نمونه‌های جدید.

## یادگیری بدون‌ناظر (Unsupervised)

- داده‌ها **هیچ متغیر هدفی ندارند**.
- کاوش در داده‌ها برای کشف ساختارهای ذاتی پنهان (Intrinsic Structures).
- دسته‌ها یا خوشه‌ها از قبل شناخته‌شده نیستند.
- تحلیل خوشه و استخراج قواعد انجمنی از نمونه‌های برجسته این یادگیری هستند.

# انواع خوشه‌بندی
## Types of Clusterings






- **خوشه‌بندی افرازی:** (Partitional Clustering)
  - تقسیم اشیاء داده به زیرمجموعه‌های غیرهم‌پوشان (خوشه‌ها).
  - هر شیء دقیقاً متعلق به **یک زیرمجموعه** است.
- **خوشه‌بندی سلسله‌مراتبی:** (Hierarchical Clustering)
  - مجموعه‌ای از خوشه‌های تودرتو که ساختار یک درخت سلسله‌مراتبی (Dendrogram) را تشکیل می‌دهند.

# جنبه‌های کلیدی تحلیل خوشه

Aspects of Cluster Analysis

- **الگوریتم خوشه‌بندی:** (Clustering Algorithm)
  - الگوریتم‌های افرازی (Partitional) نظیر K-Means
  - الگوریتم‌های مبتنی بر چگالی (Density-based) نظیر DBSCAN
  - الگوریتم‌های سلسله‌مراتبی (Hierarchical)
- **معیار مجاورت (Proximity Measure) – شباهت یا عدم‌شباهت:**
  - فاصله اقلیدسی (Euclidean Distance)، شباهت کسینوسی (Cosine Similarity)
  - معیارهای شباهت مخصوص نوع داده (Data type-specific) یا دامنه کاربرد (Domain-specific)
- **کیفیت خوشه‌بندی:** (Clustering Quality)
  - فاصله درون‌خوشه‌ای (Intra-cluster distance) ⇒ **حداقل** شود.
  - فاصله بین‌خوشه‌ای (Inter-cluster distance) ⇒ **حداکثر** شود.
  - خوشه‌بندی باید متناسب با هدف تحلیل، کاربردی و معنادار باشد.

# ابهام در مفهوم خوشه

## The Notion of a Cluster is Ambiguous



چند خوشه می‌بینید؟



شش خوشه (Six Clusters)



دو خوشه (Two Clusters)



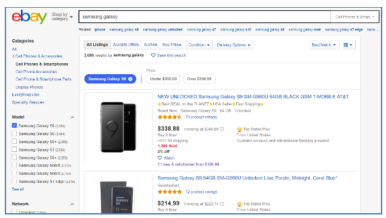
چهار خوشه (Four Clusters)

**مفید بودن یک خوشه‌بندی به هدف تحلیل بستگی دارد**

The usefulness of a clustering depends on the goal of the analysis

# نمونه‌هایی از کاربردهای خوشه‌بندی

## Example Applications








- **بخش‌بندی بازار:** (Market Segmentation)
  - هدف: شناسایی گروه‌هایی از مشتریان با رفتارهای مشابه.
  - سطح تفکیک‌پذیری به نیاز کسب‌وکار بستگی دارد.
- **تجارت الکترونیک:** (E-Commerce)
  - تطبیق و شناسایی پیشنهادات یک کالای یکسان در بازارهای برخط.
- **تشخیص و پردازش تصویر:** (Image Recognition)
  - شناسایی بخش‌هایی از تصویر که به یک شیء واحد تعلق دارند.

# خوشه‌بندی *k*-Means

K-Means Clustering

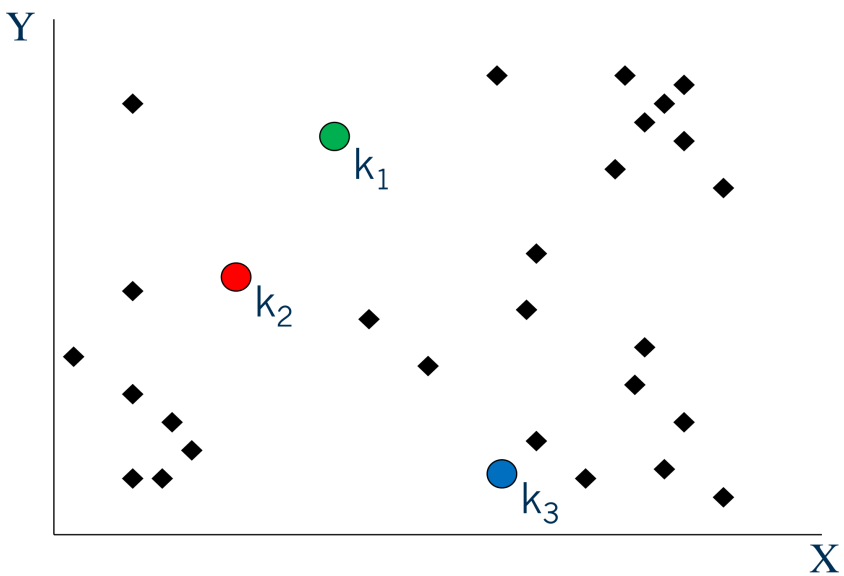
- الگوریتم خوشه‌بندی **افرازی** (Partitional Clustering).
- هر خوشه با یک نقطه مرکزی به نام **مرکزوار / میانگین** (Centroid) مشخص می‌شود.
- هر نقطه داده به خوشه‌ای با **نزدیک‌ترین مرکزوار** اختصاص می‌یابد.
- تعداد خوشه‌ها ($K$) باید **از قبل** توسط تحلیل‌گر تعیین شود.

## الگوریتم گام‌به‌گام *k*-Means (K-Means Algorithm)

۱. انتخاب تصادفی $K$ نقطه به عنوان مراکز اولیه (Initial Centroids).
۲. **تکرار:** (repeat)
   - تشکیل $K$ خوشه با تخصیص هر داده به نزدیک‌ترین مرکزوار.
   - محاسبه مجدد مرکزوار هر خوشه بر اساس میانگین بردار داده‌های آن خوشه.
۳. **تا زمانی که:** (until) مراکز خوشه‌ها تغییر نکنند (همگرایی).

# مثال الگوریتم $k$-Means: گام ۱

K-Means Example: Step 1

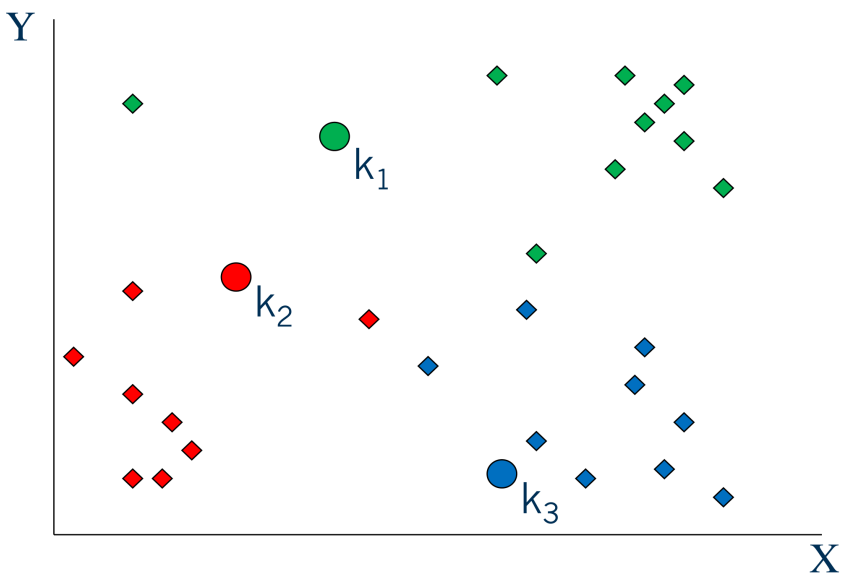



**انتخاب تصادفی مراکز اولیه:**

- انتخاب $K = 3$ مرکز اولیه به‌صورت تصادفی در فضای ویژگی‌ها:
  - $k_1$ (قرمز)
  - $k_2$ (آبی)
  - $k_3$ (سبز)
- هنوز هیچ نقطه‌ای به خوشه‌ای منتسب نشده است.

# مثال الگوریتم $k$-Means: گام ۲

K-Means Example: Step 2

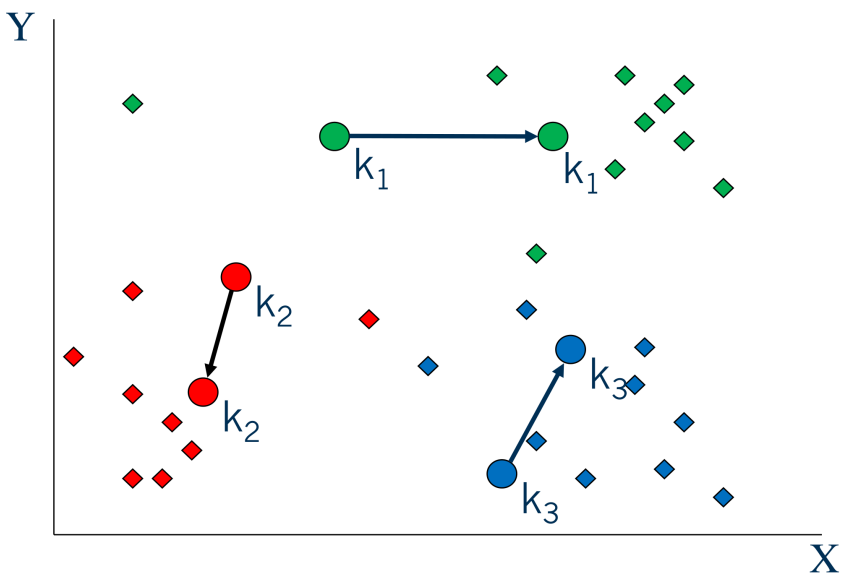



**تخصیص نقاط به نزدیک‌ترین مرکز:**

- محاسبه فاصله هر نقطه داده تا ۳ مرکز $k_1, k_2, k_3$.
- هر نقطه رنگ و برچسب نزدیک‌ترین مرکز به خود را دریافت می‌کند.
- خوشه‌های اولیه شکل می‌گیرند.

# مثال الگوریتم $k$-Means: گام ۳

K-Means Example: Step 3




**به‌روزرسانی موقعیت مراکز خوشه‌ها:**

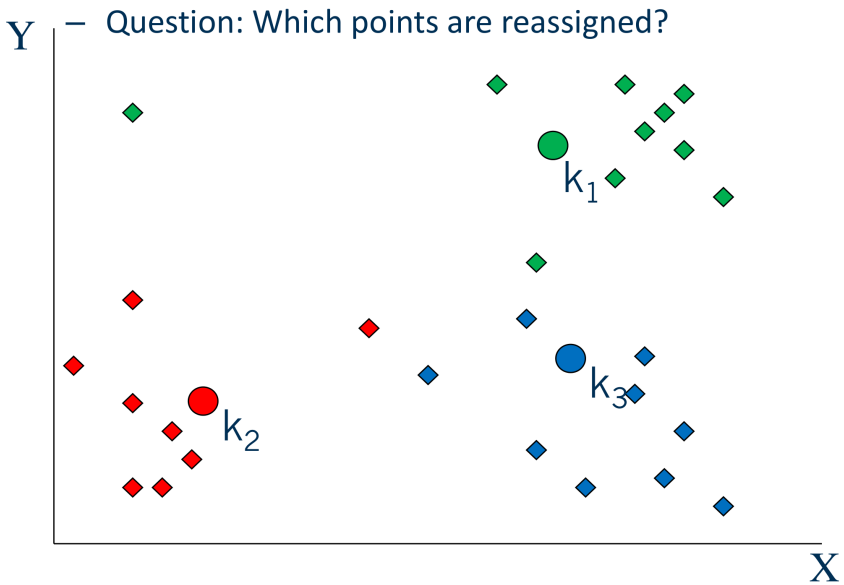
- محاسبه میانگین مختصات نقاط هر خوشه.
- انتقال هر مرکزوار به میانگین جدید نقاط متعلق به آن:
  - حرکت $k_1$ به مرکز ثقل نقاط قرمز.
  - حرکت $k_2$ به مرکز ثقل نقاط آبی.
  - حرکت $k_3$ به مرکز ثقل نقاط سبز.

# مثال الگوریتم $k$-Means: گام ۴

K-Means Example: Step 4

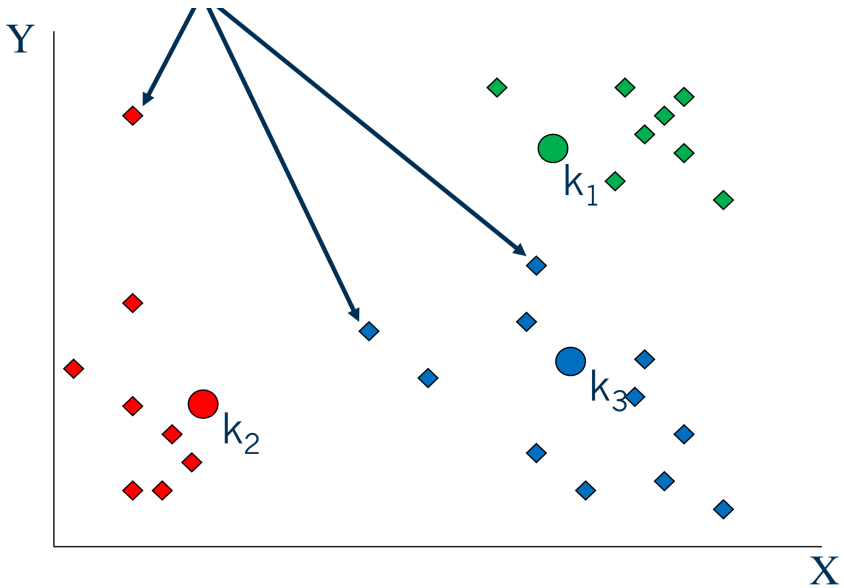
**بازتخصیص نقاط بر اساس مراکز جدید:**

- بررسی مجدد فواصل: آیا نقطه‌ای وجود دارد که اکنون به مرکز دیگری نزدیک‌تر شده باشد؟
- **پرسش:** کدام نقاط داده تغییر خوشه خواهند داد؟



# مثال الگوریتم $k$-Means: پاسخ گام ۴

K-Means Example: Step 4 (Answer)

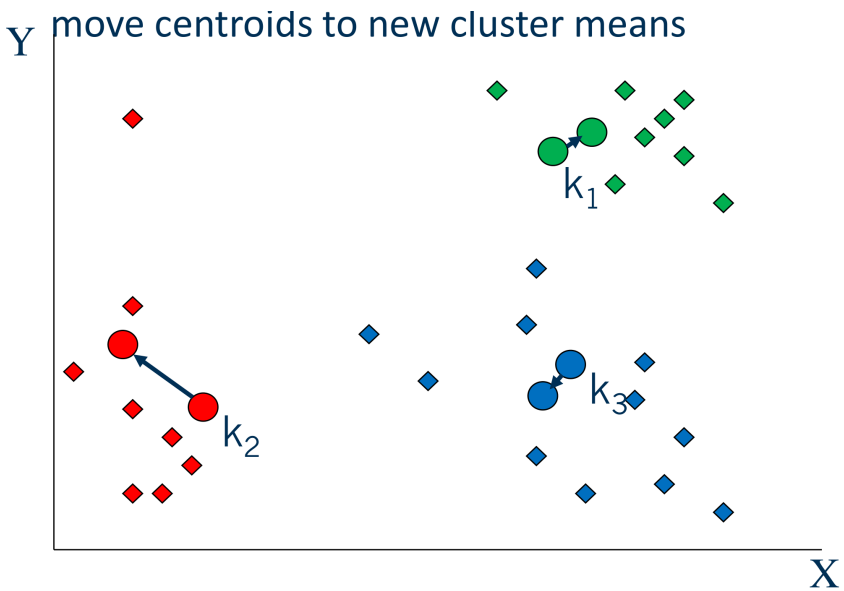



**نتیجه بازتخصیص نقاط:**

- **پاسخ:** ۳ نقطه به مرکزوار دیگری نزدیک‌تر شده و برچسب آن‌ها تغییر می‌کند:
  - تغییر عضویت از خوشه سبز به آبی یا قرمز بر اساس خطوط مرزی جدید.
- تغییر برچسب نقاط نشان‌دهنده نیاز به یک دور دیگر به‌روزرسانی مراکز است.

# مثال الگوریتم $k$-Means: گام ۵ و همگرایی

K-Means Example: Step 5




**محاسبه مجدد مراکز و همگرایی:**

- مراکز خوشه‌ها مجدداً بر اساس اعضای جدید محاسبه و جابه‌جا می‌شوند.
- با انجام گام تخصیص بعدی، هیچ نقطه‌ای تغییر خوشه نمی‌دهد.
- الگوریتم به **حالت پایدار (همگرایی)** می‌رسد و متوقف می‌شود.

# معیارهای همگرایی و توقف

## Convergence Criteria

- **معیار پیش‌فرض همگرایی:**
  - عدم تغییر (یا تغییر بسیار ناچیز کمتر از آستانه $\epsilon$) در موقعیت مراکز خوشه‌ها.
- **معیارهای جایگزین توقف:**
  - عدم بازتخصیص (یا حداقل جابه‌جایی) نقاط میان خوشه‌ها در دو تکرار متوالی.
  - رسیدن به سقف مشخصی از تعداد تکرارها (Max Iterations).
  - کاهش مجموع مربعات خطا (SSE) به کمتر از یک حد مشخص (به اسلاید بعدی مراجعه کنید).

# ارزیابی خوشه‌بندی با مجموع مربعات خطا (SSE)

Evaluating K-Means Clusterings: SSE

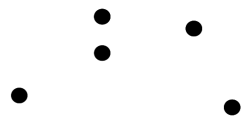
- یکی از پرکاربردترین معیارهای انسجام درون‌خوشه‌ای: **مجموع مربعات خطا (Sum of Squared Error - SSE)**.
- برای هر نقطه، خطا برابر با فاصله آن نقطه تا نزدیک‌ترین مرکزوار است. این خطاها به توان دو رسیده و جمع می‌شوند:

$$\text{SSE} = \sum_{j=1}^{K} \sum_{x \in C_j} \text{dist}(x, m_j)^2$$

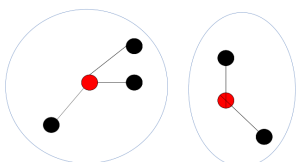
- $C_j$: خوشه $j$-ام.
- $m_j$: مرکزوار خوشه $C_j$ (بردار میانگین تمامی نقاط درون $C_j$).
- $\text{dist}(x, m_j)$: فاصله اقلیدسی میان نقطه داده $x$ و مرکزوار $m_j$.
- **اصل تصمیم‌گیری:** در میان چند اجرای مختلف با مقدار یکسان $K$، خوشه‌بندی با **کمترین مقدار SSE** برگزیده می‌شود.

# تصویرسازی مفهوم مجموع مربعات خطا

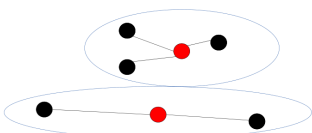
## Illustration: Sum of Squared Error



- **خوشه‌بندی مطلوب:** (Good)
  - فواصل نقاط تا مرکزوارها اندک است.
  - انسجام بالا و SSE کمینه.

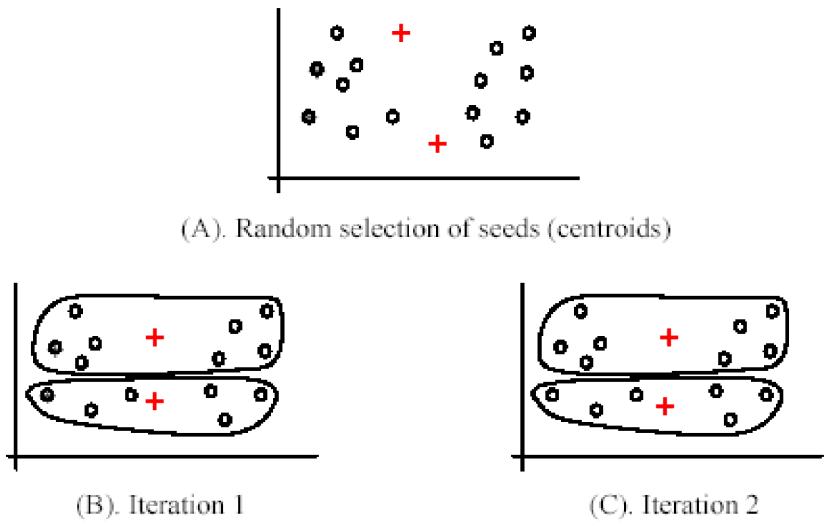


- **خوشه‌بندی نامطلوب:** (Not so good)
  - فواصل بیشتر نقاط تا مرکزوارها.
  - گیر افتادن در بهینه محلی و SSE بالاتر.



# نقاط ضعف $k$-Means: حساسیت به مراکز اولیه

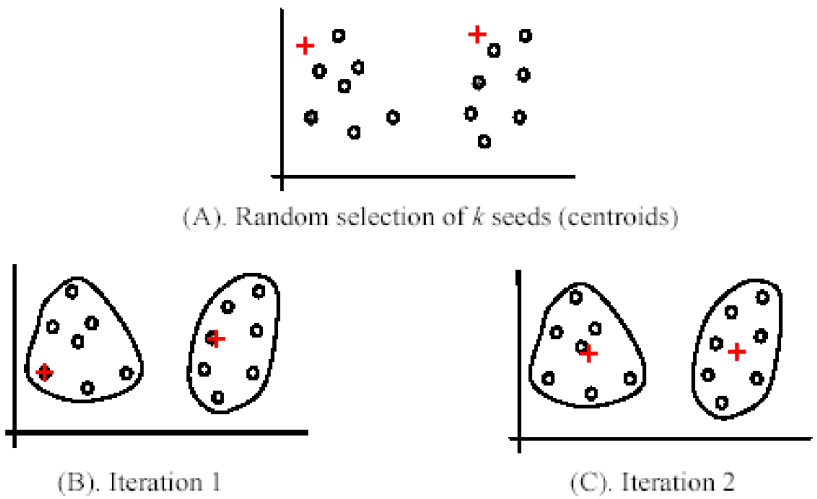
## Weaknesses of K-Means: Initial Seeds




- نتایج نهایی خوشه‌بندی به‌شدت به **موقعیت اولیه مراکز تصادفی** بستگی دارد.
- انتخاب نامناسب بذرها می‌تواند منجر به خوشه‌بندی‌های بسیار نامطلوب شود.
- در تصویر مقابل، دو مرکز در یک خوشه طبیعی و یک مرکز در خوشه‌ای دیگر قرار گرفته‌اند که نتیجه بهینه محلی نامناسب است.

# نقاط ضعف $k$-Means: بذرهای اولیه مناسب

## Weaknesses of K-Means: Initial Seeds



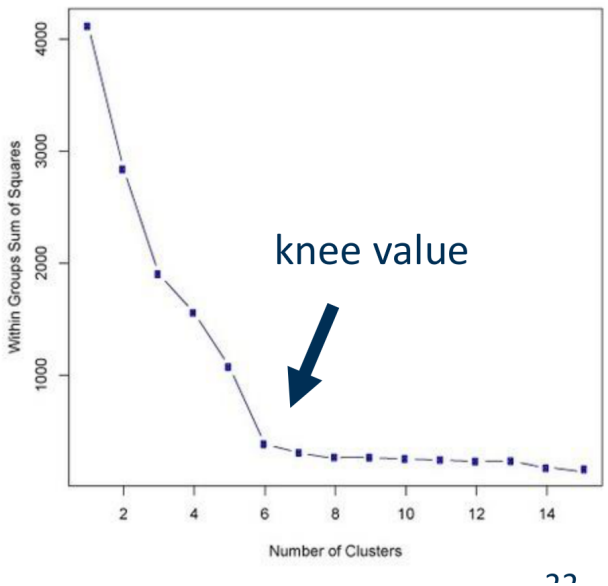

- اگر مراکز اولیه در نقاط متفاوتی قرار گیرند، الگوریتم به خوشه‌بندی ایده‌آل دست می‌یابد.
- در این حالت هر مرکز ثقل به‌درستی درون یکی از ۳ خوشه طبیعی قرار می‌گیرد.
- این موضوع نیاز به اجرای مکرر الگوریتم با مقادیر اولیه متفاوت را نشان می‌دهد.

# بهبود نتایج و تعیین تعداد خوشه‌ها

## Improving Clustering Results

- **اجرای چندباره:** (Restarts) اجرای مکرر با بذرهای تصادفی مختلف و انتخاب نتیجه دارای کمترین SSE.
- **اجرا با مقادیر مختلف $K$:**
  - توجه: مقدار SSE با افزایش $K$ همواره کاهش می‌یابد (در حالت $K = N$ مقدار $SSE = 0$ است!). بنابراین نمی‌توان مستقیماً SSE دو $K$ متفاوت را مقایسه کرد.
- **روش نقطه زانو / آرنج:** (Elbow / Knee) انتخاب $K$ در نقطه‌ای که شیب کاهش SSE به یکباره کند می‌شود.
- **الگوریتم X-Means:** نسخه خودکاری که با $K$ کوچک آغاز کرده و خوشه‌ها را تا رسیدن به تعادل تفکیک می‌کند.

xamples?

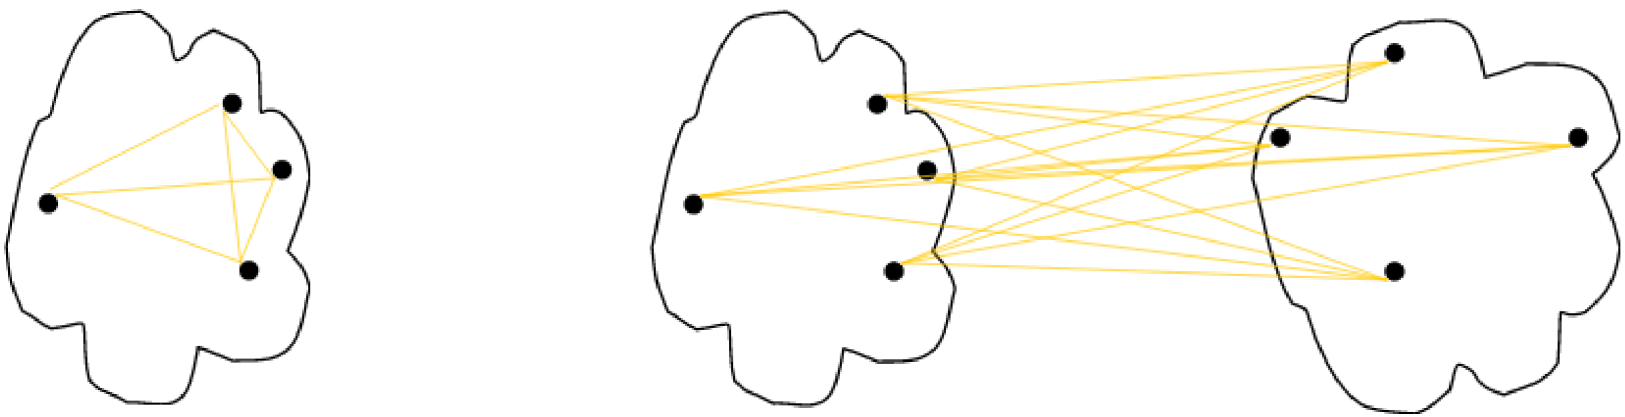


# معیارهای ارزیابی خوشه‌بندی در تعیین $k$

Choosing k – Cluster Evaluation

**یادآوری: در خوشه‌بندی به دنبال بهینه‌سازی دو مؤلفه‌ایم:**

- **انسجام درون‌خوشه‌ای:** (Cohesion) نزدیکی و تشابه اشیاء درون یک خوشه (باید بیشینه شود یا فواصل کمینه گردد).
- **تفکیک‌پذیری بین‌خوشه‌ای:** (Separation) تمایز و دوری خوشه‌ها از یکدیگر (باید بیشینه شود).



# محاسبه ضریب سیلوئت

Silhouette Coefficient

- **انسجام** $a(x)$**:** میانگین فاصله نقطه $x$ تا تمام نقاط دیگر در همان خوشه.
- **تفکیک** $b(x)$**:** میانگین فاصله $x$ تا نقاط سایر خوشه‌ها؛ کمترین میانگین در میان خوشه‌ها انتخاب می‌شود:

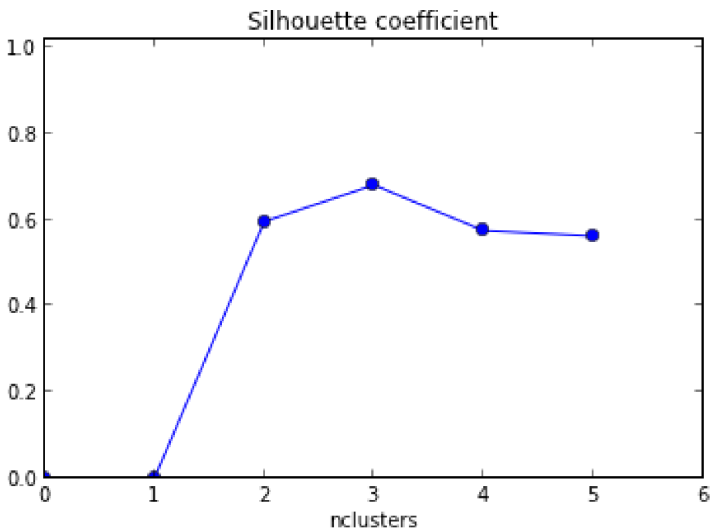
$$s(x) = \frac{b(x) - a(x)}{\max\{a(x), b(x)\}}$$

- دامنه تغییرات: $s(x) \in [-1, 1]$
  - $s(x) \approx +1$: بسیار مناسب و تفکیک عالی.
  - $s(x) \approx 0$: نقطه در مرز میان دو خوشه قرار دارد.
  - $s(x) \approx -1$: بسیار ضعیف و احتمالاً انتساب نادرست به خوشه.
- **ضریب سیلوئت کل داده‌ها (SC):** میانگین ضریب سیلوئت تمامی $N$ نقطه داده:

$$\text{SC} = \frac{1}{N} \sum_{i=1}^{N} s(x_i)$$

# تعیین تعداد خوشه‌ها با ضریب سیلوئت

## Selecting k Using the Silhouette Coefficient

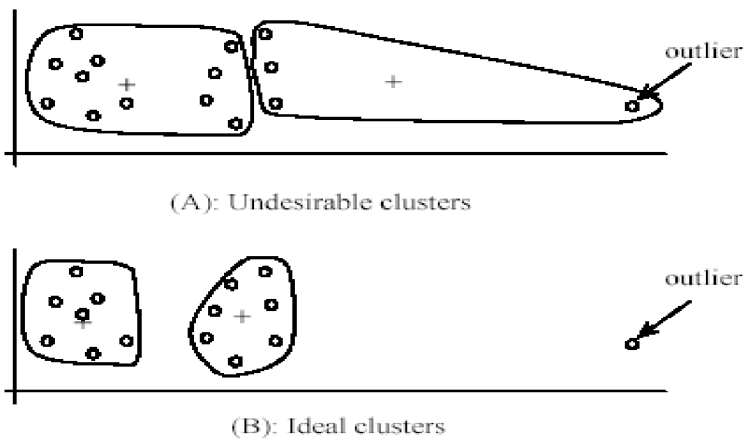



**رویکرد اجرایی:**

- اجرای الگوریتم $k$-Means با مقادیر مختلف $K$ ($K = 2, 3, 4, \ldots$).
- محاسبه و رسم نمودار ضریب سیلوئت برای هر $K$.
- انتخاب $K$ با بیشترین مقدار میانگین سیلوئت.
- **مزیت مهم:** برخلاف SSE، ضریب سیلوئت با افزایش طبیعی $K$ لزوماً بهتر نمی‌شود و معیار عادلانه‌ای برای مقایسه است.

# نقاط ضعف $k$-Means: چالش داده‌های پرت

## Weaknesses of K-Means: Problems with Outliers




- داده‌های دورافتاده مرکزوارها را به سمت خود می‌کشند و خوشه‌بندی را تحریف می‌کنند.
- **راهکارهای مقابله:**
  - حذف نقاطی که فاصله زیادی با مراکز دارند (برای اطمینان، می‌توان رفتار آن‌ها را طی چند تکرار رصد کرد).
  - استفاده از نمونه‌برداری تصادفی (Random Sampling) برای تخمین اولیه‌ی مراکز و سپس انتساب مابقی داده‌ها.

# الگوریتم خوشه‌بندی $k$-Medoids

K-Medoids Clustering

- نسخه‌ای از الگوریتم که به جای **میانگین**، از **میانه / مدوئید** (Medoid) استفاده می‌کند.
- مدوئید مرکزی‌ترین نقطه داده **واقعی موجود** درون هر خوشه است.
- مقاومت و پایداری بسیار بالاتری در برابر داده‌های پرت دارد، زیرا میانه تحت تأثیر مقادیر خیلی بزرگ قرار نمی‌گیرد:

| مجموعه داده | میانگین (Mean) | میانه (Median) |
|---|---|---|
| $\{1, 3, 5, 7, 9\}$ | 5 | 5 |
| $\{1, 3, 5, 7, 1009\}$ | **205** | **5** |

# جمع‌بندی خوشه‌بندی $k$-Means و پیاده‌سازی در پایتون

## K-Means Summary & Python Implementation

**مزایا:**

- ساده و قابل فهم شهودی.
- مرتبه زمانی کارآمد: $\mathcal{O}(n \cdot K \cdot I \cdot d)$
  - $n$: تعداد داده‌ها، $K$: تعداد خوشه‌ها
  - $I$: تکرارها، $d$: ابعاد ویژگی‌ها

**معایب:**

- نیاز به تعیین قبلی $K$.
- اجبار تمام داده‌ها به عضویت در یک خوشه.
- حساسیت به نویز و بذرهای اولیه.

```python
# 1. Import KMeans
from sklearn.cluster import KMeans

# 2. Create clusterer
estimator = KMeans(n_clusters=3)

# 3. Fit and predict cluster IDs
cluster_ids = estimator.fit_predict(
dataset[['Att1', 'Att2']]
)
```

# خوشه‌بندی مبتنی بر چگالی
## Density-based Clustering



- **محدودیت‌های کا-میانگین در کاربردهای پیچیده:**
  - **چالش ۱: اشکال غیرکروی و دلخواه** (Non-globular shapes)؛ کا-میانگین تنها خوشه‌های کروی محدب را به درستی می‌یابد.
  - **چالش ۲: داده‌های پرت و نویزها** (Outliers / Noise points)؛ کا-میانگین تمام نقاط را به زور در خوشه‌ها قرار می‌دهد.
- **راه‌حل:** تعریف خوشه‌ها بر اساس پیوستگی نواحی با **چگالی بالا** و تفکیک آن‌ها توسط نواحی کم‌چگال.

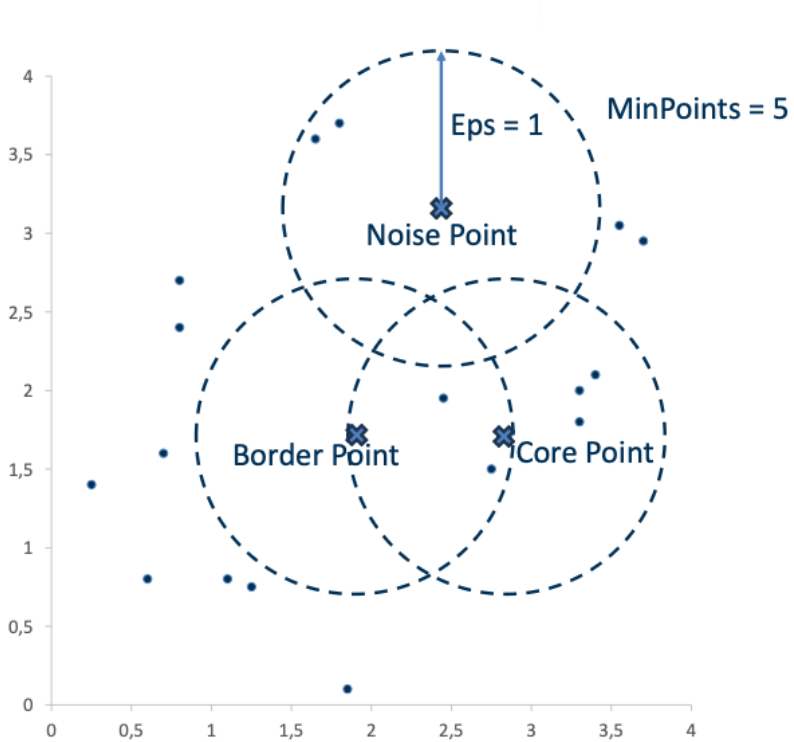
# مفاهیم پایه الگوریتم DBSCAN

## DBSCAN: Density-Based Spatial Clustering

- **تعریف چگالی:** تعداد نقاط موجود درون یک شعاع مشخص به نام **اپسیلون** ($\epsilon$ یا Eps).
- الگوریتم نقاط داده را به **سه دسته** متمایز تقسیم می‌کند:
  - **نقطه هسته:** (Core Point) نقطه‌ای که در همسایگی شعاع $\epsilon$ آن، حداقل به تعداد مشخصی نقطه (MinPts) وجود داشته باشد (خود نقطه نیز شمرده می‌شود). این نقاط بخش درونی خوشه‌ها را تشکیل می‌دهند.
  - **نقطه مرزی:** (Border Point) نقطه‌ای که تعداد همسایگان آن در شعاع $\epsilon$ کمتر از MinPts است، اما در همسایگی یک نقطه هسته قرار دارد.
  - **نقطه نویز / پرت:** (Noise Point) هر نقطه‌ای که نه نقطه هسته باشد و نه نقطه مرزی.

# نمونه‌هایی از نقاط هسته، مرزی و نویز

## Examples of Core, Border, and Noise Points




- **تنظیم پارامترها:**
  - $\text{MinPts} = 5$
  - $\text{Eps}(\epsilon) = 1$
- **نقطه هسته:** (Core) درون دایره شعاع ۱ حداقل ۵ همسایه دارد.
- **نقطه مرزی:** (Border) کمتر از ۵ همسایه دارد، اما در شعاع ۱ یک هسته قرار گرفته است.
- **نقطه نویز:** (Noise) تنها افتاده و هیچ نقطه هسته‌ای در نزدیکی آن نیست.

# شناسایی انواع نقاط در مجموعه داده

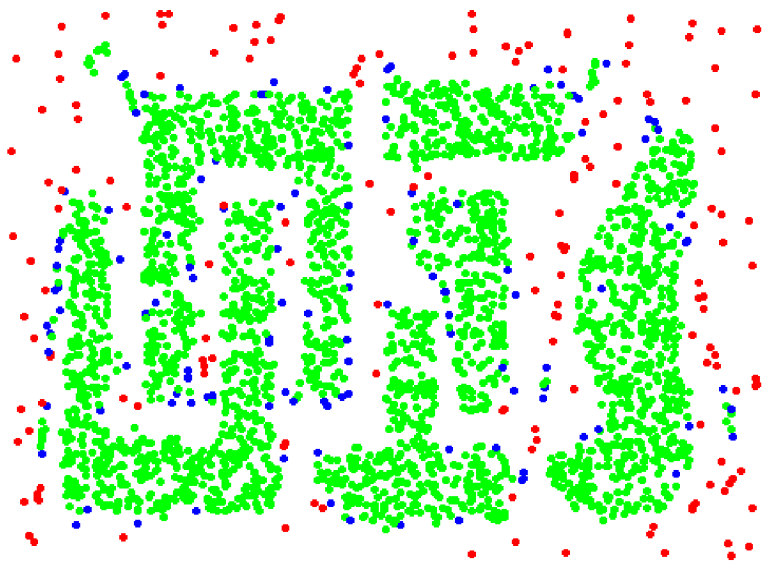
Point Types: Core, Border, and Noise

## تفکیک نقاط داده بر اساس چگالی محلی

**نقاط اصلی داده‌ها (Original Points)**



**دسته‌بندی نقاط به هسته، مرزی و نویز**



# الگوریتم خوشه‌بندی DBSCAN

## The DBSCAN Algorithm

- ۱. شناسایی و حذف تمامی نقاط نویز (Noise Points).
- ۲. تشکیل خوشه‌ها با رشد زنجیره‌ای بر روی نقاط باقی‌مانده (هسته و مرزی).

```
current_cluster_label ← 1

for all core points do
if the core point has no cluster label then
current_cluster_label ← current_cluster_label +1
Label the current core point with cluster label current_cluster_label
end if
for all points in the Eps-neighborhood, except the point itself do
if the point does not have a cluster label then
Label the point with cluster label current_cluster_label
# Perform recursion for all points in the Eps-neighborhood
end if
end for
end for
```

# خوشه‌های نهایی الگوریتم DBSCAN

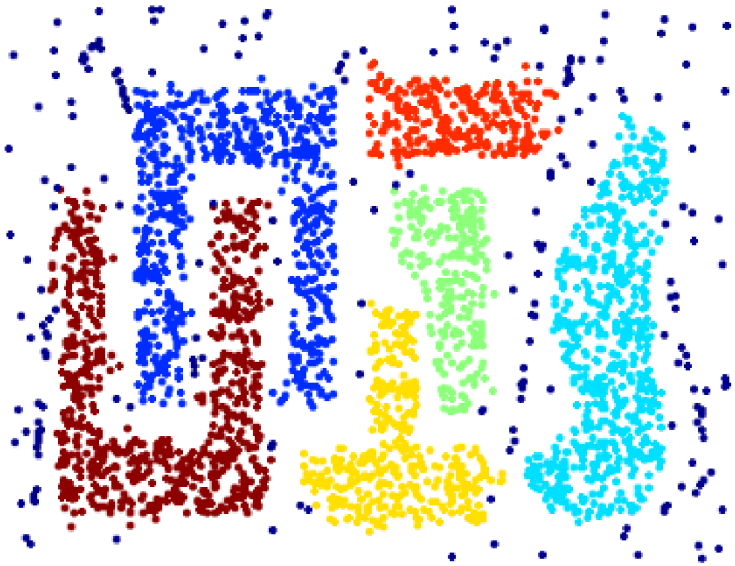
Final DBSCAN Clusters

**اتصال نقاط با تراکم بالا و حذف نویزهای محیطی**

**نقاط ورودی داده‌ها**

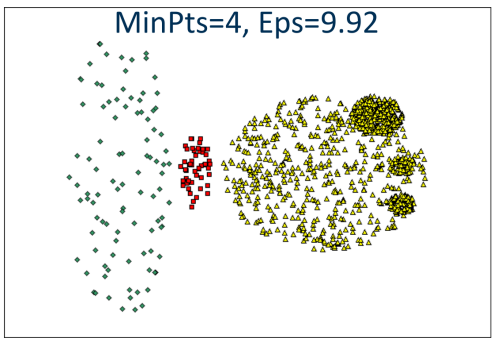


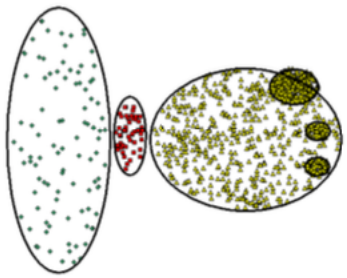
**خوشه‌های استخراج‌شده و نقاط نویز**



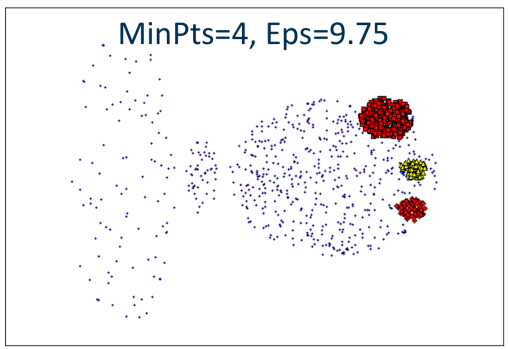
# نقاط ضعف و چالش‌های DBSCAN

## When DBSCAN Does NOT Work Well



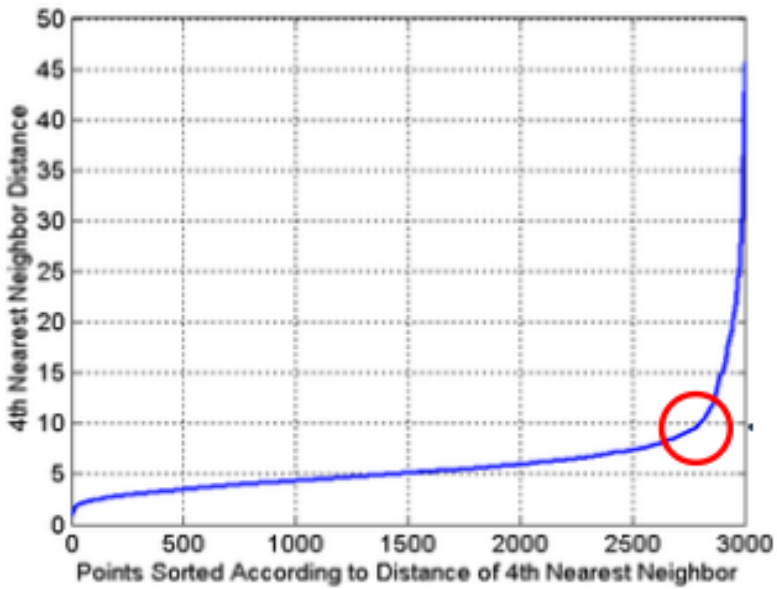
Original Points




- **چگالی‌های متغیر:** (Varying Densities)
  - با یک زوج $(\epsilon, \text{MinPts})$ ثابت نمی‌توان همزمان خوشه‌های با چگالی‌های متفاوت را تفکیک کرد.
  - تغییر ناچیز $\epsilon$ خوشه‌ها را ادغام یا تجزیه می‌کند.
- **داده‌های با ابعاد بالا:** (High-dimensional)
  - به دلیل نفرین ابعاد، فواصل یکنواخت شده و چگالی مفهوم خود را از دست می‌دهد.

# تعیین پارامترهای MinPts و Eps

## Determining EPS and MinPts




- **ایده اصلی:** برای نقاط درون یک خوشه، فاصله تا $k$-امین نزدیک‌ترین همسایه ($k$-th Nearest Neighbor) تقریباً یکسان است.
- نقاط نویز فاصله بسیار بزرگ‌تری تا $k$-امین همسایه خود دارند.
- **روش عملی:**
  - محاسبه فاصله هر نقطه تا $k$-امین همسایه.
  - مرتب‌سازی فواصل از کوچک به بزرگ و رسم نمودار.
  - انتخاب مقدار $\epsilon$ در **نقطه زانو / شکست نمودار**.

# پیاده‌سازی الگوریتم DBSCAN در پایتون

## DBSCAN in Python (Scikit-Learn)

**پارامترهای کلیدی:**

- `eps` : شعاع همسایگی ($\epsilon$).
- `min_samples` : حداقل تعداد نقاط درون شعاع (MinPts).
- `metric` : تابع محاسبه فاصله (اقلیدسی، منهتن و ...).

**نکته خروجی:**

- نقاطی که به عنوان نویز تشخیص داده شوند با برچسب `-1` مشخص می‌گردند.

```python
# 1. Import DBSCAN
from sklearn.cluster import DBSCAN

# 2. Create the clusterer
clusterer = DBSCAN(
min_samples=3,
eps=1.5,
metric='euclidean'
)

# 3. Fit and predict clusters
clusters = clusterer.fit_predict(
dataset[['Att1', 'Att2']]
)
```

# معیارهای مجاورت: شباهت و فاصله

## Proximity Measures: Similarity & Distance

- تا اینجا الگوریتم‌های مختلف خوشه‌بندی را بررسی کردیم؛ **همه این روش‌ها به معیارهای مجاورت وابسته هستند.**
- **شباهت:** (Similarity)
  - یک معیار عددی برای سنجش میزان همسانی دو شیء داده (مقدار بالاتر ⇒ شباهت بیشتر).
  - معمولاً در بازه $[0, 1]$ نرمال‌سازی می‌شود.
- **عدم‌شباهت یا فاصله:** (Dissimilarity / Distance)
  - یک معیار عددی برای سنجش میزان تفاوت دو شیء داده (مقدار بالاتر ⇒ تفاوت بیشتر).
  - حداقل عدم‌شباهت برابر با 0 است (تطابق کامل).
  - حد بالای فاصله بسته به نوع تابع متغیر است.
- انتخاب معیار مناسب کاملاً به ماهیت داده‌ها و الزامات کاربرد بستگی دارد.

# مجاورت در ویژگی‌های تک‌متغیره
## Proximity of Single Attributes

### فرمول‌های محاسبه شباهت ($s$) و عدم‌شباهت ($d$) برای مقادیر $p$ و $q$

| نوع ویژگی (Attribute Type) | عدم‌شباهت $d$ (Dissimilarity) | شباهت $s$ (Similarity) |
|---|---|---|
| اسمی (Nominal) | $d = \begin{cases} 0 & p = q \\ 1 & p \neq q \end{cases}$ | $s = \begin{cases} 1 & p = q \\ 0 & p \neq q \end{cases}$ |
| ترتیبی (Ordinal) | $d = \frac{\lvert p-q \rvert}{n-1} \quad (0 \leq p, q \leq n-1)$ | $s = 1 - \frac{\lvert p-q \rvert}{n-1}$ |
| فاصله‌ای / نسبتی (Interval / Ratio) | $d = \lvert p - q \rvert$ | $s = 1 - \frac{d - \min(d)}{\max(d) - \min(d)}$ یا $s = \frac{1}{1+d}$ یا $s = -d$ |

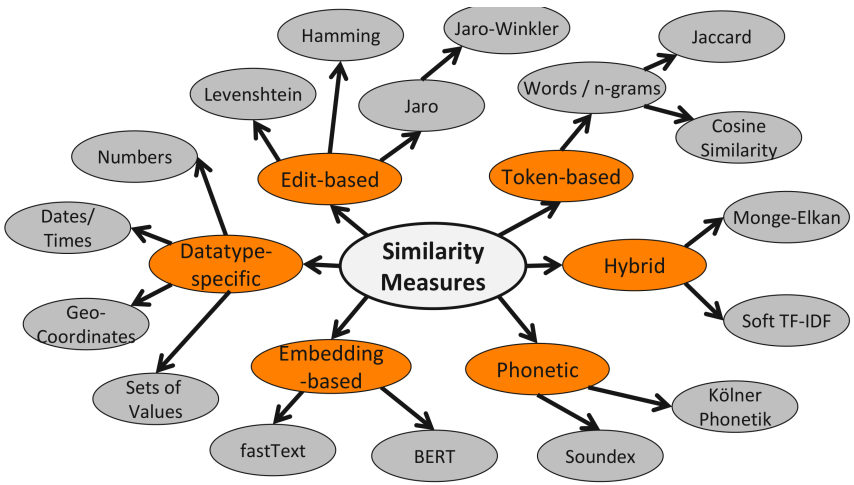
# فاصله لونشتاین برای رشته‌ها

## Levenshtein Distance for Strings

- معیاری برای اندازه‌گیری **عدم‌شباهت دو رشته متنی** (String Dissimilarity).
- برابر با **حداقل تعداد عملیات ویرایشی** لازم برای تبدیل یک رشته به رشته دیگر.
- **عملیات ویرایشی مجاز:**
  - درج یک نویسه (Insertion).
  - حذف یک نویسه (Deletion).
  - جایگزینی یک نویسه با نویسه دیگر (Substitution).
- **مثال‌ها:**
  - $\text{levenshtein}(\text{'table'}, \text{'cable'}) = 1$ (1 substitution)
  - $\text{levenshtein}(\text{Jane' 'Doe}، \text{Doe' 'Jane}) = 8$ (7 substitutions, 1 deletion)

# سایر معیارهای شباهت رشته‌ها

## Further String Similarity Measures




**دسته‌بندی معیارهای متنی:**

- **مبتنی بر ویرایش:** (Edit-based) لونشتاین، همینگ، Jaro-Winkler.
- **مبتنی بر توکن / کلمه:** (Token-based) ژاکارد (Jaccard)، کسینوسی (Cosine).
- **آوایی:** Soundex (Phonetic) و تلفظ صوتی.
- **ترکیبی و تعبیه‌محور:** (Embedding) مدل‌های fastText و BERT.

(موضوع تخصصی درس یکپارچه‌سازی داده‌های وب)

# مجاورت در نقاط داده چندبعدی
## Proximity of Multidimensional Data Points

- تا به اینجا معیارهای ارزیابی یک ویژگی منفرد را بررسی کردیم.
- اما در مسائل داده‌کاوی واقعی، رکوردها دارای **چندین بعد و ویژگی** هستند:
  - مانند سن، قد، وزن، درآمد، سابقه و ...
- بنابراین به معیارهای تجمیعی برای سنجش فاصله میان بردارها نیازمندیم.
- **نکته بسیار حیاتی: نرمال‌سازی (Normalization)**
  - ویژگی‌ها باید حتماً پیش از محاسبه فاصله نرمال‌سازی شوند (مانند Min-Max یا Z-Score) تا متغیرهایی با مقیاس‌های عددی بزرگ‌تر بر کل فاصله غلبه نکنند و همه ویژگی‌ها وزن برابری داشته باشند.

# نُرم‌ها و فواصل مینکوفسکی

## Vector Norms & Minkowski Distance

- **فاصله اقلیدسی** ($L_2$-norm)

$$\text{dist} = \sqrt{\sum_{k=1}^{n}(p_k - q_k)^2}$$

- **حالت عمومی‌تر – فاصله مینکوفسکی** ($L_p$-norm)

$$\text{dist} = \sqrt[p]{\sum_{k=1}^{n}|p_k - q_k|^p} = \left(\sum_{k=1}^{n}|p_k - q_k|^p\right)^{\frac{1}{p}}$$

- **فاصله منهتن** ($L_1$-norm)

$$\text{dist} = \sum_{k=1}^{n}|p_k - q_k|$$

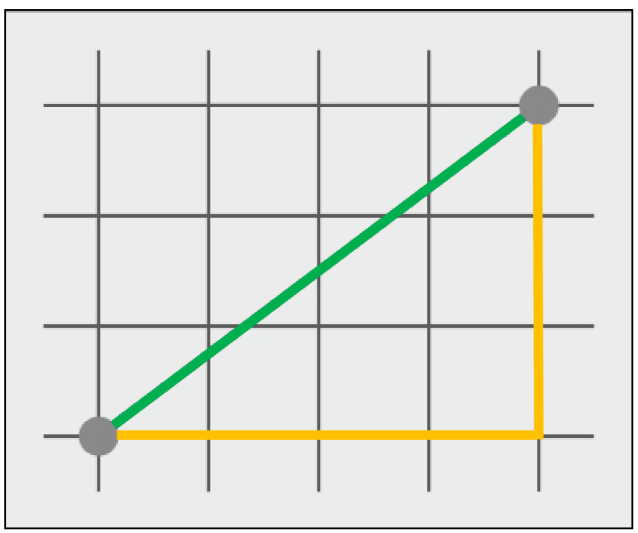
  - کوتاه‌ترین مسیر میان دو تقاطع در شهر شطرنجی (منهتن یا مانهایم!).

- ($n$: تعداد ابعاد؛ $p_k$, $q_k$: مقدار ویژگی $k$-ام نقاط داده $p$ و $q$)

**مثال عددی (Example)**

$L_2 = \sqrt{4^2 + 3^2} = 5$

$L_1 = 4 + 3 = 7$



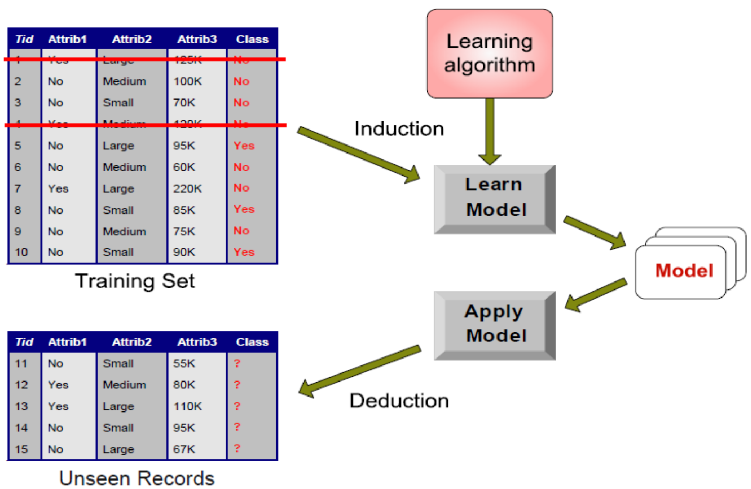
# مقدمه‌ای بر تشخیص ناهنجاری

## Anomaly Detection / Outlier Detection

- همچنین تحت عنوان **تشخیص داده‌های پرت (Outlier Detection)** شناخته می‌شود.
- **هدف:** شناسایی خودکار نمونه‌های داده‌ای که به هر نحوی رفتاری کاملاً متمایز و نامتعارف نسبت به سایر داده‌ها دارند.
- **فرض بنیادی کار:**
  - تعداد مشاهدات «عادی» در داده‌ها **بسیار بیشتر** از مشاهدات «غیرعادی» (ناهنجاری‌ها/پرت‌ها) است.
- **دسته‌بندی روش‌های اصلی:**
  - رویکردهای آماری (Statistical Approaches): نظیر IQR و MAD
  - رویکردهای مبتنی بر فاصله (Distance-based Approaches)
  - رویکردهای مبتنی بر چگالی (Density-based Approaches)
  - رویکردهای مبتنی بر خوشه‌بندی (Clustering-based Approaches)

# جایگاه تشخیص ناهنجاری در خط لوله داده‌کاوی

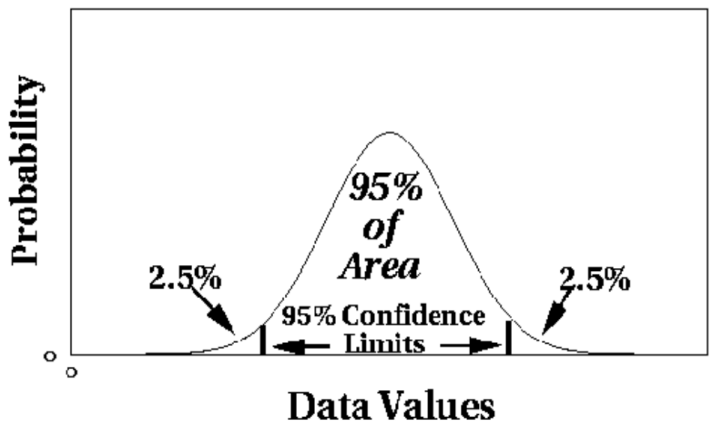
## Anomaly Detection in the Data Mining Pipeline




- **کاربرد در خط لوله:** (Pipeline)
  - شناسایی و حذف داده‌های پرت از **مجموعه آموزش (Training Set)** به منظور جلوگیری از انحراف مدل.
  - حفظ داده‌های پرت در **مجموعه آزمون (Test Set)** بدون تغییر، تا عملکرد مدل در شرایط دنیای واقعی محک بخورد.
- تفکیک ناهنجاری واقعی از خطای ثبت حسگرها یا ورود داده.

# رویکردهای آماری تشخیص ناهنجاری

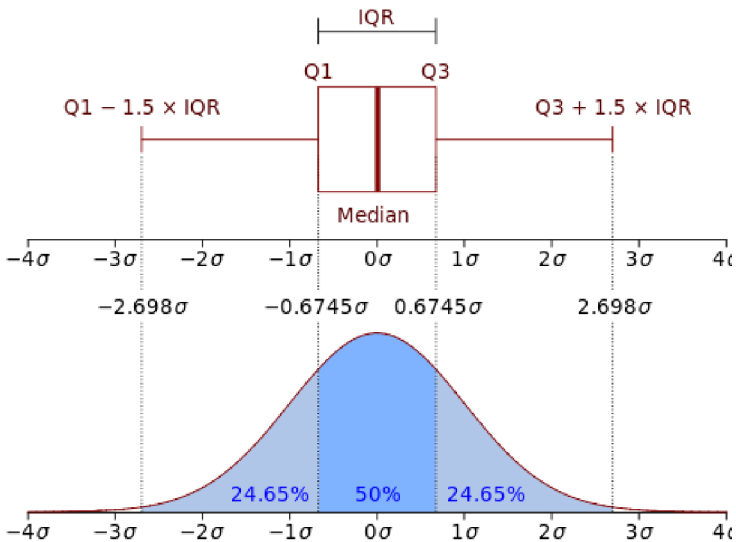
## Statistical Approaches to Outlier Detection




- فرض یک مدل پارامتریک برای توصیف توزیع داده‌ها (مانند توزیع نرمال یا گاوسی).
- اعمال آزمون‌های آماری که به عوامل زیر بستگی دارند:
  - نوع توزیع آماری داده‌ها (Data Distribution).
  - پارامترهای توزیع (مانند میانگین $\mu$ و واریانس $\sigma^2$).
  - تعداد مورد انتظار داده‌های پرت یا سطح اطمینان (Confidence Limit).
- داده‌هایی که احتمال وقوع آن‌ها تحت توزیع مفروض بسیار ناچیز است، به عنوان ناهنجاری علامت‌گذاری می‌شوند.

# دامنه میان‌چارکی (IQR)

## Interquartile Range (IQR)




- تقسیم داده‌ها به ۴ چارک آماری (با فرض توزیع نرمال):
  - $Q_1$: برای 75% داده‌ها رابطه $x \geq Q_1$ برقرار است.
  - $Q_3$: برای 25% داده‌ها رابطه $x \geq Q_3$ برقرار است.
  - $\text{IQR} = Q_3 - Q_1$
- **قاعده تشخیص دادهٔ پرت:** هر داده خارج از بازه:
  $$[Q_1 - 1.5 \times \text{IQR} \ , \ Q_3 + 1.5 \times \text{IQR}]$$
- **مثال عددی:**
  - داده‌ها: $\{0, 1, 1, 3, 3, 5, 7, 42\}$
  - میانه $= 3$، $Q_1 = 1$، $Q_3 = 7$
    $\Rightarrow \text{IQR} = 6$
  - بازه مجاز:
    $[1 - 1.5(6) \ , \ 7 + 1.5(6)] = [-8, 16]$
  - عدد **42** خارج از بازه است $\Rightarrow$ **داده پرت**.

# معیار انحراف مطلق از میانه (MAD)

Median Absolute Deviation (MAD)

- **تعریف:** MAD میانه قدرمطلق انحراف داده‌ها از میانه نمونه:

$$\tilde{X} = \text{median}(X), \quad \text{MAD} = \text{median}(|X_i - \tilde{X}|)$$

- داده‌هایی با فاصله بیش از $k \times \text{MAD}$ از میانه، پرت محسوب می‌شوند (معمولاً $k = 3$).
- **مثال عددی:**
  - داده‌ها: $X = \{0, 1, 1, 3, 5, 7, 42\} \Rightarrow \tilde{X} = 3$
  - قدرمطلق انحرافات: $\{3, 2, 2, 0, 2, 4, 39\}$
  - انحرافات مرتب‌شده: $\{0, 2, 2, \mathbf{2}, 3, 4, 39\} \Rightarrow \text{MAD} = 2$
  - بازه مجاز: $[3 - 3(2)\ ,\ 3 + 3(2)] = [-3, 9]$
  - عدد **42** خارج از بازه است $\Rightarrow$ **داده پرت**.



**Carl Friedrich Gauss**

1777–1855

# داده‌های پرت در برابر مقادیر فرین

## Outliers vs. Extreme Values

- تا اینجا فقط مقادیر فرین و کرانه‌ای (Extreme Values) را بررسی کردیم.
- اما داده‌های پرت می‌توانند در **نواحی میانی یا غیرفرین** نیز رخ دهند!
- در این شرایط روش‌های متکی بر دامنه نظیر IQR شکست می‌خورند:
  - در مثال زیر: میانه 0 است، $Q_1 = -1, Q_3 = 1 \Rightarrow \text{IQR} = 2$.
  - بازه مجاز: $[-4, +4] \Rightarrow$ هیچ نقطه‌ای به عنوان پرت شناخته نمی‌شود، در حالی که نقاط جداافتاده آشکاری وجود دارند!



# رویکردهای مبتنی بر فاصله
## Distance-based Approaches

**روش‌های مبتنی بر نزدیک‌ترین همسایه‌ها:**
(Nearest-Neighbor)

- محاسبه فواصل دوبه‌دوی تمام نقاط داده در فضا.
- **تعاریف گوناگون برای دادهٔ پرت:**
  ۱. نقاطی که کمتر از $p$ همسایه در فاصله $D$ از آن‌ها وجود دارد.
  ۲. تعداد $n$ نقطه برتر که فاصله آن‌ها تا $k$-**امین نزدیک‌ترین همسایه** بیشترین مقدار است.
  ۳. تعداد $n$ نقطه برتر که **میانگین فاصله** آن‌ها تا $k$ نزدیک‌ترین همسایه بیشترین مقدار است.

**بسته پایتون**

**PyOD**

Python Outlier Detection

شامل انواع روش‌های فاصله‌ای، زاویه‌ای و مبتنی بر همسایگی

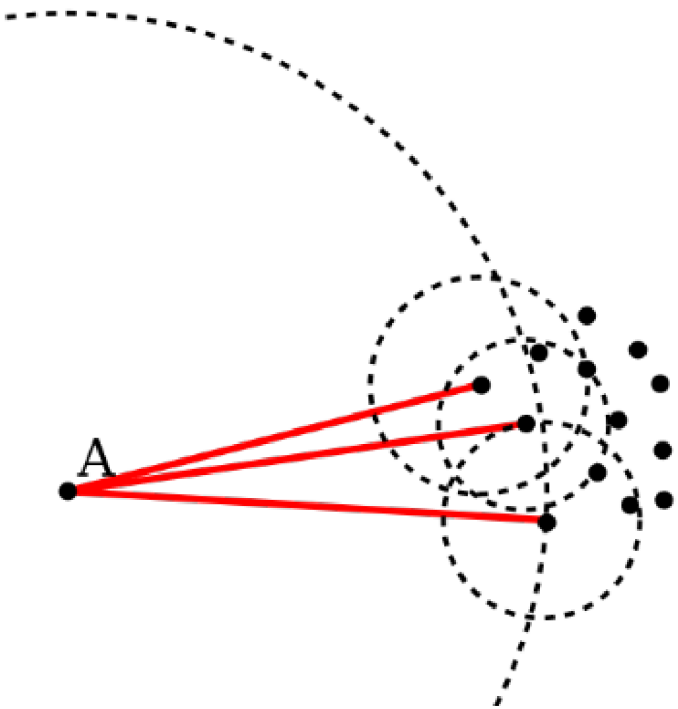
# ضریب ناهنجاری محلی (LOF) مبتنی بر چگالی

Density-based Outlier Detection: LOF

- برای هر نقطه، **چگالی همسایگی محلی** آن محاسبه می‌شود:
  - اگر این چگالی بیشتر از میانگین چگالی همسایگان باشد، نقطه درون یک خوشه متراکم قرار دارد.
  - اگر چگالی محلی به طور محسوسی کمتر از میانگین چگالی همسایگان باشد، نقطه یک **داده پرت** است.
- **ضریب ناهنجاری محلی (Local Outlier Factor - LOF):**
  - نسبت میانگین چگالی همسایگان نقطه $A$ به چگالی خود نقطه $A$.
  - نقاط نرمال و درون‌خوشه‌ای: $\text{LOF} \approx 1$
  - نقاط پرت و ناهنجار: دارای $\text{LOF} > 1$ (به شکل معنادار بزرگ‌تر از ۱).

# تصویرسازی مفهوم ضریب ناهنجاری محلی (LOF)

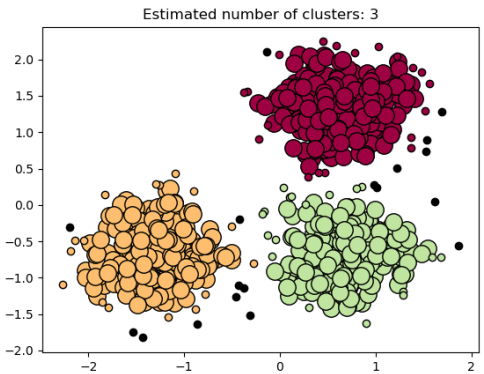
LOF: Conceptual Illustration




- با در نظر گرفتن $k = 3$ نزدیک‌ترین همسایه:
- مقادیر زیر محاسبه می‌شوند:
  - چگالی محلی نقطه $A$.
  - میانگین چگالی ۳ همسایه نزدیک به $A$.
- نقطه $A$ نسبت به همسایگانش در فضایی بسیار خلوت‌تر قرار گرفته است:
  - چگالی $A$ بسیار کمتر از چگالی همسایگان آن است.
  - بنابراین نسبت $\text{LOF}(A) \gg 1$ شده و نقطه $A$ به عنوان داده پرت شناسایی می‌شود.

# کاربرد الگوریتم DBSCAN در تشخیص داده‌های پرت

## DBSCAN for Outlier Detection




- الگوریتم DBSCAN مستقیماً نقاط نویز را شناسایی می‌کند:
  - این نقاط به هیچ خوشه‌ای تعلق ندارند (داده‌های پرت).
  - در کتابخانه scikit-learn: برچسب عددی 1− دریافت می‌کنند.
- این قابلیت امکان تشخیص مستقیم داده‌های پرت را فراهم می‌سازد.

```
# Apply DBSCAN with eps=0.5 and min_samples=5
dbscan = DBSCAN(eps=0.1, min_samples=5)
dbscan.fit(X)

# Identify the noise points
noise_mask = dbscan.labels_ == -1
print(noise_mask)

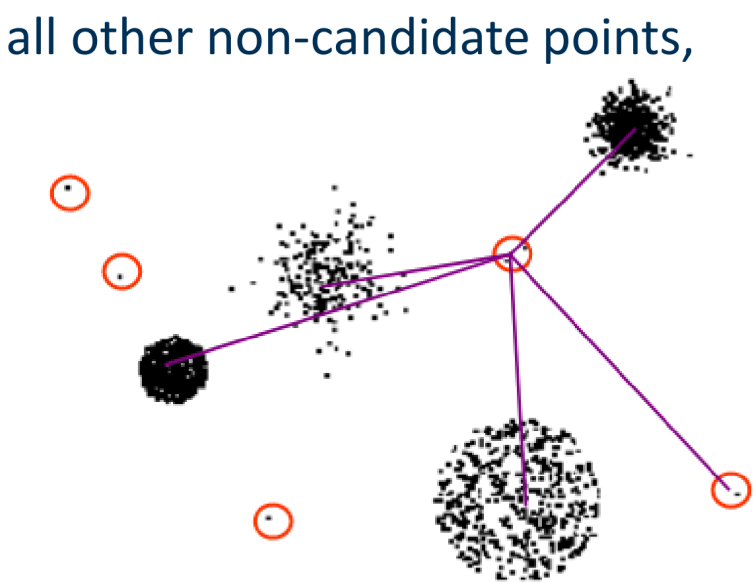
# Remove the noise points from the dataframe
X = X[~noise_mask]
```

# تشخیص داده‌های پرت مبتنی بر خوشه‌بندی

## Clustering-based Outlier Detection

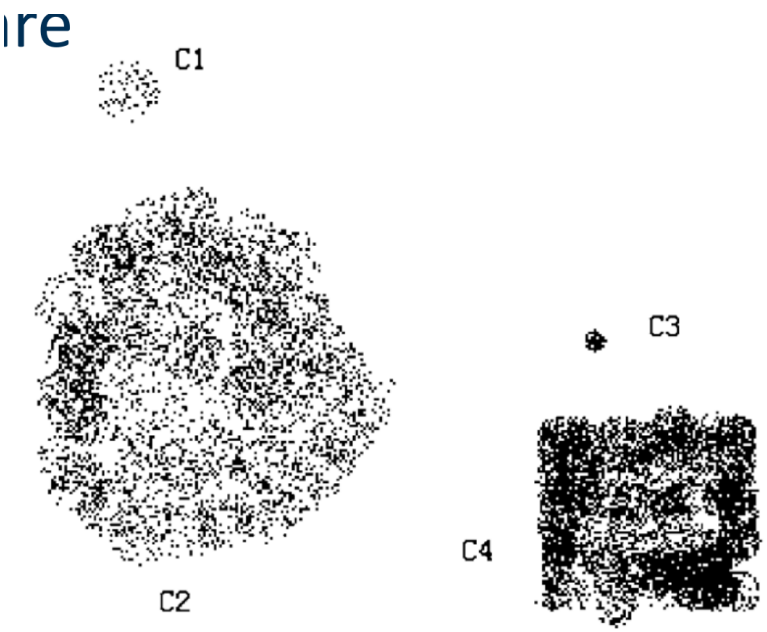
**ایده بنیادی:**

- ۱. خوشه‌بندی داده‌ها به گروه‌هایی با چگالی و اندازه متفاوت.
- ۲. انتخاب داده‌های متعلق به خوشه‌های بسیار کوچک به عنوان کاندیدای ناهنجاری.
- ۳. محاسبه فاصله میان نقاط کاندیدا و خوشه‌های اصلی بزرگ.
- ۴. اگر نقاط کاندیدا فاصله زیادی از سایر خوشه‌ها داشته باشند، رسماً به عنوان دادهٔ پرت برچسب می‌خورند.



# ضریب ناهنجاری محلی مبتنی بر خوشه (CBLOF)

Clustering-based Local Outlier Factor (CBLOF)




- **تعریف ناهنجاری در الگوریتم CBLOF:**
  - قرارگیری در یک خوشه بسیار کوچک.
  - یا داشتن فاصله زیاد تا سایر خوشه‌های اصلی داده‌ها.
- این معیار پس از اجرای یک الگوریتم خوشه‌بندی اولیه روی داده‌ها اعمال می‌شود.
- **امتیازدهی نهایی بر اساس دو عامل:**
  ۱. اندازه خوشه‌ای که نقطه داده در آن قرار دارد.
  ۲. فاصله نقطه داده تا نزدیک‌ترین خوشه بزرگ.

# فرایند اجرایی الگوریتم CBLOF و بسته PyOD

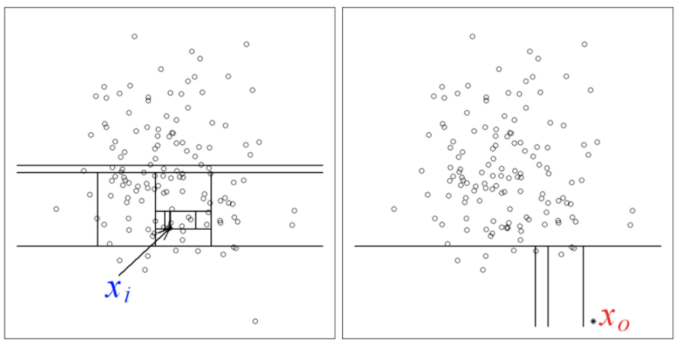
## CBLOF Workflow & PyOD

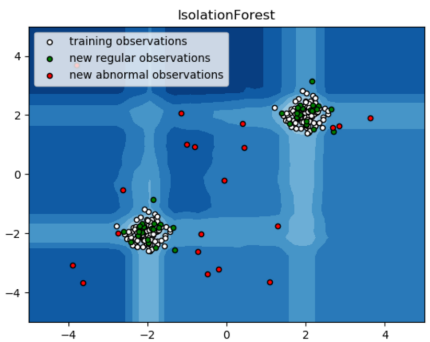
```
from sklearn.cluster import KMeans
from pyod.models.cblof import CBLOF
# clustering
clust = KMeans()
# outlier detection
detector = CBLOF(n_clusters=8,clustering_estimator=clust)
detector.fit(X)
# removal
noise_mask =detector.predict(X) == 1
X = X[~noise_mask]
```

- **مراحل گام‌به‌گام فرایند:**
  1. اجرای یک الگوریتم خوشه‌بندی دلخواه (مانند K-Means یا DBSCAN).
  2. تفکیک خوشه‌ها به خوشه‌های بزرگ (Large) و کوچک (Small).
  3. اعمال الگوریتم CBLOF بر روی نتایج حاصل.
- **خروجی:** انتساب یک امتیاز پیوسته ناهنجاری (Outlier Score) به تک‌تک نمونه‌های داده.
- پیاده‌سازی رسمی و بهینه‌سازی‌شده این روش در کتابخانه PyOD در دسترس است.

# مفاهیم پایه در الگوریتم جنگل انزوا (Isolation Forest)

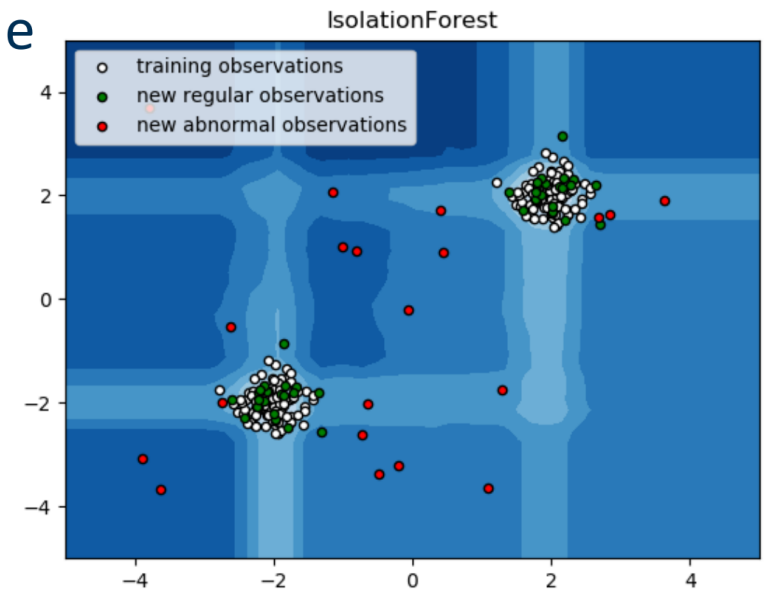
## Isolation Forest: Basic Concepts




- **درخت انزوا:** (Isolation Tree - iTree)
  - یک درخت تصمیم که هر برگ آن در نهایت شامل تنها **یک نمونه داده** است.
- **جنگل انزوا:** (Isolation Forest - iForest)
  - آموزش مجموعه‌ای (گروهی) از درخت‌های انزوای تصادفی.
- **شهود کلیدی:**
  - مسیر رسیدن به نقاط پرت در درخت **بسیار کوتاه‌تر** از نقاط عادی است (سریع‌تر منزوی می‌شوند).
  - میانگین طول مسیر در میان درختان، معیار امتیاز ناهنجاری است.

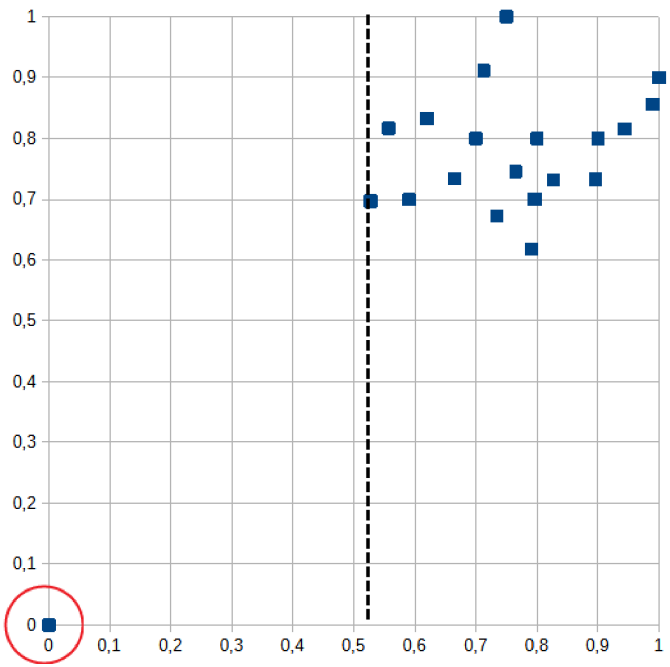
# آموزش یک درخت انزوا
## Training a Single Isolation Tree




- **فرایند تقسیم در هر گره برگ (با بیش از ۱ داده):**
  - انتخاب تصادفی یکی از ویژگی‌ها (Att).
  - انتخاب تصادفی یک مقدار برش (V) در بازه تغییرات آن ویژگی.
  - ایجاد گره درونی با شرط آزمون $Att < V$.
- تکرار بازگشتی فرایند ساخت برای هر زیردرخت.
- **خروجی:** درختی که در هر گره برگ نهایی آن فقط ۱ نمونه وجود دارد (معمولاً سقف ارتفاعی برای کارایی تعیین می‌شود).

# محاسبه احتمال انزوای نقطه دورافتاده در ارتفاع اول

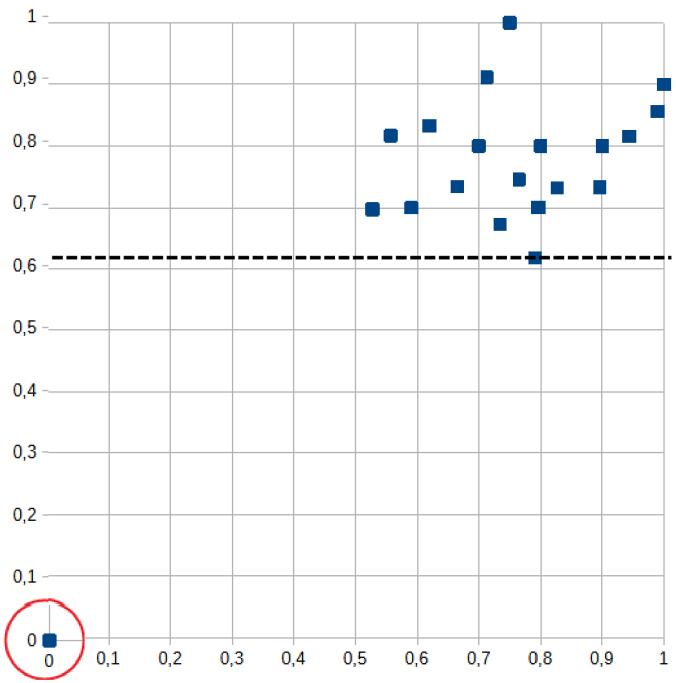
## Isolation Forest: Probability of (0,0) at Height 1




- نقطه دورافتاده با مختصات $(0, 0)$ در گوشه پایین سمت چپ را در نظر بگیرید.
- احتمال انزوای این نقطه با **تنها یک برش** در ارتفاع ۱:
- **حالت اول:**
  - انتخاب ویژگی $X$ (احتمال 0.5).
  - انتخاب مقدار برش در بازه $X < 0.52$ (احتمال 0.52).
- این برش نقطه $(0, 0)$ را فوراً از تمامی داده‌های دیگر جدا می‌کند.

# احتمال کل انزوای نقطه دورافتاده در ارتفاع اول

## Isolation Forest: Total Probability for (0,0)



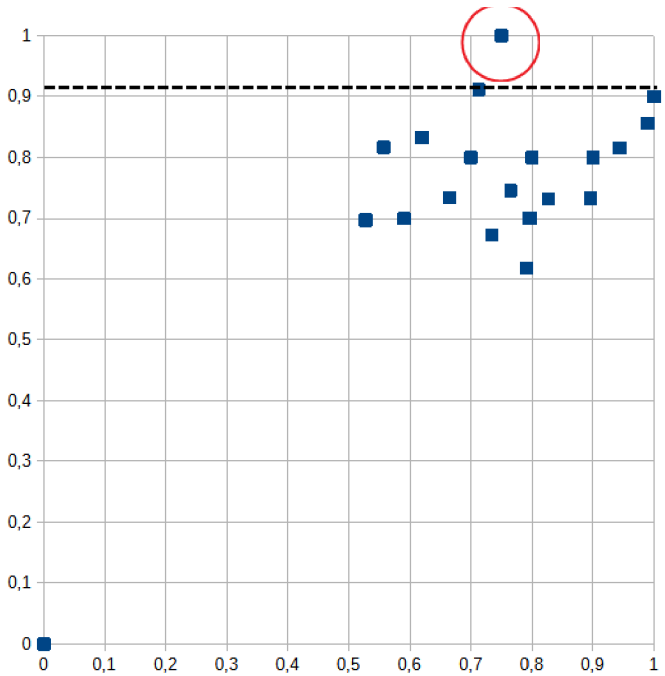

- نقطه $(0,0)$ هم با برش روی محور $X$ و هم با برش روی محور $Y$ منزوی می‌شود:
  - انتخاب محور $X$ و برش $X < 0.52$
  - یا انتخاب محور $Y$ و برش $Y < 0.62$
- **محاسبه احتمال کل:**

$$P = 0.5 \times 0.52 + 0.5 \times 0.62 = \mathbf{0.57}$$

- بیش از 57% احتمال دارد که این نقطه در **همان اولین برش** کاملاً جدا شود!

# احتمال انزوای نقطه شبه‌مرزی

## Isolation Forest: Probability of (0.74, 1)



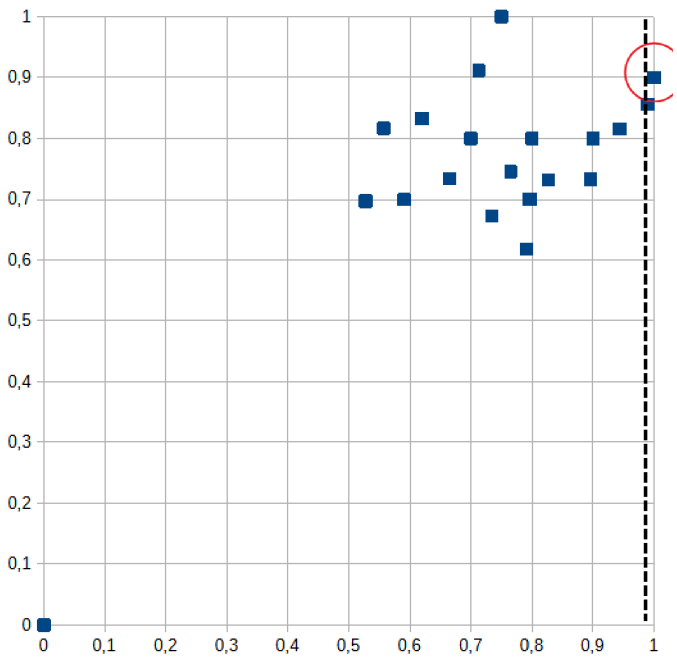

- بررسی احتمال انزوای نقطه شبه‌مرزی با مختصات $(0.74, 1)$ در ارتفاع ۱:
- تنها با برش روی ویژگی $Y$ و شرط $Y > 0.91$ منزوی می‌شود.
- **محاسبه احتمال:**

$$P = 0.5 \times (1 - 0.91) = 0.5 \times 0.09 = \mathbf{0.045}$$

- این احتمال (4.5%) بسیار کمتر از احتمال نقطه دورافتاده $(0, 0)$ با 57% است.

# احتمال انزوای نقطه مرزی

## Isolation Forest: Probability of (1, 0.9)



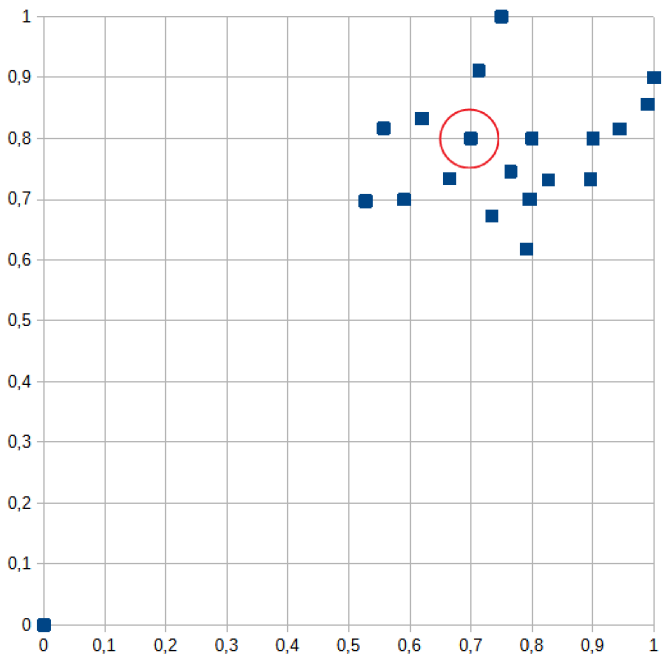

- بررسی احتمال انزوای نقطه مرزی دیگر با مختصات $(1, 0.9)$ در ارتفاع ۱:
- تنها با انتخاب ویژگی $X$ و مقدار برش $X > 0.98$ منزوی می‌شود.
- **محاسبه احتمال:**

$$P = 0.5 \times (1 - 0.98) = 0.5 \times 0.02 = \mathbf{0.01}$$

- احتمال انزوا در گام اول تنها 1% است.

# احتمال انزوای سایر نقاط داده در ارتفاع اول

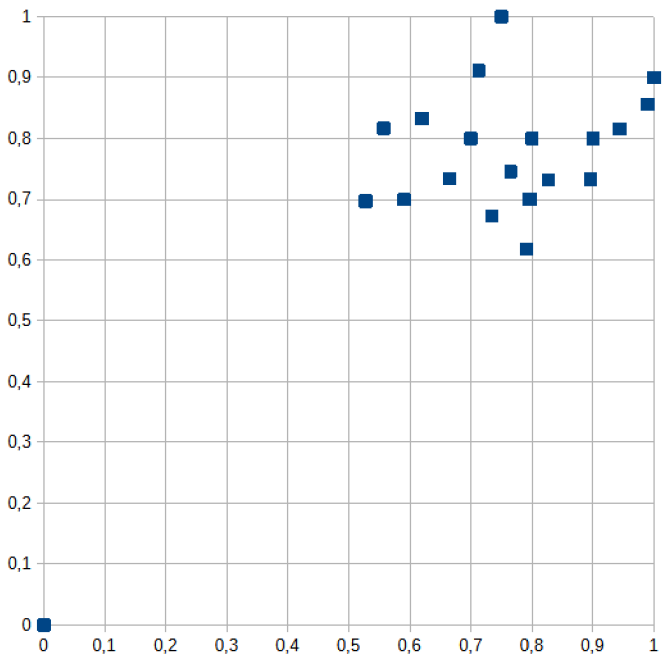
## Isolation Forest: Other Data Points




- **احتمال انزوای سایر نقاط داده در ارتفاع ۱:**
  - برای تمام نقاط دیگر داده که در ناحیه متراکم قرار دارند، انزوا در ارتفاع ۱ **غیرممکن است** ($P = 0$).
  - برای جداسازی این نقاط حداقل به دو یا چند تقسیم متوالی نیاز است.
- این امر نشان می‌دهد نقاط درونی هرگز در سطوح بالای درخت منزوی نمی‌شوند.

# مشاهدات و نتیجه‌گیری جنگل انزوا

## Isolation Forest: Key Observations




- **نقاط در نواحی متراکم:** (Dense Areas)
  - نیازمند برش‌ها و آزمون‌های بسیار بیشتری هستند.
  - در **عمق زیاد درخت** منزوی می‌شوند (طول مسیر بلند).
- **نقاط پرت و دورافتاده:** (Outliers)
  - احتمال بسیار بالایی برای انزوای زودهنگام دارند.
  - در **سطوح بالایی درخت** قرار می‌گیرند (طول مسیر کوتاه).
- مرتبه خطی و کارایی بسیار بالا در داده‌های عظیم.

# سخنرانی‌ها و منابع برخط

## Online Lectures

| Week | Wednesday (Offline Lecture) | Online Lecture (see Ilias Course) | Thursday (Exercise) |
|---|---|---|---|
| 10.02.2025 | no lecture | | Introduction to Python (13:45–15:15) |
| 17.02.2025 | Introduction to Data Mining | | Intro |
| 24.02.2025 | Preprocessing | | Preprocessing |
| 03.03.2025 | Classification 1 | Nearest Centroids | Classification 1 |
| 10.03.2025 | Classification 2 | Comparing Classifiers | Classification 2 |
| 17.03.2025 | Regression | Ensembles | Regression |
| 24.03.2025 | Clustering and Anomalies | Hierarchical Clustering | Clustering |
| 31.03.2025 | Feedback on project outlines | Time Series | Time Series |
| 07.04.2025 | Association Analysis and Subgroup Discovery | | Association Analysis |

- مطالب تکمیلی این هفته پیرامون **خوشه‌بندی سلسله‌مراتبی (Hierarchical Clustering)** ارائه شده است.
- ویدیوها و اسلایدهای آموزشی برخط مکمل مباحث کلاس بوده و برای تمرین‌های عملی و امتحانات پایانی **بسیار حائز اهمیت** می‌باشند.

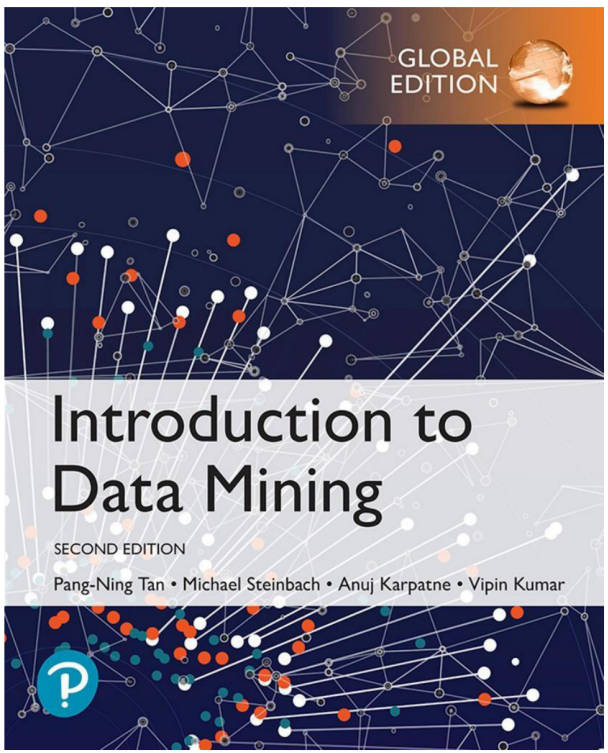
# پرسش و پاسخ
Questions?



## آیا پرسشی در مورد این فصل دارید؟

خوشه‌بندی و تشخیص ناهنجاری در داده‌کاوی

# منابع و مراجع مطالعاتی
## Literature for this Slideset




**کتاب مرجع اصلی:**

- Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, Vipin Kumar: **Introduction to Data Mining**، 2nd Edition, Pearson.

**فصول مرتبط از کتاب:**

- **فصل ۵: تحلیل خوشه (Chapter 5: Cluster Analysis)**
  - بخش ۲.۵: الگوریتم کا-میانگین (K-Means)
  - بخش ۳.۵: خوشه‌بندی سلسله‌مراتبی تراکمی (Agglomerative Hierarchical)
  - بخش ۴.۵: الگوریتم DBSCAN
- **فصل ۲: بخش ۴.۲:** معیارهای شباهت و عدم‌شباهت (Similarity & Dissimilarity Measures)