تحلیل وابستگی در داده‌کاوی

IE۵۰۰ داده‌کاوی

گروه علوم داده و وب

دانشگاه مانهایم

06.04.2025

سرفصل مطالب
Outline

- **تحلیل وابستگی چیست؟** (What is Association Analysis?)
- **تولید مجموعه‌های اقلام مکرر** (Frequent Itemset Generation)
- **تولید قواعد وابستگی** (Rule Generation)
- **پیاده‌سازی در پایتون و معیارهای جذابیت** (Interestingness Measures)
- **مدیریت ویژگی‌های پیوسته و دسته‌ای** (Continuous & Categorical Attributes)
- **کشف زیرگروه‌ها** (Subgroup Discovery)

تحلیل وابستگی
Association Analysis



R. Agrawal



R. Srikant

- **توسعهٔ نخستین الگوریتم‌ها** در اوایل دههٔ ۱۹۹۰ میلادی در شرکت IBM توسط آگراوال و سریکانت (Agrawal & Srikant).
- **انگیزهٔ اولیه:**
  - دردسترس قرار گرفتن صندوق‌های فروشگاهی بارکددار
  - (Availability of barcode cash registers)



تحلیل وابستگی
Association Analysis

- **در ابتدا برای «تحلیل سبد خرید» (Market Basket Analysis) به کار رفت:**
  - یافتن نحوهٔ ارتباط و وابستگی اقلام خریداری‌شده توسط مشتریان فروشگاه‌ها
- **سپس به ساختارهای داده‌ای پیچیده‌تر گسترش یافت:**
  - الگوهای ترتیبی (Sequential patterns)
  - الگوهای زیرگراف (Subgraph patterns)
- **و در سایر حوزه‌های کاربردی مورد استفاده قرار گرفت:**
  - علوم زیستی و بیوانفورماتیک (Life science)
  - علوم اجتماعی (Social science)
  - کاوش کاربرد وب (Web usage mining)

رویکردهای ساده
Simple Approaches

- برای فهمیدن اینکه آیا دو قلم کالا (x و y) معمولاً **با هم خریده می‌شوند** یا خیر، می‌توانیم همبستگی آن‌ها را محاسبه کنیم.
- برای مثال، ضریب همبستگی پیرسون (Pearson's correlation coefficient - PCC):

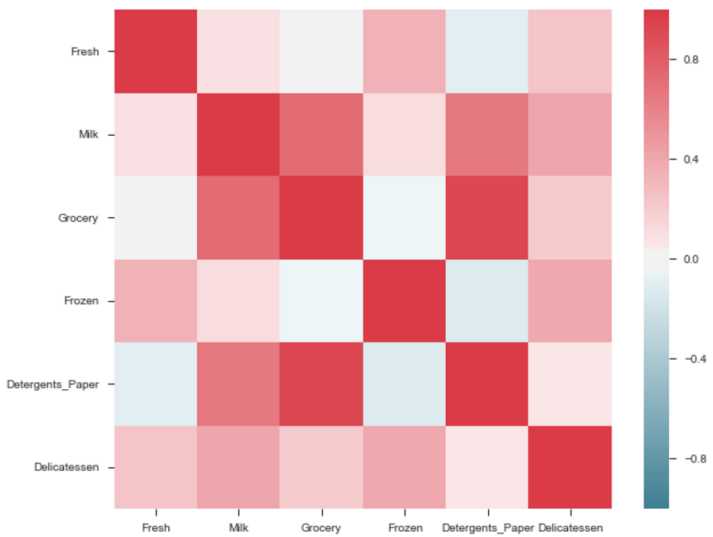
$$\text{PCC} = \frac{\sum_{i=1}^{n}(p_i - \bar{p}) \cdot (a_i - \bar{a})}{\sqrt{\sum_{i=1}^{n}(p_i - \bar{p})^2} \cdot \sqrt{\sum_{i=1}^{n}(a_i - \bar{a})^2}}$$

  - p_i: مقدار پیش‌بینی‌شده (predicted value)
  - a_i: مقدار واقعی (actual value)
- **کدگذاری عددی (Numerical coding):**
  - 1: قلم کالا خریده شده است (item was bought)
  - 0: قلم کالا خریده نشده است (item was not bought)
- $\bar{p}$ میانگین p است (یعنی اینکه قلم کالای x هر چند وقت یک‌بار خریده شده است).

تحلیل همبستگی در پایتون
Correlation Analysis in Python

- به عنوان نمونه با استفاده از کتابخانهٔ پایتون Pandas:

```
import seaborn as sns
corr = dataframe.corr()
sns.heatmap(corr)
```



تعریف مسئله

Association Analysis: Problem Definition

- با داشتن مجموعه‌ای از تراکنش‌ها، هدف **یافتن قواعدی** است که رخداد یک قلم کالا را بر پایه رخداد سایر اقلام در همان تراکنش پیش‌بینی نماید.
- **نمونه‌هایی از قواعد وابستگی:**

$$\{\text{Diaper}\} \rightarrow \{\text{Beer}\}$$
$$\{\text{Beer}, \text{Bread}\} \rightarrow \{\text{Milk}\}$$
$$\{\text{Milk}, \text{Bread}\} \rightarrow \{\text{Eggs}, \text{Coke}\}$$

تراکنش‌های خرید

(Shopping Transactions)

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

نکته مهم: علامت استلزام ($\rightarrow$) بیانگر **«هم‌رخدادی»** است، نه رابطهٔ «علّیت»!

(Implication denotes co-occurrence, not causality!)

تعریف: مجموعه‌آیتم مکرر

Definition: Frequent Itemset

- **مجموعه‌آیتم** (Itemset)
  - مجموعه‌ای شامل یک یا چند قلم کالا (آیتم).
  - مثال: {Milk, Bread, Diaper}
  - **k-مجموعه‌آیتم:** مجموعه‌آیتمی شامل k قلم کالا.
- **شمارش پشتیبان** (Support count, σ)
  - فراوانی رخداد یک مجموعه‌آیتم در کل داده‌ها:
    $\sigma(\{\text{Milk, Bread, Diaper}\}) = 2$
- **پشتیبان** (Support, s)
  - کسر تراکنش‌های دربرگیرندهٔ مجموعه‌آیتم:
    $s(\{\text{Milk, Bread, Diaper}\}) = 2/5 = 0.4$
- **مجموعه‌آیتم مکرر** (Frequent Itemset)
  - مجموعه‌آیتمی که پشتیبان آن $\geq$ minsup باشد.

تراکنش‌های خرید

(Shopping Transactions)

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

تعریف: قاعدهٔ وابستگی

Definition: Association Rule

- **قاعدهٔ وابستگی**: (Association Rule)
  - یک رابطه به فرم استلزام $X \rightarrow Y$ است که در آن X و Y دو مجموعه‌آیتم مجزا هستند: $X \cap Y = \emptyset$.
  - **تفسیر:** هرگاه X رخ دهد، Y نیز با یک احتمال مشخص رخ خواهد داد.

- **بیان دقیق‌تر به صورت احتمال شرطی:**
  - $P(Y \mid X)$: با فرض رخداد X، احتمال رخ دادن Y چقدر است؟

تراکنش‌های خرید

(Shopping Transactions)

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

ارزیابی قاعدهٔ وابستگی

Definition: Association Rule

تراکنش‌های خرید

(Shopping Transactions)

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	**Milk**, **Diaper**, **Beer**, Coke
4	Bread, **Milk**, **Diaper**, **Beer**
5	Bread, Milk, Diaper, Coke

- **مثال از قاعدهٔ وابستگی:**

$$\underbrace{\{\text{Milk, Diaper}\}}_{\text{مقدم / شرط}} \rightarrow \underbrace{\{\text{Beer}\}}_{\text{مؤخر / نتیجه}}$$

- **معیارهای ارزیابی قاعده:**
  - **پشتیبان (s):** کسر تراکنش‌های دربرگیرندهٔ هر دو مجموعهٔ X و Y به صورت زیر است:

$$s(X \rightarrow Y) = \frac{\sigma(X \cup Y)}{|T|} = \frac{2}{5} = 0.4$$

  - **اطمینان (c):** بسامد رخداد اقلام Y در تراکنش‌های حاوی X به این صورت محاسبه می‌شود:

$$c(X \rightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)} = \frac{2}{3} \approx 0.67$$

مسئلهٔ کاوش قواعد وابستگی

The Association Rule Mining Task

- با داشتن مجموعه‌ای از تراکنش‌ها T، هدف کاوش قواعد وابستگی عبارت است از:

یافتن تمامی قواعدی که در دو شرط زیر صدق کنند:

$$\text{support} \geq \text{minsup} \quad \text{and} \quad \text{confidence} \geq \text{minconf}$$

- دو آستانهٔ minsup و minconf توسط کاربر تعیین می‌شوند.
- **رویکرد جستجوی جامع** (Brute Force):
  - فهرست کردن تمامی قواعد وابستگی ممکن در فضای مسئله
  - محاسبهٔ مقدار پشتیبان و اطمینان برای تک‌تک قواعد
  - حذف قواعدی که در آستانه‌های minsup یا minconf صدق نمی‌کنند.
- **⇒ به دلیل تعداد عظیم نامزدها، جستجوی جامع از نظر محاسباتی غیرممکن است!**

استخراج قواعد وابستگی

Mining Association Rules

تراکنش‌های خرید

(Shopping Transactions)

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

نمونه قواعد مستخرج:

- $\{\text{Milk, Diaper}\} \rightarrow \{\text{Beer}\} \quad (s = 0.4, c = 0.67)$
- $\{\text{Milk, Beer}\} \rightarrow \{\text{Diaper}\} \quad (s = 0.4, c = 1.0)$
- $\{\text{Diaper, Beer}\} \rightarrow \{\text{Milk}\} \quad (s = 0.4, c = 0.67)$
- $\{\text{Beer}\} \rightarrow \{\text{Milk, Diaper}\} \quad (s = 0.4, c = 0.67)$
- $\{\text{Diaper}\} \rightarrow \{\text{Milk, Beer}\} \quad (s = 0.4, c = 0.5)$
- $\{\text{Milk}\} \rightarrow \{\text{Diaper, Beer}\} \quad (s = 0.4, c = 0.5)$

مشاهدات کلیدی:

- تمامی قواعد بالا افرازهای دودویی از یک مجموعه‌آیتم یکسان هستند: {Milk, Diaper, Beer}.
- قواعد برگرفته از یک مجموعه‌آیتم یکسان، دارای **پشتیبان یکسان** s هستند؛ اما می‌توانند **اطمینان** c **متفاوتی** داشته باشند.
- **نتیجه:** می‌توانیم نیازمندی‌های پشتیبان و اطمینان را **از یکدیگر تفکیک** نماییم!

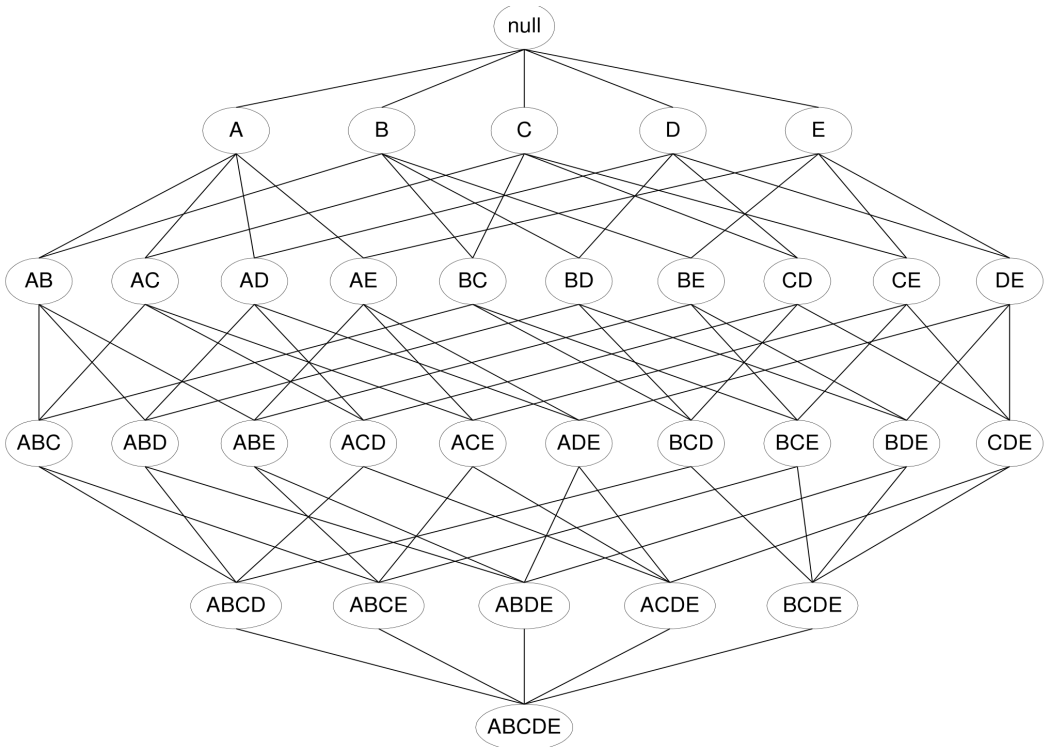
الگوریتم آپریوری: ایدهٔ بنیادین
Apriori Algorithm: Basic Idea

- **رویکرد دو مرحله‌ای:** (Two-step approach)
  ۱. **تولید مجموعه‌آیتم‌های مکرر** (Frequent Itemset Generation):
     - تولید تمامی مجموعه‌آیتم‌هایی که مقدار پشتیبان آن‌ها $\geq$ minsup باشد.
  ۲. **تولید قواعد** (Rule Generation):
     - تولید قواعد با اطمینان بالا از هر مجموعه‌آیتم مکرر، به‌طوری که هر قاعده یک افراز دودویی از مجموعه‌آیتم مکرر باشد.

- **تولید مجموعه‌آیتم‌های مکرر همچنان از نظر محاسباتی بسیار سنگین و پرهزینه است!**

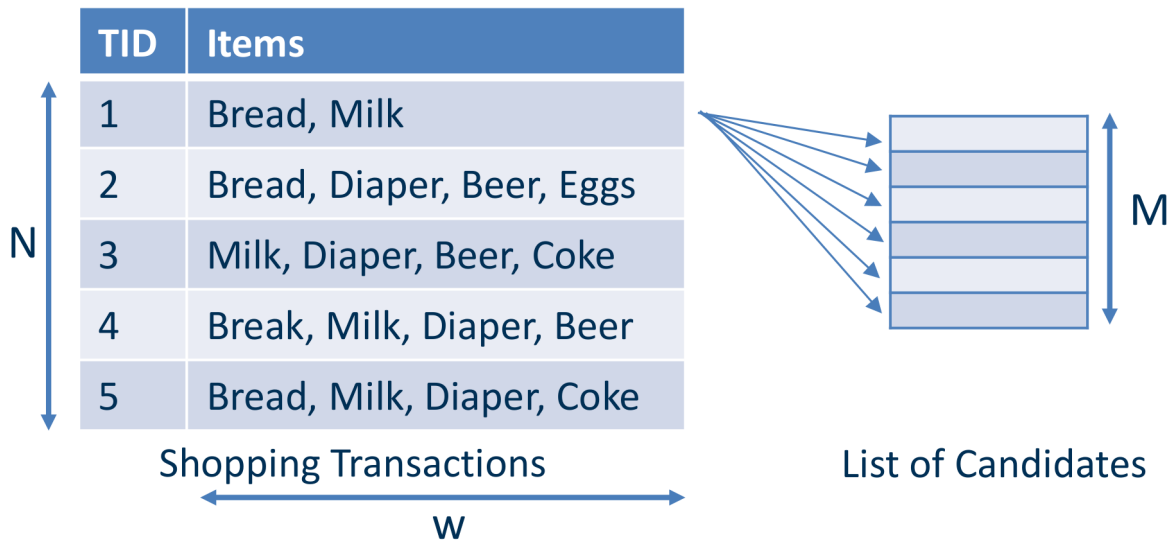
تولید مجموعه‌آیتم‌های مکرر
Frequent Itemset Generation

- به ازای d قلم کالا، دقیقاً 2^d مجموعه‌آیتم نامزد وجود دارد!



رویکرد جامع
Brute-force Approach

- هر مجموعه‌آیتم در مشبکه، یک **نامزد مکرر بودن** است.
- شمارش پشتیبان هر نامزد با پیمایش کل پایگاه داده انجام می‌شود.
- تطبیق تک‌تک تراکنش‌ها با تمام نامزدها:

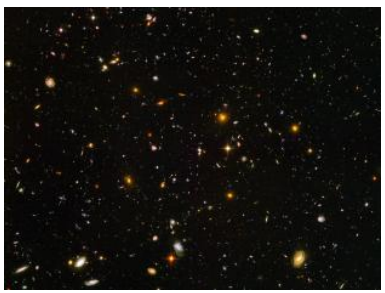


- **پیچیدگی محاسباتی:** $\mathcal{O}(N \cdot M \cdot w)$ که در آن $M = 2^d$ است (بسیار سنگین و غیرعملی).

رویکرد جامع در مقیاس واقعی

Brute-force Approach

- **آمازون** دارای بیش از ۱۲ میلیون محصول مختلف است (تا سال 2023):
  - یعنی $2^{12,000,000}$ مجموعه‌آیتم ممکن!
  - عددی با 3.6 میلیون رقم!
- **سریع‌ترین ابررایانه‌های امروزی:** حدود ۱،۲۰۰ پتافلاپس (1.2×10^{18} عملیات در ثانیه).
- **تعداد اتم‌های جهان قابل‌مشاهده:** حدود 10^{80}.
- **زمان سپری‌شده از مهبانگ (بیگ بنگ):** 13.8 میلیارد سال $\approx 4.35 \times 10^{17}$ ثانیه.



Observable Universe



1,200 Petaflops

amazon

12M Products

محاسبهٔ جامع حتی از کل عمر کیهان نیز بسیار بیشتر طول می‌کشد!

خاصیت پادیکنواختی پشتیبان

Anti-Monotonicity of Support

تراکنش‌های خرید

(Shopping Transactions)

TID	Items
1	**Milk**, Bread
2	Bread, **Diaper**, **Beer**, Eggs
3	**Milk**, **Diaper**, **Beer**, Coke
4	Bread, **Milk**, **Diaper**, **Beer**
5	Bread, **Milk**, **Diaper**, Coke

- **با بزرگ‌تر شدن یک مجموعه‌آیتم چه رخ می‌دهد؟**

$$s(\{\text{Milk}\}) = 0.8$$
$$s(\{\text{Milk, Diaper}\}) = 0.6$$
$$s(\{\text{Milk, Diaper, Beer}\}) = 0.4$$

$$s(\{\text{Bread}\}) = 0.8$$
$$s(\{\text{Bread, Milk}\}) = 0.6$$
$$s(\{\text{Bread, Milk, Diaper}\}) = 0.4$$

- **یک الگوی منظم و بنیادین در اینجا وجود دارد!**

کاهش تعداد نامزدها با ویژگی پادیکنواخت

Reducing the Number of Candidates

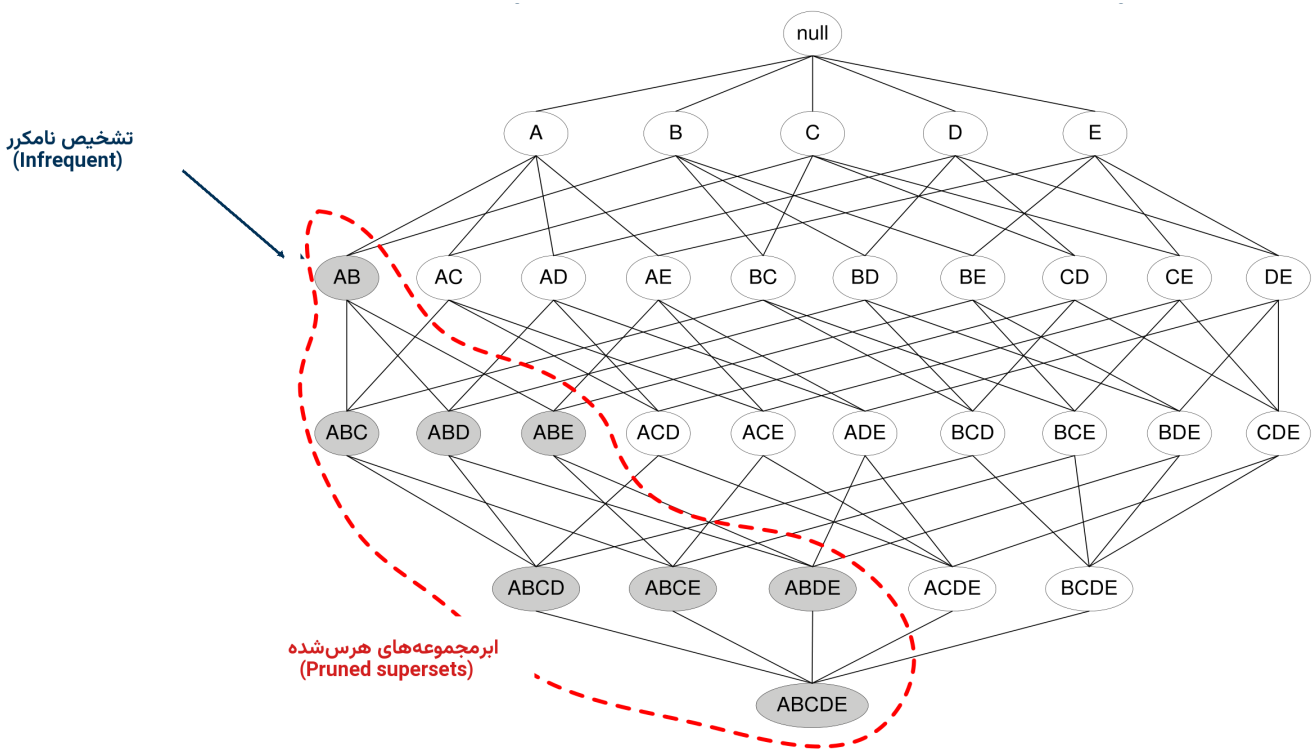
- **الگوی بنیادین:** خاصیت پادیکنواختی پشتیبان (Anti-Monotonicity):
  - اگر X زیرمجموعه‌ای از Y باشد، پشتیبان Y حداکثر می‌تواند به بزرگی پشتیبان X باشد:

$$\forall X, Y: \quad X \subseteq Y \implies s(X) \geq s(Y)$$

- **پیامدها و هرس:**
  - اگر یک مجموعه‌آیتم **مکرر** باشد، تمام زیرمجموعه‌های آن نیز قطعاً مکرر هستند.
  - **اصل آپریوری (قاعدهٔ هرس):** اگر یک مجموعه‌آیتم **نامکرر** باشد، تمام ابرمجموعه‌های آن نیز قطعاً **نامکرر** خواهند بود و نیازی به بررسی آن‌ها نیست!

هرس فضای جستجو بر اساس اصل آپریوری

Using the Apriori Principle for Pruning



اگر یک مجموعه‌آیتم نامکرر باشد، تمام ابرمجموعه‌های آن فوراً هرس می‌شوند.

الگوریتم آپریوری
The Apriori Algorithm

- مقدار $k = 1$ قرار داده می‌شود.
- مجموعه‌آیتم‌های مکرر به طول ۱ (F_1) تولید می‌شوند.
- **تکرار تا زمانی که هیچ مجموعه‌آیتم مکرر جدیدی شناسایی نشود:**
  - **تولید نامزدها:** تولید مجموعه‌آیتم‌های نامزد به طول $k + 1$ از روی اقلام مکرر به طول k.
  - **هرس نامزدها:** هرس نامزدهایی که شامل زیرمجموعه‌ای نامکرر به طول k هستند (بر اساس اصل آپریوری).
  - **شمارش پشتیبان:** شمارش پشتیبان هر نامزد با پیمایش پایگاه داده.
  - **حذف نامکررها:** حذف نامزدهای نامکرر، و نگه‌داشتن موارد مکرر (F_{k+1}).
  - $k = k + 1$

تشریح اصل آپریوری با مثال عددی

Illustrating the Apriori Principle

تراکنش‌های خرید

(Shopping Transactions)

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

حداقل شمارش پشتیبان: $\text{minsup} = 3$

مجموعه‌آیتم‌های ۱-عضوی:

Item	Count
Bread	4
Coke	2
Milk	4
Beer	3
Diaper	4
Eggs	1

بدون نیاز به تولید نامزدهای شامل Coke یا Eggs!

مجموعه‌آیتم‌های ۲-عضوی و ۳-عضوی:

2-pairs	Count
{Bread, Milk}	3
{Bread, Beer}	2
{Bread, Diaper}	3
{Milk, Beer}	2
{Milk, Diaper}	3
{Beer, Diaper}	3

3-itemset	Count
{Bread, Milk, Diaper}	3

عدم تولید {Milk, Diaper, Beer} به دلیل نامکرر بودن {Milk, Beer}.

تشریح اصل آپریوری با مثال عددی

Illustrating the Apriori Principle

تراکنش‌های خرید

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

شمارش مجموعه‌آیتم‌های ۱-عضوی:

Item	Count
Bread	4
Coke	2
Milk	4
Beer	3
Diaper	4
Eggs	1

- در این مثال با ۶ قلم کالا، الگوریتم آپریوری تنها موارد زیر را بررسی نمود:
  - ۶ مورد از مجموعه‌آیتم‌های ۱-عضوی
  - ۶ مورد از مجموعه‌آیتم‌های ۲-عضوی
  - ۱ مورد از مجموعه‌آیتم‌های ۳-عضوی
  - **در مجموع تنها ۱۳ مجموعه‌آیتم بررسی شد!**
- **در مقایسه با تمام مجموعه‌آیتم‌های ممکن:**

$$2^6 = 64$$

- **نتیجه:** کاهش چشمگیر و صرفه‌جویی نزدیک به ٪۸۰ در فضای جستجو!

از مجموعه‌آیتم‌های مکرر به قواعد

From Frequent Itemsets to Rules

تراکنش‌های خرید

(Shopping Transactions)

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

- **مسئله:** به‌ازای مجموعه‌آیتم مکرر داده‌شده L، تمام زیرمجموعه‌های ناتهی $f \subset L$ را بیابید به‌گونه‌ای که قاعدهٔ زیر شرط حداقل اطمینان (minconf) را برآورده سازد:
$$f \rightarrow L \setminus f$$
- **مثال مجموعه‌آیتم مکرر:** فرض کنید $L = \{\text{Milk, Diaper, Beer}\}$
- **مثال قاعدهٔ وابستگی:**
$$\underbrace{\{\text{Milk, Diaper}\}}_{f} \rightarrow \{\text{Beer}\}$$
$$c = \frac{\sigma(\text{Milk, Diaper, Beer})}{\sigma(\text{Milk, Diaper})} = \frac{2}{3} \approx 0.67$$

چالش: انفجار ترکیبیاتی
Challenge: Combinatorial Explosion

- برای یک مجموعه‌آیتم ۴عضوی $\{A, B, C, D\}$، می‌توان قواعد زیر را تولید کرد:

$$\{A\} \to \{B, C, D\} \quad \{A, B\} \to \{C, D\} \quad \{A, B, C\} \to \{D\}$$
$$\{B\} \to \{A, C, D\} \quad \{A, C\} \to \{B, D\} \quad \{A, B, D\} \to \{C\}$$
$$\{C\} \to \{A, B, D\} \quad \{A, D\} \to \{B, C\} \quad \{A, C, D\} \to \{B\}$$
$$\{D\} \to \{A, B, C\} \quad \{B, C\} \to \{A, D\} \quad \{B, C, D\} \to \{A\}$$
$$\{B, D\} \to \{A, C\}$$
$$\{C, D\} \to \{A, B\}$$

- یعنی در مجموع **۱۴ قاعده** تنها از یک مجموعه‌آیتم ۴عضوی!
- **فرمول کلی تعداد قواعد برای یک مجموعه‌آیتم kعضوی:**

$$2^k - 2$$

– برابر 2^k نیست زیرا قواعد بدیهی $\{\ldots\} \to \emptyset$ و $\emptyset \to \{\ldots\}$ نادیده گرفته می‌شوند.

چالش: انفجار ترکیبیاتی
Challenge: Combinatorial Explosion

- **هدف مطلوب:** یافتن یک ترفند هرس دیگر مشابه اصل آپریوری.
- **با این حال، به مثال‌های زیر دقت کنید:**
  - $c(\{\text{Milk, Diaper}\} \rightarrow \{\text{Beer}\}) = 0.67$
  - $c(\{\text{Milk}\} \rightarrow \{\text{Beer}\}) = 0.5$
  - $c(\{\text{Diaper}\} \rightarrow \{\text{Beer}\}) = 0.8$
  - مقدار $c(ABC \rightarrow D)$ می‌تواند بزرگ‌تر یا کوچک‌تر از $c(AB \rightarrow D)$ باشد!
- **نتیجه‌گیری:** به‌طور کلی، معیار اطمینان (confidence) دارای **خاصیت پادیکنواختی نیست!**

تراکنش‌های خرید

(Shopping Transactions)

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

چالش: انفجار ترکیبیاتی
Challenge: Combinatorial Explosion

- **اما:** اطمینان قواعدی که **از یک مجموعه‌آیتم یکسان** مشتق می‌شوند، دارای خاصیت پادیکنواختی است.
- برای مثال، فرض کنید مجموعه‌آیتم $L = \{\text{Milk}, \text{Diaper}, \text{Beer}\}$ باشد:
  - $\{\text{Milk}, \text{Diaper}, \text{Beer}\} \rightarrow \emptyset \quad (c = 1.0)$
  - $\{\text{Milk}, \text{Diaper}\} \rightarrow \{\text{Beer}\} \quad (c = 0.67)$
  - $\{\text{Milk}, \text{Beer}\} \rightarrow \{\text{Diaper}\} \quad (c = 1.0)$
  - $\{\text{Beer}\} \rightarrow \{\text{Milk}, \text{Diaper}\} \quad (c = 0.67)$
  - $\{\text{Milk}\} \rightarrow \{\text{Diaper}, \text{Beer}\} \quad (c = 0.5)$
  - $\{\text{Diaper}\} \rightarrow \{\text{Milk}, \text{Beer}\} \quad (c = 0.5)$
- برای مجموعه‌آیتم $L = \{A, B, C, D\}$ داریم:

$$c(ABC \rightarrow D) \geq c(AB \rightarrow CD) \geq c(A \rightarrow BCD)$$

مشاهده: انتقال مؤلفه‌ها از مقدم به مؤخر («از چپ به راست») در یک قاعده، **هرگز اطمینان را افزایش نمی‌دهد!**

تراکنش‌های خرید

(Shopping Transactions)

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

توضیح ریاضی پادیکنواختی اطمینان
Explanation

- اطمینان نسبت به **تعداد آیتم‌های سمت راست (RHS) قاعده** پادیکنوا است:
  - به این معنی که: انتقال عناصر از چپ به راست نمی‌تواند اطمینان را افزایش دهد.
- **علت ریاضی:**
  - به دلیل ویژگی پادیکنواختی پشتیبان، می‌دانیم که $s(AB) \leq s(A)$ است.
  - با توجه به تعریف اطمینان:

$$c(AB \to C) := \frac{s(ABC)}{s(AB)}, \qquad c(A \to BC) := \frac{s(ABC)}{s(A)}$$

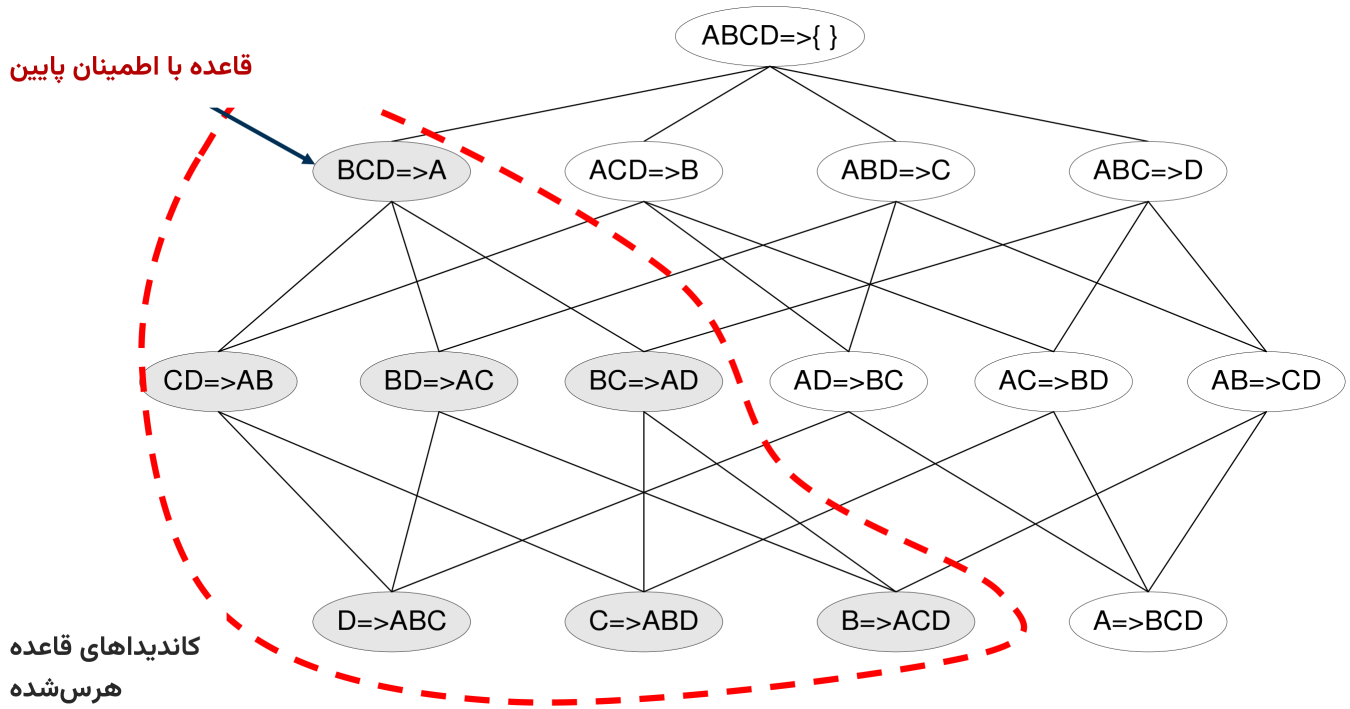
  - چون صورت هر دو کسر یکسان است و مخرج کسر اول کوچک‌تر یا مساوی است یعنی $s(AB) \leq s(A)$، در نتیجه:

$$c(AB \to C) \geq c(A \to BC)$$

هرس قواعد نامزد

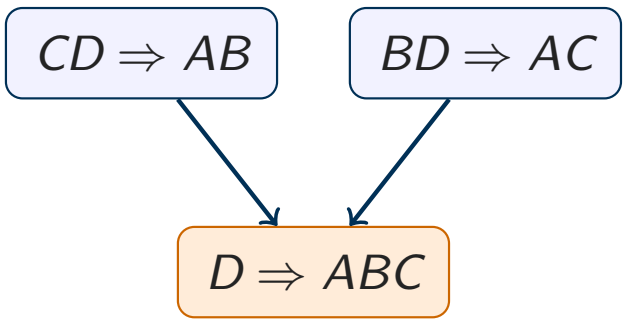
Candidate Rule Pruning

- **انتقال عناصر از چپ به راست نمی‌تواند اطمینان را افزایش دهد:**
  - اگر یک قاعده دارای اطمینان پایینی باشد، تمامی قواعد مشتق‌شده از آن با انتقال آیتم به سمت راست نیز اطمینان پایینی خواهند داشت و بلافاصله هرس می‌شوند.



تولید قاعده برای الگوریتم آپریوری

Rule Generation for Apriori Algorithm



- **قاعدهٔ کاندید** با ادغام دو قاعده‌ای تولید می‌شود که دارای پیشوند یکسانی در مؤخر (consequent) قاعده باشند:
  - ادغام $\text{join}(CD \rightarrow AB,\ BD \rightarrow AC)$ قاعدهٔ کاندید $D \rightarrow ABC$ را تولید می‌کند.
  - اگر یکی از قواعد والد (مانند $AD \rightarrow BC$) اطمینان بالایی نداشته باشد، قاعدهٔ $D \rightarrow ABC$ **هرس** می‌شود.
- **نکته کلیدی:** تمام اطلاعات موردنیاز برای محاسبهٔ اطمینان قبلاً در مرحلهٔ تولید مجموعه‌آیتم‌ها ذخیره شده است:

$$c(X \rightarrow Y) = \frac{s(X \cup Y)}{s(X)}$$

  - در نتیجه، **هیچ نیازی به پیمایش مجدد داده‌ها وجود ندارد!**

تحلیل وابستگی در پایتون

Association Analysis in Python

- بسته‌ها و کتابخانه‌های متنوعی در پایتون وجود دارند:
  - در تمرین‌ها از بستهٔ `Orange3` استفاده می‌کنیم (و کتابخانهٔ `mlxtend`).

- **تولید مجموعه‌آیتم‌های مکرر:** (با تعیین حداقل پشتیبان 20%)

```
from orangecontrib.associate.fpgrowth import frequent_itemsets
# Calculate frequent itemsets (min support = 0.20)
itemsets = dict(frequent_itemsets(dataset.values, 0.20))
```

- **استخراج قواعد وابستگی:** (با تعیین حداقل اطمینان 70%)

```
from orangecontrib.associate.fpgrowth import association_rules
# Calculate association rules from itemsets (min confidence = 0.70)
rules = association_rules(itemsets, 0.70)
```

معیارهای جذابیت قواعد

Interestingness Measures

- الگوریتم‌های قواعد وابستگی معمولاً **تعداد بسیار زیادی قاعده** تولید می‌کنند:
  - بسیاری از این قواعد **غیرجذاب یا زائد** (redundant) هستند.
  - یک قاعده زائد است اگر برای مثال $\{A, B, C\} \rightarrow \{D\}$ و $\{A, B\} \rightarrow \{D\}$ پشتیبان و اطمینان یکسانی داشته باشند.
- **معیارهای جذابیت:** برای هرس کردن، فیلتر یا رتبه‌بندی قواعد تولیدشده به کار می‌روند.
- در فرمول‌بندی اولیه، تنها دو معیار **پشتیبان** و **اطمینان** استفاده می‌شدند.
- بعدها معیارهای تکمیلی متعددی پیشنهاد شدند:
  - در این درس با معیار مهم **لیفت** (Lift) آشنا می‌شویم.
  - برای مطالعهٔ تفصیلی، مرجع تن و همکاران (فصل ۷.۶) پیشنهاد می‌شود.

نقطهٔ ضعف معیار اطمینان

Drawback of Confidence

- **قاعدهٔ وابستگی:** $\text{Tea} \rightarrow \text{Coffee}$
- اطمینان قاعده:
$c(\text{Tea} \rightarrow \text{Coffee}) = \frac{3}{4} = 0.75$
- پشتیبان کل قهوه در داده‌ها:
$s(\text{Coffee}) = \frac{18}{20} = 0.90$
- با وجود اطمینان بالا (75%)، این قاعده **گمراه‌کننده** است؛ زیرا نرخ خریداران قهوه در جامعه (90%) از اطمینان قاعده بیشتر است!
- مطلوب است که:
$\text{conf}(X \rightarrow Y) > \text{supp}(Y)$؛ در غیر این صورت، X شانس رخداد Y را کاهش می‌دهد!

جدول توافقی

(Contingency Table)

	Coffee	¬Coffee	Total
Tea	3	1	4
¬Tea	15	1	16
Total	18	2	20

تراکنش‌ها (۲۰ مورد)

TID	Items
1–15	Coffee
16–18	Tea, Coffee
19	Tea
20	Bread

معیار لیفت
Lift

- قاعده‌ای با اطمینان بالا برای $\text{tea} \rightarrow \text{coffee}$ کشف کرده‌ایم:
  - 75% از افرادی که چای می‌نوشند، قهوه نیز مصرف می‌کنند.
  - **فرضیه ذهنی:** افرادی که چای می‌نوشند، تمایل دارند قهوه بنوشند.
  - **مفهوم ضمنی:** تمایل آن‌ها **بیشتر از میانگین کل جامعه** است.
- **آزمون مقایسه:** مقایسهٔ اطمینان قاعده با **قاعدهٔ پیش‌فرض (پایه):**
  - قاعدهٔ اختصاصی: $c_{\text{tea}\rightarrow\text{coffee}} = \frac{s(\{\text{tea}\}\cup\{\text{coffee}\})}{s(\{\text{tea}\})}$
  - قاعدهٔ پیش‌فرض (جامعه): $c_{\text{all}\rightarrow\text{coffee}} = \frac{s(\text{coffee})}{1} = s(\text{coffee})$
- قاعده‌ای را **پذیرفتنی** می‌دانیم اگر اطمینان آن از قاعدهٔ پیش‌فرض جامعه بیشتر باشد:

$$\frac{c_{\text{tea}\rightarrow\text{coffee}}}{c_{\text{all}\rightarrow\text{coffee}}} = \frac{c_{\text{tea}\rightarrow\text{coffee}}}{s(\text{coffee})} > 1$$

تفسیر و ویژگی‌های معیار لیفت

Lift

- **تعریف ریاضی لیفت** برای قاعدهٔ $X \to Y$ به صورت زیر است:

$$\text{Lift}(X \to Y) = \frac{c(X \to Y)}{s(Y)} = \frac{s(X \cup Y)}{s(X) \cdot s(Y)}$$

  - در واقع: نرمال‌سازی اطمینان قاعده بر حسب پشتیبان مؤخر (نتیجه).

- **تفسیر آماری لیفت:**
  - **اگر** $\text{Lift} > 1$: اقلام X و Y دارای **همبستگی مثبت** هستند (خرید X شانس خرید Y را افزایش می‌دهد).
  - **اگر** $\text{Lift} = 1$: اقلام X و Y از نظر آماری **مستقل** هستند ($P(X \cap Y) = P(X)P(Y)$).
  - **اگر** $\text{Lift} < 1$: اقلام X و Y دارای **همبستگی منفی** هستند (خرید X مانع خرید Y می‌شود).

مثال محاسبهٔ لیفت

Lift (Example)

- **قاعدهٔ وابستگی:** $\text{Tea} \rightarrow \text{Coffee}$
- اطمینان قاعده:
$c(\text{Tea} \rightarrow \text{Coffee}) = \frac{3}{4} = 0.75$
- پشتیبان مؤخر (قهوه):
$s(\text{Coffee}) = \frac{18}{20} = 0.90$

- **محاسبهٔ لیفت:**

$$\text{Lift}_{\text{Tea}\rightarrow\text{Coffee}} = \frac{0.75}{0.90} \approx 0.833 < 1$$

- **نتیجه‌گیری:** از آنجا که $\text{Lift} < 1$ است، بین مصرف چای و قهوه **همبستگی منفی** وجود دارد و این قاعده به عنوان قاعده‌ای گمراه‌کننده **حذف می‌شود**.

جدول توافقی

(Contingency Table)

	Coffee	**¬Coffee**	**Total**
Tea	3	1	4
¬Tea	15	1	16
Total	18	2	20

تراکنش‌ها (۲۰ مورد)

TID	**Items**
1–15	Coffee
16–18	Tea, Coffee
19	Tea
20	Bread

سایر معیارهای جذابیت

Interestingness Measures

#	Measure	Formula
1	ϕ-coefficient	$\frac{P(A,B)-P(A)P(B)}{\sqrt{P(A)P(B)(1-P(A))(1-P(B))}}$
2	Goodman-Kruskal's (λ)	$\frac{\sum_j \max_k P(A_j,B_k)+\sum_k \max_j P(A_j,B_k)-\max_j P(A_j)-\max_k P(B_k)}{2-\max_j P(A_j)-\max_k P(B_k)}$
3	Odds ratio (α)	$\frac{P(A,B)P(\overline{A},\overline{B})}{P(A,\overline{B})P(\overline{A},B)}$
4	Yule's Q	$\frac{P(A,B)P(\overline{AB})-P(A,\overline{B})P(\overline{A},B)}{P(A,B)P(\overline{AB})+P(A,\overline{B})P(\overline{A},B)} = \frac{\alpha-1}{\alpha+1}$
5	Yule's Y	$\frac{\sqrt{P(A,B)P(\overline{AB})}-\sqrt{P(A,\overline{B})P(\overline{A},B)}}{\sqrt{P(A,B)P(\overline{AB})}+\sqrt{P(A,\overline{B})P(\overline{A},B)} = \frac{\sqrt{\alpha}-1}{\sqrt{\alpha}+1}$
6	Kappa (κ)	$\frac{P(A,B)+P(\overline{A},\overline{B})-P(A)P(B)-P(\overline{A})P(\overline{B})}{1-P(A)P(B)-P(\overline{A})P(\overline{B})}$
7	Mutual Information (M)	$\frac{\sum_i \sum_j P(A_i,B_j)\log\frac{P(A_i,B_j)}{P(A_i)P(B_j)}}{\min(-\sum_i P(A_i)\log P(A_i), -\sum_j P(B_j)\log P(B_j))}$
8	J-Measure (J)	$\max\left(P(A,B)\log(\frac{P(B\|A)}{P(B)})+P(A\overline{B})\log(\frac{P(\overline{B}\|A)}{P(\overline{B})}),\right.$ $\left.P(A,B)\log(\frac{P(A\|B)}{P(A)})+P(\overline{A}B)\log(\frac{P(\overline{A}\|B)}{P(\overline{A})})\right)$
9	Gini index (G)	$\max\left(P(A)[P(B\|A)^2+P(\overline{B}\|A)^2]+P(\overline{A})[P(B\|\overline{A})^2+P(\overline{B}\|\overline{A})^2]\right.$ $-P(B)^2-P(\overline{B})^2,$ $P(B)[P(A\|B)^2+P(\overline{A}\|B)^2]+P(\overline{B})[P(A\|\overline{B})^2+P(\overline{A}\|\overline{B})^2]$ $\left.-P(A)^2-P(\overline{A})^2\right)$
10	Support (s)	$P(A,B)$
11	Confidence (c)	$\max(P(B\|A),P(A\|B))$
12	Laplace (L)	$\max\left(\frac{NP(A,B)+1}{NP(A)+2},\frac{NP(A,B)+1}{NP(B)+2}\right)$
13	Conviction (V)	$\max\left(\frac{P(A)P(\overline{B})}{P(A\overline{B})},\frac{P(B)P(\overline{A})}{P(B\overline{A})}\right)$
14	Interest (I)	$\frac{P(A,B)}{P(A)P(B)}$
15	cosine (IS)	$\frac{P(A,B)}{\sqrt{P(A)P(B)}}$
16	Piatetsky-Shapiro's (PS)	$P(A,B)-P(A)P(B)$
17	Certainty factor (F)	$\max\left(\frac{P(B\|A)-P(B)}{1-P(B)},\frac{P(A\|B)-P(A)}{1-P(A)}\right)$
18	Added Value (AV)	$\max(P(B\|A)-P(B),P(A\|B)-P(A))$
19	Collective strength (S)	$\frac{P(A,B)+P(\overline{AB})}{P(A)P(B)+P(\overline{A})P(\overline{B})}\times\frac{1-P(A)P(B)-P(\overline{A})P(\overline{B})}{1-P(A,B)-P(\overline{AB})}$
20	Jaccard (ζ)	$\frac{P(A,B)}{P(A)+P(B)-P(A,B)}$
21	Klosgen (K)	$\sqrt{P(A,B)}\max(P(B\|A)-P(B),P(A\|B)-P(A))$

- در مقالات و کتب تخصصی داده‌کاوی، **ده‌ها معیار جذابیت مختلف** پیشنهاد شده است.
- برخی از معیارها برای کاربردهای خاصی عالی هستند اما در کاربردهای دیگر عملکرد ضعیفی دارند.
- **مطالعهٔ تفصیلی:** به مراجع تخصصی مراجعه شود (مانند کتاب تن و همکاران، جدول ۱۱.۶).

مدیریت ویژگی‌های پیوسته و دسته‌ای

Handling Continuous and Categorical Attributes

- چگونه تحلیل وابستگی را بر روی ویژگی‌هایی اعمال کنیم که **متغیرهای دوگانهٔ نامتقارن نیستند؟**
- **مثال قاعدهٔ ترکیبی:**

$$\{\text{Number of Pages} \in [5, 10) \wedge (\text{Browser} = \text{Firefox})\} \rightarrow \{\text{Buy} = \text{No}\}$$

شناسه	کشور	مدت جلسه (ثانیه)	صفحات دیده‌شده	جنسیت	مرورگر	خرید
۱	USA	۹۸۲	۸	Male	Chrome	No
۲	China	۸۱۱	۱۰	Female	Chrome	No
۳	USA	۲۱۲۵	۴۵	Female	Firefox	Yes
۴	Germany	۵۹۶	۴	Male	IE	Yes
۵	Australia	۱۲۳	۹	Male	Firefox	No
...	...	...	...	...	...	...

مدیریت ویژگی‌های دسته‌ای
Handling Categorical Attributes

- **تبدیل ویژگی‌های دسته‌ای به متغیرهای دودویی نامتقارن:**
  - تعریف یک «آیتم» جدید به‌ازای هر جفت مشخص (ویژگی، مقدار).
  - برای مثال، جایگزینی ویژگی «نوع مرورگر» با:
    - ویژگی: Type Browser = Chrome
    - ویژگی: Type Browser = Firefox
    - ویژگی: Type Browser = Safari و ...

- **چالش‌های پیش‌رو:**
  - **اگر ویژگی دارای مقادیر ممکن بسیار زیادی باشد:**
    - بسیاری از مقادیر ویژگی ممکن است دارای پشتیبان بسیار پایینی باشند.
    - **راهکار احتمالی:** تجمیع مقادیر کم‌پشتیبان در گروه‌های کلی‌تر.
  - **اگر توزیع مقادیر ویژگی دارای چولگی شدید باشد:**
    - برای مثال: 95% کاربران دارای Buy = No هستند.
    - اغلب آیتم‌ها با (Buy = No) همبسته خواهند شد (قواعد بدیهی).
    - **راهکار احتمالی:** حذف یا نادیده گرفتن آیتم بسیار پرتکرار.

مدیریت ویژگی‌های پیوسته

Handling Continuous Attributes

- **تبدیل متغیرهای پیوسته با گسسته‌سازی:** (Discretization)
  - دسته‌بندی با پهنای مساوی (Equal-width binning)
  - دسته‌بندی با بسامد مساوی (Equal-frequency binning)

- **چالش:** طول بازه‌های گسسته‌سازی مستقیماً بر روی پشتیبان و اطمینان اثر می‌گذارد:
  - $\{\text{Refund} = \text{No}, (\text{Income} = \$51{,}251)\} \rightarrow \{\text{Cheat} = \text{No}\}$
  - $\{\text{Refund} = \text{No}, (60\text{K} \leq \text{Income} \leq 80\text{K})\} \rightarrow \{\text{Cheat} = \text{No}\}$
  - $\{\text{Refund} = \text{No}, (0\text{K} \leq \text{Income} \leq 1\text{B})\} \rightarrow \{\text{Cheat} = \text{No}\}$

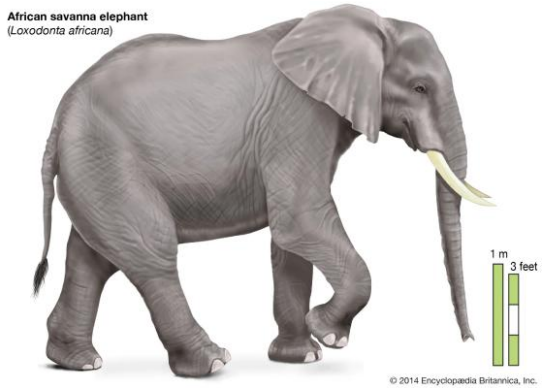
- **اگر بازه‌ها بیش از حد کوچک باشند:**
  - مجموعه‌آیتم‌ها پشتیبان کافی کسب نمی‌کنند و نادیده گرفته می‌شوند.
- **اگر بازه‌ها بیش از حد بزرگ باشند:**
  - قواعد اطمینان کافی یا معنای عملی نخواهند داشت.

کشف زیرگروه‌ها
Subgroup Discovery

- **استخراج قواعد وابستگی:** (Association Rule Mining)
  - یافتن **تمام** الگوها و همبستگی‌های موجود در کل پایگاه داده.
- **دسته‌بندی:** (Classification)
  - شناسایی **بهترین** الگوهایی که بتوانند یک متغیر هدف مشخص را پیش‌بینی کنند.
  - این الگوها لزوماً تمام روابط داده‌ها را پوشش نمی‌دهند.
- **کشف زیرگروه‌ها:** (Subgroup Discovery)
  - یافتن **تمام** زیرگروه‌ها و الگوهایی که می‌توانند یک متغیر هدف مشخص را **توصیف و تبیین** کنند.

کشف زیرگروه در برابر دسته‌بندی

Subgroup Discovery vs. Classification



- **مثال: یادگیری دسته‌بندی حیوانات** (تشخیص فیل):
  - دو مدل ممکن برای شناسایی فیل:
    ۱. $\text{has Trunk} \rightarrow \text{Elephant}$ (دقت 98%)
    ۲. $\text{has Trunk} \wedge \text{weight} > 3000\text{kg} \wedge \text{color} = \text{grey} \wedge \text{height} > 2\text{m} \rightarrow \text{Elephant}$ (دقت 99%)

- **کدام مدل را ترجیح می‌دهید؟**
  - **تیغ اوکام:** (Occam's Razor) اگر دو نظریه پدیده‌ای را به خوبی تبیین کنند، نظریهٔ ساده‌تر ترجیح دارد (مدل ۱).

- **هدف ما چیست؟**
  - در دسته‌بندی: پیش‌بینی دقیق حیوانات در کل داده‌ها.
  - در کشف زیرگروه: **یادگیری بیشترین ویژگی‌ها و شناخت عمیق** دربارهٔ فیل‌ها و داده‌ها.

الگوریتم‌های کشف زیرگروه
Subgroup Discovery – Algorithms

- **الگوریتم‌های اولیه** (مانند EXPLORA، MIDOS در دههٔ ۱۹۹۰):
  - یادگیری یک درخت تصمیم هرس‌نشده (unpruned decision tree).
  - استخراج تمام قواعد از مسیرهای درخت.
  - محاسبهٔ معیارهای آماری برای قواعد، ارزیابی، رتبه‌بندی و انتخاب برترین‌ها.

- **الگوریتم‌های نوین‌تر:**
  - مبتنی بر کاوش قواعد وابستگی (الگوریتم APRIORI-SD در دههٔ ۲۰۰۰).
  - مبتنی بر الگوریتم‌های تکاملی (Evolutionary Algorithms در دههٔ ۲۰۰۰).

معیارهای کشف زیرگروه

Subgroup Discovery – Metrics: WRAcc

- یکی از رایج‌ترین معیارها در کشف زیرگروه، معیار **WRAcc** است:
  - دقت نسبی وزن‌دار (Weighted Relative Accuracy)
  - محاسبه بر پایه احتمال زیرگروه (S) و احتمال هدف (T):

$$\text{WRAcc} = P(ST) - P(S) \cdot P(T)$$

	Elephant	**¬Elephant**
has Trunk ∧ weight>3000kg ∧ color=grey ∧ height>2m	1894	0
¬(has Trunk ∧ weight>3000kg ∧ color=grey ∧ height>2m)	**32**	54874



۳۲ مورد فیل نابالغ (بچه فیل) با وجود نداشتن وزن یا قد فیل بالغ، فیل هستند!

محاسبهٔ عددی معیار WRAcc

Subgroup Discovery – Metrics: WRAcc

- محاسبهٔ معیار بر اساس احتمالات نرمال‌شده در جدول توافقی:

$$\text{WRAcc} = P(ST) - P(S) \cdot P(T) = 0.033 - 0.033 \times 0.034 \approx 0.032$$

	Elephant	¬Elephant	Total
has Trunk ∧ weight>3000kg ∧ color=grey ∧ height>2m	**0.033**	0.000	**0.033**
¬(has Trunk ∧ weight>3000kg ∧ color=grey ∧ height>2m)	0.0006	0.966	0.967
Total	**0.034**	0.966	1.000

تحلیل و ویژگی‌های معیار WRAcc

Subgroup Discovery – Metrics: WRAcc

$$\text{WRAcc} = P(ST) - P(S) \cdot P(T)$$

- **مشاهدات و تحلیل آماری:**
  - هر چه $P(ST)$ بزرگ‌تر باشد، نمونه‌های بیشتری از متغیر هدف پوشش داده می‌شوند:
    - یعنی WRAcc بالاتر به معنای **پوشش بالاتر** (coverage) است (مشابه پشتیبان).
  - هر چه $P(S) - P(ST)$ کوچک‌تر باشد، زیرگروه دقیق‌تر است:
    - با توجه به ثابت بودن $P(T)$ در داده‌ها، WRAcc بالاتر بیانگر **دقت بالاتر** است.
- **جمع‌بندی کلیدی:** معیار WRAcc هم‌زمان نمایندهٔ **پوشش** (coverage) و **دقت** (accuracy) زیرگروه است.

حالت‌های حدی و مقدار بهینهٔ WRAcc

Subgroup Discovery – Metrics: WRAcc

$$\text{WRAcc} = P(ST) - P(S) \cdot P(T)$$

- **حالت‌های حدی:**
  - **اگر S و T مستقل باشند:** $P(ST) = P(S) \cdot P(T)$، بنابراین $\text{WRAcc} = 0.0$ است (زیرگروه بدون ارتباط با هدف).
  - **بهترین حالت ممکن:**
    - $P(ST) = P(S)$ (هیچ نمونهٔ غیرهدفی توسط زیرگروه پوشش داده نشود).
    - $P(ST) = P(T)$ (تمام نمونه‌های هدف پوشش داده شوند).
    - حد بهینهٔ تئوری: $P(T) - P(T)^2$.

- **بررسی قاعدهٔ فیل ما:**
  - **مقدار محاسبه‌شده:** $0.033 - 0.033 \times 0.034 = 0.032$
  - **حداکثر تئوری ممکن:** $0.034 - (0.034)^2 \approx 0.032844$
  - قاعدهٔ کشف‌شده بسیار به حد بهینه نزدیک بوده و **کیفیت فوق‌العاده‌ای** دارد!

مسیر پیش‌رو: دروس مرتبط در دانشگاه مانهایم

What's Next?

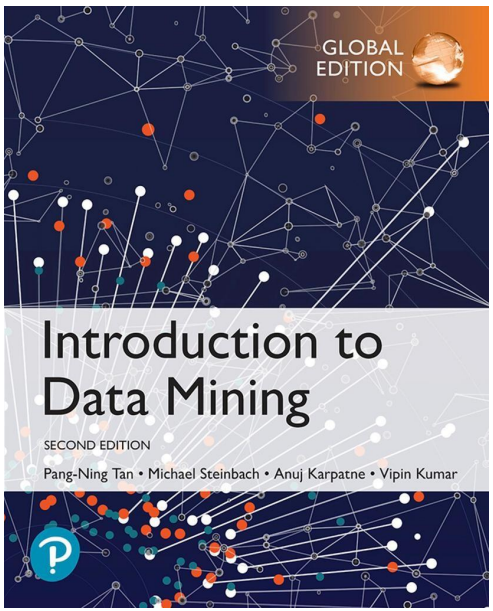
- **پروفسور گملا:** (Prof. Gemulla)
  - **نیم‌سال پاییز (HWS):** کلان‌داده، یادگیری ماشین
  - **نیم‌سال بهار (FSS):** یادگیری عمیق (Deep Learning)
- **پروفسور بیزر:** (Prof. Bizer)
  - **نیم‌سال پاییز (HWS):** یکپارچه‌سازی وب، مدل‌های زبانی بزرگ
  - **نیم‌سال بهار (FSS):** وب‌کاوی (Web Mining)
- **پروفسور اشتوکن‌اشمیت:** (Prof. Stuckenschmidt)
  - **نیم‌سال پاییز (HWS):** سامانه‌های پشتیبان تصمیم‌گیری
- **پروفسور پونزتو:** (Prof. Ponzetto)
  - **نیم‌سال پاییز (HWS):** بازیابی اطلاعات و جستجوی وب
  - **نیم‌سال بهار (FSS):** تحلیل پیشرفتهٔ متن (Text Analytics)
- **پروفسور کوپر:** (Prof. Keuper)
  - **نیم‌سال پاییز (HWS):** بینایی ماشین پیشرفته
  - **نیم‌سال بهار (FSS):** مدل‌های مولد در بینایی ماشین
- **پروفسور رهسه:** (Prof. Rehse)
  - **نیم‌سال بهار (FSS):** فرایندکاوی پیشرفته (Process Mining)

پرسش و پاسخ
Questions?

آیا سؤالی دارید؟



منابع درسی این بخش
Literature for this Slideset



- **کتاب مرجع اصلی:**
  Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, Vipin Kumar
  Introduction to Data Mining, 2nd Edition.
  Pearson.

- **فصل‌های مرتبط:**
  - **فصل ۴:** تحلیل وابستگی: مفاهیم پایه و الگوریتم‌ها
    (Chapter 4: Basic Concepts and Algorithms)
  - **فصل ۷:** تحلیل وابستگی: مفاهیم پیشرفته
    (Chapter 7: Advanced Concepts)